

군집 자폭 수상 드론 방어를 위한 LLM 기반 지휘체계와 U-Net 점수맵 기반 다중 에이전트 협력 강화학습

윤영준* 방현태* 전유라† 김덕환† 윤원근*

초 록

저비용 자폭 무인수상정(USV) 군집은 재래식 수단으로 대응하기 어렵다. 전자전에 의한 연성 대응은 유선 조종 표적에 닿지 않고, 경성 요격은 표적보다 비싼 유도탄을 한 번에 하나씩 소모한다. 본 연구는 대안으로 물리적 포획을 채택하여, 적보다 느린 소수의 방어정이 모선의 접근 회랑을 그물벽으로 미리 차단하는 방어 체계를 제안한다. 체계는 같은 주기로 갱신되지만 *응답 지연이 크게 다른* 두 계층으로 구성되며, 느린 계층을 비동기로 분리하여 그 지연이 제어 루프를 막지 않게 한다. 기동 계층은 전장을 모선 중심의 15채널 격자 지도로 래스터화하고, FiLM 조건화를 갖춘 U-Net이 해면 전체에 대한 점수맵을 낸다. 각 방어정은 자신에게 허용된 유효 영역 안에서 점수가 높은 픽셀 두 개를 순차적으로 지목하고, 두 점을 잇는 선분에 그물벽을 놓는다. 연속 좌표를 회귀시키는 대신 점수맵 위의 픽셀을 지목하므로 행동공간이 격자로 규제되고, 적선 수가 달라져도 입력 형태가 유지된다. 학습은 가치망 없이 후보 행동을 직접 진행시켜 비교하는 그룹 상대 정책 최적화를 다중 에이전트로 확장하되, 후보 하나를 기하 휴리스틱으로 고정하여 휴리스틱을 넘어서는 결합 행동만 양의 이득을 받게 한다. 전략 계층에서는 대규모 언어모델(LLM) 지휘관이 기하량이 미리 계산된 전장 상태를 받아 방어정별 담당 무리를 정하며, 조합 최적화에 의한 사후 보정을 두지 않아 배정의 책임이 전적으로 지휘관에게 있다.

8개 조건 $\times$ 3개 공격 포메이션 $\times$ 30개 시드, 총 720 에피소드를 시드 대응표본으로 수집하여 두 계층의 기여를 분리 측정하였다. 기동 계층은 LLM 없이 단독으로 포획률을 $0.844 \rightarrow 0.886$ 으로 개선하였고(파상 포메이션에서 $+0.157$), 전략 계층은 지휘관 모델에 따라 결과가 같았다. 상용 클라우드 모델은 $+0.060$ 의 개선을 보인 반면 소형 로컬 모델(Qwen2.5 7B)은 오히려 -0.192 로 코드 휴리스틱보다 유의하게 나빴다. 10개 지표에 대한 2×2 상호작용 분해에서 9개가 신뢰구간에 0을 포함하여, 두 계층의 기여는 상승이 아니라 *가산적임*을 확인하였다. 다중비교 보정에서는 포획률과 돌파 수가 유의성을 잃고 나머지 8개 지표는 유지되었다. 또한 포획률의 효과크기($d_z = 0.44$)가 측정한 10개 지표 중 최하위권이며, 총 선회량(-3.23)과 포획당 그물 소모(-2.09)에서 훨씬 큰 개선이 나타났다. 지휘관 계층의 성능은 배정 커버리지가 아니라 재계획 간 계획 안정성으로 설명되었다.

주제어 : 무인수상정, 군집 방어, 다중 에이전트 강화학습, 임무배정, 대규모 언어모델, 의미론적 분할, 그룹 상대 정책 최적화

1 서론

1.1 배경

다수의 저비용 무인수상정(Unmanned Surface Vehicle, USV)이 고가치 함정 한 척을 향해 여러 방향에서 동시에 돌진하는 자폭 공격은 대표적인 비대칭 위협이다. 유한한 방어 자산을 다수 표적에 배분하는 문제는 무기-표적 할당(weapon-target assignment)으로 오래 연구되어 왔으나 [1], 표적 수가 요격 자산을 넘어서면 최적 할당으로도 처리되지 않는 표적이 남는다.

무인 위협에 대한 기존 대응은 두 갈래로 구분된다 [2]. 표적의 통신·항법·센서를 교란하는 연성 대응(soft-kill)은 위협 자체를 제거하지 못하며, 전파를 방사하지 않는 유선 조종 표적에는 작용하지 않는다 [3]. 표적을 직접 타격하는 경성 대응(hard-kill)은 위협을 확실히 제거하지만, 수천 달러 규모의 표적에 발당 수십만에서 수백만 달러의 요격 유도탄을 소모하는 비용 구조를 지탱하기 어렵고 [4], 한 번에 한 표적만 처리하므로 표적 수가 교전 용량을 넘어서면 포화가 발생한다.

본 연구는 대안으로 저비용 그물을 이용한 물리적 포획을 채택한다. 이는 무인기 대응 분야에서 독립된 대응 범주로 다루어져 왔으며 [2], 표적의 통신 방식과 무관하게 작용하고 표적을 정지시킨다는 점에서 앞의 두 한계를 비껴간다. 방어정은 적선보다 느리므로 추격으로 따라잡을 수 없고, 대신 적선이 지나갈 접근 회랑을 앞질러 그물벽으로 차단한다 (Fig. 1).

1.2 문제의식

이 방어 문제는 성격이 다른 두 판단을 동시에 요구한다. 하나는 *어느 방어정이 어느 적 무리를 맡을 것인가*라는 이산적·전술적 배정이고, 다른 하나는 *맡은 무리를 막기 위해 해면의 어느 지점에 그물벽을 놓을 것인가*라는 연속적·기하적 기동이다. 전자는 전장 전체의 맥락과 우선순위 판단을 요구하고, 후자는 국소적이지만 매 결정마다 새로 계산되어야 한다. 두 판단은 같은 주기로 갱신되지만 *산출에 걸리는 시간이 크게 다르다*. 본 연구는 느린 쪽인 배정을 언어모델 지휘관에게, 빠른 쪽인 기동을 학습된 정책에 맡긴다.




Figure 1: 교전 개념. 중앙의 모선을 향해 자폭 USV가 여러 접근 회랑(붉은 부채꼴)으로 동시에 돌진한다. 방어정은 적선보다 느리므로(Table 1) 추격이 성립하지 않고, 대신 환상(環狀) 요격 구역 위에서 회랑을 가로지르는 그물벽을 미리 친다. 그물벽은 두 지점을 잇는 선분이며, 적선이 여기 얹히면 포획된다. 안쪽 원은 돌파 판정 반경으로, 적선이 이 안에 들어오면 방어 실패로 계수한다.

1.3 배치를 전제로 한 설계

본 연구는 시뮬레이션 안에서만 성립하는 체계를 목표로 하지 않았다. 방법을 고를 때마다 온보드에서 돌 수 있는가를 함께 물었고, 그 선택들이 본문 곳곳에 흩어져 있으므로 여기에 모아 둔다.

- **실해역 지형에서 학습·평가한다.** 교전 해역은 가상의 빈 바다가 아니라 OpenStreetMap의 실제 해안선(통영 매물도 인근)을 래스터화한 것이며, 육지는 충돌 판정과 관측 채널 양쪽에 들어간다 (§4.4.1).
- **전장을 이미지로 보고, 행동을 픽셀로 낸다.** 관측은 선박별 벡터의 나열이 아니라 모선을 중앙에 둔 50×50 격자 위의 15채널 영상이고, 정책은 그 위에서 픽셀을 지목하는 U-Net 구조이다. 행동은 연속 좌표의 회귀가 아니라 격자의 유효 픽셀 가운데 하나를 고르는 이산적인 선택이므로, 정책은 해면 전체에 대한 점수맵을 낸다. 연속 좌표 회귀에서는 불가능 영역을 피하도록 학습하거나 사후에 투영해야 하지만, 이산 선택에서는 그런 자리가 애초에 뿔하지 않게 막을 수 있다. 선박 수가 바뀌어도 입력·출력의 형태가 변하지 않으며, 배치 통계에 의존하는 정규화를 쓰지 않아 배치 크기 1의 온보드 추론이 학습과 같은 연산을 수행한다 (§4.4.1, §4.7).
- **언어모델은 느린 판단만 말고, 빠른 판단을 막지 않는다.** 배정은 언어모델 지휘관이, 기동은 학습된 정책

이 맡는다. 둘은 비동기로 분리되어 지휘관의 응답을 기다리는 동안에도 기동은 멈추지 않는다 — 응답 속도가 크게 다른 두 판단 계층을 같은 결정 주기 안에서 결합한 것이다.

- **출력이 곧 항법 명령이다.** 정책의 출력은 제어 신호가 아니라 경유점 두 개이며, 이 형식은 특정 선체 동역학에 묶이지 않는다. 저수준 추종은 학습과 분리되어 있어 실제 선체의 동역학으로 교체할 수 있고, 그만큼 시뮬레이션에서 실기로 옮기기 쉽다 (§4.7).

1.4 기여

본 논문의 기여는 무엇이 새로 가능해졌는가로 정리된다.

1. **적보다 느린 소수의 방어정으로도 군집을 물리적으로 막을 수 있다.** 핵심은 그물벽을 놓을 자리를 연속 좌표로 회귀하지 않고, 해면 격자의 픽셀 하나를 이산적으로 고른다는 행동 표현이다. 정책은 15채널 격자 관측을 FiLM 조건화 U-Net에 넣어 지도 전체에 대한 점수맵을 내고, 그 위에서 유효 픽셀 중 하나를 지목한다. 불가능한 자리(육지, 사거리 밖)로 출력이 새거나 다봉 분포를 평균 내어 어느 쪽도 아닌 자리를 내는 문제는, 이산 행동공간에 마스크를 씌워 발생 자체를 막았다. 그 결과 같은 정도로 막으면서 포획당 그물 소모를 44.5%, 총 선회량을

46.6% 줄었다. 이 가운데 언어모델 없이 기동 계층 단독으로 얻는 몫은 포획당 그물 22.9%, 그물 걸림 24.3% 감소이다.

2. 방어정 수와 적선 수가 바뀌어도 같은 모델이 돈다. 관측을 선박별 벡터의 나열이 아니라 *이미지* 형식의 15채널 격자로 바꾼 것이 핵심이다. 전장의 선박 수가 몇 척이든 관측은 같은 크기의 격자 위에 그려 지므로 입력의 형태가 유지되고, 입력 순열 문제 자체가 생기지 않는다. 가변 개수 입력을 다루는 기존 방식들인 최대 개수로 패딩하고 마스크를 붙이거나 개체 목록 위에 어텐션을 얹는 방식과 달리, 해당 방식으로는 개체 수에 따라 달라지는 것이 아무것도 없다. 계산량이 선박 수에 비례해 늘지 않고, 마스크나 최대 개수 같은 설계 상수를 둘 필요가 없다. 또한 개체로 표현되지 않는 정보(해안선·섬 같은 육지, 모선 주변의 위협 분포)도 같은 격자에 채널 하나로 얹힌다. 무엇보다 출력이 같은 격자 위의 픽셀이므로 관측과 행동이 하나의 좌표계를 공유하게 된다. 여기에 방어정 간 파라미터 공유를 더해 모델 크기 역시 방어정 수에 불변이다(총 244,389개). 그 결과 동일한 하나의 모델이 어떤 편성·어떤 상황에서도 강건하게 대응할 수 있다.
3. 가치망 없이 팀 보상 하나로 다중 방어정의 협동 기동을 학습하였다. 본 연구는 그룹 상대 정책 최적화를 다중 방어정으로 확장하되, 결합 행동 후보 하나를 기하 휴리스틱으로 고정하여 기준선으로 삼는다. 각 후보를 시뮬레이터에서 실제로 진행시켜 얻은 팀 보상을 휴리스틱과 비교하므로, 휴리스틱과 다르게 움직인 방어정의 선택만이 이득의 차이를 만들고, 학습된 비평가로 가치를 추정하지 않으므로 가치 추정 편향과 비평가 학습의 불안정성이 설계에서 사라진다. 이 기준선은 정책을 휴리스틱 근방에 붙잡는 신뢰 영역 구실도 하여, 무작위 초기화에서 흔한 초기 붕괴 없이 휴리스틱 천장을 넘어서게 한다. 한 척의 행동만 바꾸어 재평가하는 반사실적 변형도 구현하여 비교하였다.
4. 규칙으로 적기 어려운 전술 판단을 지휘 계층에 맡기고, 그 효과와 평가 기준을 수치로 제시한다. 어느 방어정이 어느 무리를 맡을지는 각 무리의 접근 방위와 요격까지의 거리·선회량, 이미 놓인 그물의 차단 효과, 방어정별 잔여 자산과 교전 규칙을 함께 저울질해야 하는 판단이며, 이를 고정된 규칙과 조합 최적화로 전부 열거하기는 어렵다. 본 연구는 이 유연한 판단을 지휘관에게 온전히 맡기고 720 에피소드를 시드 대응표본으로 수집해 두 계층의 기여를 분리 측정하였다.

논문의 구성은 다음과 같다. §2에서 관련 연구를 정리하고, §3에서 문제와 평가 지표를 정의한다. §4에서 제안 체계를 기술하고, §5에서 실험 설계와 통계 절차를 밝힌다. §6에서 결과를, §7에서 해석을 제시하고, §8에서 한계를 논의한다.

2 관련 연구

2.1 무기-표적 할당과 조합 최적화

방어 자산을 표적에 배분하는 문제는 무기-표적 할당(WTA)으로 정식화되어 정확해법과 휴리스틱이 모두 연구되었다 [1]. 1:1 배정으로 축소하면 헝가리안 알고리즘 [5]으로 다항 시간에 최소비용 매칭을 얻을 수 있다. 이러한 방법은 비용 함수가 명시적으로 주어질 때 최적을 보장하지만, 비용 함수 자체가 전술적 의도를 완전히 반영하기에는 한계가 존재한다. “이 무리의 접근로는 앞서 놓은 그물이 이미 막고 있으니, 그물이 남은 방어정은 아직 열린 회랑 쪽으로 돌려라”와 같은 판단은 이전 결정의 결과와 자산 잔량등과 같은 수많은 변수에 의해 달라지므로 고정된 거리·각도 비용으로 표현될 수 없다. 본 연구는 배정 계층에 조합 최적화 방식이 아닌 언어모델의 판단을 배치함으로써 최적성만을 고려하는 것이 아닌 전술적 맥락을 반영되도록 하였다 그 대가를 §6에서 정량적으로 보고한다.

2.2 무인 위협 대응

대무인기 체계에 관한 조사 [2]는 대응을 탐지·식별·무력화로 나누고, 무력화를 다시 연성(전자전)·경성(물리 타격)·포획(그물 등)으로 구분한다. 유선 조종 표적의 확산 [3]은 연성 대응의 적용 범위를 좁혔고, 요격 비용의 비대칭 [4]은 경성 대응의 지속성을 제약한다. 해상 영역에서 다중 USV의 협력 기동은 오래 연구되어 왔으며 [6], 최근에는 다중 에이전트 강화학습으로 회피 표적을 협조 포위하는 정책이 실선 검증과 함께 보고되었다 [7]. 선행 연구의 포위(encirclement)는 통상 방어정이 표적보다 빠르거나 대등함을 전제한다. 본 연구는 방어정이 더 느린 조건을 다룸으로써 추격 대신 공격 경로의 선제 차단을 택한다는 점에서 기존 연구와 차별된다.

2.3 다중 에이전트 강화학습과 크레딧 배분

중앙 집중 학습·분산 실행(CTDE) 계열은 팀 보상에서 개체별 기여를 분리하기 위해 가치망(비평가)을 학습한다. MADDPG [8]는 중앙 비평가를, QMIX [9]는 팀 가치를 개체 가치로 분해하는 단조 혼합망을 두며, COMA [10]는 한 에이전트의 행동만 주변화한 반사실적 기준선으로 개별 기여를 재고, MAPPO [11]는 PPO [12]를 다중 에이전트로 확장한 강한 기준선이다. 그러나 이들이 공유하는 가치망은 추정 편향과 학습 불안정 성능을 좌우하며 [13], 다른 에이전트가 함께 학습하는 비정상 환경에서 그 문제가 더 커진다 [8]. 언어모델 정렬 분야의 그룹 상대 정책 최적화(GRPO) [14]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 이득을 산정함으로써 가치망 자체를 없앤다.

본 연구는 이 GRPO를 다중 에이전트 제어로 옮기고, 후보 하나를 기하 휴리스틱으로 고정하여 기준선으로 삼는다. 후보의 팀 보상은 학습된 비평가가 아니라 *시뮬레이터 재진행*으로 얻으므로 가치 추정 편향과 비평가 학습의 불안정성이 설계에서 사라진다. COMA의

반사실적 착상을 같은 방식으로 구현한 변형(한 척의 행동만 바꾸어 재진행)도 비교하였다. CTDE 계열을 실험 기준으로 쓰지 않은 이유는 행동 표현이 달라 표현과 알고리즘의 기여가 뒤섞이기 때문이며, §8에서 다룬다.

2.4 격자 지도 표현과 픽셀 지목 행동

완전 합성곱 구조 [15]와 U-Net [16]은 입력 이미지의 모든 픽셀에 값을 매기는 조밀 예측을 가능하게 한다. CoordConv [17]는 좌표 채널을 덧붙여 합성곱이 흐리는 절대 위치를 보완하며, FiLM [18]은 조건 벡터로 특징 지도를 채널별로 변조하는 경량 조건화 기법이다. 이들은 모두 상황에 대한 지각, 즉 무엇이 어디에 있는가를 읽어내는 데 쓰였다. 한편 후보마다 점수를 매겨 그중 하나를 지목하는 출력 방식은 포인터 네트워크 [19]에서 비롯되었으며, 그 점수는 질의와 후보 특징의 내적, 즉 어텐션 [20]의 점수 계산과 같은 형식이다. 다만 이 방식은 주로 조합 최적화에 쓰였다. 본 연구는 둘을 잇는다. U-Net 이 낸 조밀 특징 지도의 각 픽셀에 방어정별 질의로 점수를 매기고 (§4.4), 그 점수맵을 지각 결과가 아니라 정책의 행동 분포로 삼아 픽셀 하나를 지목하는 것이 곧 행동이다. 행동공간이 격자로 이산화되므로 육지·사거리·배정 회랑 같은 안전 제약을 마스크로 행동 분포에 직접 부과할 수 있다.

2.5 언어모델 기반 계획

언어모델을 계획 주체로 사용하는 연구는 고수준 지시를 실행 가능한 단계로 분해하는 방향으로 발전해 왔다 [21]. SayCan [22]은 언어모델의 사전 지식과 로봇의 실행 가능성 추정을 결합하여 실행 불가능한 계획을 걸러낸다. 출력 형식을 스키마로 강제하는 구조적 출력 [23]은 언어모델 출력을 하위 시스템이 파싱 가능한 형태로 고정한다. 해당 연구에서는 보정 없이 언어모델 판단만으로 전장의 배정이 성립하는지, 그리고 어느 능력 수준부터 이득이 되는지를 측정한다.

3 문제 정의와 평가 지표

3.1 교전 시나리오

교전 해역 중앙에 고가치 모선 한 척이 있고, 가장자리에서 적 USV M 척이 모선을 향해 돌진한다. 적은 무작위로 흩어져 오지 않고 세 가지 공격 포메이션 가운데 하나를 취한다 — 한 방위에 전력을 모으는 **집중**, 세 방위로 나뉘어 동시에 도래하는 **양동**, 한 방위 부근에서 거리차를 두고 줄지어 오는 **파상**이다(상세는 아래). 방어정 P 척은 적선보다 느리며, 각각 한정된 수의 그물벽을 전개할 수 있다. 구체적인 값은 Table 1에 정리하였다.

방어정은 적을 따라가는 대신 적이 지나갈 자리를 예측하여 선점해야 한다. 그물벽은 두 좌표를 잇는 선분으로 정의되며, 방어정이 그 선분을 따라 이동하면서 전개한다. 전개된 그물은 해면에 고정되지 않아, 시간

Table 1: 교전 시나리오와 관측 설정. 값은 학습 체크포인트의 설정에서 직접 읽었다.

항목	값	단위
적 USV 수 M	10	척
방어정 수 P	3	척
적 속력	9.0	m/s
방어정 속력	6.0	m/s
교전 해역 한 변	12600	m
그물벽 최대 길이	450	m
관측 격자 반폭	6300	m
관측 격자 해상도	50	칸
적 무리 최대 수 C	4	개
관측 픽셀 한 변	252	m
방어정당 그물 (학습 / 평가)	1 / 3	장
정책 파라미터 수	244,389	개

방어정 속력이 적 속력보다 낮다 — 추적이 성립하지 않으므로 접근 회랑의 선제 차단이 유일한 대응이다. 그물 보유량은 학습 시 1장, 평가·배포 시 3장이다: 정책은 결정마다 그물벽 하나를 놓으므로 결정당 행동공간이 보유량과 무관하고, 1장으로 학습한 정책이 재학습 없이 3장 설정에서 동작한다.

이 지날수록 차단 효과가 감소하며, 미리 전개된 그물은 적에게 노출되어 회피의 여지를 준다. 따라서 그물벽은 적의 도달 직전, 적에 가까운 위치에 전개하는 것이 유리함을 가정한다.

적 편성은 세 가지 공격 포메이션으로 구성한다.

- **집중(concentrated):** 적 전 병력이 한 방위에 모여 동시에 접근한다. 차단해야 할 접근로의 방위가 동일함으로, 소수의 방어정으로도 대응이 가능하다.
- **양동(diversionary):** 적이 세 방위로 나뉘어 동시에 접근한다. 접근로가 셋으로 갈라지므로 가용 방어정을 모두 투입해야 하며, 어느 방어정을 어느 무리에 붙이는 배정과 그 경로의 교차 여부가 결과를 좌우한다.
- **파상(wave):** 적이 3개 단(rank)으로 나뉘어 단마다 방위를 조금씩 달리하며 거리차를 두고 순차적으로 도달한다. 앞 단을 막은 자원이 뒤 단에도 쓰일 수 있어야 하므로 그물벽을 어느 자리에 놓는지가 다음 단의 차단 가능성을 좌우하며, 앞 단에 소모된 그물벽을 대신할 능동적 재배치가 방어율을 결정한다.

3.2 평가 지표

방어 성과의 지표는 다섯 관점에서 총 10개 지표를 정의한다(Table 2). 지표들은 에피소드 단위로 계산되며, 표의 정의에서 $N_{\text{cap}} \cdot N_{\text{brc}}$ 는 포획된·모선까지 돌파한 적선 수, N_{col} 은 아군 상호 및 모선 충돌 건수, N_{img} 은 아군이 설치된 그물에 얽힌 횡수, N_{net} 은 소모한 그물 수, D_p 와 $\Delta\psi_{p,t}$ 는 방어정 p 의 총 이동거리와 step t 의 방위 변화량, $\mathbf{m}$ 은 모선 위치, $\mathbf{z}_k$ 와 t_k 는 k 번째 포획 지점과 시각, $\mathbf{a}_d$ 는 d 번째 그물 전개를 시작하는 방어정의 위치, $\mathcal{A}$ 는 그 시점의 생존 적선 집합, $\mathbf{e}_m$ 은 적선 m 의 위치이다. 자원 효율 지표는 교전하지 않은 조건이 가장 효율적으로 평가되는 것을 막기 위해 총량이 아니라 포획당 비율로 둔다. 초기 제압에 관한 수치는 거리축과 시간축으로 나누어 모선과 먼 곳에서 포획하는 것과, 초기에 포획하는 것 둘 다 고려하도록

Table 2: 평가 지표 10종. 방향은 개선이 어느 쪽인지를 나타내며, 기호는 본문에 정의하였다.

관점	지표	방향	정의	뜻
방어 성과	포획률	↑	$CR = N_{cap}/(N_{cap} + N_{brc})$	교전이 결판난 적선 중 포획된 비율
	돌파 수	↓	N_{brc}	모선까지 도달한 적선 수
안전	충돌률	↓	N_{col}/P	방어정 1척당 아군 상호·모선 충돌 건수
	그물 걸림	↓	N_{tng}	아군이 설치된 그물에 얽힌 횡수
자원 효율	포획당 그물	↓	N_{net}/N_{cap}	적 1척 포획에 소모한 그물 수
	포획당 이동거리	↓	$\sum_{p=1}^P D_p / N_{cap}$	적 1척 포획당 팀 총 이동거리
기동 비용	총 선회량	↓	$\sum_{p=1}^P \sum_t \Delta\psi_{p,t} $	누적 방위 변화량(궤적 부드러움)
교전 품질	포획 이격거리	↑	$\frac{1}{N_{cap}} \sum_k \ \mathbf{z}_k - \mathbf{m}\ $	포획 지점의 모선 이격 — 공간축 조기 제압
	평균 포획 시각	↓	$\frac{1}{N_{cap}} \sum_k t_k$	포획이 일어난 시각 — 시간축 조기 제압
	전개 시 적 거리	↓	$\frac{1}{N_{net}} \sum_d \min_{m \in \mathcal{A}} \ \mathbf{a}_d - \mathbf{e}_m\ $	그물 전개를 시작한 순간 최근접 적까지 거리

한다.

4 제안 방법

4.1 2계층 비동기 구조

제안 체계는 방어 판단을 전략 계층과 기동 계층으로 분리한다(Fig. 2). 전략 계층은 어느 방어정이 어느 적 무리를 맡는가를 정하고, 기동 계층은 **배정된 무리를 막기 위해 해면 어디에 그물벽을 놓는가**를 정한다. 두 계층은 같은 주기로 결정을 내리지만 **응답 속도가 다르다**. 기동 계층의 순전파는 순간에 끝나는 반면, 전략 계층의 언어모델 호출은 응답에 지연이 발생한다(\$6.8). 느린 전략 계층 호출만 비동기로 분리함으로써, 호출이 진행되는 동안 기동 계층은 직전 배정을 그대로 사용하여 결정을 계속하고 응답이 도착하면 다음 결정부터 새 배정이 반영된다.

4.2 적 무리 군집화

두 판단 계층은 개별 적선이 아니라 **무리**를 단위로 배정한다. 따라서 매 결정마다 생존 적선을 모선 기준 방위로 묶어 최대 C 개의 무리로 요약한다. 적선 m 의 모선 기준 방위를 항법 규약(북쪽 0° , 시계 방향)으로 정의한다.

$$\vartheta_m = \text{atan2}(e_{m,x} - m_x, e_{m,y} - m_y) \bmod 360^\circ \quad (1)$$

방위를 $360^\circ/C$ 폭의 고정 구간(bin)으로 나누는 방식은 한 무리가 구간 경계에 걸리면 둘로 쪼개지고, 무리가 하나뿐인 상황에서도 빈 구간을 포함한 C 개 슬롯으로 표현한다. 본 연구는 대신 **방위 간격(gap)**에 따라 무리 수를 데이터에 맞추는 적응형 군집화를 쓴다. 생존 적선 $n = |\mathcal{A}|$ 척의 방위를 오름차순으로 정렬하여 $\vartheta_{(1)} \leq \dots \leq \vartheta_{(n)}$ 이라 하고, 이웃한 방위 사이의 간격을 원형으로 정의한다.

$$g_{(q)} = \vartheta_{(q+1)} - \vartheta_{(q)} \quad (q < n), \quad g_{(n)} = \vartheta_{(1)} + 360^\circ - \vartheta_{(n)} \quad (2)$$




Figure 2: 속도가 다른 2계층 비동기 구조. 두 판단 계층은 25초마다 결정을 내리지만, 전략 계층(언어모델 지휘관)은 로컬 14B 모델에서 평균 16.6초가 걸리는 반면 기동 계층의 순전파 시간은 무시할 수 있다. 그래서 전략 계층 호출만 비동기로 분리하고, 저수준 제어(PD 조타)는 1초 주기로 돈다.

임계 δ_{gap} 보다 큰 간격의 수가 무리 수를 정하되, 1 이상 C 이하(그리고 적선 수 이하)로 자른다.

$$\hat{C} = \text{clip}\left(\left|\{q : g(q) > \delta_{\text{gap}}\}\right|, 1, \min(C, n)\right) \quad (3)$$

가장 큰 간격 $\hat{C}$ 개를 무리 경계로 삼고, 그 가운데 최대 간격을 원형 순서의 이음새로 열어 이음새 다음 적선부터 방위 순으로 걸으며 경계를 지날 때마다 무리 번호를 하나씩 올린다. 이렇게 얻은 라벨 $j_m \in \{1, \dots, \hat{C}\}$ 로 무리 j 의 구성원 집합 $A_j = \{m : j_m = j\}$ 가 정해진다. 무리 j 는 네 가지 양으로 요약한다.

$$\begin{aligned} n_j &= |A_j|, & \mathbf{c}_j &= \frac{1}{n_j} \sum_{m \in A_j} \mathbf{e}_m, \\ \Delta\vartheta_j &= 90^\circ \sqrt{1 - \bar{R}_j}, & \bar{R}_j &= \left\| \frac{1}{n_j} \sum_{m \in A_j} \hat{\mathbf{b}}_m \right\|, \\ v_j^{\text{app}} &= \frac{v_e}{n_j} \sum_{m \in A_j} \langle (\sin \psi_m, \cos \psi_m), \hat{\mathbf{d}}_m \rangle, \\ \hat{\mathbf{d}}_m &= (\mathbf{m} - \mathbf{e}_m) / \|\mathbf{m} - \mathbf{e}_m\| \end{aligned} \quad (4)$$

n_j 는 척수, $\mathbf{c}_j$ 는 무리 중심, $\Delta\vartheta_j$ 는 방위 단위벡터 $\hat{\mathbf{b}}_m = (\cos \vartheta_m, \sin \vartheta_m)$ 의 원형 결집도 $\bar{R}_j$ 에서 얻은 각도 퍼짐(한 점에 모이면 0°), v_j^{app} 는 모션 방향 평균 접근 속도이다. 본 연구는 $C = 4$, $\delta_{\text{gap}} \approx 12^\circ$ 를 쓴다. 이 규칙 아래에서 집중 포메이션은 무리 하나, 양동 포메이션은 세 방위의 무리 셋으로 요약된다. 파상 포메이션은 단(rank)마다 방위를 18° 씩 벌려 생성되므로 δ_{gap} 을 넘어 대개 단마다 별개의 무리가 되며, 단 사이의 거리차는 무리 중심의 반경 차이와 §4.4.1의 격자 관측에 함께 남는다. 척수와 중심은 §4.3의 위협도와 요격점을, 네 요약량 전부는 §4.6의 지휘관 입력을 구성한다.

4.3 기하 휴리스틱 기준 방법

§4.2의 무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법을 정의한다. 이 방법은 §6의 비교 기준 이자 §4.5.5의 행동 복제 목표이다.

4.3.1 위협 기반 배정

무리 j 의 위협도는 척수 n_j 와 모션 근접도의 곱으로 정의한다.

$$\tau_j = n_j \cdot \text{clip}\left(1 - \frac{\|\mathbf{c}_j - \mathbf{m}\|}{R_w}, 0.05, 1\right) \quad (5)$$

여기서 R_w 는 교전 해역 반폭이다. 위협 상위 P 개 무리를 방어 대상으로 삼고, 요격점은 무리 중심과 모션을 잇는 선분 위에 둔다.

$$\mathbf{I}_j = \mathbf{c}_j + \lambda_I (\mathbf{m} - \mathbf{c}_j), \quad \lambda_I = 0.55 \quad (6)$$

모션 쪽으로 치우친 위치는 적보다 느린 방어정이 먼저 도달하기 위한 것이다. 배정 비용은 요격점까지의 거리 $d_{pj} = \|\mathbf{a}_p - \mathbf{I}_j\|$ 이며, 직전 배정을 유지하는 쌍에 상수 β 를 감한 뒤 탐욕적 1:1 배정을 수행한다.

$$\tilde{d}_{pj} = d_{pj} - \beta \cdot \mathcal{K}[j = j_p^{\text{prev}}] \quad (7)$$

보너스 항은 배정의 시간적 일관성을 위한 것이다. 그 물벽을 전개하던 중에 담당이 바뀌면 그때까지의 이동과 그물이 회수되지 않으므로, 순간 최적보다 연속성이 유리하다. 활성 무리가 P 보다 적으면 남은 방어정을 부하(적 수/(1+배정 수))가 가장 큰 무리에 덧붙이되, 요격점을 모션 쪽으로 $\lambda_L = 0.18$ 만큼 안쪽 층에 두고 방위를 $\pm 40^\circ$ 씩 번갈아 틀어 경로가 겹치지 않게 한다.

4.3.2 그물벽 경유점 생성

배정된 방어정 p 는 요격점 $\mathbf{I}$ 를 중심으로 적의 접근 방향에 수직인 벽을 친다. 그물벽은 두 끝점을 잇는 선분이므로 경유점 수는 $K = 2$ 이다. 모션에서 요격점으로 향하는 단위 벡터를 $\hat{\mathbf{r}}$, 그에 수직인 방향을 $\hat{\mathbf{r}}^\perp$ 라 하면

$$\mathbf{t}_k = \mathbf{I} + \left(k - \frac{K-1}{2}\right) L_{\text{net}} \hat{\mathbf{r}}^\perp, \quad k = 0, \dots, K-1 \quad (8)$$

즉 $\mathbf{I} \pm \frac{1}{2} L_{\text{net}} \hat{\mathbf{r}}^\perp$ 로, 요격점을 가운데 둔 $L_{\text{net}} = 450\text{ m}$ 의 선분이다. 연속 좌표 $\mathbf{t}_k$ 는 모션 중심 50×50 격자 (§4.4.1)의 유효 픽셀 (§4.4.3) 가운데 최근접 칸으로 스

Table 3: 주요 기호. 혼동되기 쉬운 수량은 서로 다른 문자를 쓴다 — 특히 무리 수 C , 경유점 수 K , 학습의 그룹 후보 수 G 는 구분한다.

기호	뜻	기호	뜻
M	적 USV 수	$\mathbf{o}_p$	방어정 p 의 자체 상태 벡터
P	방어정 수	$\mathbf{q}_p$	방어정 p 의 질의 벡터
$C, \hat{C}$	무리 수 상한, 활성 무리 수	$\mathbf{f}_i$	픽셀 i 의 키 벡터
K	방어정 1척이 지목하는 경유점 수	$s_{p,i}$	방어정 p 가 픽셀 i 에 준 점수
G	학습의 그룹 후보 수	(γ_F, β_F)	FiLM 배율·이동 계수
τ_j	무리 j 의 위협도	R_k	후보 k 의 팀 보상
$\vartheta_m, g(q), \delta_{\text{gap}}$	적선 방위, 정렬 방위 간격, 분할 임계	$\mathbf{c}_j, n_j$	무리 j 의 중심, 척수
d_{pj}	방어정 $p \rightarrow$ 무리 j 요격점 거리	A_k	후보 k 의 그룹 상대 이득
β	배정 유지 보너스 (식 7)	Φ	위협 근접도 퍼텐셜
λ_L	인여 방어정의 층 분리 증분	γ	퍼텐셜 성형 할인 계수
$\mathbf{I}$	요격점	$\mathcal{V}_p^{(k)}$	k 번째 선택 시점의 후보 픽셀 집합
$\mathbf{t}_k$	k 번째 목표점 (연속 좌표)	r_{dup}	경유점 중복 배제 반경
$\hat{\mathbf{r}}$	모선 $\rightarrow$ 요격점 단위 벡터	L_{net}	그물벽 최대 길이
$\mathbf{a}_p$	방어정 p 의 위치	d_z	대응표본 효과크기
E, ℓ	관측 반폭, 픽셀 크기	H	후보 평가 창 길이
$\iota(\cdot)$	월드 $\rightarrow$ 픽셀 인덱스 사상 (식 10)	$\eta_t, \lambda_H(t)$	학습률·엔트로피 계수 스케줄
$\mathbf{u}_k, \sigma_o$	부화소 오프셋과 그 표준편차	w_n	유효 월드 마스크

기호의 실험 설정값은 Table 1와 각 정의 위치의 본문에 있다.

냅한다.

$$i_k = \arg \min_{i \in \mathcal{V}_p^{(k)}} \|\mathbf{x}_i - \mathbf{t}_k\|^2 \quad (9)$$

여기서 $\mathbf{x}_i$ 는 픽셀 i 의 중심이고 $\mathcal{V}_p^{(k)}$ 는 k 번째 선택 시점의 후보 집합으로, 직전 선택으로부터 $r_{\text{dup}} = 200 \text{ m}$ 이내와 $1.5L_{\text{net}}$ 밖을 배제하며 갱신된다. 격자·유효 마스크·배제 규칙은 §4.4의 학습 정책과 동일하므로 두 방법의 행동공간은 같으며, 후보가 비었을 때의 완화 순서만 다르다(휴리스틱은 유효 마스크 전체로 한 번에, 정책은 단계별로 되돌린다).

휴리스틱은 유효 영역 안에서 기하로 정해진 한 점을 지목할 뿐 나머지 칸에 대한 선호가 없으므로(Fig. 3 가운데), 다른 무리를 맡은 방어정이 이미 친 벽, 파상 공격의 뒤 단, 지형이 만드는 길목은 요격점 계산에 반영되지 않는다. 이들은 해면 전체를 비교해야 얻어지는 판단이며, §4.4의 점수맵이 그 비교를 학습된 함수로 대체한다.

4.4 점수맵 기반 기동 정책

4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모선을 중앙에 두고 관측 반폭 E 의 전장을 $n_g \times n_g$ 격자로 나눈 다채널 지도이다(채널별 실제 화면은 Fig. 4). 총 15개 채널은 모든 방어정이 공유하는 전역 9채널, 방어정마다 다른 3채널, CoordConv [17] 좌표 3채널로 구성되며 (Fig. 5), 각 채널의 정의와 값 범위를 Table 4에 정리하였다.

래스터화와 정규화. 픽셀 크기는 $\ell = 2E/n_g$ 이고, 월드 좌표 $\mathbf{x}$ 는 모선 위치 $\mathbf{m}$ 을 중심으로 다음 픽셀 인덱스로 사상된다.

$$\iota(\mathbf{x}) = \text{clip}\left(\left\lfloor \frac{\mathbf{x} - \mathbf{m} + E\mathbf{1}}{\ell} \right\rfloor, 0, n_g - 1\right) \quad (10)$$

적 관련 채널은 개체를 픽셀에 “칠하는” 방식으로 만

들며, 값 범위가 $[0, 1]$ 또는 $[-1, 1]$ 에 놓이도록 정규화한다. 생존 적선 집합을 $\mathcal{A}$, 적선 m 의 위치·헤딩을 $\mathbf{e}_m, \psi_m$ 이라 하면 픽셀 i 의 적 밀도·진행 방향·위협도 채널은

$$c_i^{\text{den}} = \frac{N_i}{M}, \quad c_i^{\text{vel}} = \frac{1}{\max(N_i, 1)} \sum_{m \in \mathcal{A}_i} (\sin \psi_m, \cos \psi_m) \quad (11)$$

$$c_i^{\text{thr}} = \max_{m \in \mathcal{A}_i} \left(1 - \text{clip}\left(\frac{\|\mathbf{e}_m - \mathbf{m}\|}{v_e T_{\text{max}}}, 0, 1\right)\right) \quad (12)$$

이다. 여기서 $\mathcal{A}_i = \{m \in \mathcal{A} : \iota(\mathbf{e}_m) = i\}$ 는 픽셀 i 에 놓인 생존 적선의 집합이고 $N_i = |\mathcal{A}_i|$ 이다. 밀도는 적 총수 M 으로, 진행 방향은 픽셀 안의 적 수로 나누어 평균 단위벡터가 되게 하고, 위협도는 모선까지 거리를 적 이 에피소드 상한 안에 달릴 수 있는 최대 거리 $v_e T_{\text{max}}$ 로 정규화하여 가까울수록 1에 가깝게 한다. 아군 위치 채널은 같은 방식으로 P 로 나누고, 설치된 그물 채널은 고해상도 물리 격자의 최대값 풀링, 육지 채널은 면적비 다운샘플(Fig. 6)이다. 좌표 채널은 픽셀 중심 $\mathbf{x}_i = (x_i, y_i)$ 에 대해

$$(c_i^x, c_i^y) = \frac{\mathbf{x}_i - \mathbf{m}}{E}, \quad c_i^r = \text{clip}\left(\frac{\|\mathbf{x}_i - \mathbf{m}\|}{E}, 0, 1\right) \quad (13)$$

로 두어 $[-1, 1]$ 과 $[0, 1]$ 에 놓는다. 격자에 담지 않는 방어정 p 의 자체 상태 벡터는 같은 반폭 E 로 정규화한 위치와 요격점, 헤딩 단위벡터, 그물 잔량 비율, 전개 여부이다.

$$\mathbf{o}_p = \left[\frac{1}{E}(\mathbf{a}_p - \mathbf{m}); (\sin \psi_p, \cos \psi_p); \frac{n_p}{n_{\text{max}}}; \delta_p; \mathcal{K}[\text{배정}] \frac{1}{E}(\mathbf{I}_p - \mathbf{m})\right] \in \mathbb{R}^8 \quad (14)$$

여기서 n_p 는 잔여 그물 수, n_{max} 는 적당 보유량, $\delta_p \in \{0, 1\}$ 은 전개 중 여부이며, 배정이 없으면 요격점 성분은 0이다.

스케일 불변성. 위 정의에서 길이를 가진 양은 모

기동 계층 두 방식 — 같은 전장·같은 유효 마스크 (50×50 격자 · 1 px = 252 m · 방어정 #0 · t=379)




Figure 3: 기동 계층 두 방식의 비교(학습된 체크포인트의 실제 출력, 같은 전장·같은 시점). 왼쪽: 두 방식이 공유하는 유효 마스크 — 2500칸 중 203칸만 선택 가능하다. 가운데: 휴리스틱은 유효 영역 안에서 기하로 정해진 두 점을 지목하며, 나머지 칸에 대한 선호를 표현하지 않는다(영역 전체가 균일하게 칠해져 있다). 오른쪽: 점수맵 정책은 같은 영역 위에 학습된 분포를 얹어 소수의 칸에 확률을 집중시킨다. 두 방식은 같은 격자·같은 마스크·같은 거리 제약을 통과한다 — 행동공간이 동일해야 성능 차이가 방법의 차이가 된다.




Figure 4: 래스터화된 15채널 관측의 한 장면(파상 포메이션, 통영 매물도 북측, $t = 320$, 학습·평가와 같은 50×50 격자). 01–09는 전역 채널(적 밀도, 적 진행 $x \cdot y$, 적 위협도, 아군 위치, 설치된 그물, 원점, 요격 환형, 육지), 10–12는 방어정 0의 채널(자기 위치, 배정 요격점, 유효 영역), 13–15는 좌표 채널(x, y, r)이며 모두 같은 격자에 정렬된다. 부호 없는 채널은 값이 클수록 검게, 부호 있는 채널(v_x, v_y , 좌표 $x \cdot y$)은 음을 파랑·양을 빨강으로 그렸다. 채널의 정의와 값 범위는 Table 4에 있다.




Figure 5: 15채널 관측의 구성. 전역 9채널(01-09), 방어정별 3채널(10-12), 좌표 3채널 (13-15)이 같은 격자에 걸쳐 하나의 다채널 영상을 이룬다. 오른쪽의 채널 이름은 구현의 이름과 같다. 왼쪽 아래는 격자에 담기지 않고 벡터로 들어가는 방어정 자체 상태 $\mathbf{o}_p \in \mathbb{R}^8$ — 위치 2, heading 단위벡터 2, 잔여 그물 1, 전개 중 여부 1, 배정 요격점 2이며, 요격점 두 성분은 배정이 없으면 0이다. 그림의 좌측 시선원뿔(“egocentric FOV”)과 함정 형상은 삽화의 표현이다 — 본 연구의 래스터는 방어정 시야가 아니라 모션을 중앙에 둔 전역 격자이며, 방어정마다 달라지는 것은 3채널(10-12)과 $\mathbf{o}_p$ 뿐이다.

Table 4: 15채널 격자 관측의 구성. 전역 채널은 월드당 한 번 계산하여 모든 방어정이 공유하고, 방어정별 채널만 방어정마다 다르다. 정의 열의 식 번호는 본문의 수식이다.

#	무음	채널	정의	범위
1	전역	적 밀도	픽셀 내 생존 적선 수/ M , 식 (11)	$[0, 1]$
2		적 진행 x	픽셀 내 적선 heading 단위벡터의 평균, 식 (11)	$[-1, 1]$
3		적 진행 y	위와 같음	$[-1, 1]$
4		적 위험도	모션 도달 임박도의 픽셀 내 최대, 식 (12)	$[0, 1]$
5		아군 위치	픽셀 내 생존 방어정 수/ P	$[0, 1]$
6		설치된 그물	물리 격자의 그물 점유를 최대값 풀링	$\{0, 1\}$
7		원점	모션 반경 안의 픽셀	$\{0, 1\}$
8		요격 구역	$r_{\min} \leq \ \mathbf{x}_i - \mathbf{m}\ \leq r_{\max}$ 인 픽셀	$\{0, 1\}$
9		육지	고해상도 육지 마스크의 면적비 (Fig. 6)	$[0, 1]$
10	방어정별	자기 위치	방어정 p 가 놓인 픽셀	$\{0, 1\}$
11		배정 요격점	$\mathbf{I}_p$ 가 놓인 픽셀 (미배정이면 전부 0)	$\{0, 1\}$
12		유효 영역	유효 마스크 $\mathcal{V}_p$, 식 (18)	$\{0, 1\}$
13	좌표	x	$(x_i - m_x)/E$, 식 (13)	$[-1, 1]$
14		y	$(y_i - m_y)/E$	$[-1, 1]$
15		r	$\text{clip}(\ \mathbf{x}_i - \mathbf{m}\ /E, 0, 1)$	$[0, 1]$

두 관측 반폭 E 나 픽셀 크기 ℓ 로 나뉘고, 개수는 $M \cdot P \cdot n_{\max}$ 로, 시간은 $v_e T_{\max}$ 로 나뉜다. 따라서 모든 입력은 $[-1, 1]$ 의 무차원 양이며, 교전 해역의 크기 나 격자 해상도를 바꾸어도 채널의 의미와 값 범위는 변하지 않는다 — 정책이 보는 것은 미터가 아니라 “해역 반폭 대비 어디에 있는가”이다. 별도의 통계 기반 정규화 층이 필요 없고, 학습 분포와 배치 분포 사이의 정규화 불일치도 생기지 않는다. 본 연구에 쓴 E , n_g 등의 값은 Table 1에 있다.

Fig. 4은 이 15채널 관측을 한 장면에 대해 채널별로 펼친 것이다. 채널의 값 범위와 비영 픽셀 수를 함께 적어, 어떤 채널이 실제로 정보를 담고 어떤 채널이 대부분 0인지가 드러나게 하였다 — 예컨대 좌표 채널은

전 픽셀이 비영이고, 방어정별 채널은 수십 픽셀 규모이며, 설치된 그물 채널은 전개 이전이라 전부 0이다.

목록 대신 격자 지도를 쓰면 입력 형태가 개체 수에 불변이고(적선이 늘거나 줄어도 텐서 크기가 같다), 개체의 순서에도 불변이며(순열 불변), 위의 정규화와 결합하면 해역 스케일에도 불변이다. 다만 합성곱은 평행이동 등변이라 절대 위치가 흐려지므로, 좌표 채널을 함께 넣어 위치를 보존한다.

육지 채널은 실제 해역 정보를 반영한다(Fig. 6). OpenStreetMap 에서 해안선·섬 폴리곤을 추출하여 격자로 변환한 뒤, 열림 연산으로 부두·방파제 같은 가는 돌출부를 제거하고 구멍 메우기로 내부를 정리한다. 충돌 판정은 고해상도 물리 격자에서 이진으로 수행하고,




Figure 6: 실해역 지형의 반영 과정(통영 매물도 인근, 12.6 km 박스). ① OpenStreetMap 벡터 폴리곤 → ② 고해상도 래스터 (805², 16 m/px) → ③ 충돌 판정용 물리 격자(200², 63 m/cell) → ④ 정책 격자(50², 252 m/px)로 면적비 다운샘플. **판정과 관측을 다른 해상도로 두는 이유는 충돌은 이진 판정을 요구하고, 관측은 해안선이 계단으로 들어가면 안 되기 때문이다.** ⑤는 적의 우회를 유도하는 척력장으로, 관측이 아니라 적 기동 모형의 일부다.

관측 채널은 이를 면적비로 정책 격자에 다운샘플하여 해안선이 계단이 아닌 연속값으로 들어가게 한다. 해역별로 한 번만 계산하여 캐시하므로 학습 중 외부 API 호출은 발생하지 않는다.

4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net 구조 [16]를 지나 입력과 같은 해상도의 특징 지도로 변환된다(Fig. 7). 인코더 2단(50 → 25 → 13)으로 수용 영역을 넓히고, 디코더 2단으로 원해상도를 복원하며, skip 연결이 인코더의 위치 정보를 디코더로 전달한다. 정밀 좌표와 전역 상황 판단을 동시에 요구하는 본 문제에 U자형 구조가 맞물리는 지점이 여기다.

병목에서는 전역 평균 풀링으로 압축한 전향 벡터로부터 FiLM [18]의 채널별 배율·이동 계수 (γ_F, β_F)를 만들어 병목 특징을 변조한 뒤 디코더에 넘긴다(아래첨자 F는 FiLM을 뜻하며, 식 (7)의 β 나 할인 계수 γ 와는 무관하다). 병목 특징 지도를 $\mathbf{H}_b \in \mathbb{R}^{2w \times h \times h}$ ($w = 32, h = 13$)라 하면

$$\begin{aligned} (\gamma_F, \beta_F) &= \mathbf{W}_F \text{GAP}(\mathbf{H}_b) + \mathbf{b}_F, \\ \tilde{\mathbf{H}}_b &= (1 + \gamma_F) \odot \mathbf{H}_b + \beta_F \end{aligned} \quad (15)$$

이며, $\odot$ 은 채널별 곱이다. 배율을 $1 + \gamma_F$ 로 두어 초기에는 항등 변조에서 출발한다. 국소 합성곱만으로는 “지금 전향이 급박한가”와 같은 전역 정보가 모든 위치에 고르게 전달되지 않기 때문에 이 경로를 둔다.

각 방어정 p 는 자신의 상태 벡터 $\mathbf{o}_p \in \mathbb{R}^8$ (식 (14))로부터 질의 벡터 $\mathbf{q}_p = \text{MLP}_{8 \rightarrow 128 \rightarrow 32}(\mathbf{o}_p) \in \mathbb{R}^{32}$ 를 만들고, 픽셀 i 의 특징 $\mathbf{f}_i \in \mathbb{R}^{32}$ 와의 내적으로 점수를

얻는다.

$$s_{p,i} = \frac{\langle \mathbf{W}_q \mathbf{q}_p + \mathbf{b}_q, \mathbf{f}_i \rangle}{\sqrt{d}}, \quad d = 32 \quad (16)$$

여기서 $\mathbf{W}_q \in \mathbb{R}^{d \times d}$, $\mathbf{b}_q \in \mathbb{R}^d$ 는 질의를 특징 공간에 맞추는 아핀 사영이다. 이는 어텐션 [20]의 점수 계산과 같은 형식이며, 포인터 방식 [19]으로 격자 위의 원소를 지목하는 구조에 해당한다. 특징 지도는 방어정마다 다르므로(15채널 중 3채널이 방어정별이다), 관측 텐서는 방어정을 배치 축으로 쌓아 **결정당 한 번의 배치 호출로 U-Net을 통과한다**. 합성곱 연산량은 방어정 수에 비례하지만, **가중치는 모든 방어정이 공유하므로 모델 크기는 방어정 수에 불변이다**. 방어정별로 달라지는 것은 질의 $\mathbf{q}_p$ 와 방어정별 3채널뿐이다.

합성곱 블록은 3×3 합성곱 — 그룹 정규화 [24] — SiLU로 구성한다.

$$\begin{aligned} \text{Block}(\mathbf{H}) &= \text{SiLU}(\text{GN}_8(\text{Conv}_{3 \times 3}(\mathbf{H}))), \\ \text{SiLU}(z) &= z / (1 + e^{-z}) \end{aligned} \quad (17)$$

그룹 정규화(GN₈, 8개 그룹)를 고른 이유는 성능이 아니라 배치 독립성이다. 표본 하나 안에서 채널을 묶어 정규화하므로 통계가 배치 구성에 의존하지 않으며, 이것이 §4.7에서 다루는 배치 크기 1의 실시간 추론이 학습과 같은 연산을 수행한다는 전제가 된다.

Fig. 7가 구조의 개념 일러스트라면, Fig. 8은 같은 망의 형상과 조건화 지점을 정확히 적은 구현 참조도이다 — 실제 관측 채널 화면에서 출발해 각 층의 텐서 크기, FiLM 계수가 들어가는 위치, 자기회귀 질의 갱신까지 한 장에 담았다.




Figure 7: 점수맵 정책의 구조. 각 방어정의 8차원 상태가 공유 MLP($8 \rightarrow 128 \rightarrow 32$)를 지나 질의 q 가 되고, 15채널 관측은 Stem($32 \times 50 \times 50$) – 인코더($32 \times 25 \times 25 \rightarrow 64 \times 13 \times 13$) – FiLM 병목 – 디코더($32 \times 25 \times 25 \rightarrow 32 \times 50 \times 50$)를 지난다. skip 연결이 인코더의 위치 정보를 디코더로 전달한다. 질의와 픽셀 특징의 내적이 50×50 점수맵을 이루고, 회귀 머리가 선택된 칸 안의 부화소 오프셋 2개를 낸다. 방어정을 배치 축으로 쌓아 **결정당 한 번의 배치 호출**로 통과하며 (그림의 입력 부피는 방어정마다 하나씩이다), 가중치는 전 방어정이 공유하므로 모델 크기는 방어정 수에 불변이다.




Figure 8: 기동 계층의 텐서 흐름(구현 참조도, 244,389 파라미터, $d = 32$, $K = 2$). **왼쪽:** 실제 관측 15채널 — 전역 9채널 (위)과 방어정별 3채널 + CoordConv 3채널(아래)의 학습된 체크포인트 출력 화면. **가운데:** stem $\rightarrow$ enc1 $\rightarrow$ enc2(stride 2) $\rightarrow$ bottleneck $\rightarrow$ dec2 $\rightarrow$ dec1의 U-Net. 병목에서 전역 평균 풀링 $\rightarrow$ 선형층으로 FiLM 계수 (γ, β) 를 만들어 병목 특징을 변조하고, 방어정 자체 상태 $\mathbf{o}_p \in \mathbb{R}^8$ 은 MLP($8 \rightarrow 128 \rightarrow 32$)를 거쳐 질의 q 가 된다. 스킵 연결은 위쪽 파란 화살표. **오른쪽:** 1×1 합성곱으로 픽셀 특징 f 를 내고, 질의 q 와의 내적 $\langle q, f \rangle / \sqrt{d}$ 로 점수맵을 만든 뒤 유효 마스크를 거쳐 argmax로 $K = 2$ 픽셀을 고른다. 아래 점선은 자기회귀 $q \leftarrow q + f_{k-1}$ — 첫 점의 특징을 질의에 더해 두 번째를 고른다. 본문 Fig. 7는 같은 구조의 개념 일러스트이고, 이 그림은 형상과 조건화 지점을 정확히 적은 판이다.

4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 다음 조건을 순차적으로 적용하여 유효 마스크를 구성하고, 그 밖은 $-\infty$ 로 차단한다.

1. 환상(annular) 요격 구역 — 모션에서 일정 반경 대역 — 안쪽
2. 육지가 아닌 곳
3. 배정된 요격점으로부터 반경 게이트 이내
4. 배정 무리의 방위 회랑 이내

픽셀 i 의 중심을 $\mathbf{x}_i$, 육지 픽셀 집합을 $\mathcal{L}_{\text{land}}$, 방어정 p 의 배정 요격점을 $\mathbf{I}_p$, 모션에서 본 요격점 방위를 ϑ_p , 픽셀 방위를 ϑ_i 라 하면 방어정 p 의 유효 픽셀 집합은 네 조건의 교집합이다.

$$\mathcal{V}_p = \{i : r_{\min} \leq \|\mathbf{x}_i - \mathbf{m}\| \leq r_{\max}, i \notin \mathcal{L}_{\text{land}}, \|\mathbf{x}_i - \mathbf{I}_p\| \leq r_g, |\vartheta_i - \vartheta_p|_o \leq \vartheta_g\} \quad (18)$$

여기서 $|\cdot|_o$ 는 $[0^\circ, 180^\circ]$ 로 접은 각도 차이이며 $r_{\min} = 400$, $r_{\max} = 4500$, $r_g = 3000\text{m}$, $\vartheta_g = 60^\circ$ 이다. 유효 픽셀이 하한 150개에 못 미치면 반경 게이트부터 푼다 — 방위 회랑은 “무엇을 막는 그물인가”를 정하므로 마지막까지 유지한다. 마스크는 점수에 곱해지는 것이 아니라 로짓 단계에서 적용된다.

$$\tilde{s}_{p,i} = \begin{cases} s_{p,i}, & i \in \mathcal{V}_p \\ -\infty, & i \notin \mathcal{V}_p \end{cases}, \quad \pi_\theta(i | \mathbf{s}, p) = \frac{e^{\tilde{s}_{p,i}}}{\sum_{j \in \mathcal{V}_p} e^{\tilde{s}_{p,j}}} \quad (19)$$

유효 집합 밖 픽셀의 확률은 정확히 0 이다. 이 마스크는 안전·임무 제약을 행동 분포에 직접 부과한다는 점에서 중요하다. 연속 좌표를 회귀시키는 방식에서는 이런 제약을 손실 항으로 넣어 “되도록 지키게” 유도할 수밖에 없지만, 지목 방식에서는 제약 위반이 애초에 표현 불가능하다.

이 제약이 실제로 얼마나 강한지는 측정으로 확인된다(Fig. 9). 학습된 체크포인트로 6,652회의 결정을 수집한 결과, $50 \times 50 = 2500$ 개 칸 가운데 평균 **10.5%** 만이 선택 가능하였다. 대표 사례의 단계별 감소는 전체 2500칸 → 요격 구역 1000 → 육지 제외 979 → 반경 게이트 387 → 방위 회랑 299로, 격자의 **88%**가 애초에 갈 수 없는 자리이다. 연속 좌표 회귀에는 이 구조를 표현할 수단이 없다.

왜 연속 좌표가 아니라 이산 격자인가. 마스크 말고 도 세 가지 이득이 있다. 첫째 *다봉 분포*이다. 그물벽을 놓을 만한 자리는 흔히 한 곳이 아니라 서로 떨어진 여러 곳이다. 연속 좌표에 흔히 쓰는 단봉 가우시안 정책은 이런 후보들을 평균 내어 그 사이의 — 종종 유효하지도 않은 — 지점으로 수렴하지만, 격자 위 범주형 분포는 떨어진 봉우리를 그대로 보존한다. 둘째 *탐색의 유계성*이다. 범주형 표본은 정의상 유효 영역을 벗어나지 않으므로 좌표를 자르거나 squash 하는 장치가 필요 없고, 엔트로피가 유한하여 §4.5의 그룹 후보들이 서로 다른 칸을 실제로 밟는다 — 가우시안 정책은 표준편차가 줄면 후보가 한 점으로 뭉쳐 상대 이득(식 (26))이 사라진다. 셋째 *구조의 일치*이다. 합성곱의 평행이동

등변성은 픽셀 단위 출력에서 그대로 살아나므로, 관측 격자와 행동 격자를 같은 50×50 으로 두면 “이 칸이 좋다”는 판단이 국소 기하로부터 곧바로 나온다. 대가는 해상도이다. 한 칸이 252m 이므로 순수 격자 행동은 최대 $\pm 126\text{m}$ 의 양자화 오차를 갖는데, 이를 위해 선택된 칸 안에서 $\pm$ 반픽셀의 연속 오프셋을 내는 회귀 머리를 함께 둔다(Fig. 7). 즉 *어느 칸인가*는 이산으로, *칸 안 어디인가*는 연속으로 결정하여 두 표현의 장점을 나누어 갖는다.

각 방어정은 유효 영역 안에서 점수 상위 픽셀 $K = 2$ 개를 순차적으로 고른다. k 번째 선택의 질의와 후보 집합을 $\mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}$ 라 하면 ($\mathbf{q}_p^{(0)} = \mathbf{q}_p, \mathcal{V}_p^{(0)} = \mathcal{V}_p$)

$$i_k \sim \pi_p^{(k)} \equiv \pi_\theta(\cdot | \mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}), \quad \mathbf{q}_p^{(k+1)} = \mathbf{q}_p^{(k)} + \mathbf{f}_{i_k} \quad (20)$$

$$\mathcal{V}_p^{(k+1)} = \{i \in \mathcal{V}_p^{(k)} : r_{\text{dup}} \leq \|\mathbf{x}_i - \mathbf{x}_{i_k}\| \leq 1.5 L_{\text{net}}\} \quad (21)$$

이다. 먼저 고른 픽셀의 특징을 질의에 더해 두 번째를 고르므로 두 점이 서로를 알고 뺀다. 독립적으로 뺀다면 두 점을 잇는 벽의 방향이 우연에 맡겨진다. 식 (21)는 두 점 *사이* 간격의 상·하한이다. $r_{\text{dup}} = 200\text{m}$ 안쪽은 두 점이 너무 가까워 벽이 서지 않고, 상한은 그물벽 최대 길이의 1.5배인 675m 로 두어 실제로 칠 수 없는 길이의 벽이 선택되지 않게 한다. 상한을 두지 않았을 때 휴리스틱 목표점을 유효 픽셀로 스냅한 간격의 중앙값이 504m 로 그물 길이 450m 를 초과했고(초과율 66.7%), 정책의 표본은 88.6% 가 초과했다. 이 제약으로 후보가 모두 사라지면 제약을 완화하여 결정을 반환한다(최적성보다 결정 가능성을 우선한다).

선택된 칸 안의 위치는 연속 오프셋으로 정한다. 질의와 선택 픽셀의 특징으로부터 평균을 내고, 학습되는 로그표준편차 σ_o 를 가진 가우시안에서 표집한다.

$$\mu_k = \text{MLP}_{2d \rightarrow d \rightarrow 2}([\mathbf{q}_p^{(0)}; \mathbf{f}_{i_k}]), \quad \mathbf{u}_k \sim \mathcal{N}(\mu_k, \sigma_o^2), \quad \mathbf{t}_k = \mathbf{x}_{i_k} + \frac{\ell}{2} \text{clip}(\mathbf{u}_k, -1, 1) \quad (22)$$

즉 *어느 칸인가*는 범주형으로, *칸 안 어디인가*는 가우시안으로 결정된다. 한 방어정의 행동 $a_p = \{(i_k, \mathbf{u}_k)\}_{k=0}^{K-1}$ 의 로그확률과 엔트로피는 두 분포의 합이다.

$$\log \pi_\theta(a_p) = \sum_{k=0}^{K-1} \left[\log \pi_p^{(k)}(i_k) + \log \mathcal{N}(\mathbf{u}_k; \mu_k, \sigma_o^2) \right] \quad (23)$$

$$\mathcal{H}(a_p) = \sum_{k=0}^{K-1} \left[\mathcal{H}(\pi_p^{(k)}) + \mathcal{H}(\mathcal{N}(\mu_k, \sigma_o^2)) \right] \quad (24)$$

식 (23)는 §4.5의 정책경사에, 식 (24)는 엔트로피 정책화에 그대로 쓰인다. 특징 조회에서 두 번째 점까지의 흐름을 Fig. 10에 요약하였다.

선택된 두 좌표를 잇는 선분이 그물벽 경로가 된다. 방어정은 가까운 점까지 무전개로 이동한 뒤 다음 구간에서 그물을 전개한다. 운용 시에는 최대 점수를 취하고 (greedy), 학습 시에는 확률 분포에서 표본을 뽑는다.

정지 규칙. 그물이 없거나 배정되지 않은 방어정은 정지시킨다. 이런 방어정에는 학습 중 유의미한 보상 신호가 없어 점수맵이 거의 평평해지는데(최고 확률

왜 좌표 회귀가 아니라 「점수맵 위 픽셀 지목」인가




Figure 9: 왜 좌표 회귀가 아니라 점수맵 위 픽셀 지목인가(학습된 체크포인트의 실제 출력). **왼쪽:** 연속 좌표를 회귀하는 출력에는 “놓을 수 없는 곳”을 표현할 자리가 없다 — 이 장면에서 붉은 영역이 격자의 88.0%다. **오른쪽:** 같은 장면을 후보 영역으로 확대한 점수 분포와 선택된 두 픽셀, 그리고 그 둘을 잇는 그물벽이다. 마스킹된 softmax 아래에서 부적합한 칸은 확률이 0이라 애초에 선택되지 않는다. **아래 막대**는 제약이 순차 적용되며 후보가 줄어드는 과정이다 (2500 → 1000 → 979 → 387 → 299, 12.0%). 전 결정 평균 후보는 10.5%였다.




Figure 10: 점수맵 위 픽셀 지목의 네 단계. ① 복호기가 낸 픽셀별 특징 $F(x, y)$. ② 유효 마스크 M 을 곱해 놓을 수 없는 칸을 차단한다 (§4.4.3). ③ 질의 $\mathbf{v}$ 와의 내적으로 점수맵 $S = F \cdot \mathbf{v}$ 를 얻고 최대 칸을 첫 점으로 고른다. ④ 첫 점의 특징을 질의에 더해($\mathbf{q} \leftarrow \mathbf{q} + \mathbf{f}_0$) 같은 절차로 두 번째 점을 고르되, 첫 점과의 간격 상·하한(파선 원)을 마스크에 추가한다. 두 점을 잇는 선분이 그물벽이다.

0.02 수준, 배정된 방어정은 0.5 ~ 0.7), 이 무의미한 출력에 향해 명령으로 새어 나가는 것을 막기 위함이다.

각 후보를 시뮬레이터에서 공통 구간 $H = 180 \text{ step}$ 만큼 실제로 진행시켜 창 보상 $R_k = R(\mathbf{s}, \mathbf{a}^{(k)}; H)$ 를 얻은 뒤 (§4.5.3), 후보들 사이의 상대 비교로 이득을 산정한다.

4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

4.5.1 그룹 상대 이득

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화 [14]를 다중 방어정 상황에 맞게 변형하여 수행한다. 결정 시점의 상태를 $\mathbf{s}$, 방어정 P 적의 결합 행동을 $\mathbf{a} = (a_1, \dots, a_P)$ 라 하자. 매 결정 시점에서 정책으로부터 G 개의 결합 행동 후보를 표집하되, 후보 가운데 하나($k = 0$)는 휴리스틱 (§4.3)이 내는 행동으로 고정하여 기준선으로 삼는다.

$$\mathbf{a}^{(0)} = \mathbf{a}_{\text{heur}}(\mathbf{s}), \quad \mathbf{a}^{(k)} \sim \pi_{\theta}(\cdot | \mathbf{s}), \quad k = 1, \dots, G-1 \quad (25)$$

$$A_k = \frac{R_k - R_0}{\text{std}(\{R_j\}_{j=0}^{G-1}) + \epsilon}, \quad \epsilon = 10^{-6} \quad (26)$$

$R_0 = R_{\text{heur}}$ 이므로 휴리스틱과 같은 성과를 내는 후보의 이득은 0 이고, 휴리스틱을 넘어서는 후보만 양의 이득을 받는다. 그룹 표준편차로 나누므로 이득은 크기가 없는 양이며, 그룹 안의 순위 정보만 남는다. 어떤 선택이 더 나은지를 실제 결과로 직접 비교하므로 별도의 가치망이 필요하지 않다. 이는 가치 추정 편향과 비평가 학습의 불안정성을 원천적으로 제거한다.

한 갱신은 N 개의 병렬 전장(월드)에서 동시에 수행된다. 월드 n 의 후보 보상이 모두 같으면 이득이 정의되지 않으므로, 유효 마스크 $w_n = \mathbb{I}[\text{std}(\{R_{n,k}\}_k) > \epsilon_{\text{var}}]$ ($\epsilon_{\text{var}} = 10^{-6}$)로 그런 월드를 갱신에서 제외한다. 정책경사 손실은 유효 월드의 모든 후보·모든 방어정에

대해 이득으로 가중한 로그확률 (식 (23))의 음수이다.

$$\mathcal{L}_{PG}(\theta) = -\frac{\sum_n w_n \sum_{k=0}^{G-1} A_{n,k} \sum_{p=1}^P \log \pi_\theta(a_{n,p}^{(k)} | \mathbf{s}_n)}{G \sum_n w_n} \quad (27)$$

여기에 엔트로피 정칙화(식 (24))를 더한 총손실을 Adam 으로 최소화한다.

$$\mathcal{L}(\theta) = \mathcal{L}_{PG}(\theta) - \lambda_H(t) \frac{1}{NP} \sum_{k=0}^{G-1} \sum_{n=1}^N \sum_{p=1}^P \mathcal{H}(a_{n,p}^{(k)}) \quad (28)$$

엔트로피는 G 개 후보 모두에 대해 합하므로 유효 계수는 $G\lambda_H(t)$ 이며, $\lambda_H(t)$ 는 §4.5.6의 감쇠 계수이다. 기울기는 노름 $g_{\max} = 1.0$ 에서 자른다.

$$\mathbf{g} = \nabla_\theta \mathcal{L}(\theta), \quad \theta \leftarrow \theta - \eta_t \cdot \text{Adam}\left(\mathbf{g} \cdot \min\left(1, \frac{g_{\max}}{\|\mathbf{g}\|}\right)\right) \quad (29)$$

시뮬레이터를 직접 전진시켜 후보를 평가하는 착상은 탐색 기반 의사결정 [25]과 같은 계열이되, 본 연구는 탐색 트리를 전개하지 않고 한 결정 시점의 후보 집합만 비교한다. 이 절차와 다음 소절의 크레딧 배분을 Fig. 11에 한 장으로 정리하였다.

4.5.2 반사실적 크레딧 배분: 비교 변형

식 (27)는 팀 보상의 이득 $A_{n,k}$ 를 모든 방어정의 로그 확률에 같은 값으로 곱한다. 팀 보상을 모든 방어정이 그대로 나누어 가지면 개별 기여가 가려진다. 잘한 방어정과 못한 방어정이 같은 신호를 받으면 학습이 진행되지 않는다. 따라서 한 척의 행동만 바꾸고 나머지는 고정된 채 재평가하여, 그 차이를 해당 방어정의 몫으로 돌린다. 기준 표본 $\mathbf{a}^{\text{base}} \sim \pi_\theta(\cdot | \mathbf{s})$ 를 하나 두고, 방어정 p 에 대해 p 의 행동만 바꾼 혼합 후보 G 개를 만든다.

$$\mathbf{a}^{(k,p)} = (\mathbf{a}_{-p}^{\text{base}}, \tilde{a}_p^{(k)}), \quad \tilde{a}_p^{(0)} = a_{\text{heur},p}(\mathbf{s}), \quad \tilde{a}_p^{(k)} \sim \pi_\theta(\cdot | \mathbf{s}, p) \quad (30)$$

여기서 $\mathbf{a}_{-p}$ 는 p 를 제외한 나머지 방어정의 행동이다. 각 혼합 후보를 같은 구간 H 만큼 재진행하여 얻은 창 보상 $R_k^{(p)} = R(\mathbf{s}, \mathbf{a}^{(k,p)}; H)$ 로 방어정 p 만의 이득을 산정한다.

$$A_k^{(p)} = \frac{R_k^{(p)} - R_0^{(p)}}{\text{std}(\{R_j^{(p)}\}_{j=0}^{G-1}) + \epsilon} \quad (31)$$

나머지 방어정의 행동이 고정되어 있으므로 $R_k^{(p)} - R_0^{(p)}$ 는 방어정 p 의 선택이 바뀐 데서만 온 차이이다. 이 이득은 방어정 p 의 로그확률에만 곱해진다.

$$\mathcal{L}_{CF}(\theta) = -\frac{\sum_p \sum_n w_n^{(p)} \sum_k A_{n,k}^{(p)} \log \pi_\theta(\tilde{a}_{n,p}^{(k)} | \mathbf{s}_n)}{G \sum_p \sum_n w_n^{(p)}} \quad (32)$$

$w_n^{(p)}$ 은 유효 마스크 w_n 을 방어정 p 의 후보 집합에 적용한 것이며, 이 모드에서 식 (28)의 엔트로피는 기준

표본 $\mathbf{a}^{\text{base}}$ 에서만 계산한다. 식 (32)는 식 (28)에서 $\mathcal{L}_{PG}$ 자리에 들어간다. 이는 COMA [10]의 반사실적 기준선과 같은 착상이되, 학습된 비평가로 주변화하는 대신 *시뮬레이터를 실제로 재진행하여 얻는다는 점*이 다르다. 비평가 근사 오차가 개입하지 않는 대신, 결정당 시뮬레이터 호출이 G 회에서 GP 회로 늘어난다.

채택 여부. 두 손실을 같은 예산(800 업데이트)으로 비교한 스크리닝에서 반사실 모드는 600 업데이트 시점 greedy 포획률 0.801 로 팀 이득 모드의 0.800 과 동률이었고, 시뮬레이터 호출은 3배였다. 본 논문이 평가하는 체크포인트는 팀 이득 손실(식 (27)–(29))로 학습한 것이다.

4.5.3 보상 설계

한 후보의 창 보상 $R(\mathbf{s}, \mathbf{a}; H)$ 는 결정 시점부터 H step 동안 일어난 일을 하나의 스칼라로 합산한 팀 공유 보상이며, 이벤트 항·퍼텐셜 차분·조밀 항으로 구성된다.

$$R = R_{\text{event}} + [\gamma \Phi(\mathbf{s}_{t+H}) - \Phi(\mathbf{s}_t)] + R_{\text{dense}} \quad (33)$$

이벤트 항은 창 안의 사건 수에 고정 가중을 곱한 합이다.

$$R_{\text{event}} = r_{\text{cap}} N_{\text{cap}} + r_{\text{brc}} N_{\text{brc}} + r_{\text{col}} (N_{\text{col}} + N_{\text{land}}) + r_{\text{tng}} N_{\text{tng}} + \mathbb{I}_{\text{end}} (r_{\text{wipe}} \mathbb{I}[\mathcal{A} = \emptyset] + r_{\text{surv}} |\mathcal{A}|) \quad (34)$$

계수는 포획 $r_{\text{cap}} = +13.5$, 돌파 $r_{\text{brc}} = -8.0$, 아군·모선·육지 충돌 $r_{\text{col}} = -30$, 설치 그물 접촉 $r_{\text{tng}} = -13$, 창 안에서 에피소드가 끝날 때($\mathbb{I}_{\text{end}}$) 전멸 $r_{\text{wipe}} = +8$, 잔존 적 1척당 $r_{\text{surv}} = -5$ 이다. Φ 는 적의 모선 근접도에 대한 퍼텐셜로, 차분 형태로 주어지므로 최적 정책을 보존한다 [26].

$$\Phi(\mathbf{s}) = -w_{\text{threat}} \sum_{m \in \mathcal{A}} \text{clip}\left(1 - \frac{\|\mathbf{e}_m - \mathbf{m}\|}{R_w}, 0, 1\right) \quad (35)$$

여기서 $\mathcal{A}$ 는 생존 적선 집합, $R_w = 6300 \text{ m}$ 는 교전 해역 반폭, $w_{\text{threat}} = 3.0$, $\gamma = 0.99$ 이다. 적이 포획되어 $\mathcal{A}$ 에서 빠지거나 멀어지면 Φ 가 오른다.

조밀 항은 창 안의 기동 품질을 재는 비용·보너스의 합이다. 창 길이 H , 방어정 속력 v_a , 최대 선회율 $\dot{\psi}_{\max}$, 창 안 총 이동거리 D , 소모 그물 수 N_{net} 에 대해

$$R_{\text{dense}} = -w_{\text{path}} \frac{D}{H v_a P} - w_{\text{net}} N_{\text{net}} - \frac{w_{\text{turn}}}{P} \sum_{p=1}^P S_p - w_{\text{prox}} \sum_{p=1}^P (\rho_p^{\text{m}^2} + \rho_p^{\text{a}^2}) - \frac{w_{\text{cons}}}{P} \sum_{p=1}^P \Xi_p + w_{\text{cov}} \text{Cov} + w_{\text{ray}} \text{Ray} \quad (36)$$

이다. $S_p = \sum_t |\Delta \psi_{p,t}| / (H \dot{\psi}_{\max}) \in [0, 1]$ 은 창 안 누적 선회량을 최대 가능 선회량으로 나눈 값이고, $\Xi_p = \|\mathbf{t}_p - \mathbf{t}_p^{\text{prev}}\| / L_{\max}$ 는 직전 결정 대비 목표점 이동을 최대 경로 길이 $L_{\max} = L_{\text{net}}$ 로 나눈 값이다(구현은 경유점 6개와 생존 방어정에 대해 평균하며, 여기서는 목표점




Figure 11: 가치망 없는 다중 방어정 그룹 상대 최적화의 한 갱신. 위: 한 결정 상태에서 G 개의 결합 행동 후보를 표집하고, 각 후보를 시뮬레이터에서 공통 구간만큼 실제로 진행시켜 팀 보상을 얻는다. 가운데: 후보 평가에 쓰이는 롤아웃 창. 아래 왼쪽·가운데: 팀 보상을 후보 간 상대 비교로 이득으로 바꾼다 (식 (26)). 아래 오른쪽: 반사실적 크레딧 — 한 척의 행동만 바꾸고 나머지는 고정된 채 시뮬레이터를 다시 진행시켜, 그 차이를 그 배의 몫으로 돌린다 (§4.5; 구현된 변형이며 채택 런은 팀 이득 손실을 썼다). 그림은 기전 전달을 위해 후보 수와 창을 $G = 4$, $H = 4$ 로 줄여 그렸으며 실제 학습은 $G = 8$, 평가 구간 180 step 이다.

단위로 단순화하여 적었다). 근접 패널티는 창 안에서 방어정 p 가 모션·타 방어정에 가장 가까웠던 거리 d_p^m , d_p^a 를 영향 반경으로 정규화한 뒤 제공하여, 불을수록 급격히 커지게 한다.

$$\rho_p^m = \text{clip}\left(\frac{R_m - d_p^m}{\varrho_m}, 0, 1\right), \quad \rho_p^a = \text{clip}\left(\frac{\varrho_a - d_p^a}{\varrho_a}, 0, 1\right) \quad (37)$$

($R_m = 800$, $\varrho_m = 500$, $\varrho_a = 600$ m). 커버리지는 적에서 모션으로 향하는 직선(ray)이 설치된 그물에 막힌 생존 적의 비율이며, 포획의 선행 지표로서 창 안에 포획이 없을 때도 변별력을 준다.

$$\text{Cov} = \frac{1}{|\mathcal{A}|} \sum_{m \in \mathcal{A}} \mathbb{I}[\exists \lambda \in \Lambda : \mathbf{e}_m + \lambda(\mathbf{m} - \mathbf{e}_m) \in \mathcal{W}] \quad (38)$$

여기서 $\mathcal{W}$ 는 설치된 그물이 차지하는 영역이고, Λ 는 $[0.05, 0.95]$ 를 16등분한 표본점이다. Ray 는 같은 검사를 계획된 그물벽까지 포함하되, 두 방어정이 충돌 거리 안에서 같은 ray 를 겹쳐 막으면 무효로 치고, 차단된 적마다 배율 $b_{\text{net}}(1 + g_{\text{far}}(1 - \lambda_m))$ ($b_{\text{net}} = 1.3$, $g_{\text{far}} = 1.0$, λ_m 은 차단점의 ray 상 위치로 적에 가까울수록 0)을 곱해 적에 가까운 차단을 우대하는 단일 커버 판이다 (Ray $\in [0, 2.6]$). 가중은 $w_{\text{path}} = 0.5$, $w_{\text{net}} = 0.3$, $w_{\text{prox}} = 0.75$, $w_{\text{turn}} = w_{\text{cons}} = 0.3$, $w_{\text{cov}} = 0.1$, $w_{\text{ray}} = 1.6$ 이다. 레이 커버 항을 제외한 조밀 항은 이벤트 계수의 수십분의 일 규모이고, 레이 커버 항은 최대 4.2 로 포획 1 건(13.5)의 3분의 1을 넘지 않게 두었다. 이 밖에 요격 점 접근·예비 방어정 정치·인공 퍼텐셜 척력 등 가중 0.1 ~ 0.25 의 보조 항이 있으나 규모가 작아 생략한다.

퍼텐셜 항을 둔 이유는 이벤트 항만으로는 학습 신호가 지나치게 희소하기 때문이다. 216개 결정에 대한 실측에서 포획은 평가 창의 46.8 %에서만 발생하였다. 나머지 절반의 창에서는 퍼텐셜 항이 유일한 큰 신호이며(비영 비율 100 %), 이것이 없으면 그룹 내 후보들의 순위가 갈리지 않아 식 (26)의 이득이 정의되지 않는다. 같은 측정에서 퍼텐셜 항의 평균은 +0.36 인 데 비해 절댓값 평균은 7.40 으로, 창마다 크게 변동하지만 전체적으로는 상쇄된다. 이는 퍼텐셜 기반 성형이 설계 대로 정책은 바꾸지 않고 변별력만 제공한다는 실측 증거이다.

4.5.4 학습 경과와 수렴

학습은 실해역 6곳을 에피소드마다 돌아가며 진행하였다(Fig. 12). 한 해역만으로 학습하면 정책이 그 해안선의 형상을 외워 “섬은 항상 저기 있다”를 전제로 굳는다. 여섯 곳은 육지 비율 0%(외해)에서 7.5 %까지, 요격 구역에 육지가 잠식하는 비율 0에서 6 %까지 분포하도록 골랐고, 모션에서 가장 가까운 육지까지의 여유도 1.6 km에서 무한대까지 걸쳐 있다. 평가(\$5)는 이 가운데 통영 매물도 서측 한 곳에서 수행한다.

같은 여섯 해역에서 학습된 정책이 실제로 어떻게 움직이는지는 Fig. 13에 같은 진행 시점(에피소드의 약 65 %, 그물이 전개되고 적이 요격 구역에 도달한 시점)으로 나란히 놓았다. 집중 포매이션·휴리스틱 배정·U-Net 기동으로 통일하였고 해역만 다르다. (c) 신안 흥도 북측과 (e) 통영 매물도 북측에서는 해안선이 요격 구역 안쪽까지 들어와 유효 마스크를 잠식하며, (f) 포항




Figure 12: 학습에 쓴 실패역 6곳의 육지 마스크(Fig. 6의 절차를 각 해역에 적용한 결과, 12.6km 박스). 별표는 모선, 파선 원은 요격 구역이다. 각 패널 위의 백분율은 박스 안 육지 비율, 아래는 요격 구역에 육지가 잠식한 비율과 모선에서 가장 가까운 육지까지의 여유 거리이다. 오른쪽 아래(포항 호미곶 동측)는 육지가 없는 외해로, 지형이 없는 상황을 학습 분포에 넣기 위한 대조 해역이다.

호미곶 동측은 육지가 없어 정책이 지형 제약 없이 이동하는 대조 사례다. 각 패널의 시드는 해당 해역에서 전멸 포획·돌파 0·충돌 0·아군 손실 0을 만족하는 것으로 골랐다 — 이 그림은 성능 주장이 아니라 지형이 경로와 그물 위치에 어떻게 개입하는지를 보이는 용도이다.

Fig. 14에 학습 경과를 정리하였다. 포획률(패널 (a))은 휴리스틱 기준선 0.744 부근에서 출발하여 800 업데이트 안에 greedy 평가 최고 0.805(600 업데이트)에 도달한다. 본 논문이 평가하는 정책은 이 최고 시점의 가중치이다.

세 가지를 함께 볼 필요가 있다. 첫째 보상(패널 (b))에서 후보 최대값이 후보 평균보다 꾸준히 위에 있다 — 그룹 안에서 후보들이 실제로 갈린다는 뜻이며, 갈리지 않으면 식 (26)의 이득이 0이 되어 학습 신호가 사라진다. 둘째 학습신호 유효율(패널 (c))이 0.5 안팎에 머문다 — 절반가량의 윌드는 후보 간 분산이 0이어서 그 스텝의 기울기에 기여하지 못한다. 셋째 손실(패널 (d))의 절대값은 정책경사와 엔트로피 항의 합이므로 그 자체로는 수렴 지표가 아니다.

포획률 곡선이 단조 증가하지 않고 진동하는 것은 이 구조의 특성이다. 매 업데이트마다 새로 표집한 전장에서 평가하므로 시나리오 난이도가 곡선에 그대로 실린다. 그래서 학습 중 판정은 greedy 평가(패널 (a))의 원 표식)로 하고, 최종 성능은 §5의 고정 시드 대응표본으로 따로 측정한다.

수렴 진단 Fig. 14는 채택 런의 기록이지만, 그 런은 보상·포획률·손실만 20 업데이트마다 남겼으므로 정

책이 정지점에 닿았는가를 직접 보이는 지표가 없다. 이를 보완하기 위해 같은 설정을 시드 3개로 다시 돌리며 표준적인 수렴 진단을 매 업데이트마다 기록하였다 (Fig. 15). 재현 런의 가중치는 논문의 결과에 쓰지 않는다 — 채택 런이 전형적인 학습 경과였는지, 그리고 그 경과가 수렴이라 부를 만한지를 확인하는 용도이다. 갱신 전후 정책을 θ_t, θ_{t+1} 라 하면 두 진단량은 다음과 같다.

$$\widehat{\text{KL}}_t = \frac{1}{NP(G-1)} \sum_{n,p} \sum_{k=1}^{G-1} (\zeta_{n,p,k} - 1 - \log \zeta_{n,p,k}),$$

$$\zeta_{n,p,k} = \frac{\pi_{\theta_{t+1}}(a_{n,p}^{(k)} | \mathbf{s}_n)}{\pi_{\theta_t}(a_{n,p}^{(k)} | \mathbf{s}_n)}, \quad \varsigma_t = \frac{\|\theta_t - \theta_{\text{BC}}\|}{\|\theta_{\text{BC}}\|} \quad (39)$$

$\widehat{\text{KL}}_t$ 는 같은 관측·같은 표본 후보(휴리스틱 후보 $k=0$ 은 정책의 표본이 아니므로 제외)에 대한 확률비 ζ 의 k_3 추정량으로, $\text{KL}(\pi_{\theta_t} \| \pi_{\theta_{t+1}})$ 의 비음(非陰)·저분산 몬테카를로 추정이다. ς_t 는 행동복제 초기점 θ_{BC} 로부터의 상대 파라미터 이동 거리이다.

네 지표가 같은 방향을 가리킨다. (i) 업데이트 간 근사 KL(패널 (c)) — 식 (39)의 $\widehat{\text{KL}}_t$ —은 처음 100 업데이트 평균 1.4×10^{-2} 에서 마지막 100 업데이트 1.5×10^{-4} 로 두 자릿수 줄어든다. 같은 구간에서 학습률은 16배 줄었으므로 이 감소의 일부는 스케줄의 몫이지만, 정책이 한 걸음에 움직이는 양이 사실상 0에 수렴한다는 사실 자체는 변하지 않는다. (ii) 파라미터 이동 거리 ς_t (패널 (f))는 400 업데이트에 0.031, 800 업데이트에




Figure 13: 학습 해역 6곳의 실행 장면(집중 포메이션, 휴리스틱 배정, U-Net 기동, 에피소드 진행률 65%). 패널 순서와 육지 비율은 Fig. 12와 같다. 위성 배경 위에 육지 마스크·설치된 그물(보라)·경유점·경로가 겹쳐 있고, 각 패널 상단에 전장 상황판과 적/아군 확대 창이 있다. 시드는 해역별로 사고 없는 에피소드를 골랐다(`tools/find_demo_seeds.py --site`).

0.034 로 뒤 절반에서 포화한다 — 정책이 행동복제 초기점 근방의 한 지점에 정착했다는 뜻이다. (iii) **정책 엔트로피**(패널 (b)): 1단계 픽셀 분포, 균일분포 상한 $\ln 273 \approx 5.6 \text{ nat}$ 는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하고, 최빈 픽셀의 확률은 0.25 에서 0.37 로 오른다. 정책이 붕괴하지 않으면서(엔트로피가 0 으로 가지 않으면서) 첨예해진다. (iv) **휴리스틱 후보 대비 보상 이득**(패널 (e)) — 같은 전장·같은 평가 창에서 표본 후보의 보상에서 휴리스틱 후보의 보상을 뺀 값 — 은 처음 100 업데이트 평균 -1.3 에서 마지막 100 업데이트 $+5.1$ 로 부호가 바뀐다. 학습 초기에는 정책의 표본이 휴리스틱보다 못했고, 후반에는 평균적으로 휴리스틱을 앞선다.

greedy 평가 포획률(패널 (a))은 세 시드 모두 800 업데이트에서 기준선 0.749 위에 있다 (0.817, 0.777, 0.801; 평균 0.798). 채택 런의 세 평가점(별표)은 이 세 곡선의 범위 안에 들어, 채택 런이 특별히 운 좋은 경과가 아니었음을 보인다. 다만 시드 하나는 100 업데이트에서 0.417 까지 떨어졌다가 회복하였고 500 업데이트에서 다시 기준선 아래로 내려갔다 — 그룹 상대 이득이 순 위만 쓰는 이 학습이 초기에 한 번 크게 흔들릴 수 있음을 그대로 보여 주는 사례이며, 학습 중 판정을 **greedy** 평가로 하는 이유이기도 하다.

한 가지 지표는 수렴 지표로 읽으면 안 된다. **그래디언트 노름**(패널 (d))은 800 업데이트내내 클립 한계 1.0 의 12배 이상이어서 모든 갱신이 잘린 상태로 진행된다. 이는 식 (26)의 이득이 그룹 표준편차로 정규화되어 크기가 없는 양이기 때문이다 — 후보들의 보상 차이가

아무리 작아도 이득의 스케일은 같으므로 기울기의 크기는 줄지 않는다. 따라서 이 구조에서 실제 보폭을 정하는 것은 기울기가 아니라 학습률이며, 수렴의 증거는 기울기 노름이 아니라 KL·파라미터 이동·엔트로피에서 찾아야 한다.

4.5.5 행동 복제 초기화

그룹 상대 이득은 후보들이 실제로 갈릴 때만 신호를 주므로, 무작위 초기화된 정책에서 곧바로 시작하면 초기 후보가 모두 무의미한 자리에 흩어져 갱신이 잡히지 않는다. 그래서 그룹 상대 최적화에 앞서 휴리스틱 행동 (§4.3)을 목표로 하는 행동 복제를 300 step 수행하여 정책을 부팅한다(Adam, 학습률 3×10^{-4}). 목표 분포에는 가우시안 라벨 스무딩을 적용한다. 휴리스틱이 지목한 픽셀 i_k^* 주변에 유효 픽셀로 제한한 가우시안 가중을 두고, 그 가중과 정책의 교차엔트로피를 최소화한다.

$$\omega_k(i) = \frac{\mathbb{I}[i \in \mathcal{V}_p^{(k)}] \exp(-\|\mathbf{x}_i - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{\text{BC}}^2)}{\sum_{j \in \mathcal{V}_p^{(k)}} \exp(-\|\mathbf{x}_j - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{\text{BC}}^2)} \quad (40)$$

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{P} \sum_{p=1}^P \sum_{k=0}^{K-1} \sum_{i \in \mathcal{V}_p^{(k)}} \omega_k(i) \log \pi_p^{(k)}(i) \quad (41)$$

$\sigma_{\text{BC}} = 0.8 \text{ px} (\approx 202 \text{ m})$ 이며, 두 번째 픽셀의 질의는 휴리스틱의 첫 픽셀로 갱신한다(teacher forcing). 격자 위의 인접 픽셀은 사실상 같은 행동이므로 단일 픽셀




Figure 14: GRPO 학습 경과(50^2 격자, 후보 $G = 8$, 후보 평가 구간 180 step, 실해역 6곳 로테이션(Fig. 12), 800 업데이트). 검정 굵은 선은 20 업데이트마다 기록한 원자료의 100 업데이트 이동평균이며, (a)에만 원자료를 연회색 가는 선으로 함께 두었다. (a) 포획률(Capture rate). 원 표식은 200 업데이트마다의 greedy 평가, 파선은 휴리스틱 기준선 0.744이다. **채운 원(600 업데이트, 0.805)**이 본 논문이 평가하는 가중치이다. (b) 후보 평균 보상(실선)과 후보 최대 보상(파선) — 둘의 간격이 그룹 내 변별력이다. (c) 후보 간 분산이 0이 아닌 월드의 비율(Valid-signal fraction; 학습 신호가 실제로 생긴 비율). (d) 손실(정책경사 + 엔트로피). 부호와 크기 자체는 수렴 지표가 아니다.




Figure 15: 수렴 진단 — 채택 런과 같은 설정을 시드 3개로 다시 돌린 학습 동역학. 검정 굵은 선은 시드 평균(40 업데이트 이동평균)이며, 시드별 꺾은선은 (a)에만 연회색으로 두었다. (a) 100 업데이트마다의 greedy 포획률(연회색은 시드별, 빈 원은 평균, 채운 사각형은 채택 런의 평가점, 파선은 같은 프로토콜로 랜 휴리스틱 기준선 0.749). (b) 1단계 픽셀 분포의 엔트로피. 유효 픽셀 중앙값 273개의 균일분포 상한은 $\ln 273 \approx 5.6$ nat로 축 밖에 있다. (c) 갱신 전후 정책의 근사 KL 발산(같은 관측·같은 표본 후보, 로그축). (d) 클리핑 전 그래디언트 노름 — 800 업데이트 내내 클립 한계 1.0의 수십 배라 수렴 지표가 아니다. (e) 표본 후보 보상에서 휴리스틱 후보 보상을 뺀 값. 0을 넘으면 정책의 표본이 휴리스틱을 앞선다. (f) 행동복제 초기점으로부터의 상대 파라미터 이동 거리.

원-핫을 목표로 두면 불필요하게 뾰족한 분포를 강요하게 되고, 조밀한 점수맵에서 원-핫 교차엔트로피의 기울기는 지나치게 희소하여 초기 학습이 불지 않기 때문이다. 그룹 상대 최적화 단계에서는 이 항을 쓰지 않으며, 대신 식 (26)의 휴리스틱 기준선이 정책을 휴리스틱 근방에 붙잡는 신뢰 영역 구실을 한다.

4.5.6 학습률·엔트로피 계수 스케줄

옵티마이저는 Adam이고 학습률은 재시작 없는 단일 주기 코사인 어닐링 [27]으로 줄인다(Fig. 16(a)):

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})\left(1 + \cos \frac{\pi t}{T}\right), \quad (42)$$

$$\eta_0 = 10^{-4}, \quad \eta_{\min} = 0.05 \eta_0, \quad T = 800.$$

주기 T 를 총 업데이트 수에 묶었으므로 예산을 바꾸면 스케줄 전체가 함께 늘어난다 — 비교 실험은 같은 T 로만 한다. 같은 축 위에서 식 (28)의 엔트로피 계수는 선형으로 감쇠한다(Fig. 16(b)).

$$\lambda_H(t) = \lambda_0 \left(1 - (1 - \kappa) \frac{t}{T}\right), \quad \lambda_0 = 0.01, \quad \kappa = 0.1 \quad (43)$$

즉 0.01에서 0.001로 줄어든다. 기울기는 식 (29)대로 노름 $g_{\max} = 1.0$ 에서 자른다.




Figure 16: 학습 코드가 실제로 쓴 스케줄. (a) 식 (42)의 단일 주기 코사인 학습률. 원 표식은 200 업데이트마다의 greedy 평가 시점, 별표는 채택 가중치(600 업데이트, $\eta_t \approx 1.9 \times 10^{-5}$), 회색 파선은 $\eta_{\min}$ 이다. (b) 엔트로피 계수 $\lambda_H(t)$ 의 선형 감쇠 (0.01 $\rightarrow$ 0.001).

코사인을 고른 이유는 이 학습 구조의 두 가지 성질 때문이다. 첫째, 그룹 상대 이득 (식 (26))은 매 업데이트마다 새로 표집한 전장에서 $G = 8$ 개 후보의 순위만 쓰므로 기울기의 분산이 크고 시나리오 난이도가 그대로 실린다(Fig. 14(a)의 진동). 앞 구간의 큰 학습률은 휴리스틱 부팅 분포에서 빨리 벗어나게 하고, 뒤 구간의 작은 학습률은 이 잡음 섞인 기울기가 정책을 이리저리 끌지 못하게 한다. 둘째, 학습률과 엔트로피 계수를 같은 예산 축에서 함께 줄이면 분포가 뾰족해지는 시점과 보폭이 작아지는 시점이 맞물려, 탐색이 남아 있는 동안에는 큰 걸음을, 수렴 국면에는 작은 걸음을 딛는다. 계단식 감쇠와 달리 불연속점이 없어 정책의 표본 분포가 갑자기 바뀌지 않는 점도 순위 기반 이득에는 유리하다.

학습 경과에서 이 설계와 일치하는 관찰은 다음과 같다. 학습 중 후보 평균 포획률을 세 구간으로 나누면 앞 두 구간(업데이트 20–260, 280–520)은 평균 0.697, 0.703에 표준편차 0.060, 0.069인 데 비해, 학습률이 η_0 의 20% 아래로 내려간 마지막 구간(540–800)은 평균 0.762, 표준편차 0.048로 더 높고 더 좁다. 채택한 가중

치(greedy 평가 최고 0.805)도 이 구간의 600 업데이트 시점, $\eta_t \approx 1.9 \times 10^{-5}$ 에서 나왔다. 다만 상수 학습률과의 대조 실험은 수행하지 않았으므로, 이 관찰은 스케줄의 효과를 분리해 보인 것이 아니라 설계 의도와 모순되지 않음을 보인 것이다.

4.6 언어모델 기반 전략 계층

전략 계층의 위치는 Fig. 2에, 실제 동작 화면은 Fig. 17에 있다. 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고, 출력은 무리별 배정과 대기(HOLD)이며, 그 배정이 기동 계층으로 전달되어 각 방어정의 그물벽 위치 결정을 조건짓는다.

언어모델에는 좌표 원시 데이터 대신 *기하량*이 미리 계산된 전장 상태를 직렬화하여 전달한다. 각 적 무리의 요격점까지의 이동거리와 선회량, 모션 기준 방위, 설치된 그물에 의한 접근로 차단 여부 등이 포함된다. 언어모델이 삼각함수를 암산하게 하는 대신 판단에 필요한 양을 미리 제공하는 것이다.

4.6.1 구조적 출력에 의한 행동 규제

언어모델의 출력을 자유 문장으로 받으면 하위 계층이 파싱에 실패할 수 있고, 실패 시 그 주기의 배정이 통째로 사라진다. 본 연구는 출력을 *스키마*로 강제하여 이 실패 모드를 구조적으로 차단한다 [23]. 계획을 다음 자료형으로 선언하고, 그로부터 생성한 JSON 스키마를 모델 호출에 함께 넘긴다.

```
CommandPlan {
  rationale: str
  deployments: List[{
    cluster_id: int,
    ally_ids: List[int]
  }]
  hold_ships: List[int]
}
```

이 스키마는 디코딩 단계에서 문법으로 작용하여, 형식에 맞지 않는 토큰이 애초에 생성되지 않게 한다. 지역 실행에서는 스키마를 `format` 인자로, 상용 API에서는 `response_schema`로 전달하며, 두 경우 모두 응답을 같은 자료형으로 역직렬화하여 검증한다. 온도는 0으로 두어 같은 전장에서 같은 배정이 나오게 한다. 이는 §5.2의 시드 대응표본 설계가 성립하기 위한 전제이기도 하다.

필드 순서가 곧 사고 순서다. 스키마는 판단 근거 $\rightarrow$ 무리별 배정 $\rightarrow$ 대기 목록 순으로 고정된다. 자기회귀 생성에서 뒤 필드는 앞 필드를 조건으로 하므로, 근거를 먼저 쓰게 하면 배정이 그 근거를 조건으로 결정된다. 순서를 뒤집어 배정을 먼저 내게 하면 근거는 이미 정해진 답에 대한 사후 설명이 되므로, 최소한 설명 가능성은 잃는다. 실제로 이 필드에는 각 방어정의 요격점까지 거리와 선회량을 인용하도록 요구하여, 근거가 제공된 기하량에 닿아 있게 만들었다. **다만 이 요구의 준수 여부는 본 연구가 검증하지 못한다** — 실험에서 보존한 것은 근거의 길이뿐이고 원문은 저장하지 않았기 때문이다 (§8). 따라서 이 설계는 근거를 확인 가능하게 만들 수 있는 구조라는 주장이지, 본 실험이 그 확인을 수행했다는 주장이 아니다.




Figure 17: 실행 화면(양동 포메이션, Gemini 지휘관, 재계획 주기 25 step). 왼쪽은 위성 영상 위에 육지 마스크·그물벽·요격 회랑을 겹친 전장과 적/아군 확대 창이고, 오른쪽은 지휘관이 낸 배정과 그 근거이다. 상단 표시에서 이 시점의 전과(포획 3, 돌파 0, 아군 총돌 0)를 확인할 수 있다.

빈 배정의 의미는 프롬프트가 규정한다. `ally_ids`를 비우는 것은 “시스템이 대신 고르라”가 아니라 “이 무리에는 아무도 보내지 않는다”를 뜻한다. 앞에서 밝혔듯 코드 보완이 없으므로 빈 목록은 그대로 무방비를 낳으며, 프롬프트가 이 결과를 명시하여 지휘관이 그 대가를 알고 결정하게 한다.

조합 최적화 후처리를 두지 않는다. 언어모델이 지목한 배가 그대로 배정되며, 최소비용 매칭이나 2-opt 개선이 개입하지 않는다. 언어모델이 비워 둔 무리는 담당 없이 남고, 지목되지 않은 방어정은 대기한다. 후처리를 두면 최종 배정이 사실상 비용 함수의 산물이 되어 언어모델의 기여를 측정할 수 없기 때문이다. 이 선택은 성능이 아니라 측정 가능성을 위한 것이며, 그 대가는 §6에서 정량적으로 드러난다.

후처리를 두지 않는다는 것이 기하 보정이 없다는 뜻은 아니다. 언어모델이 정할 수 있는 것은 출력 스키마가 정확히 제한한다 — 무리별 배정 항목의 필드는 `cluster_id`와 `ally_ids` 둘뿐이고, 그 밖에 결정되는 것은 판단 근거와 대기 목록(`hold_ships`) 뿐이다. 즉 권한은 어느 배가 어느 무리를 맡는가와 이번 주기에 누가 멈추는가로 달여 있다. 그물 전개 여부도, 벽의 방위도, 교전 반경도 출력에 없다. 배정으로부터 요격 점을 만드는 기하는 전적으로 코드다.

그 기하는 두 경로에서 같은 규칙을 쓴다. 한 무리에 두 척 이상이 배정되면 §4.3의 잉여 배정과 같은 두 손잡이가 작동한다 — 모선 쪽으로 $\lambda_L = 0.18$ 씩 미는

반경 층 분리와 $\pm 40^\circ$ 씩 번갈아 트는 방위 분리다. 완전히 같지는 않아서, 언어모델 경로는 (i) 층 순서를 기본 요격점에 가까운 배부터 주고, (ii) 층을 깊게 넣다 요격 점이 모선 코앞으로 들어오는 것을 막기 위해 반경을 요격 구역 안으로 자른다. 구역을 벗어난 요격점은 기동 계층의 유효 마스크를 붕괴시켜 폴백으로 떨어지기 때문이다.

권한이 배정과 대기로 달여 있다는 점이 중요하다. 전략 계층이 기하까지 건드릴 수 있으면 §6.1에서 관측되는 차이가 배정 판단에서 온 것인지 기하 조정에서 온 것인지 분리되지 않는다. 두 경로가 같은 기하 규칙을 공유하기 때문에, 조건 간 차이는 배정 그 자체의 차이로 읽을 수 있다.

배정이 확정되면 각 방어정의 요격점이 정해지고, 그 요격점을 중심으로 기동 계층이 그물벽을 놓을 수 있는 후보 영역(유효 마스크)이 함께 결정된다. 즉 배정은 기동 계층의 선행 조건이며, 배정이 바뀌면 후보 영역 자체가 바뀐다.

4.7 온보드 배치 고려사항

제안 정책에는 배치 통계에 의존하는 정규화가 일절 없다. 정규화는 전부 그룹 정규화이고 (§4.4), 관측은 격자 크기와 설정 상수로만 나누어 정규화한다 — 이동 평균으로 갱신되는 **running statistics**가 없다는 뜻이다. 그래서 배치 크기 1의 실시간 추론이 학습과 같은 연

산을 수행한다. 통계 위밍업이 필요 없고, 학습 모드와 추론 모드의 동작이 같아지지 않는다.

또한 정책은 경유점만 지정하고 조타는 저수준 제어기가 담당하므로 선체 동역학과 분리되어 있다. 수상정의 조종 동역학은 확립된 모형이 존재하므로 [28]이 분리는 정책을 재학습하지 않고도 선체 특성이 다른 플랫폼에 이식할 여지를 남긴다. 관측과 행동은 절대 길이가 아닌 격자 상대 좌표로 표현된다. 이는 실해역 이식 시 격자 축척만 재설정하면 되는 구조로, Sim2Real 전이에 유리한 성질이다. 다만 본 논문은 시뮬레이션 검증에 한정되며, 이 성질의 실증은 §8에서 논의한다.

5 실험 설계

5.1 실험 조건

두 계층의 기여를 분리하려면 각 계층을 독립적으로 쪼개고 끝 수 있어야 한다. 따라서 배정 축과 기동 축을 각각 이분하여 2×2 조건 행렬을 구성한다(Table 5).

휴리스틱 배정과 기동은 §4.3의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직접 비교 가능하다. `heur_unet` 조건은 언어모델을 호출하지 않아 외부 API 없이 재현된다. 전략 계층에는 능력 수준이 다른 세 모델 — Qwen2.5 7B, Qwen2.5 14B(로컬), Gemini 3.5 Flash-Lite(클라우드) — 을 두어, LLM 조건은 온보드 대 클라우드라는 배치 선택지까지 포함해 총 8조건이 된다.

5.2 수집 프로토콜

모든 조건이 동일한 시드 집합(0–29)을 사용한다. 시드 k 의 전장은 조건이 달라도 동일하므로 조건 간 차이를 취하면 시나리오 난이도의 변동이 상쇄되어 독립표본 설계보다 좁은 신뢰구간을 얻는다. 총 수집량은 8조건 $\times$ 3포메이션 $\times$ 30시드 = **720 에피소드**이며, 조건·포메이션별 칸이 모두 30개로 균형을 이룸을 확인하였다 (불균형 시 공통 교집합만 집계한다). 지휘관 재계획은 배치 설정과 같이 매 결정(25 step)마다 수행한다 — 주기를 늘리면 매 결정 새로 계산되는 휴리스틱 배정과 낡은 LLM 계획을 비교하게 되어 LLM 조건에 불리한 편향이 생기기 때문이다.

5.3 통계 절차

신뢰구간. 조건별 평균의 95% 신뢰구간은 편향-가속 보정(BCa) 부트스트랩 [29, 30]으로 구한다. 포획률은 $[0, 1]$ 로 잘려 분포가 치우치므로 단순 백분위 부트스트랩은 편향된 구간을 주기 때문이다.

대응 차이. 기준선 대비 개선은 시드별 차이의 부트스트랩 분포로 평가한다. 조건 X 와 기준선 Y 의 시드

k 에서의 지표값을 x_k, y_k 라 하면

$$\begin{aligned} d_k &= x_k - y_k, & \bar{d} &= \frac{1}{n_s} \sum_{k=1}^{n_s} d_k, \\ s_d^2 &= \frac{1}{n_s - 1} \sum_{k=1}^{n_s} (d_k - \bar{d})^2, & d_z &= \frac{\bar{d}}{s_d} \end{aligned} \quad (44)$$

이며 시드 수 $n_s = 30$ 이다. $\bar{d}$ 의 BCa 신뢰구간은 $\{d_k\}$ 를 $B = 9999$ 회 재표집하여 얻으며, 구간이 0을 포함하면 평균이 높아도 기준선과 다르다고 말하지 않는다.

효과크기. 지표마다 단위가 달라 개선 폭의 절대값으로 지표 간 비교가 불가능하므로 식 (44)의 대응표본 효과크기 d_z 를 함께 보고한다(관례상 $|d_z|$ 0.2·0.5·0.8 이 작음·중간·큼).

다중비교. 한 조건에 대해 지표 10개를 동시에 검정하므로, 보정하지 않은 95% 구간과 지표 $m = 10$ 개에 대한 Bonferroni 보정 구간($\alpha' = \alpha/m = 0.005$, 즉 99.5% 구간)을 함께 보고한다(Table 9). 조건 수까지 곱하지 않은 것은 조건별 비교가 각각 독립된 질문이기 때문이다. 어느 결론이 보정을 건디는지는 §6.3에서 보고한다.

상호작용 분해. 두 계층이 서로를 돕는지는 2×2 상호작용으로 판정한다.

$$\begin{aligned} \text{Int} &= (\text{llm_unet} - \text{llm_heur}) \\ &\quad - (\text{heur_unet} - \text{heur_heur}) \end{aligned} \quad (45)$$

$\text{Int} > 0$ 이면 상승, ≈ 0 이면 가산, < 0 이면 상쇄이며, 모든 지표에 대해 보고한다.

5.4 지휘관 계층 계측

포획률은 체계 전체의 지표이므로 언어모델 계층의 기여를 가린다. 따라서 계획이 산출된 시점에 확인 가능한 양을 시뮬레이션 결과와 독립적으로 계측한다: 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지, churn, 교차 배정. 재계획 t 에서 방어정 p 가 맡은 무리를 j_p^t (미배정이면 $\emptyset$), 활성 무리 집합을 $\mathcal{C}^t$, 직전 계획에도 있던 방어정 집합을 $\mathcal{P}^t$ 라 하면 커버리지와 churn은 다음과 같다.

$$\begin{aligned} \text{Cover}^t &= \frac{|\{j_p^t : j_p^t \neq \emptyset\}|}{|\mathcal{C}^t|}, \\ \text{Churn}^t &= \frac{1}{|\mathcal{P}^t|} \sum_{p \in \mathcal{P}^t} \mathbb{I}[j_p^t \neq j_p^{t-1}] \end{aligned} \quad (46)$$

교차 배정은 방어정 위치와 배정 무리 중심을 잇는 선분 쌍 가운데 서로 교차하는 쌍의 수이다. 세 지표 모두 에피소드 안의 재계획에 걸쳐 평균한다.

폴백률이 0이 아니면 해당 LLM 조건의 일부는 휴리스틱 출력이다. 본 수집에서 폴백률은 Gemini 0.000, Qwen2.5 14B 0.001, Qwen2.5 7B 0.007로 무시할 수 있는 수준이었다.

Table 5: 2 × 2 조건 행렬. 조건 사이에 달라지는 것은 두 스위치뿐이며, 체크포인트·환경 설정·난수 시드는 모두 동일하다.

조건	배정 × 기동	무엇을 측정하는가
heur_heur	휴리스틱 × 휴리스틱	기준선(baseline)
heur_unet	휴리스틱 × U-Net	기동 계층의 순수 기여 — LLM을 쓰지 않는다
llm_heur	LLM × 휴리스틱	전략 계층의 순수 기여
llm_unet	LLM × U-Net	제안 체계(상호작용 포함)

6 결과

6.1 기동 계층: 휴리스틱 대 U-Net 점수맵 (LLM 미사용)

먼저 언어모델을 배제하고, §4.3의 기하 휴리스틱과 §4.4의 점수맵 정책만 비교한다. 두 조건 모두 배정은 휴리스틱이므로 차이는 오직 기동 방식이다 (Table 6). 3개 포메이션 통합 기준으로 포획률은 0.844 → 0.886 (+0.041, $d_z = 0.37$)로 개선되었고 95 % 신뢰구간이 0을 포함하지 않는다. **다만 이 개선은 아슬아슬하다** — 지표 10개에 대한 다중비교 보정을 걸면 구간이 $[-0.013, +0.100]$ 로 0을 포함한다 (§5.3). 이 절이 보이려는 것은 포획률의 증가가 아니라, 뒤에서 보이듯 같은 정도로 막으면서 자원과 기동을 크게 줄인다는 쪽이다.

포메이션별로 보면 기여가 고르지 않다. 파상 포메이션에서 +0.157($d_z = 0.48$)로 가장 크고, 집중 포메이션에서는 0.000, 양동 포메이션에서는 −0.033 으로 오히려 소폭 낮다(다만 후자의 신뢰구간은 0을 포함하므로 악화라고 말할 수 없다).

이 분포는 포메이션의 구조와 대응한다. 파상 공격은 이웃한 방위의 3개 단이 거리차를 두고 도달하므로, 앞단을 막은 그물벽의 위치가 뒤 단까지 막을 수 있는지를 좌우한다. 해면 전체를 평가하여 자리를 고르는 점수맵 방식이 여기서 직접적으로 값을 한다. 반면 양동 공격은 세 방위에서 동시에 도래하여 방어정 수와 무리 수가 같으므로, 결정적인 것은 어느 방어정을 어느 무리에 붙이는가라는 **배정** 판단이다. 배정이 어긋나면 기동 계층이 아무리 좋은 자리를 골라도 애초에 잘못된 무리를 막게 되므로 보정되지 않는다. 집중 포메이션은 뒤에서 보이듯 천장 구간이다.

6.2 전체 조건 비교

Table 7과 Fig. 18에 8개 조건의 포획률을 정리하였다.

Gemini 지휘관을 쓴 두 조건이 기준선 대비 유의한 개선을 보인다(각각 +0.060, +0.062). 반면 Qwen2.5 7B는 두 기동 조건 모두에서 기준선보다 **유의하게 나쁘다** (−0.192, −0.203). 이 음의 결과는 §6.5에서 다룬다.

포메이션별 분해 통합 수치는 포메이션에 따라 다르게 읽어야 한다(Table 8). 집중 포메이션은 휴리스틱만으로 포획률 0.997에 도달하므로 개선 방향으로는 어떤 방법도 변별되지 않고(기동 계층 단독 차이 +0.000, 95 % CI $[-0.010, +0.010]$), 통합값은 이 구간이 3분의 1을 차지하여 희석된다. 양동과 파상만 보면 제안 체계의 개선은

각각 +0.090, +0.103 으로 통합값 +0.062 보다 크다. 한편 이 구간은 악화 방향으로는 여전히 변별력을 가진다 — Qwen2.5 7B 배정이 −0.157 ($[-0.323, -0.057]$), 같은 모델에 점수맵을 붙여도 −0.110 ($[-0.247, -0.043]$), 14B에 점수맵을 붙인 경우가 −0.040 ($[-0.100, -0.010]$)으로, 약한 지휘관은 거의 완벽한 상황도 악화시킨다. 이는 §6.5의 능력 임계가 가장 쉬운 포메이션에서도 관측된다는 뜻이다.

6.3 포획률은 가장 둔한 지표다

§3.2에서 정의한 10개 지표 전부에 대해 제안 체계와 기준선의 대응 차이를 계산하였다(Table 9, Fig. 19).

결과는 명확하다. **포획률의 효과크기($d_z = 0.44$)는 측정한 10개 지표 중 최하위권이며, 총 선회량(−3.23)의 7분의 1 수준이다.** 개선이 가장 큰 지표는 기동 비용과 자원 효율 쪽이다.

- 총 선회량 1625 → 868 (−47 %, $d_z = -3.23$)
- 포획당 그물 0.737 → 0.409 (−45 %, $d_z = -2.09$)
- 포획 이격거리 1511 → 1734 m ($d_z = +1.81$)
- 그물 걸림 0.82 → 0.22 (−73 %, $d_z = -1.19$)

이 대조는 다중비교 보정에서 더 선명해진다. 지표 10개에 대한 Bonferroni 보정 (99.5 % 구간)을 적용하면 10개 중 8개가 그대로 유의하지만, **포획률과 돌파 수는 유의성을 잃는다**(Table 9의 단검 표시). 포획률의 보정 구간은 $[-0.003, +0.132]$ 로 0을 아슬아슬하게 포함한다. 기동 계층 단독 조건에서도 같은 두 지표가 탈락한다($[-0.013, +0.100]$).

이 결과를 감출 이유가 없다. 오히려 이 논문이 말하려는 바를 정확히 드러내기 때문이다 — **보정을 건디지 못하는 것은 “더 많이 막는다”는 주장이고, 건디는 것은 “같은 정도로 막으면서 자원과 기동과 위험을 크게 줄인다”는 주장이다.** 따라서 본 논문은 포획률 개선을 주장의 중심에 두지 않는다.

즉 제안 체계의 이득은 “더 많이 잡는다”보다 **“같은 정도로 막으면서 훨씬 적은 자원과 기동, 더 낮은 위험으로 해낸다”**에 가깝다. 이는 자원이 제한된 실운용에서 오히려 더 중요한 성질이다. 포획률의 효과크기가 작은 것은 방법의 한계가 아니라 지표의 천장 때문이며 (§6.2), 효율 지표에는 그러한 천장이 없다.

6.4 두 계층의 기여는 가산적이다

식 (45)의 상호작용을 10개 지표 전부에 대해 계산하였다 (Table 10, Fig. 20).




Figure 18: 포메이션 × 조건 포획률. 색은 전략 계층(지휘관), 빗금은 기동 계층을 나타내며, 같은 색 안에서 인접한 두 막대가 곧 그 지휘관에서의 U-Net 효과이다. 무채색 두 막대는 언어모델을 쓰지 않는 기준선이고, 그 오른쪽부터가 언어모델 지휘관이며 모델 규모 오름차순으로 놓았다 — 성능 순서가 아니다. 실제로 7B는 기준선보다 낮다(\$6.5). 오차막대는 표준편차가 아니라 시드 부트스트랩 95% 신뢰구간이다. 집중 포메이션에서 여덟 조건이 모두 상단에 몰려 있는 것이 천장 효과이며(\$6.2), 양동 포메이션에서만 지휘관 능력축이 넓게 벌어진다.




Figure 19: 제안(11m_unet@Gemini) 대 기준선(heur_heur)의 전 지표 효과크기. 마름모가 점추정이고, 굵은 선이 95% 신뢰 구간, 그 바깥의 얇은 선이 지표 10개에 대한 Bonferroni 보정 구간(99.5%)이다. 속이 찬 표식은 보정 구간까지 0을 배제한 지표이며, 속이 빈 둘(포획률·돌파 수)은 보정을 견디지 못해 n.s.로 적었다 — Table 9의 단검 표시와 같은 판정이다. 부호는 개선 방향이 항상 양수가 되도록 통일하였다(낮을수록 좋은 지표는 뒤집었다). d_z 의 구간은 평균차의 BCa 신뢰구간을 $sd(d)$ 로 나눈 것이므로, 이 그림이 0을 배제하는 것과 Table 9의 평균차 구간이 0을 배제하는 것은 같은 사건이다. 포획률의 효과크기가 10개 지표 중 최하위권이라는 점이 이 그림의 요지이다.

Table 6: 기동 계층(U-Net 점수맵 + GRPO)의 단독 기여. 두 조건 모두 배정은 휴리스틱이며 **LLM을 전혀 사용하지 않는다** — 따라서 이 결과는 외부 API에 의존하지 않고 재현 가능하다. 파상 포메이션에서 가장 크다.

포메이션	휴리스틱 기동	U-Net 기동	Δ [95 % CI]	d_z
집중	0.997	0.997	+0.000 [-0.010, +0.010]	+0.00
양동	0.787	0.753	-0.033 [-0.077, +0.000]	-0.31
파상	0.750	0.907	+0.157 [+0.043, +0.270]*	+0.48
전체	0.844	0.886	+0.041 [+0.003, +0.082]*	+0.37

* 신뢰구간이 0을 포함하지 않음. 전체 행은 3개 포메이션 통합.

Table 7: 조건별 포획률. 평균과 부트스트랩 95 % 신뢰구간, baseline 대비 대응표본 차이. 3개 포메이션 통합(각 조건 30시드).

지휘관(배정)	기동	포획률 [95 % CI]	Δ vs baseline	d_z
휴리스틱 (baseline)	휴리스틱	0.844 [0.808, 0.880]	—	—
휴리스틱	U-Net 점수맵	0.886 [0.847, 0.918]	+0.041 [+0.003, +0.082]*	+0.37
Qwen2.5 7B	휴리스틱	0.652 [0.571, 0.716]	-0.192 [-0.264, -0.129]*	-1.00
Qwen2.5 14B	휴리스틱	0.811 [0.766, 0.854]	-0.033 [-0.086, +0.017]	-0.23
Gemini 3.5 Flash-Lite	휴리스틱	0.904 [0.864, 0.937]	+0.060 [+0.024, +0.100]*	+0.56
Qwen2.5 7B	U-Net 점수맵	0.641 [0.582, 0.693]	-0.203 [-0.274, -0.138]*	-1.03
Qwen2.5 14B	U-Net 점수맵	0.754 [0.698, 0.806]	-0.090 [-0.153, -0.033]*	-0.54
Gemini 3.5 Flash-Lite	U-Net 점수맵	0.907 [0.869, 0.937]	+0.062 [+0.013, +0.113]*	+0.44

* 신뢰구간이 0을 포함하지 않음. d_z 는 대응표본 효과크기. 첫 두 열이 2×2 설계의 두 축이다 — 같은 지휘관 행 두 개를 비교하면 기동 계층의 기여가, 같은 기동 열을 비교하면 지휘관의 기여가 나온다. Qwen2.5는 로컬(단일 RTX 4070) 서빙, Gemini는 클라우드 API 다.




Figure 20: 2×2 상호작용(지휘관 = Gemini 3.5 Flash-Lite). (a) 네 셀의 포획률 평균. 두 선이 평행에 가까울수록 두 계층의 기여가 가산적이다. (b) 이 논문이 실제로 검정한 양 — 시드 대응차이 세 가지와 그 BCa 95 % 신뢰구간. 속이 빈 표식은 구간이 0을 포함한다. (a)에 오차막대를 두지 않은 것은 의도적이다 — 셀별 구간은 대응이 풀린 구간이라 시나리오 난이도의 분산을 그대로 포함해 넓고, 그것을 겹쳐 그리면 유의한 대응차이가 유의하지 않은 것처럼 읽힌다. 불확실성은 전부 (b)에 있다.

Table 8: 포메이션별 천장 효과. 집중 포메이션은 baseline이 이미 0.997이라 개선 여지가 0.003 뿐이다 — 이 포메이션 단독으로 결론을 내면 안 된다.

포메이션	baseline	남은 여유	제안	Δ
집중	0.997	0.003	0.990	-0.007
양동	0.787	0.213	0.877	+0.090*
파상	0.750	0.250	0.853	+0.103

* 신뢰구간이 0을 포함하지 않음.

10개 지표 중 9개에서 상호작용의 신뢰구간이 0을 포함한다. 즉 두 계층은 서로를 돕지도, 서로를 잠식하지도 않는다. 본 논문은 이를 상승효과로 포장하지 않고 **가산적**이라고 보고한다. 이는 약점이 아니라 설계 검증으로 읽어야 한다. 두 계층이 서로 다른 실패 모

드를 다루므로 기여가 독립적으로 누적된다는 뜻이기 때문이다.

이 판정은 다중비교 보정에도 흔들리지 않는다. Bonferroni 보정 구간(99.5%)으로 바꾸어도 0을 포함하는 지표는 그대로 9개다 — 보정은 구간을 넓히므로 “차이 없음”을 더 쉽게 만드는 방향인데, 그 방향으로 옮겨도 판정이 바뀌지 않는다는 뜻이다.

한 가지 예외는 평균 포획 시각이다. 상호작용이 -11.98 이고 95 % 신뢰구간이 $[-19.84, -5.93]$ 로 유의한 상해를 보인다. 이 예외는 보정 구간에서도 살아남는다 — 99.5 % 구간이 $[-23.31, -3.54]$ 이다. 따라서 다중비교가 만들어 낸 우연이 아니다. 이는 해석이 된다. 두 계층 모두 제압을 앞당기는 방향으로 작용하는데, 같은 포획률 두 번 앞당길 수는 없다. 공유 메커니즘에

Table 9: 전 지표 효과크기 (제안 = LLM 지휘관 + U-Net 점수맵, Gemini). $|d_z|$ 내림차순. 포획률이 가장 둔한 지표이며, 다중비교 보정에서 유의성을 잃는 유일한 방어 성과 지표다.

지표	방향	baseline	제안	Δ	d_z
총 선회량 (rad)	↓	1625	868	-757*†	-3.23
포획당 그물	↓	0.737	0.409	-0.328*†	-2.09
포획 이격거리 (m)	↑	1511	1734	+223*†	+1.81
전개 시 적 거리 (m)	↓	1499	1128	-371*†	-1.60
그물 걸림	↓	0.82	0.22	-0.60*†	-1.19
평균 포획 시각 (step)	↓	430	408	-22*†	-1.04
포획당 이동거리 (m)	↓	825	643	-182*†	-0.65
충돌률(척당)	↓	0.130	0.078	-0.052*†	-0.52
돌파 수	↓	1.56	0.93	-0.62*	-0.44
포획률	↑	0.844	0.907	+0.062*	+0.44

방향 ↑ = 높을수록 좋음, ↓ = 낮을수록 좋음. * 95 % 신뢰구간이 0 을 포함하지 않음. † 지표 10개에 대한 Bonferroni 보정(99.5 % 구간)에서도 0 을 배제함 — 즉 단검이 없는 행은 보정을 건디지 못한다.

Table 10: 2×2 상호작용 분해 (Gemini 지휘관). 10개 지표 중 9개에서 상호작용 신뢰구간이 0 을 포함한다 — 두 계층의 기여는 가산적이다.

지표	총효과	상호작용 [95 % CI]	판정
포획률	+0.062	-0.039 [-0.083, +0.012]	가산
돌파 수	-0.62	+0.39 [-0.13, +0.83]	가산
충돌률(척당)	-0.052	-0.015 [-0.070, +0.022]	가산
그물 걸림	-0.60	+0.17 [-0.08, +0.41]	가산
포획당 그물	-0.328	+0.004 [-0.045, +0.059]	가산
포획당 이동거리 (m)	-182	-55 [-125, +30]	가산
총 선회량 (rad)	-757	-56 [-165, +59]	가산
포획 이격거리 (m)	+223	+38 [-2, +81]	가산
평균 포획 시각 (step)	-22	-12 [-20, -6]	상쇄
전개 시 적 거리 (m)	-371	+26 [-44, +109]	가산

상호작용 = (LLM+U-Net − LLM+휴리스틱) − (휴리스틱+U-Net − baseline). 신뢰구간이 0 을 포함하면 두 계층이 서로를 돕지도 잡아먹지도 않는다.

대한 수확체감이다.

포메이션별로 보면 두 계층의 분업이 드러난다. 양동 포메이션에서는 기동 계층 단독 (−0.033)도 전략 계층 단독(+0.070)도 신뢰구간이 0 을 포함하여 유의하지 않는데, 둘을 결합하면 +0.090 으로 유의해진다. 각각으로는 부족한 두 기여가 합쳐져 임계를 넘는 것이며, 2 계층 설계가 값을 하는 지점이 여기다. 이는 이 포메이션의 구조와 부합한다 — 세 무리가 동시에 도래하고 방어정도 세 척이라 여유가 전혀 없으므로, 배정과 기동 어느 한쪽만 좋아서는 부족하고 둘 다 맞아야 막힌다. 반대로 파상 포메이션에서는 단이 시간차를 두고 오므로 자원 재배분의 여지가 있고, 기동 계층 단독(+0.157)이 이미 유의하며 결합이 그보다 낮지 않다.

6.5 지휘관 능력 임계

기동 계층을 휴리스틱으로 고정하여 지휘관 축만 분리하면, 모델 능력에 따른 단조 증가가 나타난다(Fig. 21).

3개 포메이션 통합 기준으로 Qwen2.5 7B는 0.652, Qwen2.5 14B는 0.811, Gemini는 0.904이며, 휴리스틱 기준선은 0.844이다. 즉 휴리스틱 선을 14B와 Gemini 사이에서 교차한다.

이 결과가 함의하는 바는 “LLM 지휘관을 쓰면 좋다”가 아니라 “일정 능력 수준에 못 미치는 지휘관은 코드 휴리스틱보다 못하다”이다. Qwen2.5 7B의 −0.192($d_z = -1.00$)는 유의한 악화이며, 이 음의 결과가 임계 주장을 신뢰할 수 있게 만든다.

6.6 무엇이 지휘관 성능을 만드는가

능력 순위 자체는 모델이 바뀌면 낡는다. 더 오래 남는 질문은 무엇이 성능을 만드는가이다. 계획 단위 계층 결과를 Table 11와 Fig. 22에 정리하였다.

결정적인 관측은 다음과 같다. Qwen2.5 7B는 커버리지 가장 높은데(0.934) 포획률은 가장 낮다(0.652). 즉 막아야 할 무리를 배정하지 않아서 지는 것이 아니다. 오히려 7B는 거의 모든 무리에 배를 지목한다.

성능과 단조로 대응하는 것은 churn과 경로 교차이다. churn은 0.324 → 0.167 → 0.098, 경로 교차는 0.152 → 0.111 → 0.033 으로 능력축을 따라 감소하며, 같은 순서로 포획률은 0.652 → 0.811 → 0.904 로 증가한다(모두 기동 계층을 휴리스틱으로 고정한 조건). churn 0.324는 재계획마다 방어정의 약 3분의 1이 담당을 바꾼다는 뜻이며, 이는 반쯤 전개한 그물벽을 버리고 떠난다는 것을 의미한다. 경로 교차는 두 방어정이 서로의 진로를 가로지르는 배정으로, 충돌 위험으로 직결된다.

이 관찰은 순위표가 아니라 설계 원리를 제시한다. 주기적으로 재계획하는 구조에서는 계획의 최적성보다 계획의 안정성이 중요하다. 매 재계획마다 국소적으로 더 나은 배정을 찾아 바꾸는 것은, 그 전환 비용(버려지는 그물, 교차하는 경로)을 고려하면 손해일 수 있다.




Figure 21: 지휘관 능력 사다리(기동 계층은 휴리스틱으로 고정). 점선과 오른쪽 이름표는 같은 포메이션의 휴리스틱 배정 기준선이고, 오차막대는 시드 부트스트랩 95% 신뢰구간이다. **관건은 성능이 오르는지가 아니라 어디에서 기준선을 교차하는 가이다** — 양동 포메이션에서 7B와 14B는 기준선 아래에 있고 Gemini 에서 처음 위로 올라선다. 집중 포메이션은 기준선이 0.997로 천장이지만 세 모델이 거기 붙어 있는 것은 아니다 — Gemini만 기준선에 닿고, 7B는 0.840으로 기준선보다 유의하게 낮다. 천장은 개선 여지를 없앨 뿐 악화 여지를 없애지 않는다(§6.2).

Table 11: 지휘관 계획 품질과 성능. 계획 품질은 시뮬레이션 결과와 독립적으로, 계획이 산출된 시점에 측정한다. **7B는 커버리지가 가장 높는데 포획률은 가장 낮다** — 실패 원인은 미배정이 아니다.

지휘관	지연 (s)	커버리지 ↑	churn ↓	교차 ↓	폴백 ↓	포획률 ↑
Qwen2.5 7B (로컬)	2.75	0.934	0.324	0.152	0.007	0.652
Qwen2.5 14B (로컬)	16.59	0.877	0.167	0.111	0.001	0.811
Gemini 3.5 Flash-Lite (클라우드)	1.56	0.881	0.098	0.033	0.000	0.904

커버리지 = 배정된 활성 클러스터 비율. churn = 재계획 간 담당이 바뀐 배의 비율. 교차 = 두 방어정의 요격 경로가 교차한 비율. 포획률은 기동 계층을 휴리스틱으로 고정한 조건(LLM 지휘관 + 휴리스틱 기동)의 값이다.




Figure 22: 계획 품질(가로축)과 성능(세로축). 점 하나가 지휘관 모델 하나이고 오차막대는 양방향 부트스트랩 95% 신뢰구간이다. **세 패널의 대조가 핵심이다** — (a) 커버리지는 성능과 같이 움직이지 않는다(7B가 커버리지 최고, 성능 최저). (b) churn과 (c) 경로 교차는 성능과 단조로 반대 방향이다. 회귀선이나 상관계수는 없지 않았다. 모델이 3종이라 $n = 3$ 이며, 여기에 상관을 적으면 없는 통계적 근거를 주장하는 셈이 된다.

6.7 정성적 예시

Fig. 17은 제안 체계가 실제로 동작하는 한 장면이다. 지휘관이 세 무리에 세 방어정을 각각 배정하고(패널 우측의 배정과 근거), 각 방어정이 배정된 회랑에 그물 벽을 친 결과 이 시점까지 적 3척이 포획되고 돌파와 아군 충돌은 없다. 재계획 주기는 §5의 평가 설정과 같은 25 step이다.

6.8 배치 관점: 지연

응답 지연은 모델 규모에 단조가 아니다(Table 11). 로컬 14B가 16.59초인 데 비해 클라우드 모델은 1.56초로, **로컬이 10.6배 느리다**. 한 결정 주기가 25초 ($25 \text{ step} \times \Delta t = 1 \text{ s}$)이므로 14B의 평균 지연은 주기의 **약 3분의 2**를 소모한다.

평균만 보면 주기 안에 들어오지만, 결정적인 것은 분포의 꼬리다 (Table 12). 14B 호출 5,366건 가운데 **4.2%가 25초 주기를 초과**하였고, 99 백분위는 27.8초, 최댓값은 296.4초였다. 동기 구조라면 이 4.2%마다 제어 루프가 실제로 정지한다. 반면 클라우드 모델은 최댓값이 2.75초로 주기의 11%에 그쳐 동기 호출로도 여유가 있다.

단 이 수치의 측정 구성에는 교란 요인이 있다(§8 참조). 즉 §4.1의 비동기 설계는 클라우드 배치에서는 선택이지만 **로컬 배치에서는 지연 꼬리에 대한 안전장치**로서 실질적 의미를 갖는다.

Table 12: 지휘관 응답 지연 분포. 결정 주기 25초와 비교한다. 로컬 14B만 주기를 초과하는 꼬리를 갖는다.

지휘관	n	평균	p_{99}	최대	> 25초
Qwen2.5 7B (로컬)	4,299	2.75	7.08	10.06	0.0 %
Qwen2.5 14B (로컬)	5,366	16.59	27.81	296.41	4.2 %
Gemini (클라우드)	3,882	1.56	2.30	2.75	0.0 %

단위는 초. 로컬 모델은 Ollama 서빙(Qwen2.5 14B는 Q4_K_M 양자화, 문맥 16,384 토큰), NVIDIA RTX 4070(12GB) 단일 GPU에서 측정하였다. ★ **해석 시 주의:** 이 GPU에는 시뮬레이터와 정책 추론이 동시에 올라가 있었다. 14B는 Q4 가중치만 약 9GB이므로 KV 캐시를 더하면 12GB를 압박하며, 최댓값 296초는 가중치 오프로드/재적재를 시사한다. 실제로 본 저장소의 설치 문서는 같은 GPU에서 2 ~ 4초를 예상하고 있어 실측과 4 ~ 8배 차이가 난다. 따라서 **14B의 꼬리가 로컬 중형 모델 서빙의 본질적 성질인지, 이 구성에서 GPU를 공유한 결과인지는 본 실험으로 구분되지 않는다.** 여기서 읽어야 할 것은 개별 수치가 아니라 **자원이 제한된 온보드 환경에서는 로컬 중형 모델의 지연이 결정 주기를 넘길 수 있다**는 정성적 사실이며, 이는 전용 가속기를 갖추면 완화될 수 있다.

7 고찰

7.1 계획 안정성이라는 설계 원리

§6.6의 관찰 — 커버리지는 성능을 예측하지 못하고 churn과 경로 교차가 예측한다 — 은 본 문제에 국한되지 않는 함의를 갖는다.

주기적으로 재계획하는 계층 구조에서는 상위 계층의 결정 변경이 하위 계층에 **전환 비용**을 발생시킨다. 본 문제에서 그 비용은 구체적이다. 방어정이 그물벽을 절반쯤 전개한 상태에서 담당이 바뀌면, 그때까지 소모한 이동과 그물이 회수되지 않는다. 상위 계층이 매 재계획마다 순간 최적을 추구하면 이 비용이 누적되어, 국소적으로 더 나은 배정이 전역적으로 손해가 된다.

이는 계획 주체를 언어모델로 바꾼다고 자동으로 해결되지 않는다. 오히려 언어모델은 매 호출이 독립적이므로 **일관성이 구조적으로 보장되지 않는다**. 본 연구에서 직전 배정을 상태에 포함시키고 담당 무리를 방위로 식별하게 한 것은 이 때문이다. 무리 식별자는 매 결정마다 방위 정렬 순서로 다시 매겨지므로, 식별자만 보면 같은 무리인데도 담당이 사라진 것처럼 보여 불필요한 전환이 발생한다.

따라서 언어모델을 계획 계층에 도입할 때의 설계 지침은 다음과 같이 정리된다. 계획 품질을 **커버리지**나 국소 **최적성**으로 평가하지 말고 **시간에 걸친 일관성**으로 평가해야 하며, 프롬프트와 상태 표현이 그 일관성을 지원해야 한다.

7.2 조합 최적화를 제거한 선택의 대가

§4.6에서 배정 후처리를 제거한 것은 측정 가능성을 위한 선택이었다. 그 대가가 §6.5의 음의 결과로 나타난다. 후처리가 있었다면 Qwen2.5 7B의 배정 오류는 상당 부분 코드에 의해 교정되어 -0.192 라는 악화가 관측되지 않았을 것이다.

그러나 그 경우 얻어지는 것은 “LLM 지휘관이 잘한다”가 아니라 “후처리가 잘한다”이다. 본 연구의 예비 측정에서 후처리를 둔 구성은 배정안의 64.5%를 변경하였고 14개 상황 중 57%에서 언어모델 출력과 무관하게 동일한 최종 배정에 수렴하였다. 2-opt 개선이 사실상 완전탐색에 가까워 초기값이 무엇이든 같은 국소 최적으로 수렴하기 때문이다.

이 점은 언어모델 기반 계획 연구 전반에 대한 방법론적 지적이기도 하다. 언어모델의 출력을 최적화나

규칙으로 보정한 뒤 종단 성능만 보고하면, 보고된 성능이 언어모델에서 온 것인지 보정기에서 온 것인지 원리적으로 구분되지 않는다. 기여를 주장하려면 보정을 제거한 조건이 함께 보고되어야 한다.

7.3 로컬 대 클라우드 배치

§6.8의 지연 측정은 배치 선택에 직접적인 함의를 갖는다. 로컬 14B는 클라우드 대비 10.6배 느리면서 성능도 낮았다(0.811 대 0.904). 해상 방어에서 오프라인 운용이 요구조건이라면, 현시점에서 온보드 언어모델 지휘관은 다음 두 조건을 동시에 만족해야 한다.

첫째, §6.5의 능력 임계를 넘어야 한다. 본 실험에서 14B는 넘지 못했다. 둘째, 지연이 결정 주기 안에 **여유**를 남기고 들어와야 한다. 14B의 평균 16.59초는 25초 주기 안에 들어오지만, 실측에서 호출의 4.2%가 주기를 초과했고 최댓값은 296초였다(Table 12). 동기 구조라면 그 4.2%마다 제어 루프가 정지한다. 비동기 설계는 이 꼬리 위험을 제거한다는 점에서 로컬 배치의 전제 조건에 가깝다.

이는 평균 지연만 보고 배치를 판단하면 안 된다는 실무적 함의를 갖는다. 다만 이 지연은 시뮬레이터와 GPU를 공유한 구성에서 측정한 값이므로, 절대값은 §8의 교란 요인과 함께 읽어야 한다. 평균으로는 주기의 3분의 2에 불과해 여유가 있어 보이지만, 분포의 최댓값은 주기의 12배에 달한다.

다만 이 결론은 시점 의존적이다. 동일 파라미터 규모의 모델 품질은 계속 향상되고 있으므로, 임계를 넘는 로컬 모델의 크기는 낮아질 것으로 예상된다. 본 연구가 제시하는 것은 특정 모델의 순위가 아니라 **임계가 존재하며 그것을 측정하는 방법**이다.

7.4 점수맵 표현의 이득

§6.3에서 가장 큰 개선이 나타난 지표가 총 선회량($d_z = -3.23$)이라는 점은 점수맵 표현의 성질과 직접 연결된다. 경유점이 격자 위에 고정되므로 연속 회귀에서 발생하는 미세 진동이 구조적으로 배제되고, 그 결과 궤적이 부드러워진다. 선회 감소는 단순한 심미적 개선이 아니라 실제 선박에서 연료·시간·기동 여유로 환산되는 양이다.

포획당 그물 소모의 감소(-45%) 역시 표현과 연관된다. 유효 마스크가 배정 회량과 사거리 제약을 행동 분포에 직접 부과하므로, 애초에 무의미한 위치에 그물

벽을 놓는 행동이 표현되지 않는다. 손실 향으로 제약을 유도하는 방식에서는 이런 행동이 낮은 확률로나마 남는다.

8 한계와 향후 연구

8.1 시뮬레이션 한정

본 연구의 모든 결과는 시뮬레이션에서 얻은 것이며 실해역 검증을 포함하지 않는다. §4.7에서 밝힌 성질들 — 경유점과 동역학의 분리, 격자 상대 좌표 사용, 배치 통계 정규화의 부재 — 은 실해역 이식에 유리한 조건이지만, 그 자체가 전이 성공의 증거는 아니다. 특히 다음 요소가 시뮬레이션에서 단순화되어 있다.




Figure 23: 실제 그물 전개가 갖는 형상(참고). 두 척이 그물을 예인하면 벽이 아니라 곡선으로 펼쳐진 면적이 만들어지고, 그 면적이 위협 방향과 얼마나 겹치는지가 차단 성능을 좌우한다. 본 연구의 모형은 이를 단순화하여, 방어진 한 척이 두 좌표를 잇는 직선 그물벽을 치고 그 선분에 적선이 닿으면 포획되는 것으로 처리한다. 전개 곡률, 예인 편대, 면적의 시간 변화는 반영하지 않는다. 그림의 치수 또한 개념 전달을 위한 것으로 본 연구의 설정(최대 450 m)과 다르다.

- **그물의 유체 거동과 전개 형상.** 본 모형에서 그물벽은 선분으로 표현되며 표류를 거리 감쇠로 근사한다. 실제 전개는 곡선 형상의 면적을 이루며 (Fig. 23), 침강·조류에 의한 변형도 발생한다. 이 차이는 특히 유효 차단 폭을 과소 또는 과대 평가할 수 있다.
- **추진기 얽힘 판정.** 적선이 그물에 접촉하면 무력화되는 것으로 처리하나, 실제 얽힘 확률은 접근 속도와 각도에 의존한다.
- **관측 완전성.** 적선의 위치와 진행 방향이 오차 없이 주어진다고 가정한다. 실제 해상 감시에서는 탐지 누락, 위치 오차, 식별 지연이 발생한다.

특히 관측 불확실성은 점수맵 정책보다 지휘관 계층에 더 큰 영향을 줄 것으로 예상된다. 배정 판단은 무리 구조에 의존하는데, 무리 구성이 관측 오차로 흔들리면 §6.6에서 문제로 지적한 churn이 직접 증가하기 때문이다. 관측 불확실성 하에서의 계획 안정성은 향후 연구 과제이다.

8.2 지연 측정의 교란 요인

§6.8의 지연은 단일 GPU(RTX 4070, 12 GB)에서 시뮬레이터·정책 추론과 언어모델 서빙을 함께 올린 구성에서 측정하였다. Qwen2.5 14B는 Q4 양자화 가중치만 약 9GB를 차지하므로 이 구성에서는 메모리 압박이 발생하며, 최댓값 296초는 가중치 오프로드를 시사한다. 따라서 14B에서 관측된 4.2%의 주기 초과가 로컬 중형 모델 서빙의 본질적 성질인지, 이 자원 구성의 결과인지 본 실험은 구분하지 못한다. 전용 가속기를 분리하거나 더 큰 메모리를 갖춘 환경에서 같은 측정을 반복하는 것이 필요하다.

다만 이 한계가 §4.1의 설계 논거를 무효화하지는 않는다. 온보드 배치에서 자원을 공유해야 하는 상황 자체가 현실적 제약이며, 비동기 구조는 그런 제약 아래에서 지연 꼬리가 제어 루프를 막는 것을 방지한다.

8.3 폐쇄형 모델에 대한 의존과 재현성

가장 좋은 성능을 보인 지휘관은 상용 API로 제공되는 폐쇄형 모델이다. 이런 모델은 버전이 예고 없이 갱신되거나 서비스가 종료될 수 있어, 그 수치의 재현이 장기적으로 보장되지 않는다.

본 연구는 이 위험을 구조적으로 완화하였다. 논문의 첫 번째 기여인 기동 계층의 성능 (§6.1, `heur_unet` 조건)은 언어모델을 전혀 사용하지 않으므로 외부 API와 무관하게 재현 가능하다. 폐쇄형 모델은 지휘관 능력측의 상단 참조점으로서만 기능한다. 또한 모든 계획 호출의 계층값(지연·폴백·커버리지·churn·교차·근거 길이)을 보존하였다. 다만 근거 원문은 저장하지 않아 사후 재검토가 제한된다.

그럼에도 §6.5의 임계 위치는 시점 의존적인 수치이며, 절대적 기준으로 인용되어서는 안 된다.

8.4 비교하지 않은 대안

본 논문의 기동 계층 비교는 같은 행동공간 위에서 이루어진다 — 두 방법이 같은 격자, 같은 유효 마스크, 같은 거리 제약을 통과한다 (§4.3). 이 통제가 §6.1의 비교를 성립시키는 조건이며, 그래서 기준 방법으로 기하 휴리스틱을 골랐다.

표준 다중 에이전트 강화학습(MADDPG, QMIX, MAPPO)과는 비교하지 않았다. 이유는 성능에 대한 자신감이 아니라 통제 문제다. 이 계열을 관례대로 쓰면 행동이 연속 좌표나 에이전트별 이산 행동으로 표현되므로, 관측되는 차이에 표현(연속 회귀 대 픽셀 지목)과 알고리즘(가치망 유무, 크레딧 배분 방식)이 뒤섞인다. 그러면 §6.1가 답하려는 질문 — 결정 규칙을

바꾸면 무엇이 달라지는가 — 에 답할 수 없다. 공정한 비교는 그 알고리즘들을 같은 픽셀 지목 행동공간으로 옮겨 학습시키는 작업이며, 이는 별도의 연구 분량이다. 본 논문의 결과는 **제안 표현이 최선임을 주장하지 않는다**.

구성요소 절제 실험도 체계적으로 수행하지 않았다. 개별 설계 선택에는 측정 근거를 붙였으나 — 도달성 상한은 상한이 없을 때 선택 간격 중앙값이 504m로 그물 길이 450m를 넘고 초과율이 66.7%였다는 실측에서, 잉여 배정의 층 분리는 집중 포메이션에서 배정의 과반이 그 경로로 결정된다는 관찰에서, 퍼텐셜 성형은 포획이 평가 창의 46.8%에서만 발생한다는 계측에서 나왔다 — 이는 각 요소가 **왜 필요한가**에 대한 근거이지 **얼마나 기여하는가**에 대한 측정이 아니다. FiLM 조건화, 좌표 채널, 자기회귀 두 번째 선택의 기여를 분리하려면 각각을 **뺀** 재학습이 필요하며, 본 논문은 이를 수행하지 않았다.

8.5 규모와 일반화

본 실험은 적 10척 대 방어정 3척의 고정된 규모에서 수행되었다. 점수맵 표현은 원리적으로 적선 수에 불변이고 파라미터 공유로 방어정 수에도 불변이지만, 그 불변성이 성능 유지로 이어지는지는 별도 검증이 필요하다. 특히 방어정 수가 늘면 배정 조합이 급격히 증가하여 지휘관 계층의 부담이 커지며, 이때 능력 임계가 어떻게 이동하는지는 측정되지 않았다.

또한 세 가지 공격 포메이션은 사전에 정의된 규칙 기반 행동이며, 방어 체계에 적응하는 지능적 적을 포함하지 않는다. 적이 그물벽 배치 패턴을 학습하여 회피하는 상황에서의 성능은 본 연구의 범위 밖이다.

8.6 천장 지표

§6.2에서 보였듯 집중 포메이션의 포획률은 기준선에서 이미 0.997이다. 이 구간을 포함한 통합 수치는 개선을 과소평가한다. 향후 평가에서는 난이도를 조절하여 천장을 피하거나(예: 적 수 증가, 방어정 수 감소), 천장 구간을 통합에서 분리 보고하는 것이 바람직하다.

9 결론

본 연구는 자폭 무인수상정 군집에 대한 대응으로 저비용 그물을 이용한 물리적 포획을 채택하고, 이를 두 계층으로 구성한 방어 체계를 제안하였다. 두 계층은 같은 주기로 갱신되지만 판단에 걸리는 시간이 크게 달라, 느린 전략 계층의 호출만 비동기로 분리하였다. 나아가 두 계층의 기여를 720 에피소드의 시드 대응표본으로 분리 측정하였다.

기동 계층에서는 전장을 15채널 격자 지도로 래스터화하고, FiLM 조건화를 갖춘 U-Net이 낸 점수맵 위에서 픽셀을 지목하게 하여 행동공간을 규제하였다. 연속 좌표 회귀와 달리 경유점이 격자에 고정되므로 미세 진동이 구조적으로 배제되고, 유효 마스크를 통해 안전·

임무 제약을 행동 분포에 직접 부과할 수 있다. 학습은 가치망 없이 후보 행동을 실제로 진행시켜 비교하는 그룹 상대 최적화로 수행하되, 후보 하나를 기하 휴리스틱으로 고정하여 휴리스틱을 넘어서는 결합 행동만 양의 이득을 받게 하였다. 이 계층은 언어모델을 전혀 쓰지 않고 포획률을 0.844 → 0.886 으로 개선하였으며, 특히 파상 공격에서 +0.157 로 컸다.

전략 계층에서는 언어모델 지휘관이 기하량이 미리 계산된 전장 상태로부터 배정을 확정하되, 조합 최적화에 의한 사후 보정을 두지 않았다. 이 설계는 성능이 아니라 측정 가능성을 위한 선택이며, 그 결과 언어모델 계층의 기여가 그대로 드러났다. 상용 클라우드 모델은 +0.060 의 유의한 개선을 보였으나, 소형 로컬 모델은 -0.192 로 코드 휴리스틱보다 유의하게 나뉘었다.

측정에서 세 가지 결과가 얻어졌다. 첫째, 두 계층의 기여는 **가산적**이다 — 10개 지표 중 9개에서 상호작용의 신뢰구간이 0을 포함하였다. 본 논문은 이를 상승효과로 포장하지 않았다. 둘째, **포획률은 측정된 지표 중 가장 둔하다**. 효과크기 기준으로 총 선회량(-3.23)과 포획당 그물 소모(-2.09)의 개선이 포획률(+0.44)보다 훨씬 크다. 다중비교 보정을 걸면 이 대조가 판정으로 바뀐다 — 10개 지표 중 8개가 보정을 건디는데 포획률과 돌파 수만 유의성을 잃는다. 즉 제안 체계의 실질적 이득은 “더 많이 막는다”보다 “같은 정도로 막으면서 훨씬 적은 자원과 위험으로 해낸다”에 있다. 셋째, **언어모델 지휘관에는 능력 임계가 존재하며**, 그 성능을 설명하는 것은 배정 커버리지가 아니라 재계획 간 계획 안정성이다. 가장 낮은 성능을 보인 모델이 오히려 커버리지는 가장 높았다는 관측은, 주기적 재계획 구조에서 계획의 최적정보보다 일관성이 중요하다는 설계 원리를 시사한다.

본 연구의 검증은 시뮬레이션에 한정되며, 실험역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.

재현성

표 11개 가운데 7개 — 설정 표(Table 1)와 결과 표 6 중 — 는 tools/make_paper_tables.py 가 평가 하네스의 원자료 CSV에서 굽는다. 표 안의 숫자를 손으로 고칠 수 없다는 뜻이며, 평가를 다시 돌리면 표가 따라 바뀐다. 나머지 4개 중 Table 3, 2, 5는 기호·지표·조건 정의 표이고, 수치를 담은 수동 표는 지연 분포(Table 12) 하나뿐이며 같은 원자료에서 계산해 옮겨 적었다. 도판도 같은 원칙으로 갈린다 — 결과 도판(Fig. 18--22)은 같은 CSV에서 생성되고, 나머지는 구조도와 개념 삽화다. 본문 문장의 수치 또한 원자료에서 계산한 것이다. 평가 실행과 표·도판 생성은 다음으로 재현된다.

```
# 조건행렬 전체 수집 (30 시드)
python run_eval.py --seeds 30 \
  --backends ollama,gemini

# 표 생성 (원자료 CSV → tables/*.tex)
python tools/make_paper_tables.py

# 논문 결과 도판 (Fig. 18--22)
```

```
python -m boatattack_sim.eval.paper_figs \
    --csv results/eval_merged
# 전면부·기호 규약 검사
python tools/check_paper_meta.py
```

정책 체크포인트와 환경 설정, 그리고 계획 호출의 계측값(지연·폴백·커버리지·churn·교차·근거 길이)을 보존하였다. 근거 원문은 저장하지 않았다.

CRedit authorship contribution statement

[투고 전 저자 확인 필요] 아래는 CRedit 분류에 따른 초안이며, 각 저자의 실제 기여로 교체하여야 한다.

윤영준: 개념 설계, 방법론, 소프트웨어, 검증, 형식 분석, 조사, 자료 큐레이션, 초고 작성. **방현태:** 소프트웨어, 검증, 시각화. **전유라:** 방법론, 조사, 검토 및 편집. **김덕환:** 검토 및 편집, 감독. **윤원근:** 개념 설계, 감독, 연구 관리, 자원 획득.

Declaration of competing interest

[투고 전 저자 확인 필요] 저자들은 본 논문에 보고된 연구에 영향을 미칠 수 있는 경쟁적 재정적 이해관계나 개인적 관계가 없음을 선언한다.

Declaration of generative AI and AI-assisted technologies in the writing process

원고 작성 과정에서 저자들은 문헌 정리, 초고 문장 다듬기, $\text{\LaTeX}$ 조판 및 도판 생성 스크립트 작성에 생성형 인공지능 보조 도구를 사용하였다. 모든 실험 설계, 데이터 수집, 수치 산출과 해석은 저자들이 수행하였으며, 저자들은 원고 전체를 검토하고 그 내용에 대해 전적인 책임을 진다.

Data availability

본 연구의 결과를 재현하는 데 필요한 자료는 다음과 같이 구성된다.

- **원 자료:** 720 에피소드의 에피소드별 지표(episodes.csv) 및 계획 호출 계측값(llm_metrics.csv). 본문의 모든 표와 그림은 이 두 파일에서 기계적으로 생성되며(tools/make_paper_tables.py, boatattack_sim/eval/paper_figs.py), 손으로 옮겨 적은 수치는 없다.
- **정책 체크포인트:** 기동 계층의 가중치와 그 학습 설정(u-net_map.pt). 설정은 체크포인트 안에 함께 저장되어 있어 별도 설정 파일 없이 복원된다.

- **시뮬레이터:** 환경, 관측 래스터화, 평가 하네스 전체.

[투고 전 공개 URL 기입 필요] 위 자료는 논문 게재 시 공개 저장소를 통해 배포한다.

보존하지 않은 것. 언어모델이 생성한 판단 근거(rationale)의 원문은 저장하지 않았고, 길이만 계속하였다. 따라서 근거 문장 자체에 대한 사후 분석은 본 자료로 재현할 수 없다 (§8). 또한 상용 API로 제공되는 폐쇄형 지휘관 모델은 버전이 갱신되거나 서비스가 종료될 수 있어, 그 조건의 수치가 시점에 따라 달라질 수 있다. 언어모델을 쓰지 않는 조건(heur_heur, heur_unet)은 이 위험 없이 재현 가능하다.

References

- [1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., 2007. Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem. *Operations Research*, 55(6), pp.1136–1146.
- [2] Wang, J., Liu, Y. and Song, H., 2021. Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends. *IEEE Aerospace and Electronic Systems Magazine*, 36(3), pp.4–29.
- [3] Sutea, V., 2026. *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*. Atlantic Council UkraineAlert, 24 February 2026.
- [4] Rumbaugh, W., 2024. *Cost and Value in Air and Missile Defense Intercepts*. Washington, DC: Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024.
- [5] Kuhn, H.W., 1955. The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly*, 2(1–2), pp.83–97.
- [6] Liu, Z., Zhang, Y., Yu, X. and Yuan, C., 2016. Unmanned surface vehicles: An overview of developments and challenges. *Annual Reviews in Control*, 41, pp.71–93.
- [7] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., 2025. Multi-USV cooperative target encirclement through learning-based distributed transferable policy and experimental validation. *Ocean Engineering*, 318, 120124.
- [8] Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P. and Mordatch, I., 2017. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [9] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., 2018. QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning. *International Conference on Machine Learning (ICML)*, pp.4295–4304.
- [10] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., 2018. Counterfactual Multi-Agent Policy Gradients. *AAAI Conference on Artificial Intelligence*, pp.2974–2982.
- [11] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., 2022. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. *Advances in Neural Information Processing Systems 35 (NeurIPS)*.
- [12] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. and Klimov, O., 2017. Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*.
- [13] Haarnoja, T., Zhou, A., Abbeel, P. and Levine, S., 2018. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. *International Conference on Machine Learning (ICML)*, pp.1861–1870.
- [14] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. and Guo, D., 2024. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. *arXiv preprint arXiv:2402.03300*.

- [15] Long, J., Shelhamer, E. and Darrell, T., 2015. Fully Convolutional Networks for Semantic Segmentation. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp.3431–3440.
- [16] Ronneberger, O., Fischer, P. and Brox, T., 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp.234–241.
- [17] Liu, R., Lehman, J., Molino, P., Petroski Such, F., Frank, E., Sergeev, A. and Yosinski, J., 2018. An Intriguing Failing of Convolutional Neural Networks and the CoordConv Solution. *Advances in Neural Information Processing Systems 31 (NeurIPS)*.
- [18] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., 2018. FiLM: Visual Reasoning with a General Conditioning Layer. *AAAI Conference on Artificial Intelligence*, pp.3942–3951.
- [19] Vinyals, O., Fortunato, M. and Jaitly, N., 2015. Pointer Networks. *Advances in Neural Information Processing Systems 28 (NeurIPS)*.
- [20] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł. and Polosukhin, I., 2017. Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [21] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., 2022. Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents. *International Conference on Machine Learning (ICML)*, pp.9118–9147.
- [22] Ahn, M., Brohan, A., Brown, N., et al., 2022. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances. *Conference on Robot Learning (CoRL)*.
- [23] OpenAI, 2026. *Function calling*. [Online] Available at: <https://developers.openai.com/api/docs/guides/function-calling> [Accessed 9 August 2026].
- [24] Wu, Y. and He, K., 2018. Group Normalization. *European Conference on Computer Vision (ECCV)*.
- [25] Silver, D., Huang, A., Maddison, C.J., et al., 2016. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), pp.484–489.
- [26] Ng, A.Y., Harada, D. and Russell, S., 1999. Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *International Conference on Machine Learning (ICML)*, pp.278–287.
- [27] Loshchilov, I. and Hutter, F., 2017. SGDR: Stochastic Gradient Descent with Warm Restarts. *International Conference on Learning Representations (ICLR)*.
- [28] Fossen, T.I., 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chichester: John Wiley & Sons.
- [29] Efron, B. and Tibshirani, R.J., 1993. *An Introduction to the Bootstrap*. New York: Chapman & Hall.
- [30] DiCiccio, T.J. and Efron, B., 1996. Bootstrap Confidence Intervals. *Statistical Science*, 11(3), pp.189–228.
- [31] Sutton, R.S. and Barto, A.G., 2018. *Reinforcement Learning: An Introduction*. 2nd ed. Cambridge, MA: MIT Press.

English Abstract

LLM-Based Command Architecture and U-Net Score-Map Multi-Agent Cooperative Reinforcement Learning for Defense Against Suicide USV Swarms

Suicide unmanned surface vehicle (USV) swarms resist conventional counters: electronic warfare cannot reach wire-guided targets, and interception spends a missile costlier than its target. We adopt physical capture: defense

boats slower than the attackers pre-block the mothership approach corridor with net walls. Two layers update on the *same* decision period but differ sharply in *response latency*, so only the slow layer is decoupled asynchronously. The maneuver layer rasterizes the battlefield into a mothership-centered 15 channel grid; a FiLM-conditioned U-Net emits a score map; each boat points at two high-scoring pixels in its valid region and lays a net wall between them. Pixel pointing keeps the action space grid-regularized and the input invariant to swarm size. Training extends critic-free group relative policy optimization to the multi-agent case, anchoring one candidate to the geometric heuristic so that only joint actions that beat the heuristic receive positive advantage. In the strategy layer a large language model (LLM) commander assigns boats to enemy clusters from pre-computed geometry, with no combinatorial post-optimization.

We collected 720 seed-paired episodes: 8 conditions $\times$ 3 formations $\times$ 30 seeds. The maneuver layer alone raised capture rate from 0.844 to 0.886 (+0.157 under wave), while the strategy layer split by model — a cloud model gained +0.060, whereas Qwen2.5 7B was significantly *worse* than the heuristic at -0.192 . In a 2×2 decomposition over 10 metrics, 9 interaction intervals contained 0: the layers are *additive*, not synergistic. Under Bonferroni correction capture rate and breaches lose significance; the other 8 metrics hold. The capture-rate effect size ($d_z = 0.44$) ranked lowest of the 10, far below total turning (-3.23) and nets per capture (-2.09). Commander skill tracked plan stability across replans, not assignment coverage.

Keywords : unmanned surface vehicle; swarm defense; multi-agent reinforcement learning; task assignment; large language model; semantic segmentation; group relative policy optimization

Highlights

- Two judgment layers share one 25 s period; only the slow one is decoupled
- Pointing at score-map pixels keeps the action space invariant to swarm size
- Critic-free, heuristic-anchored group relative optimization for multi-boat coordination
- Across 720 paired episodes the two layers are additive in 9 of 10 metrics
- Commander skill is explained by plan stability, not assignment coverage