

군집 자폭 수상 드론 방어를 위한 LLM 기반 지휘체계와 U-Net 점수맵 기반 다중 에이전트 협력 강화학습

윤영준* 방현태* 전유라† 김덕환† 윤원근*

초 록

저비용 자폭 무인수상정(USV) 군집은 전자전이 유선 조종 표적에 닿지 않고 요격탄은 표적보다 비싸 포획되는, 재래식 대응의 사각지대에 있다. 본 연구는 적보다 느린 소수의 방어정이 모선의 접근 회랑을 그물벽으로 선제 차단하는 두 계층 방어 체계를 제안한다. 전략 계층에서는 대규모 언어모델(LLM) 지휘관이 방어정별 담당 무리를 정하고, 기동 계층에서는 U-Net 이 전장 격자 지도 위에 낸 점수맵에서 각 방어정이 픽셀을 지목해 그물벽 위치를 정한다. 두 계층은 같은 주기로 갱신되지만 응답 지연이 크게 달라 느린 전략 계층만 비동기로 분리한다. 픽셀 지목은 행동공간을 격자에 가두어 안전·임무 제약을 마스킹으로 직접 부과하고 적선 수에 불변이며, 학습은 가치망 없는 그룹 상대 정책 최적화를 다중 에이전트로 확장한다. 8개 조건 $\times$ 3개 포메이션 $\times$ 30개 시드, 720 에피소드를 시드 대응표본으로 수집해 두 계층의 기여를 2×2 로 분리 측정하였다. 기동 계층은 LLM 없이 단독으로 포획률을 $0.844 \rightarrow 0.886$ 으로 높였고, 제안 체계 전체는 같은 방어 수준에서 포획당 그물 소모를 44.5%, 총 선회량을 46.6% 줄였으며, 두 계층의 기여는 상승이 아닌 가산적이었다. 지휘관은 능력 임계 위에서만 이득이었다. 클라우드 모델은 $+0.060$, 로컬 Qwen2.5 7B 는 -0.192 로 코드 휴리스틱보다 유의하게 나뉘었다. 지휘관 성능을 설명한 것은 배정 커버리지가 아니라 재계획 간 계획 안정성으로, 주기적으로 재계획하는 구조에서는 국소 최적성보다 시간에 걸친 일관성이 중요하다는 설계 지침을 얻었다.

주제어 : 무인수상정, 군집 방어, 다중 에이전트 강화학습, 임무배정, 대규모 언어모델, 의미론적 분할, 그룹 상대 정책 최적화

1 서론

다수의 저비용 무인수상정(USV)이 고가치 함정을 향해 여러 방향에서 동시에 돌진하는 자폭 공격은 비대칭 위협의 전형이다. 유한한 방어 자산의 배분은 무기-표적 할당 문제로 오래 연구되었으나 [1], 표적 수가 요격 자산을 넘어서면 최적 할당으로도 남는 표적이 생긴다. 기존 대응도 한계가 있다 [2]. 교란에 의한 연성 대응(soft-kill)은 위협을 제거하지 못하고 유선 조종 표적에 무력하며 [3], 직접 타격하는 경성 대응(hard-kill)은 값싼 표적에 고가 유도탄을 쓰는 비용 구조 [4]와 표적 수에 따른 포화를 피하지 못한다.

본 연구는 저비용 그물에 의한 물리적 포획을 택한다 [2]. 이 방식은 통신 방식과 무관하게 표적을 정지시킨다. 방어정은 적선보다 느려 추격할 수 없으므로, 적선이 지나갈 접근 회랑을 앞질러 그물벽으로 차단한다.

이 문제는 두 판단을 요구한다. 하나는 어느 방어정이 어느 적 무리를 맡는가라는 이산적 배정이고, 다른 하나는 맡은 무리를 해면 어디에서 막는가라는 연속적 기동이다. 둘은 같은 주기로 갱신되지만 산출에 걸리는 시간이 크게 다르다. 본 연구는 느린 배정을 언어모델 지휘관에게, 빠른 기동을 학습된 정책에 맡긴다(Fig. 1). 적보다 느린 방어정과 한 척당 몇 장의 그물이라는 제약 아래에서 묻는 것은 “쓸 수 있는가”가 아니라 각 계층이 무엇을 얼마나 개선하는가이다.

설계 선택은 세 가지다.

- **실해역 지형에서 학습·평가한다.** OpenStreetMap 해안선을 래스터화한 육지가 충돌 판정과 관측 채널에 들어간다(4.4.1절).
- **전장을 이미지로 보고, 행동을 픽셀로 낸다.** 관측은 모선 중심 50×50 격자의 15채널 영상이고, 정책은 그 위의 유효 픽셀 하나를 고르는 U-Net 점수맵이다. 불가능한 자리는 애초에 뽑히지 않고, 선택 수가 바뀌어도 입출력 형태가 같다(4.4.1절, 4.4절).
- **출력이 경유점이다.** 정책이 제어 신호 대신 경유점 두 개를 내므로 저수준 추종과 분리된다(4.4절).

본 논문의 기여는 다음과 같다.

1. **공학 해법.** 적보다 느린 방어정 세 척으로 자폭 군집을 막는 2계층 체계를 제안한다. 배정은 언어모델 지휘관이, 그물벽 위치는 U-Net 점수맵 정책이 맡고, 느린 계층만 비동기로 분리한다.
2. **검증 결과.** 시드 대응 2×2 설계로 두 계층의 기여를 분리 측정하여, 그물벽 방어가 같은 포획률에서 포획당 그물 소모와 총 선회량을 각각 약 45% 줄이고, 언어모델 지휘관의 이득은 능력 임계 위의 모델에서만 나타남을 보였다. 같은 행동공간 위의 다중 에이전트 근위 정책 최적화(MAPPO)와 절대 비교하여 자원 절약이 표현이 아니라 갱신 규칙에서 옴을 확인하였다.
3. **배치 판단 기준.** 지휘관은 배정 커버리지가 아니라




Figure 1: 제안 체계의 개요: 전략 계층(위)의 무리별 배정과 기동 계층(아래)의 그물벽 위치 결정

재계획 간 계획 안정성으로 평가해야 하며, 로컬 중형 모델은 응답 지연이 결정 주기를 넘길 수 있어 비동기 분리가 전제다.

2절 관련 연구, 3절 문제 정의, 4절 제안 체계, 5절 실험 설계, 6절 결과, 7절 고찰 및 결론이 이어진다.

2 관련 연구

2.1 무기-표적 할당과 조합 최적화

방어 자산을 표적에 배분하는 문제는 무기-표적 할당(WTA)으로 정식화되어 정확해법과 휴리스틱이 모두 연구되었고 [1], 1:1 배정으로 축소하면 헝가리안 알고리즘 [5]으로 다항 시간에 최소비용 매칭을 얻는다. 이 방법들은 비용 함수가 주어지면 최적을 보장하지만, “앞서 놓은 그물이 이미 막은 회랑은 두고 남은 그물을 열린 쪽으로 돌려라”처럼 이전 결정의 결과와 자산 잔량에 따라 달라지는 판단은 고정된 거리·각도 비용으로 표현되지 않는다. 본 연구는 배정 계층에 조합 최적화 대신 언어모델의 판단을 두어 전술적 맥락을 반영하고, 그 대가를 6절에서 정량적으로 보고한다.

2.2 무인 위협 대응

무인 위협의 무력화 수단은 연성(전자전)·경성(물리 타격)·포획(그물 등)으로 구분된다 [2]. 유선 조종 표적의 확산 [3]은 연성 대응의 범위를 좁혔고, 요격 비용의 비대칭 [4]은 경성 대응의 지속성을 제약한다. 해상에서는 다중 USV 협력 기동 [6]과 다중 에이전트 강화학습에 의한 협조 포위 [7]가 보고되었으나, 포위는 방어정이 표적보다 빠르거나 대등함을 전제한다. 본 연구는 방어정이 더 느린 조건에서 추격 대신 접근 경로의 선제 차단을 택한다.

2.3 다중 에이전트 강화학습과 크레딧 배분

중량 집중 학습·분산 실행(CTDE) 계열은 팀 보상에서 개체별 기여를 분리하기 위해 가치망을 학습하며, 중앙 비평가(MADDPG [8]), 단조 가치 분해(QMIX [9]), 반사실적 기준선(COMA [10]), PPO [12]의 다중 에이전트 확장(MAPPO [11])이 이에 속한다. 공유 가치망의 추정 편향과 학습 불안정 [13]은 다른 에이전트가 함께 학습하는 비정상 환경에서 더 커진다 [8]. 언어모델 정렬 분야의 그룹 상대 정책 최적화(GRPO) [14]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 이득을 산정함으로써 가치망을 없앤다. 본 연구는 GRPO를 다중 에이전트 제어로 옮기고 후보 하나를 기하 휴리스틱으로 고정해 기준선으로 삼으며, 후보의 팀 보상을 비평가가 아니라 시뮬레이터 재진행으로 얻는다. COMA의 반사실적 착상을 같은 방식으로 구현한 변형도 비교하였고, MAPPO는 같은 픽셀 행동공간 위의 기준선으로 두어 표현과 갱신 규칙의 기여를 분리한다(6.1.2절).

2.4 격자 지도 표현과 픽셀 지목 행동

완전 합성곱 구조 [15]와 U-Net [16]은 모든 픽셀에 값을 매기는 조밀 예측을 가능하게 하고, CoordConv [17]는 좌표 채널로 절대 위치를, FiLM [18]은 조건 벡터에 의한 채널별 선형 변조(Feature-wise Linear Modulation)를 더한다. 이들은 모두 상황 지각에 쓰였다. 후보마다 점수를 매겨 하나를 지목하는 출력은 포인터 네트워크 [19]에서 비롯되었고, 그 점수는 어텐션 [20]과 같은 질의-후보 내적이지만 주로 조합 최적화에 쓰였다. 본 연구는 둘을 잇는다. U-Net 특징 지도의 각 픽셀에 방어정별 질의로 점수를 매기고(4.4절), 그 점수맵을 정책의 행동 분포로 삼아 픽셀 하나를 지목하는 것이 곧 행동이다. 격자 행동공간이므로 안전 제약을 마스크로 행동 분포에 직접 부과할 수 있다.




Figure 2: 세 가지 공격 포메이션: 집중(왼쪽), 양동(가운데), 파상(오른쪽)

2.5 언어모델 기반 계획

언어모델을 계획 주체로 쓰는 연구는 고수준 지시를 실행 가능한 단계로 분해하는 방향으로 발전했고 [21], SayCan [22]은 사전 지식에 로봇의 실행 가능성 추정을 결합해 불가능한 계획을 걸러낸다. 구조적 출력 [23]은 언어모델 출력을 하위 시스템이 파싱 가능한 형태로 고정한다. 본 연구도 SayCan처럼 언어모델의 판단을 실행 가능성으로 거르지만, 언어모델 점수와 가치함수를 곱해 기술을 고르는 대신 언어모델에는 배정만 맡기고 실행 가능성은 기동 계층의 유효 마스크가 픽셀 수준에서 강제한다(4.4.3절). 이 분리 위에서 언어모델 판단만으로 배정이 성립하는지, 어느 능력 수준부터 이득인지를 측정한다.

3 문제 정의와 평가 지표

3.1 교전 시나리오

Table 1: 교전 시나리오와 관측 설정 (길이는 관측 픽셀 한 번 ℓ 단위)

항목	값
적 USV 수 M	10
방어정 수 P	3
적 무리 최대 수 C	4
관측 격자 $n_g \times n_g$ (모션 중심)	50×50
교전 해역 한 번	50ℓ
속력비 v_e/v_a	1.5
결정 주기당 이동거리 (적 / 방어정)	$0.89\ell / 0.60\ell$
그물벽 최대 길이 L_{net}	1.8ℓ
방어정당 그물 (학습 / 평가)	1 / 3
정책 파라미터 수	244,389

관측·행동·보상이 모두 픽셀 한 번 $\ell = 2E/n_g$ 로 정규화되므로 (§4.4.1) 시나리오는 위의 비율로 정해지고, 물리 척도는 ℓ 과 결정 주기 두 값이 준다. 본 실험의 기준 인스턴스는 $\ell = 252\text{m}$, 결정 주기 25s이며 본문의 m 값은 이 인스턴스 기준이다. 값은 학습 체크포인트의 설정에서 직접 읽었다. 방어정이 적보다 느려 추격이 성립하지 않으므로 접근 회랑의 선제 차단이 유일한 대응이다. 그물 보유량은 학습 시 1장, 평가·배포 시 3장이다: 정책은 결정마다 그물벽 하나를 놓으므로 결정당 행동공간이 보유량과 무관하고, 1장으로 학습한 정책이 재학습 없이 3장 설정에서 동작한다.

교전 해역 중앙에 고가치 모션 한 척이 있고, 가장자

리에서 적 USV M 척이 모션을 향해 돌진한다. 적은 무작위로 흩어져 오지 않고 집중, 양동, 파상의 세 가지 공격 포메이션 가운데 하나를 취한다(Fig. 2; 정의는 아래). 방어정 P 척은 적선보다 느리며, 각각 한정된 수의 그물벽을 전개할 수 있다. 설정값은 관측 픽셀 한 번 ℓ 을 단위로 Table 1에 정리하였다. 관측·행동·보상이 모두 ℓ 로 정규화되므로(4.4.1절) 시나리오를 정하는 것은 물리 치수가 아니라 이 비율들이다.

방어정은 적이 지나갈 자리를 미리 예측하여 선점해야 한다. 그물벽은 두 좌표를 잇는 선분으로 정의되며, 방어정이 그 선분을 따라 이동하면서 전개한다. 물리적으로는 방어정 후미의 전개 장치가 부유식 그물을 해면에 풀어 놓고, 그 위를 지나는 적 USV의 프로펠러가 그물에 얽혀 추진을 잃는 것을 포획으로 본다(Fig. 3). 전개된 그물은 해면에 고정되지 않아, 시간이 지날수록 차단 효과가 감소하며, 미리 전개된 그물은 적에게 노출되어 회피의 여지를 준다. 따라서 그물벽은 적의 도달 직전, 적에 가까운 위치에 전개하는 것이 유리함을 가정한다.




Figure 3: 후미 투하식 부유 그물에 의한 포획 개념: 그물 위를 지나는 적 USV의 프로펠러가 얽혀 추진을 잃는다.

세 포메이션의 정의는 다음과 같다.

- **집중(concentrated):** 적 전 병력이 한 방위에 모여 동시에 접근한다. 차단해야 할 접근로의 방위가 동일하므로, 소수의 방어정으로도 대응이 가능하다.




Figure 4: 판단 지연이 다른 2계층 비동기 구조

- **양동(diversionary)**: 적이 세 방위로 나뉘어 동시/에 접근한다. 접근로가 셋으로 갈라지므로 가용 방어정을 모두 투입해야 하며, 어느 방어정을 어느 무리에 붙이는 배정과 그 경로의 교차 여부가 결과를 좌우한다.
- **파상(wave)**: 적이 3개 단(rank)으로 나뉘어 단마다 방위를 조금씩 달리하며 거리차를 두고 순차적으로 도달한다. 앞 단을 막는 데 쓴 그물벽은 그 자리에 남고 방어정의 그물 보유량은 한정되어 있으므로, 뒤 단이 오기 전에 방어정이 다음 접근로로 이동하여 남은 그물을 다시 전개해야 한다. 따라서 그물벽을 어느 자리에 놓아 여러 단을 겹쳐 막을지, 그리고 단 사이의 짧은 시간에 얼마나 빨리 재배치할지가 방어율을 결정한다.

적선 수, N_{col} 은 아군 상호 및 모선 충돌 건수, N_{tng} 는 아군이 설치된 그물에 얹힌 횡수, N_{net} 은 소모한 그물 수, D_p 와 $\Delta\psi_{p,t}$ 는 방어정 p 의 총 이동거리와 step t 의 방위 변화량, $\mathbf{m}$ 은 모선 위치, $\mathbf{z}_k$ 와 t_k 는 k 번째 포획 지점과 시각, $\mathbf{a}_d$ 는 d 번째 그물 전개를 시작한 방어정의 위치, $\mathcal{A}$ 는 그 시점의 생존 적선 집합, $\mathbf{e}_m$ 은 적선 m 의 위치이다. 자원 효율 지표는 교전하지 않은 조건이 가장 효율적으로 평가되는 것을 막기 위해 총량이 아니라 포획당 비율로 둔다. 교전 품질의 지표들은 거리축과 시간축으로 나누어, 모선에서 먼 곳의 포획과 이른 포획을 함께 본다.

3.2 평가 지표

방어 성과의 지표는 다섯 관점에서 총 10개 지표를 정의한다(Table 2). 지표들은 에피소드 단위로 계산되며, 표의 정의에서 $N_{cap} \cdot N_{brc}$ 는 포획된 · 모선까지 돌파한

Table 2: 평가 지표 10종. 방향은 개선이 어느 쪽인지를 나타내며, 기호는 본문에 정의하였다.

관점	지표	방향	정의	뜻
방어 성과	포획률	↑	$CR = N_{cap} / (N_{cap} + N_{brc})$	교전이 결판난 적선 중 포획된 비율
	돌파 수	↓	N_{brc}	모선까지 도달한 적선 수
안전	충돌률	↓	N_{col} / P	방어정 1척당 아군 상호 · 모선 충돌 건수
	그물 걸림	↓	N_{tng}	아군이 설치된 그물에 얹힌 횡수
자원 효율	포획당 그물	↓	N_{net} / N_{cap}	적 1척 포획에 소모한 그물 수
	포획당 이동거리	↓	$\sum_{p=1}^P D_p / N_{cap}$	적 1척 포획당 팀 총 이동거리
기동 비용	총 선회량	↓	$\sum_{p=1}^P \sum_t \Delta\psi_{p,t} $	누적 방위 변화량(궤적 부드러움)
교전 품질	포획 이격거리	↑	$\frac{1}{N_{cap}} \sum_k \ \mathbf{z}_k - \mathbf{m}\ $	포획 지점의 모선 이격(공간축 조기 제압)
	평균 포획 시각	↓	$\frac{1}{N_{cap}} \sum_k t_k$	포획이 일어난 시각(시간축 조기 제압)
	전개 시 적 거리	↓	$\frac{1}{N_{net}} \sum_d \min_{m \in \mathcal{A}} \ \mathbf{a}_d - \mathbf{e}_m\ $	그물 전개를 시작한 순간 최근접 적까지 거리

4 제안 방법

4.1 2계층 비동기 구조

제안 체계는 방어 판단을 전략 계층과 기동 계층으로 분리한다(Fig. 4). 전략 계층은 어느 방어정이 어느 적 무리를 막는가를 정하고, 기동 계층은 배정된 무리를 막기 위해 해면 어디에 그물벽을 놓는가를 정한다. 두 계층은 같은 주기로 결정을 내리지만 **응답 속도가 다르다**. 기동 계층의 순전파는 순간에 끝나는 반면, 전략 계층의 언어모델 호출은 응답에 지연이 발생한다(6.4절). 느린 전략 계층 호출만 비동기로 분리하여, 호출이 진행되는 동안 기동 계층은 직전 배정으로 결정을 계속하고 응답이 도착하면 다음 결정부터 새 배정을 반영한다. 이하에서 쓰는 기호는 Table 3에 모았다.

4.2 적 무리 군집화




Figure 5: 방위각 정렬, 군집화, 군집 배정

두 판단 계층은 개별 적선이 아니라 무리를 단위로 배정하므로, 매 결정마다 생존 적선을 모션 기준 방위로

묶어 최대 C 개의 무리로 요약한다(Fig. 5). 적선 m 의 위치를 $\mathbf{e}_m = (e_{m,x}, e_{m,y})$, 모션 위치를 $\mathbf{m} = (m_x, m_y)$ 라 하면, 적선의 모션 기준 방위 ϑ_m 은 항법 규약(북쪽 0° , 시계 방향)으로 정의된다.

$$\vartheta_m = \text{atan2}(e_{m,x} - m_x, e_{m,y} - m_y) \bmod 360^\circ \quad (1)$$

고정 방위 구간(bin)은 한 무리가 경계에 걸리면 둘로 쪼개지므로, 방위 간격(gap)으로 무리 수를 데이터에 맞추는 적응형 군집화를 쓴다. 생존 적선 $n = |\mathcal{A}|$ 척의 방위를 오름차순으로 정렬하여 $\vartheta_{(1)} \leq \dots \leq \vartheta_{(n)}$ 이라 하고, 이웃한 방위 사이의 간격 $g_{(q)}$ 를 원형으로 정의한다.

$$g_{(q)} = \vartheta_{(q+1)} - \vartheta_{(q)} \quad (q < n), \quad g_{(n)} = \vartheta_{(1)} + 360^\circ - \vartheta_{(n)} \quad (2)$$

마지막 항은 북쪽을 지나 되돌아오는 이음새 간격으로, 북쪽에 걸친 무리가 쪼개지는 것을 막는다. 원 위에서는 임계 δ_{gap} 을 넘는 간격 k 개가 곧 무리 k 개이므로 그 수를 활성 무리 수 $\hat{C}$ 로 삼되, 1 이상 $\min(C, n)$ 이하로 자른다.

$$\hat{C} = \text{clip}(|\{q : g_{(q)} > \delta_{\text{gap}}\}|, 1, \min(C, n)) \quad (3)$$

가장 큰 간격 $\hat{C}$ 개에서 잘라 라벨 $j_m \in \{1, \dots, \hat{C}\}$ 와 구성원 집합 $\mathcal{A}_j = \{m : j_m = j\}$ 를 얻는다. 무리 j 는 척수 n_j , 중심 $\mathbf{c}_j$, 각도 퍼짐 $\Delta\vartheta_j$, 모션 방향 접근 속도 v_j^{app} 의 네 가지 양으로 요약한다. 각도 퍼짐은 방위의 산술 편차가 $0^\circ/360^\circ$ 경계에서 깨지므로 방위 단위벡터 $\hat{\mathbf{b}}_m = (\cos \vartheta_m, \sin \vartheta_m)$ 의 평균 길이(원형 결집도) $\bar{R}_j$ 로 잰다. 접근 속도는 적선 침로와 모션 방향의 내적에

Table 3: 제안 체계(4절)의 기호. 각 기호는 처음 쓰이는 자리에서 정의하며 이 표는 찾아보기다. 혼동되기 쉬운 수량은 서로 다른 문자를 쓴다(무리 수 C , 경유점 수 K , 학습의 그룹 번호 수 G). 설정값은 Table 1와 각 정의 위치의 본문에 있다.

기호	뜻	기호	뜻
A_k	후보 k 의 그룹 상태 이득	$\hat{\mathbf{r}}$	모션 $\rightarrow$ 요격점 단위 벡터
$\mathbf{a}_p$	방어정 p 의 위치	r_{dup}	경유점 중복 배제 반경
$C, \hat{C}$	무리 수 상한, 활성 무리 수	$s_{p,i}$	방어정 p 가 픽셀 i 에 준 점수
$\mathbf{c}_j, n_j$	무리 j 의 중심, 척수	$\mathbf{t}_k$	k 번째 목표점 (연속 좌표)
d_{pj}	방어정 $p \rightarrow$ 무리 j 요격점 거리	$\mathbf{u}_k, \sigma_o$	부화소 오프셋과 그 표준편차
E, ℓ	관측 반폭, 픽셀 크기	$\mathcal{V}_p^{(k)}$	k 번째 선택 시점의 후보 픽셀 집합
$\mathbf{f}_i$	픽셀 i 의 키 벡터	w_n	유효 월드 마스크
G	학습의 그룹 번호 수	β	배정 유지 보너스 (식 6)
$g_{(q)}$	정렬한 적선 방위의 q 번째 간격	(γ_F, β_F)	FILM 배율·이동 계수
H	후보 평가 창 길이	γ	퍼텐셜 성형 할인 계수
$\mathbf{I}$	요격점	δ_{gap}	무리 분할 방위 임계
K	방어정 1척이 지목하는 경유점 수	$\eta_t, \lambda_H(t)$	학습률·엔트로피 계수 스케줄
L_{net}	그물벽 최대 길이	ϑ_m	모션에서 본 적선 m 의 방위
M	적 USV 수	$\iota(\cdot)$	월드 $\rightarrow$ 픽셀 인덱스 사상 (식 8)
$\mathbf{o}_p$	방어정 p 의 자체 상태 벡터	λ_L	임여 방어정의 층 분리 증분
P	방어정 수	τ_j	무리 j 의 위험도
$\mathbf{q}_p$	방어정 p 의 질의 벡터	Φ	위험 근접도 퍼텐셜
R_k	후보 k 의 팀 보상		

속력 v_e 를 곱한 값으로, 이탈 시 음수다.

$$\begin{aligned} n_j &= |\mathcal{A}_j|, & \mathbf{c}_j &= \frac{1}{n_j} \sum_{m \in \mathcal{A}_j} \mathbf{e}_m, \\ \Delta \vartheta_j &= 90^\circ \sqrt{1 - \bar{R}_j}, & \bar{R}_j &= \left\| \frac{1}{n_j} \sum_{m \in \mathcal{A}_j} \hat{\mathbf{b}}_m \right\|, \\ v_j^{\text{app}} &= \frac{v_e}{n_j} \sum_{m \in \mathcal{A}_j} \langle (\sin \psi_m, \cos \psi_m), \hat{\mathbf{d}}_m \rangle, \\ \hat{\mathbf{d}}_m &= (\mathbf{m} - \mathbf{e}_m) / \|\mathbf{m} - \mathbf{e}_m\| \end{aligned} \quad (4)$$

이 규칙 아래에서 집중은 무리 하나, 양동은 셋으로 요약되고, 파상은 단(rank)마다 방위를 벌려 내보내므로 대개 단마다 별개의 무리가 된다. 단 사이의 거리차는 무리 중심의 반경 차이와 4.4.1절의 격자 관측에 남는다. 척수와 중심은 4.3절의 위협도와 요격점을, 네 요약량 전부는 4.6절의 지휘관 입력을 구성한다.

4.3 기하 휴리스틱 기준 방법

4.2절의 무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법으로, 6절의 비교 기준이자 4.5.4절의 행동 복제 목표다.

배정. 위협도 τ_j 는 척수에 모션 근접도를 곱한 양, 요격점 $\mathbf{I}_j$ 는 무리 중심에서 모션 쪽으로 λ_I 만큼 옮긴 점이다.

$$\begin{aligned} \tau_j &= n_j \cdot \text{clip}\left(1 - \frac{\|\mathbf{c}_j - \mathbf{m}\|}{R_w}, 0.05, 1\right), \\ \mathbf{I}_j &= \mathbf{c}_j + \lambda_I (\mathbf{m} - \mathbf{c}_j), \quad \lambda_I = 0.55 \end{aligned} \quad (5)$$

하한은 해역 가장자리의 먼 무리도 척수에 비례하는 최소 위협을 갖게 한다. 방어정이 적보다 느려 무리 중심 가까이 잡은 요격점은 적이 먼저 지나치므로, 요격점을 모션 쪽으로 치우쳐 두어 방어정이 먼저 도달할 수 있게 한다. 위협 상위 P 개 무리에 대해 탐욕적 1:1 배정을 한다. 방어정 p 의 위치를 $\mathbf{a}_p$, 요격점까지의 거리를 $d_{pj} = \|\mathbf{a}_p - \mathbf{I}_j\|$, 직전 결정에서 p 가 맡았던 무리를 j_p^{prev} 라 하면, 배정 비용 $\tilde{d}_{pj}$ 는 이 거리에서 직전 배정을 유지하는 쌍에만 보너스 $\beta = 6000\text{m}$ 를 감한 값이다.

$$\tilde{d}_{pj} = \begin{cases} d_{pj} - \beta, & j = j_p^{\text{prev}} \\ d_{pj}, & \text{그 밖} \end{cases} \quad (6)$$

활성 무리가 P 보다 적으면 남은 방어정은 부하가 가장 큰 무리에 안쪽 층으로 붙인다. 층은 반경 증분 λ_L 과 방위차만큼 어긋나게 둔다.

경유점. 그물벽은 요격점 $\mathbf{I}$ 를 가운데 두고 접근 방향에 수직인 길이 L_{net} 의 선분이고, 경유점 $\mathbf{t}_k$ 는 그 양 끝 $K = 2$ 개다. 모션에서 요격점을 향한 단위 벡터에 수직인 벡터를 $\hat{\mathbf{r}}^\perp$ 라 하면

$$\mathbf{t}_k = \mathbf{I} + \left(k - \frac{K-1}{2}\right) L_{\text{net}} \hat{\mathbf{r}}^\perp, \quad k = 0, \dots, K-1 \quad (7)$$

이다. 각 $\mathbf{t}_k$ 는 학습 정책과 같은 격자·유효 마스크·간격 제약(4.4.3절) 안의 최근접 픽셀로 스냅하므로 두

방법의 행동공간은 같다. 휴리스틱은 기하로 정해진 점만 지목하며, 다른 방어정의 벽, 파상 공격의 뒤단, 지형의 길목은 고려하지 않는다. 반면 학습된 점수맵(4.4절)은 이 요소들을 반영하여 해면 전체의 후보 위치를 한꺼번에 비교한다. 따라서 6.1.1절의 차이는 표현력이 아니라 결정 규칙의 차이이다.

4.4 점수맵 기반 기동 정책

4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모션을 중앙에 두고 관측 반폭 E 의 전장을 $n_g \times n_g$ 격자로 나눈 다채널 지도이다. 15개 채널은 전역 9채널, 방어정별 3채널, CoordConv [17] 좌표 3채널이며, 정의와 값 범위는 Table 4, 구성과 예시는 Fig. 7, 6에 있다.

픽셀 크기는 $\ell = 2E/n_g$ 이고, 월드 좌표 $\mathbf{x} = (x, y)$ 는 모션 위치 $\mathbf{m} = (m_x, m_y)$ 를 중심으로 픽셀 인덱스 $i = (\iota_x, \iota_y)$ 로 사상된다.

$$\begin{aligned} \iota_x &= \text{clip}\left(\left\lfloor \frac{x - m_x + E}{\ell} \right\rfloor, 0, n_g - 1\right), \\ \iota_y &= \text{clip}\left(\left\lfloor \frac{y - m_y + E}{\ell} \right\rfloor, 0, n_g - 1\right) \end{aligned} \quad (8)$$

개체 채널은 이 사상으로 픽셀에 모은 뒤 집계해 만든다. 생존 적선 집합을 $\mathcal{A}$, 적선 m 의 위치·헤딩을 $\mathbf{e}_m$, ψ_m , 픽셀 i 로 사상되는 적선의 집합을 $\mathcal{A}_i = \{m \in \mathcal{A} : \iota(\mathbf{e}_m) = i\}$, 그 수를 N_i , 적이 에피소드 상한 T_{max} 동안 달릴 거리를 $v_e T_{\text{max}}$ 라 하면, 픽셀 i 의 적 밀도·진행 방향·위협도 채널은

$$c_i^{\text{den}} = \frac{N_i}{M}, \quad c_i^{\text{vel}} = \frac{1}{\max(N_i, 1)} \sum_{m \in \mathcal{A}_i} (\sin \psi_m, \cos \psi_m) \quad (9)$$

$$c_i^{\text{thr}} = \max_{m \in \mathcal{A}_i} \left(1 - \text{clip}\left(\frac{\|\mathbf{e}_m - \mathbf{m}\|}{v_e T_{\text{max}}}, 0, 1\right)\right) \quad (10)$$

이다. 나머지 격자 채널은 Table 4의 정의를 같은 방식으로 래스터화한 것이며, 육지 채널만 OpenStreetMap 해안선·섬 폴리곤에서 얻고 충돌 판정은 다운샘플 전 물리 격자에서 한다. 합성곱은 평행이동 등변이라 절대 위치가 흐려지므로, 픽셀 중심 $\mathbf{x}_i = (x_i, y_i)$ 의 좌표 자체를 세 채널로 함께 넣는다.

$$(c_i^x, c_i^y) = \frac{\mathbf{x}_i - \mathbf{m}}{E}, \quad c_i^r = \text{clip}\left(\frac{\|\mathbf{x}_i - \mathbf{m}\|}{E}, 0, 1\right) \quad (11)$$

이다. 격자에 담기지 않는 방어정 p 의 상태는 위치·요격점·헤딩·잔여 그물 비용·전개 중 여부를 같은 기준으로 정규화한 벡터 $\mathbf{o}_p$ 로 따로 준다.

$$\begin{aligned} \mathbf{o}_p &= \left[\frac{1}{E} (\mathbf{a}_p - \mathbf{m}); (\sin \psi_p, \cos \psi_p); \frac{n_p}{n_{\text{max}}}; \delta_p; \right. \\ &\quad \left. \frac{1}{E} (\mathbf{I}_p - \mathbf{m}) \right] \in \mathbb{R}^8 \end{aligned} \quad (12)$$

모든 입력은 길이 $E \cdot \ell$, 개수 $M \cdot P \cdot n_{\text{max}}$, 시간 $v_e T_{\text{max}}$ 로 나뉜 무차원 양이고 격자 지도는 개체 수와 순서에 불변이므로, 해역 크기·격자 해상도·선박 수가 바뀌어




Figure 6: 래스터화된 15채널 관측의 예(파상 포메이션, 통영 매물도 북측)

Table 4: 15채널 격자 관측의 구성. 전역 채널은 월드당 한 번 계산하여 모든 방어정이 공유하고, 방어정별 채널만 방어정마다 다르다. 정의 열의 식 번호는 본문의 수식이다.

#	무음	채널	정의	범위
1		적 밀도	픽셀 내 생존 적선 수/ M , 식 (9)	$[0, 1]$
2		적 진행 x	픽셀 내 적선 heading 단위벡터의 평균, 식 (9)	$[-1, 1]$
3		적 진행 y	위와 같음	$[-1, 1]$
4		적 위험도	모선 도달 임박도의 픽셀 내 최대, 식 (10)	$[0, 1]$
5	전역	아군 위치	픽셀 내 생존 방어정 수/ P	$[0, 1]$
6		설치된 그물	물리 격자의 그물 점유를 최대값 풀링	$\{0, 1\}$
7		원점	모선 반경 안의 픽셀	$\{0, 1\}$
8		요격 구역	$r_{\min} \leq \ \mathbf{x}_i - \mathbf{m}\ \leq r_{\max}$ 인 픽셀	$\{0, 1\}$
9		육지	고해상도 육지 마스크의 면적비	$[0, 1]$
10		자기 위치	방어정 p 가 놓인 픽셀	$\{0, 1\}$
11	방어정별	배정 요격점	$\mathbf{I}_p$ 가 놓인 픽셀 (미배정이면 전부 0)	$\{0, 1\}$
12		유효 영역	유효 마스크 $\mathcal{V}_p$, 식 (15)	$\{0, 1\}$
13		x	$(x_i - m_x)/E$, 식 (11)	$[-1, 1]$
14	좌표	y	$(y_i - m_y)/E$	$[-1, 1]$
15		r	$\text{clip}(\ \mathbf{x}_i - \mathbf{m}\ /E, 0, 1)$	$[0, 1]$




Figure 7: 15채널 관측의 구성: 전역·방어정별·좌표 채널의 격자 중첩과 격자 밖 자체 상태 벡터

도 입출력의 의미와 형태가 같고 통계 기반 정규화 층이 필요 없다(설정값은 Table 1).

4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net [16]을 지나 같은 해상도의 특징 지도로 변환된다(Fig. 8). 인코더 2단($50 \rightarrow 25 \rightarrow 13$)이 수용 영역을 넓히고 디코더 2단이 원해상도를 복원하며, skip 연결이 위치 정보를 전달한다.

병목에서는 전역 평균 풀링(GAP)으로 압축한 전향 벡터로부터 FiLM [18]의 채널별 배율·이동 계수를 만들어 병목 특징을 변조한 뒤 디코더에 넘긴다. 병목 특징 지도를 $\mathbf{H}_b \in \mathbb{R}^{2w \times h \times h}$ ($w = 32, h = 13$), 계수를 내는 선형층을 $\mathbf{W}_F, \mathbf{b}_F$, 채널별 곱을 $\odot$ 이라 하면 변조된 특징은

$$(\gamma_F, \beta_F) = \mathbf{W}_F \text{GAP}(\mathbf{H}_b) + \mathbf{b}_F, \quad (13)$$

$$\tilde{\mathbf{H}}_b = (1 + \gamma_F) \odot \mathbf{H}_b + \beta_F$$

이다. 배율을 $1 + \gamma_F$ 로 두어 항등 변조에서 출발한다. 국소 합성곱만으로는 “지금 전향이 급박한가”와 같은 전역 정보가 모든 위치에 고르게 전달되지 않으므로 이 경로를 둔다.




Figure 8: 점수맵 정책의 구조: 방어정 상태 질의와 U-Net 특징맵의 내적으로 얻는 점수맵과 부화소 오프셋

각 방어정 p 는 상태 벡터(식 (12))에서 질의 $\mathbf{q}_p = \text{MLP}_{8 \rightarrow 128 \rightarrow 32}(\mathbf{o}_p)$ 를 만들고, 픽셀 특징 $\mathbf{f}_i \in \mathbb{R}^d$ 와의 내적으로 점수 $s_{p,i}$ 를 얻는다. 질의의 아핀 사영을 $\mathbf{W}_q$, $\mathbf{b}_q$ ($d = 32$)라 하면

$$s_{p,i} = \frac{\langle \mathbf{W}_q \mathbf{q}_p + \mathbf{b}_q, \mathbf{f}_i \rangle}{\sqrt{d}}, \quad d = 32 \quad (14)$$

이다. 어텐션 [20]의 점수 계산과 같은 형식으로 격자 위의 원소를 지목한다 [19]. 특징 지도는 방어정마다 다르므로, 관측 텐서는 방어정을 묶어 결정마다 한 번의 순전파로 U-Net 을 통과한다. 연산량은 방어정 수에 비례하지만 가중치는 모두가 공유하므로 모델 크기는 방어정 수에 불변이다. 합성곱 블록은 3×3 합성곱, 그룹 정규화(8그룹) [24], SiLU 의 순이며, 그룹 정규화는 배치 통계를 쓰지 않아 묶음 크기와 무관하게 같은 연산이다.

4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 방어정 p 의 유효 픽셀 집합 $\mathcal{V}_p$ 는 환상 요격 구역 안, 육지 밖, 배경 요격점의 반경 조건 안, 배경 무리의 방위 조건 안이라는 네 조건의 교집합이다. 육지 픽셀 집합을 $\mathcal{L}_{\text{land}}$, 모션에서 본 요격점·픽셀 방위를 $\vartheta_p, \vartheta_i, [0^\circ, 180^\circ]$ 로 접은 각도 차이를 $|\cdot|_\circ$ 라 하고, 요격 구역의 반경을 $r_{\min} = 400$, $r_{\max} = 4500$ m, 요격점 반경 조건을 $r_g = 3000$ m, 방위 조건을 $\vartheta_g = 60^\circ$ 로 두면

$$\mathcal{V}_p = \left\{ i : r_{\min} \leq \|\mathbf{x}_i - \mathbf{m}\| \leq r_{\max}, i \notin \mathcal{L}_{\text{land}}, \|\mathbf{x}_i - \mathbf{I}_p\| \leq r_g, |\vartheta_i - \vartheta_p|_\circ \leq \vartheta_g \right\} \quad (15)$$

이다. 유효 픽셀이 하한에 못 미치면 반경 조건부터 푼다 — 방위 조건은 “무엇을 막는 그물인가”를 정하므로 마지막까지 유지한다. 마스크는 로짓 단계에서 적용된다. 유효 집합 밖의 점수를 $-\infty$ 로 바꾼 뒤 소프트맥스에 넣어 선택 확률 $\pi_\theta(i | \mathbf{s}, p)$ 를 얻는다.

$$\tilde{s}_{p,i} = \begin{cases} s_{p,i}, & i \in \mathcal{V}_p \\ -\infty, & i \notin \mathcal{V}_p, \end{cases} \quad \pi_\theta(i | \mathbf{s}, p) = \frac{e^{\tilde{s}_{p,i}}}{\sum_{j \in \mathcal{V}_p} e^{\tilde{s}_{p,j}}} \quad (16)$$

유효 집합 밖 픽셀의 확률이 정확히 0 이므로, 안전·임무 제약은 손실 항이 아니라 행동 분포에 직접 부과되어 위반이 표현 불가능하다. 학습된 체크포인트에서 유효 비율은 평균 10.5 % 에 그치며(Fig. 9(c)), 연속 좌표 회귀에는 이 구조를 표현할 수단이 없다.

이산 격자의 또 다른 이득은 범주형 표본이 유효 영역을 벗어나지 않아 4.5절의 그룹 후보들이 서로 다른 칸을 밟는다는 점이다 — 가우시안 정책은 표준편차가 줄면 후보가 한 점으로 뭉친다. 칸의 해상도는 아래의 칸 안 연속 오프셋으로 보완한다.

각 방어정은 유효 영역 안에서 픽셀 $K = 2$ 개를 순차적으로 고른다. k 번째 선택의 질의·후보 집합·선택 분포·선택된 픽셀을 $\mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}, \pi_p^{(k)}, i_k$ 라 하고, 두 점 사이 간격에 하한(중복 배제 반경 r_{dup})과 상한을 두면

$$\begin{aligned} i_k &\sim \pi_p^{(k)} \equiv \pi_\theta(\cdot | \mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}), \\ \mathbf{q}_p^{(k+1)} &= \mathbf{q}_p^{(k)} + \mathbf{f}_{i_k}, \\ \mathcal{V}_p^{(k+1)} &= \{i \in \mathcal{V}_p^{(k)} : r_{\text{dup}} \leq \|\mathbf{x}_i - \mathbf{x}_{i_k}\| \leq 1.5 L_{\text{net}}\} \end{aligned} \quad (17)$$

이다. 먼저 고른 픽셀의 특징을 질의에 더하므로 두 점이 서로를 알고 뺄리고, 간격의 하한은 벽이 서지 않을 만큼 가까운 두 점을, 상한은 그물 길이를 넘는 벽을 배제한다. 후보가 모두 사라지면 제약을 완화한다.

선택된 칸 안의 위치는 연속 오프셋으로 정한다. 첫 질의와 선택 픽셀의 특징으로부터 MLP 로 평균 $\boldsymbol{\mu}_k$ 를 내고, 학습되는 표준편차 $\boldsymbol{\sigma}_o$ 의 가우시안에서 정규화 오프셋 $\mathbf{u}_k$ 를 표집해 $[-1, 1]$ 로 자른 뒤 반픽셀 $\ell/2$ 를 곱해 픽셀 중심에 더한 것이 k 번째 목표점 $\mathbf{t}_k$ 이다.

$$\begin{aligned} \boldsymbol{\mu}_k &= \text{MLP}_{2d \rightarrow d \rightarrow 2}([\mathbf{q}_p^{(0)}; \mathbf{f}_{i_k}]), \quad \mathbf{u}_k \sim \mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\sigma}_o^2), \\ \mathbf{t}_k &= \mathbf{x}_{i_k} + \frac{\ell}{2} \text{clip}(\mathbf{u}_k, -1, 1) \end{aligned} \quad (18)$$

즉 어느 칸인가는 범주형으로, 칸 안 어디인가는 가우시안으로 결정된다. 행동 $a_p = \{(i_k, \mathbf{u}_k)\}_{k=0}^{K-1}$ 의 로 그 확률은 두 분포의 합이고, 엔트로피 $\mathcal{H}(a_p)$ 도 같은 꼴이다.

$$\log \pi_\theta(a_p) = \sum_{k=0}^{K-1} \left[\log \pi_p^{(k)}(i_k) + \log \mathcal{N}(\mathbf{u}_k; \boldsymbol{\mu}_k, \boldsymbol{\sigma}_o^2) \right] \quad (19)$$

특징 조회에서 두 번째 점까지의 흐름을 Fig. 10에 요약하였다.




Figure 9: 유효 마스크와 픽셀 지목(학습된 체크포인트의 실제 출력): (a) 유효 영역, (b) 점수맵과 선택된 픽셀 쌍, (c) 제약별 후보 수 감소(대표 사례에서 2500 $\rightarrow$ 1000 $\rightarrow$ 979 $\rightarrow$ 387 $\rightarrow$ 299 칸, 6,652회 결정 평균 유효 비율 10.5 %)




Figure 10: 점수맵 위 픽셀 지목의 네 단계: 픽셀 특징, 유효 마스크, 첫 점 선택, 간격 제약 아래 둘째 점 선택

선택된 두 좌표를 잇는 선분이 그물벽 경로다. 방어정은 가까운 점까지 무전개로 이동한 뒤 다음 구간에서 전개한다. 운용 시에는 최대 점수를(greedy), 학습 시에는 분포에서 표본을 뽑는다.

정지 규칙. 그물이 없거나 배정되지 않은 방어정은 정지시킨다. 보상 신호가 없어 평평해진 점수맵이 항해 명령으로 새어 나가지 않게 하기 위함이다.

4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

4.5.1 그룹 상대 이득

학습은 가치함수를 두지 않는 그룹 상대 정책 최적화 [14]를 다중 방어정 상황에 맞게 변형한 것이다. 결정 시점의 상태 $\mathbf{s}$ 에서 결합 행동 $\mathbf{a} = (a_1, \dots, a_P)$ 후보 G 개를 표집하되, 하나($k=0$)는 휴리스틱(4.3절)의 행동 $\mathbf{a}_{\text{heur}}(\mathbf{s})$ 로 고정해 기준선으로 삼는다.

$$\mathbf{a}^{(0)} = \mathbf{a}_{\text{heur}}(\mathbf{s}), \quad \mathbf{a}^{(k)} \sim \pi_\theta(\cdot | \mathbf{s}), \quad k = 1, \dots, G-1 \quad (20)$$

각 후보를 시뮬레이터에서 공통 구간 $H = 180$ step 진행시켜 창 보상 $R_k = R(\mathbf{s}, \mathbf{a}^{(k)}; H)$ 를 얻고(4.5.3절), 휴리스틱 후보의 보상 R_0 를 기준으로 그룹 표준편차로 나누어 이득 A_k 를 산정한다. ϵ 은 0 나눗셈을 막는다.

$$A_k = \frac{R_k - R_0}{\text{std}(\{R_j\}_{j=0}^{G-1}) + \epsilon}, \quad \epsilon = 10^{-6} \quad (21)$$

휴리스틱과 같은 성과를 내는 후보의 이득은 0 이고, 그룹 표준편차로 나누므로 이득에는 그룹 안의 순위만 남는다. 어떤 선택이 더 나았는지를 실제 결과로 비교하므로 가치망과 그 추정 편향·학습 불안정이 없다.

한 갱신은 N 개의 병렬 전장(월드)에서 수행된다. 후보 보상이 모두 같은 월드는 이득이 정의되지 않으므로, 유효 마스크 $w_n = \mathbf{1}[\text{std}(\{R_{n,k}\}_k) > \epsilon_{\text{var}}]$ ($\epsilon_{\text{var}} = 10^{-6}$) 로 그런 월드를 갱신에서 제외한다. 월드 n 의 상태를 $\mathbf{s}_n$, 후보 k 의 이득을 $A_{n,k}$, 그 후보에서 방어정 p 의 행동을 $a_{n,p}^{(k)}$ 라 하면, 정책경사 손실 $\mathcal{L}_{\text{PG}}$ 는 유효 월드의 모든 후보·모든 방어정에 대해 이득으로 가중한 로그 확률(식 (19))의 음수이다.

$$\mathcal{L}_{\text{PG}}(\theta) = - \frac{\sum_n w_n \sum_{k=0}^{G-1} A_{n,k} \sum_{p=1}^P \log \pi_\theta(a_{n,p}^{(k)} | \mathbf{s}_n)}{G \sum_n w_n} \quad (22)$$

여기에 계수 $\lambda_H(t)$ (4.5.4절)의 엔트로피 정칙화를 더한 총손실을 최소화한다.

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{PG}}(\theta) - \lambda_H(t) \frac{1}{NP} \sum_{k=0}^{G-1} \sum_{n=1}^N \sum_{p=1}^P \mathcal{H}(a_{n,p}^{(k)}) \quad (23)$$

엔트로피는 G 개 후보 모두에 대해 합하므로 유효 계수는 $G\lambda_H(t)$ 이다. 기울기 노름을 클립한 뒤 갱신하며, 관련 상수는 Table 7에 모았다. 이 절차와 다음 소절의 크레딧 배분을 Fig. 11에 정리하였다.




Figure 11: 가치망 없는 그룹 상대 최적화의 한 갱신: 후보 표집(위), 몰아웃 창 평가(가운데), 상대 비교와 반사실적 크레딧 (아래). 그림은 $G = 4$, $H = 4$ 로 줄여 그렸으며 실제 학습 설정은 Table 7에 있다.

4.5.2 반사실적 크레딧 배분: 비교 변형

식 (22)는 팀 이득을 모든 방어정에 같은 값으로 곱하므로 개별 기여가 가려질 수 있다. 이를 분리하는 변형으로, 기준 표본에서 방어정 p 의 행동만 바꾼 혼합 후보 G 개를 같은 구간 H 만큼 재진행해 창 보상 $R_k^{(p)}$ 를 얻고, p 만의 이득

$$A_k^{(p)} = \frac{R_k^{(p)} - R_0^{(p)}}{\text{std}(\{R_j^{(p)}\}_{j=0}^{G-1}) + \epsilon} \quad (24)$$

을 방어정 p 의 로그확률에만 곱한다. 나머지 방어정이 고정되어 있으므로 이 차이는 p 의 선택에서만 온다. COMA [10]의 반사실적 기준선과 같은 착상이되 학습된 비평가 대신 시뮬레이터를 실제로 재진행한다. 본 논문이 평가하는 정책은 팀 이득 손실(식 (22)–(23))로 학습한 것이며, 같은 액터 위에서 갱신 규칙만 MAPPO로 바꾼 기준선과의 비교는 6.1.2절에 둔다.

4.5.3 보상 설계

창 보상 $R(\mathbf{s}, \mathbf{a}; H)$ 는 H step 동안 일어난 일을 스칼라로 합산한 팀 공유 보상으로, 이벤트 항, 창 시작·끝 상태에서 켜진 퍼텐셜 Φ 의 할인 차분, 조밀 항으로 구성된다. 계수는 Table 5에 모았다.

$$R = R_{\text{event}} + [\gamma \Phi(\mathbf{s}_{t+H}) - \Phi(\mathbf{s}_t)] + R_{\text{dense}} \quad (25)$$

이벤트 항은 사건 수에 고정 가중을 곱한 합이다. 사건 수는 3.2절의 네 가지에 육지 충돌 N_{land} 를 더한 것이고, 창 안에서 에피소드가 끝나면 전멸과 잔존 적 1척당 항을 더한다.

$$R_{\text{event}} = r_{\text{cap}} N_{\text{cap}} + r_{\text{brc}} N_{\text{brc}} + r_{\text{col}} (N_{\text{col}} + N_{\text{land}}) + r_{\text{tng}} N_{\text{tng}} + \mathbf{1}_{\text{end}} (r_{\text{wipe}} \mathbf{1}[\mathcal{A} = \emptyset] + r_{\text{surv}} |\mathcal{A}|) \quad (26)$$

퍼텐셜 Φ 는 생존 적선의 모션 근접도 합에 w_{threat} 을 곱해 부호를 바꾼 것으로, 차분 형태라 최적 정책을 보

Table 5: 보상 계수. 이벤트 항은 사건 1건당 가중, 퍼텐셜·조밀 항은 정규화된 수량에 곱하는 가중과 정규화 상수다.

항	기호	값	의미
이벤트	r_{cap}	+13.5	포획 1건
	r_{brc}	−8.0	돌파 1건
	r_{col}	−30	충돌·육지 충돌 1건
	r_{tng}	−13	그물 접촉 1건
	r_{wipe}	+8	창 안 종료 시 전멸
	r_{surv}	−5	창 안 종료 시 잔존 적 1척당
퍼텐셜	w_{threat}	3.0	모션 근접도 합의 가중
	R_w	6300 m	근접도 정규화(교전 해역 반폭)
	γ	0.99	할인
조밀	w_{path}	0.5	이동거리 비용
	w_{net}	0.3	그물 소모 비용
	w_{turn}	0.3	선회량 비용
	w_{cons}	0.3	목표점 일관성 비용
	w_{prox}	0.75	모션·타 방어정 근접 비용
	w_{cov}	0.1	커버리지 보너스
	w_{ray}	1.6	배울판 보너스(Ray ∈ [0, 2.6])
	R_m	800 m	모션 안전 반경
	ϱ_m	500 m	모션 근접 영향 반경
	ϱ_a	600 m	타 방어정 근접 영향 반경

존한다 [26].

$$\Phi(\mathbf{s}) = -w_{\text{threat}} \sum_{m \in \mathcal{A}} \text{clip} \left(1 - \frac{\|\mathbf{e}_m - \mathbf{m}\|}{R_w}, 0, 1 \right) \quad (27)$$

조밀 항은 창 안 기동 품질의 비용·보너스 합이다. 총 이동거리 D 와 소모 그물 수 N_{net} 에 더해, 방어정 p 의 누적 선회량을 최대 가능 선회량으로 나눈 값을 S_p , 직전 결정 대비 목표점 이동을 L_{net} 으로 나눈 값을 Ξ_p , 모션·타 방어정 근접도를 ρ_p^m , ρ_p^a (식 (29)), 설치된 그물이 적의 접근로를 막는 비율을 Cov(식 (30)), 계획된

벽까지 포함한 배울판을 Ray 라 하면

$$R_{\text{dense}} = -w_{\text{path}} \frac{D}{Hv_a P} - w_{\text{net}} N_{\text{net}} - \frac{w_{\text{turn}}}{P} \sum_{p=1}^P S_p - \frac{w_{\text{cons}}}{P} \sum_{p=1}^P \Xi_p - w_{\text{prox}} \sum_{p=1}^P (\rho_p^m{}^2 + \rho_p^a{}^2) + w_{\text{cov}} \text{Cov} + w_{\text{ray}} \text{Ray} \quad (28)$$

이다. 근접도는 창 안 최근접 거리 d_p^m , d_p^a 를 안전 반경과 영향 반경으로 정규화한 것이며, 제곱하여 붙을수록 페널티가 급격히 커지게 한다.

$$\rho_p^m = \text{clip}\left(\frac{R_m - d_p^m}{\varrho_m}, 0, 1\right), \quad \rho_p^a = \text{clip}\left(\frac{\varrho_a - d_p^a}{\varrho_a}, 0, 1\right) \quad (29)$$

커버리지 Cov 는 적에서 모션으로 향하는 직선이 설치된 그물 영역 $\mathcal{W}$ 에 막힌 생존 적의 비율로, 선분 위 표본점 $\lambda \in \Lambda$ 에서 검사한다 — 창 안에 포획이 없을 때도 후보를 변별하는 선행 지표다.

$$\text{Cov} = \frac{1}{|\Lambda|} \sum_{m \in \mathcal{A}} \mathbf{1}[\exists \lambda \in \Lambda : \mathbf{e}_m + \lambda(\mathbf{m} - \mathbf{e}_m) \in \mathcal{W}] \quad (30)$$

Ray 는 같은 검사를 계획된 그물벽까지 포함하되 적에 가까운 차단을 우대한 배울판이다. 퍼텐셜 항은 이벤트 항의 희소성을 매운다 — 216개 결정의 실측에서 포획은 평가 창 46.8% 에서만 발생했고, 나머지 창에서는 퍼텐셜 항이 후보 순위를 갈랐다.

4.5.4 초기화, 스케줄, 수렴 진단

행동 복제 초기화 그룹 상대 이득은 후보들이 갈릴 때만 신호를 주므로, 휴리스틱 행동(4.3절)을 목표로 짧은 행동 복제로 정책을 부팅한다. 목표는 원-핫이 아니라 휴리스틱 픽셀 i_k^* 를 중심으로 폭 σ_{BC} 의 가우시안을 유효 픽셀 위에서 정규화한 가중 $\omega_k(i)$ 이며 — 인접 픽셀은 사실상 같은 행동이라 원-핫은 기울기가 지나치게 희소하다 — 손실은 이 가중을 건 교차 엔트로피다.

$$\omega_k(i) = \frac{\mathbf{1}[i \in \mathcal{V}_p^{(k)}] \exp(-\|\mathbf{x}_i - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{\text{BC}}^2)}{\sum_{j \in \mathcal{V}_p^{(k)}} \exp(-\|\mathbf{x}_j - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{\text{BC}}^2)} \quad (31)$$

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{P} \sum_{p=1}^P \sum_{k=0}^{K-1} \sum_{i \in \mathcal{V}_p^{(k)}} \omega_k(i) \log \pi_p^{(k)}(i) \quad (32)$$

두 번째 픽셀의 질의는 휴리스틱의 첫 픽셀로 갱신한다 (teacher forcing).

학습률·엔트로피 계수 스케줄 옵티마이저는 Adam 이다. 학습률은 $\eta_0 = 10^{-4}$ 에서 $0.05 \eta_0$ 까지 단일 주기 코사인 어닐링 [27]($T = 800$ 업데이트)으로, 엔트로피 계수는 $\lambda_0 = 0.01$ 에서 $0.1 \lambda_0$ 까지 같은 예산 축에서 선형으로 줄여, 분포가 뽀족해지는 시점과 보폭이 작아지는 시점을 맞춘다. 채택 가중치(600 업데이트, 5.2절)는 $\eta \approx 0.19 \eta_0$ 인 감쇠 후반에 놓인다.

수렴 진단 채택 런은 20 업데이트마다의 요약만 남겼으므로, 같은 설정을 시드 3개로 다시 돌려 매 업데이트마다 수렴 진단을 기록하였다(Fig. 12). 진단량은 갱신 전후 정책 사이의 근사 KL(k_3 추정량)과 행동복제 초기점으로부터의 상대 파라미터 이동이다. 세 시드에서 근사 KL은 처음 100 업데이트 평균 1.4×10^{-2} 에서 마지막 100 업데이트 1.5×10^{-4} 로 두 자릿수 줄고, 파라미터 이동은 뒤 절반에서 포화하며, 정책 엔트로피는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하다. greedy 포획률은 세 시드 모두 800 업데이트에서 기준선 0.749 위에 있고 채택 런의 평가점도 그 범위 안에 든다.

4.6 언어모델 기반 전략 계층

전략 계층(Fig. 4 상단)의 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고, 출력은 무리별 배정과 대기 (HOLD)이다(실행 화면은 Fig. 13).

언어모델에는 좌표 원시 데이터 대신 *기하량이 미리 계산된* 전장 상태를 텍스트로 전달한다 — 무리별 요격점까지의 이동거리와 선화량, 모션 기준 방위, 설치된 그물에 의한 접근로 차단 여부.

출력은 다음 자료형에서 생성한 JSON 스키마로 강제한다 [23]. 스키마는 디코딩 단계에서 문법으로 작용하므로, 파싱 실패로 그 주기의 배정을 통째로 잃는 일이 없다.

```
CommanderPlan {
  rationale: str
  deployments: List[{
    cluster_id: int,
    ally_ids: List[int] }]
  hold_ships: List[int]
}
```

언어모델이 정하는 것은 *어느 배가 어느 무리를 맡고 누가 대기하는가*뿐이며, 그물 전개 여부·벽의 방위·요격점 기하는 기동 계층이 정한다. 배정은 코드가 보정하지 않고 그대로 쓰여, 비워 둔 ally_ids는 그 무리를 무방비로 둔다. 따라서 6절의 조건 간 차이는 배정 판단 자체에 귀속된다. 온도 0 으로 같은 전장에서 같은 배정이 나오게 한 것은 5.3절 시드 대응 설계의 전제다.

한 무리에 두 척 이상이 배정되면 4.3절의 잉여 배정과 같은 층·방위 분리가 작동하되, 요격점이 요격 구역을 벗어나 유효 마스크가 붕괴하지 않도록 반경을 구역 안으로 자른다. 배정이 바뀌면 요격점과 함께 기동 계층의 유효 마스크(4.4.3절)도 바뀐다.




Figure 12: 수렴 진단(회색 시드별, 파란 실선 시드 평균): (a) greedy 포획률, (b) 정책 엔트로피, (c) 근사 KL 발산, (d) 파라미터 이동



Figure 13: 실행 화면(양동 포메이션, Gemini 지휘관): 전장(왼쪽)과 지휘관의 배정·근거(오른쪽)

5 실험 설계

실험의 목적은 두 계층의 기여를 분리하여 식별하는 것이다. 이를 위해 배정 축과 기동 축을 각각 이분한 2×2 조건 행렬을 두고, 모든 조건을 같은 시드 집합으로 수집해 시드 대응 차이로 판정한다.

5.1 실험 환경

시뮬레이터·관측 래스터화·평가 하네스는 자체 구현이며 공개한다(Data availability 참조). 교전 설정값은 Table 1, 지표는 Table 2를 따르고, 두 계층 모두 25 step

주기로 결정하며 지휘관 재계획도 매 결정마다 수행한다. 지휘관은 로컬 모델(Qwen2.5 7B·14B)과 클라우드 모델(Gemini 3.5 Flash-Lite)이며, 세 모델 모두 온도 0, 같은 프롬프트, 같은 JSON 스키마의 구조적 출력(4.6절)을 사용한다.

학습은 질점 운동학 시뮬레이터에서 수행하고, 학습된 정책의 성능은 선체 거동과 충돌을 물리 엔진으로 다루는 언리얼 엔진 환경(Fig. 14)에서 검증한다. 6절의 통계 비교는 같은 시드 집합을 조건마다 되풀이 수집해야 하므로 질점 시뮬레이터에서 수행하였다.



Figure 14: 언리얼 엔진 기반 검증 환경. 위: 교전에 쓰는 세 에셋(그물벽, 아군 방어정, 적 자폭 USV). 아래: 모션 방어 운용 화면과 적 자폭 USV의 폭발 장면. 학습된 정책의 성능은 이 환경에서 물리 기반으로 검증하며, 학습에는 쓰지 않는다.

시뮬레이터 충실도 결과의 적용 범위는 시뮬레이터의 생략에 좌우되므로, 물리·판정 모델과 그 단순화를 Table 6에 모았다. 실전 동역학 [28] 대신 쓴 질점 운동학, 규칙 기반의 반응형 적, 설치 후 고정되는 그물벽과 접촉 즉시 포획, 잡음 없는 완전 관측은 모두 방어 쪽에 유리한 가정이다. 따라서 포획률은 상한에 가깝게 읽어야 하고, 조건 간 상대 비교는 네 조건이 같은 가정을 공유하므로 유효하다.

5.2 학습 실행

학습은 실해역 6곳(Fig. 15)을 에피소드마다 돌려가며 진행하여 정책이 한 해안선의 형상을 외우지 않게 했고, 평가는 그중 한 곳(통영 매물도 서측)에서 한다. 총 800 업데이트(설정은 Table 7)를 돌리며 200 업데이트마다 greedy 평가를 두고, 그 **최고점의 가중치**를 채택하였다 — 600 업데이트, 포획률 0.805로 휴리스틱 기준선 0.744를 넘는다. 학습 곡선은 매 업데이트 새로 표집한 전장의 난이도로 진동하므로 채택 판정은 고정 프로토콜의 greedy 평가로 한다.

5.3 조건과 수집

휴리스틱 배정과 기동은 4.3절의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직접 비교 가능하다(Table 8). 전략 계층에는 능력 수준이 다른 세 모델, 즉 로컬 Qwen2.5 7B·14B와 클라우드 Gemini 3.5 Flash-Lite를 두어 총 8조건이 된다. 모든 조건은 동일한 시드 집합(0–29)과 세 포메이션을 사용하며, 8조건 × 3포메이션 × 30시드 = 720 에피소드를 수집하였다.

기동 정책의 갱신 규칙 자체를 검증하기 위해, 같은 액터·관측·행동공간·보상·행동복제 초기화 위에서 갱신 규칙만 MAPPO [11](중앙 크리틱 + PPO clip)로 바꾼 정책을 학습 시드 3개로 학습하였다(6.1.2절). 환경 step 예산은 GRPO 채택 런과 같게 맞추고, 학습률·epoch·clip은 예비 런에서 가장 높았던 값을 썼다. 같은 greedy




Figure 15: 학습에 쓴 실해역 6곳의 육지 마스크(별표 모선, 파선 원 요격 구역)

평가로 최고점을 채택하고, 세 정책을 `heur_unet`과 같은 프로토콜로 평가해 GRPO와 시드 대응 비교한다.

5.4 판정 기준과 계층

조건 X 와 기준선 Y 의 시드 $k(k = 1, \dots, n_s, n_s = 30)$ 지표값을 x_k, y_k , 대응 차이 d_k 의 표준편차를 s_d 라 할 때 차이의 평균과 효과크기는

$$d_k = x_k - y_k, \quad \bar{d} = \frac{1}{n_s} \sum_k d_k, \quad d_z = \frac{\bar{d}}{s_d} \quad (33)$$

이며, $\bar{d}$ 의 95% 신뢰구간은 편향 보정·가속(bias-corrected and accelerated, BCa) 부트스트랩 [29, 30] ($B = 9999$)으로 구한다. 구간이 0을 포함하면 기준선과 다르다고 말하지 않으며, 지표 10개의 다중비교에는 Bonferroni 보정 구간(99.5%)을 병기한다. 두 계층의 상호작용은 배정 축 $a \in \{H, L\}$ (휴리스틱, LLM)과 기동 축 $m \in \{H, U\}$ (휴리스틱, U-Net)로 조건을 (a, m)

Table 6: 시뮬레이터의 물리·판정 모델과 단순화(\$7.2)

요소	모델과 설정값	단순화
시간	$\Delta t = 1$ s; 에피소드 상한 2,000 step	결정 주기 고정
방어정 운동	정속 6.0 m/s; 최대 선회 $8^\circ/\text{step}$; 경유점 도착 반경 200 m	관성·조류·파랑 없는 질점 운동학
적 운동	정속 9.0 m/s; 모선 방위 추종 + 사인 위빙; 최대 선회 $5^\circ/\text{step}$	학습·통신 없는 규칙 기반
적 회피	전방 500 m 의 설치 그물·육지에 $\pm 32^\circ$ 측면 조향	배치 패턴을 학습하지 않는 지역적 반응
스폰	집중·양동 반경 5,450 m; 파상 4,000 m 부터 1,000 m 간격 3단; 방위는 시드 별 무작위	도메인 랜덤화 없는 고정 구조
그물벽	두 픽셀을 잇는 선분, 최대 450 m; 이동하며 전개	설치 후 고정, 표류·유실 없음
포획·돌파	포획 = 설치 그물 칸 진입; 돌파 = 모선 260 m 진입	엄밀 지연·부분 손상 없음
충돌	방어정 상호 115 m, 모선 300 m, 육지, 설치 그물 진입; 해당 방어정 비활성화	접촉 즉시 완전 상실
공간 격자	물리·충돌·그물 격자 200×200 , 63 m/칸	관측·행동 격자는 이보다 4배 거침
관측	전 선박의 위치·헤딩·잔여 그물 완전 관측	센서 잡음·지연·탐지 실패 없음
육지	OpenStreetMap 해안선 래스터; 학습 6곳(Fig. 15), 평가 통영 매물도 서측	수심·조석 없음

Table 7: 기동 정책 학습 설정. 수식 기호는 §4를 따른다.

구분	항목	값
환경	병렬 전장 수 N	24
	학습 포메이션	집중·양동·파상 순환
	적당 그물 (학습 / 평가)	1 / 3
	학습 해역	실해역 6곳 순환
GRPO	그룹 크기 G (휴리스틱 포함)	8
	롤아웃 창 H	180 step
	이득 정규화	휴리스틱 기준·그룹 표준편차
	분산 임계 ϵ_{var}	10^{-6}
	크레딧 배분	결합(joint)
최적화	옵티마이저	Adam
	총 업데이트 T	800
	학습률 $\eta_0 \rightarrow \eta_{\text{min}}$, 코사인	$10^{-4} \rightarrow 5 \times 10^{-6}$
	엔트로피 계수 $\lambda_0 \rightarrow \kappa \lambda_0$, 선형	$0.01 \rightarrow 0.001$
	가울기 노름 클립 g_{max}	1.0
BC 초기화	갱신 수 / 학습률	$300 / 3 \times 10^{-4}$
	라벨 가우시안 σ_{BC}	0.8 px (202 m)
	목표	기하 휴리스틱(§4.3)
평가·채택	greedy 평가 주기 (채택 런 / 재현 런)	200 / 100 업데이트
	채택 기준	평가 최고점 (600, 0.805)
	재현 런 시드	0, 1, 2

Table 8: 2×2 조건 행렬. 조건 사이에 달라지는 것은 두 스위치뿐이며, 체크포인트·환경 설정·난수 시드는 모두 동일하다.

조건	배정 $\times$ 기동	무엇을 측정하는가
heur_heur	휴리스틱 $\times$ 휴리스틱	기준선(baseline)
heur_unet	휴리스틱 $\times$ U-Net	기동 계층의 순수 기여 (LLM 미사용)
llm_heur	LLM $\times$ 휴리스틱	전략 계층의 순수 기여
llm_unet	LLM $\times$ U-Net	제안 체계(상호작용 포함)

으로 쓰고, 시드 k 의 지표값 x_k^{am} 에 대해

$$\text{Int}_k = (x_k^{\text{LU}} - x_k^{\text{LH}}) - (x_k^{\text{HU}} - x_k^{\text{HH}}) \quad (34)$$

의 평균과 신뢰구간을 식 (33)와 같은 절차로 구해 판정한다(> 0 상승, ≈ 0 가산, < 0 상쇄).

포획률은 체계 전체의 지표라 지휘관 계층의 기여를 가리므로, 계획 산출 시점에 확인 가능한 양을 따로 계측한다: 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지 (활성 무리 중 배정된 비율),

churn(재계획 간 담당을 바꾼 방어정 비율), 교차 배정(방어정-담당 무리 선분이 서로 교차하는 쌍의 수). 커버리지·churn·교차 배정은 에피소드 안의 재계획에 걸쳐 평균한다.

6 결과

5절의 2×2 설계는 두 계층의 기여를 따로 켜다. 이 절은 그 결과를 기동 계층 단독의 효과(6.1절), 지휘관 계층의 효과와 그것이 성립하는 조건(6.2절), 두 효과의 결합 방식(6.3절) 순으로 보고하고, 배치 관점의 지연 측정을 덧붙인다(6.4절).

6.1 기동 계층의 효과: 자원과 기동의 절감

6.1.1 기동 계층: 휴리스틱 대 U-Net 점수맵

언어모델 없이 4.3절의 기하 휴리스틱과 4.4절의 점수맵 정책만 비교한다. 배정은 둘 다 휴리스틱이므로 차이는 기동 방식뿐이다(Table 9). 3개 포메이션 통합 기준으로 포획률은 $0.844 \rightarrow 0.886$ (+0.041, $d_z = 0.37$)로 유의하게 개선되었다. 다만 지표 10개에 대한 다중비교 보정을 걸면 구간이 $[-0.013, +0.100]$ 로 0을 포함하여(5.4절) 이 개선은 유의성을 잃는다. 이 절의 요점은 포획률의 증가가 아니라 같은 정도로 막으면서 자원과 기동을 크게 줄인다는 데 있다.

같은 비교를 10개 지표 전부에 걸쳐 보인 것이 Fig. 16다. 각 축은 8개 조건의 범위로 0–1 정규화하여 바깥일수록 우수하다. U-Net 은 포획당 이동거리 축에서만 안쪽이다 — 자리를 골라 그물벽을 놓는 대신 더 멀리 움직인다. 충돌률·전개 시 적 거리 축은 겹치고, 나머지 일곱 축에서 바깥에 있다.

포메이션별로 보면 기여가 고르지 않다. 파상 포메이션에서는 +0.157($d_z = 0.48$)로 가장 크고, 집중 포메이션에서는 0.000, 양동 포메이션에서는 -0.033 으로 오히려 소폭 낮다. 다만 후자의 차이가 유의하지 않아 악화라고 말할 수 없다. 파상의 +0.157 이 소수 시드가 끄는 값은 아니다. 시드 대응 차이의 분포(Fig. 17)를 보

Table 9: 기동 계층(U-Net 점수맵 + GRPO)의 단독 기여. 두 조건 모두 배정은 휴리스틱이며 **LLM을 전혀 사용하지 않는다**. 기여는 파상 포메이션에서 가장 크다.

포메이션	휴리스틱 기동	U-Net 기동	Δ [95 % CI]	d_z
집중	0.997	0.997	+0.000 [-0.010, +0.010]	+0.00
양동	0.787	0.753	-0.033 [-0.077, +0.000]	-0.31
파상	0.750	0.907	+0.157 [+0.043, +0.270]*	+0.48
전체	0.844	0.886	+0.041 [+0.003, +0.082]*	+0.37

* 신뢰구간이 0을 포함하지 않음. 전체 행은 3개 포메이션 통합.




Figure 16: 휴리스틱 대 U-Net 기동의 지표 프로파일(바깥일수록 우수): (a) 전체, (b) 집중, (c) 양동, (d) 파상

면 30개 시드 가운데 15개에서 양, 12개에서 0, 3개에서 음이고 중앙값은 +0.050이다. 양동에서는 양 2개, 음 10개로 방향이 반대다. 이 대비가 다음 설명의 근거다.

이 분포는 3.1절의 포메이션 구조와 대응한다. 파상에서는 앞 단을 막은 그물벽의 위치가 뒤 단의 차단을 좌우하므로 해면 전체를 평가하는 점수맵이 직접 효과를 내고, 양동에서는 무리 수와 방어정 수가 같이 결정적인 것이 *배정*이라 배정이 어긋나면 기동이 보정하지 못한다. 집중은 6.2.1절에서 보이듯 천장 구간이다.

6.1.2 학습 알고리즘: 같은 행동공간의 그룹 상대 최적화와 MAPPO

점수맵 정책의 이득이 픽셀 지목이라는 표현에서 오는 지 가치망 없는 갱신 규칙에서 오는지를 가르기 위해, 같은 액터·행동공간·보상·예산 위에서 갱신 규칙만 MAPPO로 바꾼 정책 세 개를 같은 프로토콜로 평가하였다(Table 10, Fig. 18).

포획률은 같아지지 않는다. MAPPO 0.859와 GRPO 0.886의 차이는 유의하지 않고, 포메이션별 방향도 파상 개선·양동 저하로 같다. 같아지는 것은 *자원*과 *조기 제압*이다. MAPPO의 프로파일은 포획률·돌파 축을 빼면 휴리스틱 위에 그대로 겹치는 반면, GRPO는 포획당 그물을 0.568로 줄이고($d_z = -1.19$), 포획 이격 거리를 154m 늘리며($d_z = +1.21$), 평균 포획 시각과

전개 시 적 거리를 각각 12 step과 100m 앞당긴다. 네 지표 모두 다중비교 보정에서도 유의하다. MAPPO가 이기는 축은 포획당 이동거리 하나다.

즉 같은 표현을 공유하는 한 갱신 규칙은 포획률을 가르지 못하고, 그물 절약과 조기 제압만 갱신 규칙에 좌우된다. 휴리스틱 후보를 기준으로 삼는 그룹 상대 이득(4.5절)은 휴리스틱을 넘어서는 선택에만 양의 이득을 주어 휴리스틱의 자원 사용 패턴에서 벗어나는 반면, 팀 가치로 학습하는 MAPPO는 어느 배가 그물을 아꼈는지를 개별 배에 귀속시킬 신호가 약해 그 패턴을 물려받는 것으로 해석된다.

6.2 지휘관 계층의 효과와 성립 조건

6.2.1 전체 조건 비교

Table 11과 Fig. 19에 8개 조건의 포획률을 정리하였다. 그림의 무채색 두 막대가 언어모델 없는 기준선이고 그 오른쪽은 모델 규모 오름차순이다.

Gemini 지휘관을 쓴 두 조건이 기준선 대비 유의한 개선을 보인다(각각 +0.060, +0.062). 반면 Qwen2.5 7B는 두 기동 조건 모두에서 기준선보다 *유의하게 나쁘다* ($-0.192, -0.203$). 이 음의 결과는 6.2.2절에서 다룬다.

포메이션별 분해 통합 수치는 포메이션에 따라 다르게 읽어야 한다(Table 12). 집중 포메이션은 휴리스틱만으로 포획률 0.997에 도달하여 개선 방향으로는 어떤 방법도 변별되지 않고, 통합값은 이 구간이 3분의 1을 차지하여 희석된다. 양동과 파상만 보면 제안 체계의 개선은 각각 +0.090, +0.103으로 통합값 +0.062보다 크다. 반면 악화 방향으로는 이 구간도 변별력을 가져, Qwen2.5 7B 배정은 -0.157 ($[-0.323, -0.057]$)로 거의 완벽한 상황마저 악화시킨다. 즉 6.2.2절의 능력 임계는 가장 쉬운 포메이션에서도 관측된다.

6.2.2 지휘관 능력 임계

기동 계층을 휴리스틱으로 고정하여 지휘관 측만 분리하면, 모델 능력에 따른 단조 증가가 나타난다(Fig. 20).

3개 포메이션 통합 기준으로 Qwen2.5 7B는 0.652, Qwen2.5 14B는 0.811, Gemini는 0.904이며, 휴리스틱 기준선은 0.844이다. 즉 **휴리스틱 선을 14B와 Gemini 사이에서 교차한다**.

함의는 “LLM 지휘관을 쓰면 좋다”가 아니라 “**일정 능력에 못 미치는 지휘관은 코드 휴리스틱보다 못하다**”




Figure 17: 시드 대응 차이의 분포(포획률, 기준선 *heur_heur* 대비). 점은 시드, 마름모는 평균과 BCa 95 % 신뢰구간; 왼쪽 열은 기동 계층 단독(*heur_unet*), 오른쪽 열은 제안 체계(*llm_unet*, Gemini).

Table 10: 같은 픽셀 행동공간 위의 학습 알고리즘 비교. 배정은 모두 휴리스틱이며 기동 정책의 액터·보상·초기화·환경 step 예산이 같고 갱신 규칙만 다르다. MAPPO 는 학습 시드 3런의 에피소드별 평균, Δ 는 GRPO – MAPPO 의 시드 대응 차이.

지표	휴리스틱	MAPPO	GRPO(채택)	Δ [95 % CI]	d_z
포획률 $\uparrow$	0.844	0.859	0.886	+0.026 [-0.003, +0.056]	+0.31
돌파 수 $\downarrow$	1.56	1.41	1.14	-0.26 [-0.57, +0.03]	-0.31
충돌률(적당) $\downarrow$	0.130	0.138	0.119	-0.020 [-0.047, +0.004]	-0.27
그물 걸림 $\downarrow$	0.82	0.70	0.62	-0.08 [-0.23, +0.05]	-0.20
포획당 그물 $\downarrow$	0.737	0.733	0.568	-0.165 [-0.213, -0.116]* [†]	-1.19
포획당 이동거리 (m) $\downarrow$	825	813	896	+82 [+40, +139]* [†]	+0.59
총 선회량 (rad) $\downarrow$	1625	1541	1464	-77 [-158, +17]	-0.31
포획 이격거리 (m) $\uparrow$	1511	1523	1678	+154 [+112, +202]* [†]	+1.21
평균 포획 시각 (step) $\downarrow$	430	430	418	-12 [-19, -5]* [†]	-0.58
전개 시 적 거리 (m) $\downarrow$	1499	1525	1425	-100 [-154, -51]* [†]	-0.68

* 95 % 구간이 0 을 배제. [†] Bonferroni 보정(99.5 %)에서도 배제. MAPPO 런별 포획률 0.876, 0.838, 0.864. 3개 포메이션 통합(각 조건 30시드).

Table 11: 조건별 포획률. 평균과 부트스트랩 95 % 신뢰구간, baseline 대비 대응표본 차이. 3개 포메이션 통합(각 조건 30시드).

지휘관(배정)	기동	포획률 [95 % CI]	Δ vs baseline	d_z
휴리스틱 (baseline)	휴리스틱	0.844 [0.808, 0.880]	—	—
휴리스틱	U-Net 점수맵	0.886 [0.847, 0.918]	+0.041 [+0.003, +0.082]*	+0.37
Qwen2.5 7B	휴리스틱	0.652 [0.571, 0.716]	-0.192 [-0.264, -0.129]*	-1.00
Qwen2.5 14B	휴리스틱	0.811 [0.766, 0.854]	-0.033 [-0.086, +0.017]	-0.23
Gemini 3.5 Flash-Lite	휴리스틱	0.904 [0.864, 0.937]	+0.060 [+0.024, +0.100]*	+0.56
Qwen2.5 7B	U-Net 점수맵	0.641 [0.582, 0.693]	-0.203 [-0.274, -0.138]*	-1.03
Qwen2.5 14B	U-Net 점수맵	0.754 [0.698, 0.806]	-0.090 [-0.153, -0.033]*	-0.54
Gemini 3.5 Flash-Lite	U-Net 점수맵	0.907 [0.869, 0.937]	+0.062 [+0.013, +0.113]*	+0.44

* 신뢰구간이 0 을 포함하지 않음. d_z 는 대응표본 효과크기. 첫 두 열이 2×2 설계의 두 축이다. 같은 지휘관 행 두 개를 비교하면 기동 계층의 기여가, 같은 기동 열을 비교하면 지휘관의 기여가 나온다. Qwen2.5 는 로컬(단일 RTX 4070) 서빙, Gemini 는 클라우드 API 다.




Figure 18: 같은 픽셀 행동공간 위의 휴리스틱·MAPPO·GRPO 기동의 지표 프로파일(바깥일수록 우수)

Table 12: 포메이션별 천장 효과. 집중 포메이션은 baseline 이 이미 0.997 이라 개선 여지가 0.003 뿐이므로 이 포메이션 단독으로 결론을 내면 안 된다.

포메이션	baseline	남은 여유	제안	Δ
집중	0.997	0.003	0.990	-0.007
양동	0.787	0.213	0.877	+0.090*
파상	0.750	0.250	0.853	+0.103

* 신뢰구간이 0 을 포함하지 않음.

이며, 7B의 유의한 악화(-0.192 , $d_z = -1.00$)가 이 임계 주장의 근거다.

7B가 어디서 지는지는 휴리스틱 배정과의 일치율이 보여 준다. 계획 호출마다 같은 상태에 4.3절의 코드가 널 배정을 함께 계산하고, 방어정별로 언어모델의 배정이 그것과 같은 비율을 재면(Fig. 21) 평균 일치율은 7B 0.391, 14B 0.538, Gemini 0.591 이고 세 방어정이 모두 일치한 호출의 비율은 각각 0.215, 0.365, 0.374 이다. 7B는 휴리스틱과 다르게 배정하는 일이 가장 많고 그




Figure 19: 포메이션별·조건별 포획률(색: 지휘관, 빗금: 기동 계층, 오차막대: 시드 부트스트랩 신뢰구간)




Figure 20: 지휘관 능력 사다리(기동 계층 휴리스틱 고정, 점선: 휴리스틱 배경 기준선)

결과는 기준선 아래다. 즉 임계 아래 모델의 이탈은 판단이 아니라 오류다. 다만 Gemini 도 호출의 41 %에서 휴리스틱과 다르게 배경하면서 기준선을 넘었으므로 일치율이 높을수록 좋다는 뜻은 아니며, 임계 위의 모델은 벗어나되 맞게 벗어난다.

6.2.3 지휘관 성능의 결정 요인

능력 순위는 모델 세대가 바뀌면 의미를 잃으므로, 더 오래 남은 질문은 무엇이 성능을 만드는가이다. 계획 단위 계층 결과를 Table 13와 Fig. 22에 정리하였다(점 하나가 지휘관 모델 하나, 오차막대는 양방향 부트스트랩 95% 신뢰구간; $n = 3$ 이라 회귀선·상관계수는 없지 않았다).

결정적 관측은 Qwen2.5 7B가 커버리지는 가장 높은데(0.934) 포획률은 가장 낮다(0.652)는 것이다. 즉 막아야 할 무리를 배경하지 않아서 지는 것이 아니다.

성능과 단조로 대응하는 것은 churn과 경로 교차이다. churn은 0.324 → 0.167 → 0.098, 경로 교차는 0.152 → 0.111 → 0.033 으로 능력축을 따라 감소하며, 같은 순서로 포획률은 0.652 → 0.811 → 0.904 로 증가한다(모두 기동 계층을 휴리스틱으로 고정한 조건). churn 0.324는 재계획마다 방어정의 약 3분의 1이 담당을 바꾼다는 뜻이며, 이는 반쯤 전개한 그물벽을 버리고 떠난다는 것을 의미한다. 경로 교차는 두 방어정이 서로의 진로를 가로지르는 배경이다.

이 관찰이 제시하는 설계 원리는 주기적으로 재계획

하는 구조에서는 계획의 최적성보다 안정성이 중요하다(7절).

6.3 두 기여의 결합

6.3.1 두 계층 기여의 가산성

식 (34)의 상호작용을 10개 지표 전부에 대해 계산하였다(Table 14, Fig. 23). 그림의 (a)에서 두 선이 평행에 가까울수록 두 계층의 기여가 가산적이고, (b)의 속이 빈 표식은 유의하지 않은 차이이다. (a)에 오차막대를 두지 않은 것은 대응이 풀린 셀별 구간이 시나리오 난이도의 분산을 포함해 넓어 유의한 대응 차이를 가리기 때문이며, 불확실성은 전부 (b)에 있다.

10개 지표 중 9개에서 상호작용이 유의하지 않고, 다중비교 보정 후에도 그대로 9개다. 두 계층은 서로를 돕지도 잠식하지도 않는다. 본 논문은 이를 상승효과로 해석하지 않고 가산적이라고 보고한다. 두 계층이 서로 다른 실패 모드를 다루므로 기여가 독립적으로 누적된다.

한 가지 예외는 평균 포획 시각이다. 상호작용 -11.98 , 95% 구간 $[-19.84, -5.93]$ 의 유의한 상쇄이며 보정 구간 $[-23.31, -3.54]$ 에서도 살아남는다. 두 계층 모두 제압을 앞당기는 방향으로 작용하는데 같은 포획을 두 번 앞당길 수는 없으므로, 공유 메커니즘에 대한 수확제감이다.

포메이션별로 보면 두 계층의 분업이 드러난다. 양동 포메이션에서는 기동 계층 단독 (-0.033)도 전략 계층 단독 ($+0.070$)도 유의하지 않은데, 둘을 결합하면 $+0.090$ 으로 유의해진다. 무리 수와 방어정 수가 같아 여유가 없는 이 포메이션에서는 배경과 기동이 둘 다 맞아야 막히며, 2계층 설계의 효과가 드러나는 지점이 여기다. 반대로 단이 시간차를 두고 오는 파상에서는 기동 계층 단독($+0.157$)이 이미 유의하며 결합이 그보다 낮지 않다.

6.3.2 지표별 효과크기와 다중비교 보정

3.2절에서 정의한 10개 지표 전부에 대해 제안 체계와 기준선의 대응 차이를 계산하였다. 비교는 제안 체계




Figure 21: 휴리스틱 배정과의 일치율. (a) 모델별 평균 일치율(95 % 신뢰구간)과 완전 일치 호출 비율(빗금), (b) 일치율 대 포획률(기동 계층 휴리스틱 고정; 파선은 휴리스틱 배정 기준선 0.844).




Figure 22: 계획 품질 대 성능: (a) 배정 커버리지, (b) 재계획 간 churn, (c) 경로 교차

Table 13: 지휘관 계획 품질과 성능. 계획 품질은 시뮬레이션 결과와 독립적으로, 계획이 산출된 시점에 측정한다. 7B는 커버리지가 가장 높은데 포획률은 가장 낮다. 실패 원인은 미배정이 아니다.

지휘관	커버리지 ↑	churn ↓	교차 ↓	포획률 ↑
Qwen2.5 7B	0.934	0.324	0.152	0.652
Qwen2.5 14B	0.877	0.167	0.111	0.811
Gemini 3.5 Flash-Lite	0.881	0.098	0.033	0.904

커버리지 = 배정된 활성 클러스터 비율. churn = 재계획 간 담당이 바뀐 배의 비율. 교차 = 두 방어정의 요격 경로가 교차한 비율. 포획률은 기동 계층을 휴리스틱으로 고정한 조건(LLM 지휘관 + 휴리스틱 기동)의 값이다. 세 모델 모두 언어모델 호출이 실패해 휴리스틱이 대신 배정한 비율은 0.007 이하였으므로, 배정은 사실상 전부 언어모델이 낸 것이다.




Figure 23: 2 × 2 상호작용(Gemini 지휘관): (a) 네 셀의 포획률을 평균, (b) 시드 대응 차이와 BCa 신뢰구간

11m_unet@Gemini와 기준선 `heur_heur` 사이이며, 결과는 Table 15와 Fig. 24에 있다. 그림의 d_z 구간은 평균차의 BCa 구간을 $sd(d)$ 로 나눈 것이라 표의 판정과 같은 사건이다.

포획률의 효과크기는 $d_z = 0.44$ 로 측정한 10개 지표 중 최하위권이며, 총 선회량의 7분의 1 수준이다. 가장 크게 개선된 것은 기동 비용과 자원 효율이다. 총 선회량은 1625에서 868로 47% 줄어 $d_z = -3.23$, 포획

당 그물은 0.737에서 0.409로 45% 줄어 -2.09 , 그물 걸림은 0.82에서 0.22로 73% 줄어 -1.19 이고, 포획 이격거리는 1511에서 1734m로 늘어 $+1.81$ 이다.

다중비교 보정을 걸면 이 대조가 더 분명해진다. 10개 중 8개는 그대로 유의하지만 포획률과 돌파 수는 유의성을 잃는다. 포획률의 보정 구간은 $[-0.003, +0.132]$ 로 유의성을 잃으며, 6.1.1절의 기동 계층 단독 조건도 같다. 보정을 건디지 못하는 것은 “더 많이 막는다”는

Table 14: 2×2 상호작용 분해 (Gemini 지휘관). 10개 지표 중 9개에서 상호작용이 유의하지 않으므로 두 계층의 기여는 가산적이다.

지표	총효과	상호작용 [95% CI]
포획률	+0.062	-0.039 [-0.083, +0.012]
돌파 수	-0.62	+0.39 [-0.13, +0.83]
충돌률(적당)	-0.052	-0.015 [-0.070, +0.022]
그물 걸림	-0.60	+0.17 [-0.08, +0.41]
포획당 그물	-0.328	+0.004 [-0.045, +0.059]
포획당 이동거리 (m)	-182	-55 [-125, +30]
총 선회량 (rad)	-757	-56 [-165, +59]
포획 이격거리 (m)	+223	+38 [-2, +81]
평균 포획 시각 (step)	-22	-12 [-20, -6]*
전개 시 적 거리 (m)	-371	+26 [-44, +109]

상호작용 = (LLM+U-Net - LLM+휴리스틱) - (휴리스틱+U-Net - baseline). 표식 * 은 유의한 상호작용이며, 나머지는 두 계층이 서로를 돕지도 잡아먹지도 않는다는 뜻이다.

Table 15: 전 지표 효과크기 (제안 = LLM 지휘관 + U-Net 점수맵, Gemini). $|d_z|$ 내림차순. 포획률이 가장 둔한 지표이며, 다중비교 보정에서 유의성을 잃는 유일한 방어 성과 지표다.

지표	방향	baseline	제안	Δ	d_z
총 선회량 (rad)	↓	1625	868	-757*†	-3.23
포획당 그물	↓	0.737	0.409	-0.328*†	-2.09
포획 이격거리 (m)	↑	1511	1734	+223*†	+1.81
전개 시 적 거리 (m)	↓	1499	1128	-371*†	-1.60
그물 걸림	↓	0.82	0.22	-0.60*†	-1.19
평균 포획 시각 (step)	↓	430	408	-22*†	-1.04
포획당 이동거리 (m)	↓	825	643	-182*†	-0.65
충돌률(적당)	↓	0.130	0.078	-0.052*†	-0.52
돌파 수	↓	1.56	0.93	-0.62*	-0.44
포획률	↑	0.844	0.907	+0.062*	+0.44

방향 ↑ = 높을수록 좋음, ↓ = 낮을수록 좋음. * 95% 신뢰구간이 0 을 포함하지 않음. † 지표 10개에 대한 Bonferroni 보정(99.5% 구간)에서도 0 을 배제함(단검이 없는 행은 보정을 건디지 못한다).




Figure 24: 제안 대 기준선의 전 지표 효과크기 d_z . 굵은 선은 신뢰구간, 얇은 선은 다중비교 보정 구간이며, 속이 빈 표식은 보정 후 유의성을 잃는 지표다.

주장이고, 건디는 것은 “같은 정도로 막으면서 자원과 기동과 위험을 크게 줄인다”는 주장이다. 포획률의 효과크기가 작은 까닭은 6.2.1절의 천장이며, 효율 지표에는 그러한 천장이 없다.

6.4 지휘관 응답 지연

응답 지연은 모델 규모에 단조가 아니다(Table 16). 로컬 14B가 16.59초인 데 비해 클라우드 모델은 1.56초로, 로컬이 10.6배 느리다. 한 결정 주기가 25초 (25 step × $\Delta t = 1$ s)이므로 14B의 평균 지연은 주기의 약 3분의 2




Figure 25: 지휘관 응답 지연의 경험 누적분포(파선은 결정 주기)

를 소모한다.

평균만 보면 주기 안에 들어오지만, 결정적인 것은 분포의 꼬리다 (Table 16, Fig. 25). 14B 호출 5,366건 가운데 4.2%가 25초 주기를 초과하였고, 99 백분위는 27.8초, 최댓값은 296.4초였다. 동기 구조라면 이 4.2%마다 제어 루프가 실제로 정지한다. 반면 클라우드 모델은 최댓값이 2.75초로 주기의 11%에 그쳐 동기 호출로도 여유가 있다.

이 수치의 측정 구성에는 교란 요인이 있으나(Table 16 주석), 결론은 같다. 4.1절의 비동기 설계는 클라우드

Table 16: 지휘관 응답 지연 분포. 결정 주기 25초와 비교한다. 로컬 14B만 주기를 초과하는 꼬리를 갖는다.

지휘관	n	평균	p_{99}	최대	> 25 초
Qwen2.5 7B (로컬)	4,299	2.75	7.08	10.06	0.0 %
Qwen2.5 14B (로컬)	5,366	16.59	27.81	296.41	4.2 %
Gemini (클라우드)	3,882	1.56	2.30	2.75	0.0 %

단위는 초. 로컬 모델은 학습·평가와 GPU 한 대를 공유한 워크스테이션에서 4비트 양자화로 서빙하였다. 14B의 최댓값 296초는 가중치 재적재를 시사하며, 이 꼬리가 로컬 중형 모델의 본질인지 자원 공유의 결과인지는 본 실험으로 구분되지 않는다. 읽어야 할 것은 로컬 중형 모델의 지연이 결정 주기를 넘길 수 있다는 정성적 사실이다.

배치에서는 선택이지만 로컬 배치에서는 지연 꼬리에 대한 안전장치다.

7 고찰 및 결론

7.1 결과의 해석

6절의 결과를 실무 판단으로 옮기면 세 가지다. 기동 계층은 언어모델 없이도 같은 방어 성과를 더 적은 자원으로 내므로 조건 없이 넣는다. 지휘관 계층은 능력 임계를 넘는 모델에만 켜다. 본 실험에서 그 경계는 로컬 14B와 클라우드 모델 사이였고 로컬 7B는 코드 휴리스틱보다 유의하게 나뉘었다(6.2.2절). 두 계층의 기여는 가산적이므로(6.3절) 지휘관 모델 교체와 기동 정책 재학습을 독립적으로 진행할 수 있다.

지휘관의 성능을 설명하는 것은 커버리지가 아니라 재계획 간 계획 안정성이라는 관찰(6.2.3절)의 함의는 다음과 같다. 주기적으로 재계획하는 계층 구조에서 상위 결정의 변경은 하위 계층에 *전환 비용*(회수되지 않는 이동과 그물)을 발생시킨다. 상위 계층이 매 재계획마다 순간 최적을 추구하면 이 비용이 누적되어 국소적으로 나은 배정이 전역적으로 손해가 된다. 언어모델은 매 호출이 독립적이라 이 일관성이 구조적으로 보장되지 않으므로, 직전 배정을 상태에 포함시키고 담당 무리를 방위로 식별하게 한 것이 그 대응이다. 따라서 언어모델을 계획 계층에 둘 때는 계획 품질을 국소 최적성이 아니라 *시간에 걸친 일관성*으로 평가해야 하며, 프롬프트와 상태 표현이 그 일관성을 지원해야 한다.

가장 큰 개선이 총 선회량($d_z = -3.23$, 6.3.2절)에서 나타난 것은 점수맵 표현의 성질과 직결된다. 경유점이 격자에 고정되므로 연속 회귀의 미세 진동이 구조적으로 배제되어 궤적이 부드러워진다. 포획당 그물 소모의 감소(-45%) 역시 유효 마스크가 배정 무리의 방위 조건과 사거리 제약을 행동 분포에 직접 부과해 무의미한 위치의 그물벽이 애초에 표현되지 않기 때문이다. 이 이득이 점수맵의 *다봉* 표현력에서 오는 것은 아니다. 학습된 체크포인트로 6,652회의 결정을 수집하면, 유효 마스크가 남기는 셀은 결정당 평균 10.5%(2,500칸 중 264칸, 범위 6–12%)에 그쳐 격자의 약 90%가 매 결정마다 행동 분포에서 제거된다(Fig. 26a). 그 안에서 점수맵의 조건부 평균(연속 좌표 회귀가 수렴할 점)과 최빈 셀(정책이 실제로 고르는 점) 사이 거리는 중앙값 0.3셀(75 m)이고, 결정의 98.8%가 한 셀(252 m) 안에서 정해진다(Fig. 26b). 즉 점수맵은 거의 단봉이며, 이득은 분포의 모양이 아니라 유효 셀을 좁히는 마스크와 격자 양자화에서 온다.

7.2 한계와 향후 과제

시뮬레이션 한정. 모든 결과는 시뮬레이션에서 얻었으며 그물 거동·엄힘 판정·관측이 단순화되어 있다(Table 6). 이 가운데 관측 불확실성은 배정이 의존하는 무리 구성을 흔들어 *churn*을 직접 키우므로, 점수맵 정책보다 지휘관 계층에 더 크게 작용할 것이다. 지연 측정이 GPU 공유 구성의 교란을 받는 점은 Table 16의 주석에 밝혔다.

폐쇄형 모델 의존. 가장 좋은 지휘관은 상용 API의 폐쇄형 모델이라 그 수치의 장기 재현은 보장되지 않고, 능력 임계의 위치(6.2.2절)도 시점 의존적이다. 근거 원문을 저장하지 않아 판단 근거의 사후 검토가 제한된다. 기동 계층 단독 조건은 언어모델을 쓰지 않으므로 이 위험과 무관하게 재현된다.

규모와 일반화. 실험은 적 10척 대 방어정 3척의 고정 규모이며, 방어정 수가 늘어 배정 조합이 급증할 때 능력 임계가 어디로 이동하는지는 측정되지 않았다. 세 공격 포메이션은 규칙 기반이고, 그물벽 배치 패턴을 학습해 회피하는 적응적 적은 범위 밖이다. 학습 알고리즘 비교는 같은 픽셀 행동공간 위의 MAPPO 한 종에 한정되며(6.1.2절), 관례적인 연속 행동공간의 MARL 기준선, 같은 백본의 좌표 회귀 출력, FiLM·좌표 채널·유효 마스크의 구성요소별 절제는 남은 과제다.

7.3 결론

시드 대응 2×2 설계로 두 계층의 기여를 분리 측정한 720 에피소드에서 세 가지가 얻어졌다. 첫째, 두 계층의 기여는 **가산적**이다. 10개 지표 중 9개에서 상호작용이 유의하지 않았고, 본 논문은 이를 상승효과로 해석하지 않았다. 둘째, **체계의 이득은 포획률보다 자원·기동 지표에서 크다**. 효과크기로 총 선회량(-3.23)과 포획당 그물 소모(-2.09)의 개선이 포획률(+0.44)보다 훨씬 크고, 다중비교 보정을 걸면 10개 지표 중 8개가 건디는데 포획률과 돌파 수만 유의성을 잃는다. 제안 체계의 실질적 이득은 “더 많이 막는다”보다 “같은 정도로 막으면서 훨씬 적은 자원과 위험으로 해낸다”에 있다. 셋째, **언어모델 지휘관에는 능력 임계가 존재하며**, 그 성능을 설명하는 것은 배정 커버리지가 아니라 재계획 간 계획 안정성이다. 가장 낮은 성능의 모델이 오히려 커버리지는 가장 높았다는 관측은 주기적 재계획 구조에서 최적성보다 일관성이 중요하다는 설계 원리를 시사한다.

검증은 시뮬레이션에 한정되며, 실해역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.




Figure 26: 학습된 점수맵의 첩예도: (a) 결정당 유효 셀 비율, (b) 조건부 평균과 최빈 셀 사이 거리(격자 셀 단위)

CRediT authorship contribution statement

[투고 전 저자 확인 필요] 아래는 CRediT 분류에 따른 초안이며, 각 저자의 실제 기여로 교체하여야 한다.

윤영준: 개념 설계, 방법론, 소프트웨어, 검증, 형식 분석, 조사, 자료 큐레이션, 초고 작성. **방현태:** 소프트웨어, 검증, 시각화. **전유라:** 방법론, 조사, 검토 및 편집. **김덕환:** 검토 및 편집, 감독. **윤원근:** 개념 설계, 감독, 연구 관리, 자원 획득.

Declaration of competing interest

[투고 전 저자 확인 필요] 저자들은 본 논문에 보고된 연구에 영향을 미칠 수 있는 경쟁적 재정적 이해관계나 개인적 관계가 없음을 선언한다.

Declaration of generative AI and AI-assisted technologies in the writing process

원고 작성 과정에서 저자들은 문헌 정리, 초고 문장 다듬기, $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ 조판 및 도판 생성 스크립트 작성에 생성형 인공지능 보조 도구를 사용하였다. 모든 실험 설계, 데이터 수집, 수치 산출과 해석은 저자들이 수행하였으며, 저자들은 원고 전체를 검토하고 그 내용에 대해 전적인 책임을 진다.

Acknowledgements

[투고 전 저자 확인 필요] 과제 번호와 지원 기관명을 확인하여 채워야 한다. 국가과제는 보통 2건까지 중복 사자가 허용된다.

본 연구는 [지원 기관·과제명·과제번호]의 지원을 받아 수행되었다.

Data availability

본 연구의 결과를 재현하는 데 필요한 자료는 다음과 같이 구성된다.

- **원 자료:** 720 에피소드의 에피소드별 지표 (`episodes.csv`) 및 계획 호출 계층 값 (`llm_metrics.csv`). 본문의 모든 표와 그림은 이 두 파일에서 기계적으로 생성되며 (`tools/make_paper_tables.py`, `boatattack_sim/eval/paper_figs.py`), 손으로 옮겨 적은 수치는 없다.
- **정책 체크포인트:** 기동 계층의 가중치와 그 학습 설정 (`u-net_map.pt`). 설정은 체크포인트 안에 함께 저장되어 있어 별도 설정 파일 없이 복원된다.
- **시뮬레이터:** 환경, 관측 래스터화, 평가 하네스 전체.

[투고 전 공개 URL 기입 필요] 위 자료는 논문 게재 시 공개 저장소를 통해 배포한다.

보존하지 않은 것. 언어모델이 생성한 판단 근거 (`rationale`)의 원문은 저장하지 않았고, 길이만 계층 하였다. 따라서 근거 문장 자체에 대한 사후 분석은 본 자료로 재현할 수 없다(7.2절). 또한 상용 API로 제공되는 폐쇄형 지휘관 모델은 버전이 갱신되거나 서비스가 종료될 수 있어, 그 조건의 수치가 시점에 따라 달라질 수 있다. 언어모델을 쓰지 않는 조건(`heur_heur`, `heur_unet`)은 이 위험 없이 재현 가능하다.

References

- [1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., 2007. Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem. *Operations Research*, 55(6), pp.1136–1146.
- [2] Wang, J., Liu, Y. and Song, H., 2021. Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends. *IEEE Aerospace and Electronic Systems Magazine*, 36(3), pp.4–29.
- [3] Sutea, V., 2026. *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*. Atlantic Council UkraineAlert, 24 February 2026.
- [4] Rumbaugh, W., 2024. *Cost and Value in Air and Missile Defense Intercepts*. Washington, DC: Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024.
- [5] Kuhn, H.W., 1955. The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly*, 2(1–2), pp.83–97.

- [6] Liu, Z., Zhang, Y., Yu, X. and Yuan, C., 2016. Unmanned surface vehicles: An overview of developments and challenges. *Annual Reviews in Control*, 41, pp.71–93.
- [7] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., 2025. Multi-USV cooperative target encirclement through learning-based distributed transferable policy and experimental validation. *Ocean Engineering*, 318, 120124.
- [8] Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P. and Mordatch, I., 2017. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [9] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., 2018. QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning. *International Conference on Machine Learning (ICML)*, pp.4295–4304.
- [10] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., 2018. Counterfactual Multi-Agent Policy Gradients. *AAAI Conference on Artificial Intelligence*, pp.2974–2982.
- [11] Yu, C., Velu, A., Vinitisky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., 2022. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. *Advances in Neural Information Processing Systems 35 (NeurIPS)*.
- [12] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. and Klimov, O., 2017. Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*.
- [13] Haarnoja, T., Zhou, A., Abbeel, P. and Levine, S., 2018. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. *International Conference on Machine Learning (ICML)*, pp.1861–1870.
- [14] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. and Guo, D., 2024. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. *arXiv preprint arXiv:2402.03300*.
- [15] Long, J., Shelhamer, E. and Darrell, T., 2015. Fully Convolutional Networks for Semantic Segmentation. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp.3431–3440.
- [16] Ronneberger, O., Fischer, P. and Brox, T., 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp.234–241.
- [17] Liu, R., Lehman, J., Molino, P., Petroski Such, F., Frank, E., Sergeev, A. and Yosinski, J., 2018. An Intriguing Failing of Convolutional Neural Networks and the CoordConv Solution. *Advances in Neural Information Processing Systems 31 (NeurIPS)*.
- [18] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., 2018. FiLM: Visual Reasoning with a General Conditioning Layer. *AAAI Conference on Artificial Intelligence*, pp.3942–3951.
- [19] Vinyals, O., Fortunato, M. and Jaitly, N., 2015. Pointer Networks. *Advances in Neural Information Processing Systems 28 (NeurIPS)*.
- [20] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł. and Polosukhin, I., 2017. Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [21] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., 2022. Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents. *International Conference on Machine Learning (ICML)*, pp.9118–9147.
- [22] Ahn, M., Brohan, A., Brown, N., et al., 2022. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances. *Conference on Robot Learning (CoRL)*.
- [23] OpenAI, 2026. *Function calling*. [Online] Available at: <https://developers.openai.com/api/docs/guides/function-calling> [Accessed 9 August 2026].
- [24] Wu, Y. and He, K., 2018. Group Normalization. *European Conference on Computer Vision (ECCV)*.
- [25] Silver, D., Huang, A., Maddison, C.J., et al., 2016. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), pp.484–489.
- [26] Ng, A.Y., Harada, D. and Russell, S., 1999. Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *International Conference on Machine Learning (ICML)*, pp.278–287.
- [27] Loshchilov, I. and Hutter, F., 2017. SGDR: Stochastic Gradient Descent with Warm Restarts. *International Conference on Learning Representations (ICLR)*.
- [28] Fossen, T.I., 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chichester: John Wiley & Sons.
- [29] Efron, B. and Tibshirani, R.J., 1993. *An Introduction to the Bootstrap*. New York: Chapman & Hall.
- [30] DiCiccio, T.J. and Efron, B., 1996. Bootstrap Confidence Intervals. *Statistical Science*, 11(3), pp.189–228.
- [31] Sutton, R.S. and Barto, A.G., 2018. *Reinforcement Learning: An Introduction*. 2nd ed. Cambridge, MA: MIT Press.