

군집 자폭 수상 드론 방어를 위한 LLM 기반 지휘체계와 U-Net 점수맵 기반 다중 에이전트 협력 강화학습

윤영준* 방현태* 전유라† 김덕환† 윤원근*

초 록

저비용 자폭 무인수상정(USV) 군집은 전자전이 유선 조종 표적에 닿지 않고 요격탄은 표적보다 비싸 포화되는, 재래식 대응의 사각지대에 있다. 본 연구는 적보다 느린 소수의 방어정이 모선의 접근 회랑을 그물벽으로 선제 차단하는 두 계층 방어 체계를 제안한다. 전략 계층에서는 대규모 언어모델(LLM) 지휘관이 방어정별 담당 무리를 정하고, 기동 계층에서는 U-Net 이 전장 격자 지도 위에 낸 점수맵에서 각 방어정이 픽셀을 지목해 그물벽 위치를 정한다. 두 계층은 같은 주기로 갱신되지만 응답 지연이 크게 달라 느린 전략 계층만 비동기로 분리한다. 픽셀 지목은 행동공간을 격자에 가두어 안전·임무 제약을 마스킹으로 직접 부과하고 적선 수에 불변이며, 학습은 가치망 없는 그룹 상대 정책 최적화를 다중 에이전트로 확장한다. 조합 최적화 후처리를 두지 않은 조건에서 8개 조건 $\times$ 3개 포메이션 $\times$ 30개 시드, 720 에피소드를 시드 대응표본으로 수집해 두 계층의 기여를 2×2 로 분리 측정하였다. 기동 계층은 LLM 없이 단독으로 포획률을 $0.844 \rightarrow 0.886$ 으로 높였고, 제안 체계 전체는 같은 방어 수준에서 포획당 그물 소모를 44.5%, 총 선회량을 46.6% 줄였으며, 두 계층의 기여는 상승이 아닌 가산적이었다. 지휘관은 능력 임계 위에서만 이득이었다 — 클라우드 모델은 +0.060, 로컬 Qwen2.5 7B는 -0.192 로 코드 휴리스틱보다 유의하게 나뉘었다. 지휘관 성능을 설명한 것은 배정 커버리지가 아니라 재계획 간 계획 안정성으로, 주기적으로 재계획하는 구조에서는 국소 최적성보다 시간에 걸친 일관성이 중요하다는 설계 지침을 얻었다.

주제어 : 무인수상정, 군집 방어, 다중 에이전트 강화학습, 임무배정, 대규모 언어모델, 의미론적 분할, 그룹 상대 정책 최적화

1 서론

1.1 배경

다수의 저비용 무인수상정(Unmanned Surface Vehicle, USV)이 고가치 함정 한 척을 향해 여러 방향에서 동시에 돌진하는 자폭 공격은 대표적인 비대칭 위협이다. 유한한 방어 자산을 다수 표적에 배분하는 문제는 무기-표적 할당(weapon-target assignment)으로 오래 연구되어 왔으나 [1], 표적 수가 요격 자산을 넘어서면 최적 할당으로도 처리되지 않는 표적이 남는다.

무인 위협에 대한 기존 대응은 두 갈래로 구분된다 [2]. 표적의 통신·항법·센서를 교란하는 연성 대응(soft-kill)은 위협 자체를 제거하지 못하며, 전파를 방사하지 않는 유선 조종 표적에는 작용하지 않는다 [3]. 표적을 직접 타격하는 경성 대응(hard-kill)은 위협을 확실히 제거하지만, 수천 달러 규모의 표적에 발당 수십만에서 수백만 달러의 요격 유도탄을 소모하는 비용 구조를 지탱하기 어렵고 [4], 한 번에 한 표적만 처리하므로 표적 수가 교전 용량을 넘어서면 포화가 발생한다.

본 연구는 대안으로 저비용 그물을 이용한 물리적 포획을 채택한다. 이는 무인기 대응 분야에서 독립된 대응 범주로 다루어져 왔으며 [2], 표적의 통신 방식과 무관하게 작용하고 표적을 정지시킨다는 점에서 앞의 두 한계를 비껴간다. 방어정은 적선보다 느리므로 추격으로 따라잡을 수 없고, 대신 적선이 지나갈 접근 회

랑을 앞질러 그물벽으로 차단한다 (Fig. 1). 그림의 함정 형상과 패널은 개념 전달용 삽화이며, 실제 입출력 형식은 §4에 정의한다.

1.2 문제의식

이 방어 문제는 성격이 다른 두 판단을 동시에 요구한다. 하나는 *어느 방어정이 어느 적 무리를 맡을 것인가*라는 이산적·전술적 배정이고, 다른 하나는 *맡은 무리를 막기 위해 해면의 어느 지점에 그물벽을 놓을 것인가*라는 연속적·기하적 기동이다. 전자는 전장 전체의 맥락과 우선순위 판단을 요구하고, 후자는 국소적이지만 매 결정마다 새로 계산되어야 한다. 두 판단은 같은 주기로 갱신되지만 산출에 걸리는 시간이 크게 다르다. 본 연구는 느린 쪽인 배정을 언어모델 지휘관에게, 빠른 쪽인 기동을 학습된 정책에 맡긴다(Fig. 1). 운용 제약도 설계에 들어간다 — 결정 주기는 25초, 온보드 자원은 단일 GPU이며, 방어정은 적선보다 느리고 그물은 한 척당 몇 장뿐이다. 따라서 묻는 것은 “언어모델과 학습 정책을 쓸 수 있는가”가 아니라 *그 제약 아래에서 각 계층이 실제로 무엇을 얼마나 사는가*이다.

1.3 배치를 전제로 한 설계

본 연구는 시뮬레이션 안에서만 성립하는 체계를 목표로 하지 않았다. 방법을 고를 때마다 온보드에서 돌 수




Figure 1: 제안 체계의 개요 — 전략 계층(위)의 무리별 배정과 기동 계층(아래)의 그물벽 위치 결정

있는가를 함께 물었고, 그 선택들이 본문 곳곳에 흩어져 있으므로 여기에 모아 둔다.

- **실해역 지형에서 학습·평가한다.** 교전 해역은 가상의 빈 바다가 아니라 OpenStreetMap의 실제 해안선(통영 매물도 인근)을 래스터화한 것이며, 육지는 충돌 판정과 관측 채널 양쪽에 들어간다 (§4.4.1).
- **전장을 이미지로 보고, 행동을 픽셀로 낸다.** 관측은 선박별 벡터의 나열이 아니라 모션을 중앙에 둔 50×50 격자 위의 15채널 영상이고, 정책은 그 위에서 픽셀을 지목하는 U-Net 구조이다. 행동은 연속 좌표의 회귀가 아니라 격자의 유효 픽셀 가운데 하나를 고르는 *이산적인 선택*이므로, 정책은 해면 전체에 대한 점수맵을 낸다. 연속 좌표 회귀에서는 불가능 영역을 피하도록 학습하거나 사후에 투영해야 하지만, 이산 선택에서는 그런 자리가 애초에 뿔히지 않게 막을 수 있다. 선박 수가 바뀌어도 입력·출력의 형태가 변하지 않으며, 배치 통계에 의존하는 정규화를 쓰지 않아 배치 크기 1의 온보드 추론이 학습과 같은 연산을 수행한다 (§4.4.1, §4.7).
- **언어모델은 느린 판단만 맡고, 빠른 판단을 막지 않는다.** 배정은 언어모델 지휘관이, 기동은 학습된 정책이 맡는다. 둘은 비동기로 분리되어 지휘관의 응답을 기다리는 동안에도 기동은 멈추지 않는다 — 응답 속도가 크게 다른 두 판단 계층을 같은 결정 주기 안에서 결합한 것이다.
- **출력이 곧 항법 명령이다.** 정책의 출력은 제어 신호가 아니라 경유점 두 개이며, 이 형식은 특정 선체 동역학에 묶이지 않는다. 저수준 추종은 학습과 분리되어 있어 실제 선체의 동역학으로 교체할 수 있고, 그만큼 시뮬레이션에서 실기로 옮기기 쉽다 (§4.7).

1.4 기여

본 논문의 기여는 무엇이 새로 가능해졌는가로 정리된다.

1. **공학 해법.** 적보다 느린 방어정 세 척으로 자폭 군집을 막는 2계층 방어 체계 — 배정은 언어모델 지휘관, 그물벽 위치는 15채널 격자 관측 위의 U-Net 점수맵 정책이 맡고, 느린 계층만 비동기로 분리한다. 관측·행동이 격자 위에 있어 방어정·적선 수가 바뀌어도 같은 모델(244,389 파라미터)이 돌고, 배치 통계 없는 정규화와 경유점 출력으로 온보드 실시간 추론과 항법 스택 연결이 그대로 된다 (§4.7).
2. **검증 결과.** 적보다 느린 방어정 세 척이 그물벽만으로 자폭 군집을 같은 수준으로 막으면서 포획당 그물 소모를 44.5%, 총 선회량을 46.6% 줄이고, 언어모델 지휘관은 능력 임계 위의 모델에서만 이득이며 로컬 7B급은 오히려 손해라는 것을 — 조합 최적화 후처리 없이 시드 대응 2×2 설계로 두 계층의 기여를 분리 측정하여 720 에피소드에서 보였다. 기동 계층 단독으로도 포획당 그물 22.9%, 그물 걸림 24.3%를 줄이며, 이 조건은 외부 API 없이 재현된다. 10개 지표 중 9개에서 두 계층의 기여는 가산적이다 — 서로를 돕지도 잠식하지도 않는다.
3. **배치 판단 기준.** 언어모델 지휘관은 배정 커버리지가 아니라 *재계획 간 계획 안정성*으로 평가해야 하며 (가장 많이 배정한 모델이 가장 나빴다), 로컬 중형 모델의 응답 지연은 결정 주기를 넘길 수 있어(14B 호출의 4.2%) 로컬 배치에서는 비동기 분리가 전제다. 언제 지휘관 계층을 켜고 어느 모델을 쓸지에 대한 판단 기준을 수치로 제공한다.

논문의 구성은 다음과 같다. §2에서 관련 연구를 정리하고, §3에서 문제와 평가 지표를 정의한다. §4에서 제

안 체계를 기술하고, §5에서 실험 설계와 통계 절차를 밝힌다. §6에서 결과를 보고하고, §7에서 해석과 한계, 결론을 제시한다.

2 관련 연구

2.1 무기-표적 할당과 조합 최적화

방어 자산을 표적에 배분하는 문제는 무기-표적 할당(WTA)으로 정식화되어 정확해법과 휴리스틱이 모두 연구되었다 [1]. 1:1 배정으로 축소하면 헝가리안 알고리즘 [5]으로 다항 시간에 최소비용 매칭을 얻을 수 있다. 이러한 방법은 비용 함수가 명시적으로 주어질 때 최적을 보장하지만, 비용 함수 자체가 전술적 의도를 완전히 반영하기에는 한계가 존재한다. “이 무리의 접근로는 앞서 놓은 그물이 이미 막고 있으니, 그물이 남은 방어정은 아직 열린 회랑 쪽으로 돌려라”와 같은 판단은 이전 결정의 결과와 자산 잔량등과 같은 수많은 변수에 의해 달라지므로 고정된 거리·각도 비용으로 표현될 수 없다. 본 연구는 배정 계층에 조합 최적화 방식이 아닌 언어모델의 판단을 배치함으로써 최적성만을 고려하는 것이 아닌 전술적 맥락을 반영되도록 하였다 그 대가를 §6에서 정량적으로 보고한다.

2.2 무인 위협 대응

대무인기 체계에 관한 조사 [2]는 대응을 탐지·식별·무력화로 나누고, 무력화를 다시 연성(전자전)·경성(물리 타격)·포획(그물 등)으로 구분한다. 유선 조종 표적의 확산 [3]은 연성 대응의 적용 범위를 좁혔고, 요격 비용의 비대칭 [4]은 경성 대응의 지속성을 제약한다. 해상 영역에서 다중 USV의 협력 기동은 오래 연구되어 왔으며 [6], 최근에는 다중 에이전트 강화학습으로 회피 표적을 협조 포위하는 정책이 실선 검증과 함께 보고되었다 [7]. 선행 연구의 포위(encirclement)는 통상 방어정이 표적보다 빠르거나 대등함을 전제한다. 본 연구는 방어정이 더 느린 조건을 다룸으로써 추격 대신 공격 경로의 선제 차단을 택한다는 점에서 기존 연구와 차별된다.

2.3 다중 에이전트 강화학습과 크레딧 배분

중앙 집중 학습·분산 실행(CTDE) 계열은 팀 보상에서 개체별 기여를 분리하기 위해 가치망(비평가)을 학습한다. MADDPG [8]는 중앙 비평가를, QMIX [9]는 팀 가치를 개체 가치로 분해하는 단조 혼합망을 두며, COMA [10]는 한 에이전트의 행동만 주변화한 반사실적 기준선으로 개별 기여를 재고, MAPPO [11]는 PPO [12]를 다중 에이전트로 확장한 강한 기준선이다. 그러나 이들이 공유하는 가치망은 추정 편향과 학습 불안정이 성능을 좌우하며 [13], 다른 에이전트가 함께 학습하는 비정상 환경에서 그 문제가 더 커진다 [8]. 언어모델 정렬 분야의 그룹 상대 정책 최적화(GRPO) [14]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 이득을 산정함으로써 가치망 자체를 없앤다.

본 연구는 이 GRPO를 다중 에이전트 제어로 옮기고, 후보 하나를 기하 휴리스틱으로 고정하여 기준선으로 삼는다. 후보의 팀 보상은 학습된 비평가가 아니라 *시뮬레이터 재진행*으로 얻으므로 가치 추정 편향과 비평가 학습의 불안정성이 설계에서 사라진다. COMA의 반사실적 착상을 같은 방식으로 구현한 변형(한 척의 행동만 바꾸어 재진행)도 비교하였다. CTDE 계열을 실험 기준선으로 쓰지 않은 이유는 행동 표현이 달라 표현과 알고리즘의 기여가 뒤섞이기 때문이며, §7.2에서 다룬다.

2.4 격자 지도 표현과 픽셀 지목 행동

완전 합성곱 구조 [15]와 U-Net [16]은 입력 이미지의 모든 픽셀에 값을 매기는 조밀 예측을 가능하게 한다. CoordConv [17]는 좌표 채널을 덧붙여 합성곱이 흐리는 절대 위치를 보완하며, FiLM [18]은 조건 벡터로 특징 지도를 채널별로 변조하는 경량 조건화 기법이다. 이들은 모두 상황에 대한 *지각*, 즉 무엇이 어디에 있는가를 읽어내는 데 쓰였다. 한편 후보마다 점수를 매겨 그중 하나를 *지목*하는 출력 방식은 포인터 네트워크 [19]에서 비롯되었으며, 그 점수는 질의와 후보 특징의 내적, 즉 어텐션 [20]의 점수 계산과 같은 형식이다. 다만 이 방식은 주로 조합 최적화에 쓰였다. 본 연구는 둘을 잇는다. U-Net 이 낸 조밀 특징 지도의 각 픽셀에 방어정별 질의로 점수를 매기고(\$4.4), 그 점수맵을 지각 결과가 아니라 *정책의 행동 분포*로 삼아 픽셀 하나를 지목하는 것이 곧 행동이다. 행동공간이 격자로 이산화되므로 육지·사거리·배정 회랑 같은 안전 제약을 마스크로 행동 분포에 직접 부과할 수 있다.

2.5 언어모델 기반 계획

언어모델을 계획 주체로 사용하는 연구는 고수준 지시를 실행 가능한 단계로 분해하는 방향으로 발전해 왔다 [21]. SayCan [22]은 언어모델의 사전 지식과 로봇의 실행 가능성 추정을 결합하여 실행 불가능한 계획을 걸러낸다. 출력 형식을 스키마로 강제하는 구조적 출력 [23]은 언어모델 출력을 하위 시스템이 파싱 가능한 형태로 고정한다. 해당 연구에서는 보정 없이 언어모델 판단만으로 전장의 배정이 성립하는지, 그리고 어느 능력 수준부터 이득이 되는지를 측정한다.

3 문제 정의와 평가 지표

3.1 교전 시나리오

교전 해역 중앙에 고가치 모선 한 척이 있고, 가장자리에서 적 USV M 척이 모선을 향해 돌진한다. 적은 무작위로 흩어져 오지 않고 세 가지 공격 포메이션 — 집중, 양동, 파상 — 가운데 하나를 취한다(Fig. 2; 정의는 아래). 방어정 P 척은 적선보다 느리며, 각각 한정된 수의 그물벽을 전개할 수 있다. 구체적인 값은 Table 1에 정리하였다.




Figure 2: 세 가지 공격 포메이션 — 집중(왼쪽), 양동(가운데), 파상(오른쪽)

Table 1: 교전 시나리오와 관측 설정. 값은 학습 체크포인트의 설정에서 직접 읽었다.

항목	값	단위
적 USV 수 M	10	척
방어정 수 P	3	척
적 속력	9.0	m/s
방어정 속력	6.0	m/s
교전 해역 한 변	12600	m
그물벽 최대 길이	450	m
관측 격자 반폭	6300	m
관측 격자 해상도	50	칸
적 무리 최대 수 C	4	개
관측 픽셀 한 변	252	m
방어정당 그물 (학습 / 평가)	1 / 3	장
정책 파라미터 수	244,389	개

방어정 속력이 적 속력보다 낮다 — 추적이 성립하지 않으므로 접근 회랑의 선제 차단이 유일한 대응이다. 그물 보유량은 학습 시 1장, 평가·배포 시 3장이다: 정책은 결정마다 그물벽 하나를 놓으므로 결정당 행동공간이 보유량과 무관하고, 1장으로 학습한 정책이 재학습 없이 3장 설정에서 동작한다.

방어정은 적을 따라가는 대신 적이 지나갈 자리를 예측하여 선점해야 한다. 그물벽은 두 좌표를 잇는 선분으로 정의되며, 방어정이 그 선분을 따라 이동하면서 전개한다. 전개된 그물은 해면에 고정되지 않아, 시간이 지날수록 차단 효과가 감소하며, 미리 전개된 그물은 적에게 노출되어 회피의 여지를 준다. 따라서 그물벽은 적의 도달 직전, 적에 가까운 위치에 전개하는 것이 유리함을 가정한다.

세 포메이션의 정의는 다음과 같다.

- **집중(concentrated):** 적 전 병력이 한 방위에 모여 동시에 접근한다. 차단해야 할 접근로의 방위가 동일하므로, 소수의 방어정으로도 대응이 가능하다.
- **양동(diversionary):** 적이 세 방위로 나뉘어 동시에 접근한다. 접근로가 셋으로 갈라지므로 가용 방어정을 모두 투입해야 하며, 어느 방어정을 어느 무리에 붙이는 배치와 그 경로의 교차 여부가 결과를 좌우한다.
- **파상(wave):** 적이 3개 단(rank)으로 나뉘어 단마다 방위를 조금씩 달리하며 거리차를 두고 순차적으로 도달한다. 앞 단을 막은 자원이 뒤 단에도 쓰일 수 있어야 하므로 그물벽을 어느 자리에 놓는지가 다음

단의 차단 가능성을 좌우하며, 앞 단에 소모된 그물벽을 대신할 능동적 재배치가 방어율을 결정한다.

3.2 평가 지표

방어 성과의 지표는 다섯 관점에서 총 10개 지표를 정의한다(Table 2). 지표들은 에피소드 단위로 계산되며, 표의 정의에서 $N_{\text{cap}} \cdot N_{\text{brc}}$ 는 포획된·모선까지 돌파한 적선 수, N_{col} 은 아군 상호 및 모선 충돌 건수, N_{img} 은 아군이 설치된 그물에 얹힌 횟수, N_{net} 은 소모한 그물 수, D_p 와 $\Delta\psi_{p,t}$ 는 방어정 p 의 총 이동거리와 step t 의 방위 변화량, $\mathbf{m}$ 은 모선 위치, $\mathbf{z}_k$ 와 t_k 는 k 번째 포획 지점과 시각, $\mathbf{a}_d$ 는 d 번째 그물 전개를 시작한 방어정의 위치, $\mathcal{A}$ 는 그 시점의 생존 적선 집합, $\mathbf{e}_m$ 은 적선 m 의 위치이다. 자원 효율 지표는 교전하지 않은 조건이 가장 효율적으로 평가되는 것을 막기 위해 총량이 아니라 포획당 비율로 둔다. 조기 제압에 관한 수치는 거리축과 시간축으로 나누어 모선과 먼 곳에서 포획하는 것과, 조기에 포획하는 것 둘 다 고려하도록 한다.

Table 2: 평가 지표 10종. 방향은 개선이 어느 쪽인지를 나타내며, 기호는 본문에 정의하였다.

관점	지표	방향	정의	뜻
방어 성과	포획률	$\uparrow$	$CR = N_{\text{cap}} / (N_{\text{cap}} + N_{\text{brc}})$	교전이 결판난 적선 중 포획된 비율
	돌파 수	$\downarrow$	N_{brc}	모선까지 도달한 적선 수
안전	충돌률	$\downarrow$	N_{col} / P	방어정 1척당 아군 상호·모선 충돌 건수
	그물 걸림	$\downarrow$	N_{ing}	아군이 설치된 그물에 얽힌 횡수
자원 효율	포획당 그물	$\downarrow$	$N_{\text{net}} / N_{\text{cap}}$	적 1척 포획에 소모한 그물 수
	포획당 이동거리	$\downarrow$	$\sum_{p=1}^P D_p / N_{\text{cap}}$	적 1척 포획당 팀 총 이동거리
기동 비용	총 선회량	$\downarrow$	$\sum_{p=1}^P \sum_t \Delta \psi_{p,t} $	누적 방위 변화량(궤적 부드러움)
교전 품질	포획 이격거리	$\uparrow$	$\frac{1}{N_{\text{cap}}} \sum_k \ \mathbf{z}_k - \mathbf{m}\ $	포획 지점의 모선 이격 — 공간축 조기 제압
	평균 포획 시각	$\downarrow$	$\frac{1}{N_{\text{cap}}} \sum_k t_k$	포획이 일어난 시각 — 시간축 조기 제압
	전개 시 적 거리	$\downarrow$	$\frac{1}{N_{\text{net}}} \sum_d \min_{m \in \mathcal{A}} \ \mathbf{a}_d - \mathbf{e}_m\ $	그물 전개를 시작한 순간 최근접 적까지 거리

Table 3: 주요 기호. 혼동되기 쉬운 수량은 서로 다른 문자를 쓴다 — 특히 무리 수 C , 경유점 수 K , 학습의 그룹 후보 수 G 는 구분한다.

기호	뜻	기호	뜻
M	적 USV 수	$\mathbf{o}_p$	방어정 p 의 자체 상태 벡터
P	방어정 수	$\mathbf{q}_p$	방어정 p 의 질의 벡터
$C, \hat{C}$	무리 수 상한, 활성 무리 수	$\mathbf{f}_i$	픽셀 i 의 키 벡터
K	방어정 1척이 지목하는 경유점 수	$s_{p,i}$	방어정 p 가 픽셀 i 에 준 점수
G	학습의 그룹 후보 수	(γ_F, β_F)	FiLM 배율·이동 계수
τ_j	무리 j 의 위협도	R_k	후보 k 의 팀 보상
$\vartheta_m, g_{(q)}, \delta_{\text{gap}}$	적선 방위, 정렬 방위 간격, 분할 임계	$\mathbf{c}_j, n_j$	무리 j 의 중심, 척수
d_{pj}	방어정 $p \rightarrow$ 무리 j 요격점 거리	A_k	후보 k 의 그룹 상대 이득
β	배정 유지 보너스 (식 7)	Φ	위협 근접도 퍼텐셜
λ_L	잉여 방어정의 층 분리 증분	γ	퍼텐셜 성형 할인 계수
$\mathbf{I}$	요격점	$\mathcal{V}_p^{(k)}$	k 번째 선택 시점의 후보 픽셀 집합
$\mathbf{t}_k$	k 번째 목표점 (연속 좌표)	r_{dup}	경유점 중복 배제 반경
$\hat{\mathbf{r}}$	모선 $\rightarrow$ 요격점 단위 벡터	L_{net}	그물벽 최대 길이
$\mathbf{a}_p$	방어정 p 의 위치	d_z	대응표본 효과크기
E, ℓ	관측 반폭, 픽셀 크기	H	후보 평가 창 길이
$\iota(\cdot)$	월드 $\rightarrow$ 픽셀 인덱스 사상 (식 10)	$\eta_t, \lambda_H(t)$	학습률·엔트로피 계수 스케줄
$\mathbf{u}_k, \sigma_o$	부화소 오프셋과 그 표준편차	w_n	유효 월드 마스크

기호의 실험 설정값은 Table 1와 각 정의 위치의 본문에 있다.

4 제안 방법

4.1 2계층 비동기 구조

제안 체계는 방어 판단을 전략 계층과 기동 계층으로 분리한다(Fig. 3; 두 계층은 25초 주기로 결정하고 저수준 조타(PD)는 1초 주기로 돈다). 전략 계층은 어느 방어가 어느 적 무리를 맡는가를 정하고, 기동 계층은 배정된 무리를 막기 위해 해면 어디에 그물벽을 놓는가를 정한다. 두 계층은 같은 주기로 결정을 내리지만 **응답 속도가 다르다**. 기동 계층의 순전파는 순간에 끝나는 반면, 전략 계층의 언어모델 호출은 응답에 지연이 발생한다(§6.4). 느린 전략 계층 호출만 비동기로 분리함으로써, 호출이 진행되는 동안 기동 계층은 직전 배정을 그대로 사용하여 결정을 계속하고 응답이 도착하면 다음 결정부터 새 배정이 반영된다.

§6에서 지연은 설계 가정이 아니라 실측값으로 보고되며(§6.4), 비동기 분리는 그 실측이 요구한 결과다.

4.2 적 무리 군집화

두 판단 계층은 개별 적선이 아니라 무리를 단위로 배정한다. 따라서 매 결정마다 생존 적선을 모션 기준 방위로 묶어 최대 C 개의 무리로 요약한다. 적선 m 의 모션 기준 방위를 항법 규약(북쪽 0° , 시계 방향)으로 정의한다. 절차는 Fig. 4의 네 단계 — 모션 기준 방위각 정렬, 임계 δ_{gap} 를 넘는 방위 빈틈 탐색, 빈틈에서 잘라 $1-C$ 개 무리 확정, 무리별 위협도와 요격점(무리 중심-모션 선분 위) 산출 — 로 이루어진다.

$$\vartheta_m = \text{atan2}(e_{m,x} - m_x, e_{m,y} - m_y) \bmod 360^\circ \quad (1)$$

방위를 $360^\circ/C$ 폭의 고정 구간(bin)으로 나누는 방식은 한 무리가 구간 경계에 걸리면 둘로 쪼개지고, 무리가 하나뿐인 상황에서도 빈 구간을 포함한 C 개 슬롯으로 표현한다. 본 연구는 대신 방위 간격(gap)에 따라 무리 수를 데이터에 맞추는 적응형 군집화를 쓴다. 생존 적선 $n = |\mathcal{A}|$ 척의 방위를 오름차순으로 정렬하여 $\vartheta_{(1)} \leq \dots \leq \vartheta_{(n)}$ 이라 하고, 이웃한 방위 사이의 간격

을 원형으로 정의한다.

$$g_{(q)} = \vartheta_{(q+1)} - \vartheta_{(q)} \quad (q < n), \quad g_{(n)} = \vartheta_{(1)} + 360^\circ - \vartheta_{(n)} \quad (2)$$

임계 δ_{gap} 보다 큰 간격의 수가 무리 수를 정하되, 1 이상 C 이하(그리고 적선 수 이하)로 자른다.

$$\hat{C} = \text{clip}\left(|\{q : g_{(q)} > \delta_{\text{gap}}\}|, 1, \min(C, n)\right) \quad (3)$$

가장 큰 간격 $\hat{C}$ 개를 무리 경계로 삼고, 그 가운데 최대 간격을 원형 순서의 이음새로 열어 이음새 다음 적선부터 방위 순으로 걸으며 경계를 지날 때마다 무리 번호를 하나씩 올린다. 이렇게 얻은 라벨 $j_m \in \{1, \dots, \hat{C}\}$ 로 무리 j 의 구성원 집합 $\mathcal{A}_j = \{m : j_m = j\}$ 가 정해진다. 무리 j 는 네 가지 양으로 요약한다.

$$\begin{aligned} n_j &= |\mathcal{A}_j|, & \mathbf{c}_j &= \frac{1}{n_j} \sum_{m \in \mathcal{A}_j} \mathbf{e}_m, \\ \Delta\vartheta_j &= 90^\circ \sqrt{1 - \bar{R}_j}, & \bar{R}_j &= \left\| \frac{1}{n_j} \sum_{m \in \mathcal{A}_j} \hat{\mathbf{b}}_m \right\|, \\ v_j^{\text{app}} &= \frac{v_e}{n_j} \sum_{m \in \mathcal{A}_j} \langle (\sin \psi_m, \cos \psi_m), \hat{\mathbf{d}}_m \rangle, \\ \hat{\mathbf{d}}_m &= (\mathbf{m} - \mathbf{e}_m) / \|\mathbf{m} - \mathbf{e}_m\| \end{aligned} \quad (4)$$

n_j 는 척수, $\mathbf{c}_j$ 는 무리 중심, $\Delta\vartheta_j$ 는 방위 단위벡터 $\hat{\mathbf{b}}_m = (\cos \vartheta_m, \sin \vartheta_m)$ 의 원형 결집도 $\bar{R}_j$ 에서 얻은 각도 퍼짐(한 점에 모이면 0°), v_j^{app} 는 모션 방향 평균 접근 속도이다. 본 연구는 $C = 4$, $\delta_{\text{gap}} \approx 12^\circ$ 를 쓴다. 이 규칙 아래에서 집중 포메이션은 무리 하나, 양동 포메이션은 세 방위의 무리 셋으로 요약된다. 파상 포메이션은 단(rank)마다 방위를 18° 씩 벌려 생성되므로 δ_{gap} 을 넘어 대개 단마다 별개의 무리가 되며, 단 사이의 거리차는 무리 중심의 반경 차이와 §4.4.1의 격자 관측에 함께 남는다. 척수와 중심은 §4.3의 위협도와 요격점을, 네 요약량 전부는 §4.6의 지휘관 입력을 구성한다.

4.3 기하 휴리스틱 기준 방법

§4.2의 무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법을 정의한다. 이 방법은 §6의 비교 기준이자 §4.5.4의 행동 복제 목표이다.

4.3.1 위협 기반 배정

무리 j 의 위협도는 척수 n_j 와 모션 근접도의 곱으로 정의한다.

$$\tau_j = n_j \cdot \text{clip}\left(1 - \frac{\|\mathbf{c}_j - \mathbf{m}\|}{R_w}, 0.05, 1\right) \quad (5)$$

여기서 R_w 는 교전 해역 반폭이다. 위협 상위 P 개 무리를 방어 대상으로 삼고, 요격점은 무리 중심과 모션을 잇는 선분 위에 둔다.

$$\mathbf{I}_j = \mathbf{c}_j + \lambda_I (\mathbf{m} - \mathbf{c}_j), \quad \lambda_I = 0.55 \quad (6)$$

모션 쪽으로 치우친 위치는 적보다 느린 방어정이 먼저 도달하기 위한 것이다. 배정 비용은 요격점까지의 거리 $d_{pj} = \|\mathbf{a}_p - \mathbf{I}_j\|$ 이며, 직전 배정을 유지하는 쌍에 상수 β 를 감한 뒤 탐욕적 1:1 배정을 수행한다.

$$\tilde{d}_{pj} = d_{pj} - \beta \cdot \mathcal{K}[j = j_p^{\text{prev}}] \quad (7)$$

보너스 항은 배정의 시간적 일관성을 위한 것이다. 그 물벽을 전개하던 중에 담당이 바뀌면 그때까지의 이동

과 그물이 회수되지 않으므로, 순간 최적보다 연속성이 유리하다. 활성 무리가 P 보다 적으면 남은 방어정을 부하(적 수/(1+배정 수))가 가장 큰 무리에 덧붙이되, 요격점을 모션 쪽으로 $\lambda_L = 0.18$ 만큼 안쪽 층에 두고 방위를 $\pm 40^\circ$ 씩 번갈아 틀어 경로가 겹치지 않게 한다.




Figure 3: 판단 지연이 다른 2계층 비동기 구조




Figure 4: 방위각 정렬, 군집화, 군집 배정

4.3.2 그물벽 경유점 생성

배정된 방어정 p 는 요격점 $\mathbf{I}$ 를 중심으로 적의 접근 방향에 수직인 벽을 친다. 그물벽은 두 끝점을 잇는 선분이므로 경유점 수는 $K = 2$ 이다. 모션에서 요격점으로 향하는 단위 벡터를 $\hat{\mathbf{r}}$, 그에 수직인 방향을 $\hat{\mathbf{r}}^\perp$ 라 하면

$$\mathbf{t}_k = \mathbf{I} + \left(k - \frac{K-1}{2}\right) L_{\text{net}} \hat{\mathbf{r}}^\perp, \quad k = 0, \dots, K-1 \quad (8)$$

즉 $\mathbf{I} \pm \frac{1}{2} L_{\text{net}} \hat{\mathbf{r}}^\perp$ 로, 요격점을 가운데 둔 $L_{\text{net}} = 450 \text{ m}$ 의 선분이다. 연속 좌표 $\mathbf{t}_k$ 는 모션 중심 50×50 격자 (§4.4.1)의 유효 픽셀 (§4.4.3) 가운데 최근접 칸으로 스넵한다.

$$i_k = \arg \min_{i \in \mathcal{V}_p^{(k)}} \|\mathbf{x}_i - \mathbf{t}_k\|^2 \quad (9)$$

여기서 $\mathbf{x}_i$ 는 픽셀 i 의 중심이고 $\mathcal{V}_p^{(k)}$ 는 k 번째 선택 시점의 후보 집합으로, 직전 선택으로부터 $r_{\text{dup}} = 200 \text{ m}$ 이내와 $1.5L_{\text{net}}$ 밖을 배제하며 갱신된다. 격자·유효 마스크·배제 규칙은 §4.4의 학습 정책과 동일하므로 두 방법의 행동공간은 같으며, 후보가 비었을 때의 완화 순서만 다르다(휴리스틱은 유효 마스크 전체로 한 번에, 정책은 단계별로 되돌린다).

휴리스틱은 유효 영역 안에서 기하로 정해진 한 점을 지목할 뿐 나머지 칸에 대한 선호가 없으므로, 다른 무리를 맡은 방어정이 이미 친 벽, 파상 공격의 뒤 단, 지형이 만드는 길목은 요격점 계산에 반영되지 않는다. 이들은 해면 전체를 비교해야 얻어지는 판단이며, §4.4의 점수맵이 그 비교를 학습된 함수로 대체한다. 두 방법이 같은 격자·같은 유효 마스크·같은 거리 제약 위에서 동작하므로, §6.1.1의 차이는 표현력의 차이가 아니라 결정 규칙의 차이로 읽힌다.

4.4 점수맵 기반 기동 정책

4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모션을 중앙에 두고 관측 반폭 E 의 전장을 $n_g \times n_g$ 격자로 나눈 다채널 지도이다(채널별 실제 화면은 Fig. 5). 총 15개 채널은 모든 방어정이 공유하는 전역 9채널, 방어정마다 다른 3채널, CoordConv [17] 좌표 3채널로 구성되며 (Fig. 6), 각 채널의 정의와 값 범위를 Table 4에 정리하였다. 그림의 좌측 시선원뿔과 함정 형상은 삽화의 표현이다 — 본 연구의 래스터는 방어정 시야가 아니라 모션을 중앙에 둔 전역 격자이며, 방어정마다 달라지는 것은 3채널(10–12)과 $\mathbf{o}_p$ 뿐이다.

래스터화와 정규화. 픽셀 크기는 $\ell = 2E/n_g$ 이고, 월드 좌표 $\mathbf{x}$ 는 모션 위치 $\mathbf{m}$ 을 중심으로 다음 픽셀 인덱스로 사상된다.

$$\iota(\mathbf{x}) = \text{clip}\left(\left\lfloor \frac{\mathbf{x} - \mathbf{m} + E\mathbf{1}}{\ell} \right\rfloor, 0, n_g - 1\right) \quad (10)$$

적 관련 채널은 개체를 픽셀에 “칠하는” 방식으로 만들며, 값 범위가 $[0, 1]$ 또는 $[-1, 1]$ 에 놓이도록 정규화한다. 생존 적선 집합을 $\mathcal{A}$, 적선 m 의 위치·헤딩을

$\mathbf{e}_m, \psi_m$ 이라 하면 픽셀 i 의 적 밀도·진행 방향·위협도 채널은

$$c_i^{\text{den}} = \frac{N_i}{M}, \quad c_i^{\text{vel}} = \frac{1}{\max(N_i, 1)} \sum_{m \in \mathcal{A}_i} (\sin \psi_m, \cos \psi_m) \quad (11)$$

$$c_i^{\text{thr}} = \max_{m \in \mathcal{A}_i} \left(1 - \text{clip}\left(\frac{\|\mathbf{e}_m - \mathbf{m}\|}{v_e T_{\text{max}}}, 0, 1\right)\right) \quad (12)$$

이다. 여기서 $\mathcal{A}_i = \{m \in \mathcal{A} : \iota(\mathbf{e}_m) = i\}$ 는 픽셀 i 에 놓인 생존 적선의 집합이고 $N_i = |\mathcal{A}_i|$ 이다. 밀도는 적 총수 M 으로, 진행 방향은 픽셀 안의 적 수로 나누어 평균 단위벡터가 되게 하고, 위협도는 모션까지 거리를 적이 에피소드 상한 안에 달릴 수 있는 최대 거리 $v_e T_{\text{max}}$ 로 정규화하여 가까울수록 1에 가깝게 한다. 아군 위치 채널은 같은 방식으로 P 로 나누고, 설치된 그물 채널은 고해상도 물리 격자의 최대값 풀링, 육지 채널은 면적비 다운샘플이다. 좌표 채널은 픽셀 중심 $\mathbf{x}_i = (x_i, y_i)$ 에 대해

$$(c_i^x, c_i^y) = \frac{\mathbf{x}_i - \mathbf{m}}{E}, \quad c_i^r = \text{clip}\left(\frac{\|\mathbf{x}_i - \mathbf{m}\|}{E}, 0, 1\right) \quad (13)$$

로 두어 $[-1, 1]$ 과 $[0, 1]$ 에 놓는다. 격자에 담지 않는 방어정 p 의 자체 상태 벡터는 같은 반폭 E 로 정규화한 위치와 요격점, 헤딩 단위벡터, 그물 잔량 비율, 전개 여부이다.

$$\mathbf{o}_p = \left[\frac{1}{E}(\mathbf{a}_p - \mathbf{m}); (\sin \psi_p, \cos \psi_p); \frac{n_p}{n_{\text{max}}}; \delta_p; \mathcal{K}[\text{배정}] \frac{1}{E}(\mathbf{I}_p - \mathbf{m})\right] \in \mathbb{R}^8 \quad (14)$$

여기서 n_p 는 잔여 그물 수, n_{max} 는 적당 보유량, $\delta_p \in \{0, 1\}$ 은 전개 중 여부이며, 배정이 없으면 요격점 성분은 0이다.

스케일 불변성. 위 정의에서 길이를 가진 양은 모두 관측 반폭 E 나 픽셀 크기 ℓ 로 나뉘고, 개수는 $M \cdot P \cdot n_{\text{max}}$ 로, 시간은 $v_e T_{\text{max}}$ 로 나뉜다. 따라서 모든 입력은 $[-1, 1]$ 의 무차원 양이며, 교전 해역의 크기나 격자 해상도를 바꾸어도 채널의 의미와 값 범위는 변하지 않는다 — 정책이 보는 것은 미터가 아니라 “해역 반폭 대비 어디에 있는가”이다. 별도의 통계 기반 정규화 층이 필요 없고, 학습 분포와 배치 분포 사이의 정규화 불일치도 생기지 않는다. 본 연구에 쓴 E, n_g 등의 값은 Table 1에 있다.

Fig. 5은 이 15채널 관측을 한 장면($t = 320, 50 \times 50$ 격자)에 대해 채널별로 펼친 것이다 — 01–09가 전역, 10–12가 방어정 0, 13–15가 좌표 채널이며, 부호 없는 채널은 값이 클수록 검게, 부호 있는 채널은 음을 파랑·양을 빨강으로 그렸다. 채널의 값 범위와 비영 픽셀 수를 함께 적어, 어떤 채널이 실제로 정보를 담고 어떤 채널이 대부분 0인지가 드러나게 하였다 — 예컨대 좌표 채널은 전 픽셀이 비영이고, 방어정별 채널은 수십 픽셀 규모이며, 설치된 그물 채널은 전개 이전이라 전부 0이다.

목록 대신 격자 지도를 쓰면 입력 형태가 개체 수에 불변이고(적선이 늘거나 줄어도 텐서 크기가 같다), 개




Figure 5: 래스터화된 15채널 관측의 예(파상 포메이션, 통영 매물도 북측)

Table 4: 15채널 격자 관측의 구성. 전역 채널은 월드당 한 번 계산하여 모든 방어정이 공유하고, 방어정별 채널만 방어정마다 다르다. 정의 열의 식 번호는 본문의 수식이다.

#	묶음	채널	정의	범위
1	전역	적 밀도	픽셀 내 생존 적선 수/ M , 식 (11)	$[0, 1]$
2		적 진행 x	픽셀 내 적선 헤딩 단위벡터의 평균, 식 (11)	$[-1, 1]$
3		적 진행 y	위와 같음	$[-1, 1]$
4		적 위험도	모선 도달 임박도의 픽셀 내 최대, 식 (12)	$[0, 1]$
5		아군 위치	픽셀 내 생존 방어정 수/ P	$[0, 1]$
6		설치된 그물	물리 격자의 그물 점유를 최대값 풀링	$\{0, 1\}$
7		원점	모선 반경 안의 픽셀	$\{0, 1\}$
8		요격 구역	$r_{\min} \leq \ \mathbf{x}_i - \mathbf{m}\ \leq r_{\max}$ 인 픽셀	$\{0, 1\}$
9		육지	고해상도 육지 마스크의 면적비	$[0, 1]$
10	방어정별	자기 위치	방어정 p 가 놓인 픽셀	$\{0, 1\}$
11		배정 요격점	$\mathbf{I}_p$ 가 놓인 픽셀 (미배정이면 전부 0)	$\{0, 1\}$
12		유효 영역	유효 마스크 $\mathcal{V}_p$, 식 (18)	$\{0, 1\}$
13	좌표	x	$(x_i - m_x)/E$, 식 (13)	$[-1, 1]$
14		y	$(y_i - m_y)/E$	$[-1, 1]$
15		r	$\text{clip}(\ \mathbf{x}_i - \mathbf{m}\ /E, 0, 1)$	$[0, 1]$




Figure 6: 15채널 관측의 구성 — 전역·방어정별·좌표 채널의 격자 중첩과 격자 밖 자체 상태 벡터

체의 순서에도 불변이며(순열 불변), 위의 정규화와 결합하면 해역 스케일에도 불변이다. 다만 합성곱은 평행이동 등변이라 절대 위치가 흐려지므로, 좌표 채널을 함께 넣어 위치를 보존한다.

육지 채널은 실제 해역 정보를 반영한다(학습에 쓴 해역 6곳은 Fig. 7). OpenStreetMap 에서 해안선·섬 폴리곤을 추출하여 격자로 변환한 뒤, 열림 연산으로 부두·방파제 같은 가는 돌출부를 제거하고 구멍 메우기로 내부를 정리한다. 충돌 판정은 고해상도 물리 격자에서 이진으로 수행하고, 관측 채널은 이를 면적비로 정책 격자에 다운샘플하여 해안선이 계단이 아닌 연속값으로 들어가게 한다. 해역별로 한 번만 계산하여 캐시하므로 학습 중 외부 API 호출은 발생하지 않는다.

4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net 구조 [16]를 지나 입력과 같은 해상도의 특징 지도로 변환된다(Fig. 8). 인코더 2단($50 \rightarrow 25 \rightarrow 13$)으로 수용 영역을 넓히고, 디코더 2단으로 원해상도를 복원하며, skip 연결이 인코더의 위치 정보를 디코더로 전달한다. 정밀 좌표와 전역 상황 판단을 동시에 요구하는 본 문제에 U자형 구조가 맞물리는 지점이 여기다.




Figure 7: 학습에 쓴 실해역 6곳의 육지 마스크(별표 모선, 파선 원 요격 구역)

병목에서는 전역 평균 풀링으로 압축한 전향 벡터로부터 FiLM [18]의 채널별 배율·이동 계수 (γ_F, β_F)를 만들어 병목 특징을 변조한 뒤 디코더에 넘긴다(아래첨자 F는 FiLM을 뜻하며, 식 (7)의 β 나 할인 계수 γ 와는 무관하다). 병목 특징 지도를 $\mathbf{H}_b \in \mathbb{R}^{2w \times h \times h}$ ($w = 32, h = 13$)라 하면

$$(\gamma_F, \beta_F) = \mathbf{W}_F \text{GAP}(\mathbf{H}_b) + \mathbf{b}_F, \quad (15)$$

$$\tilde{\mathbf{H}}_b = (1 + \gamma_F) \odot \mathbf{H}_b + \beta_F$$

이며, $\odot$ 은 채널별 곱이다. 배율을 $1 + \gamma_F$ 로 두어 초기에는 항등 변조에서 출발한다. 국소 합성곱만으로는 “지금 전향이 급박한가”와 같은 전역 정보가 모든 위치에 고르게 전달되지 않기 때문에 이 경로를 둔다.

각 방어정 p 는 자신의 상태 벡터 $\mathbf{o}_p \in \mathbb{R}^8$ (식 (14))로부터 질의 벡터 $\mathbf{q}_p = \text{MLP}_{8 \rightarrow 128 \rightarrow 32}(\mathbf{o}_p) \in \mathbb{R}^{32}$ 를 만들고, 픽셀 i 의 특징 $\mathbf{f}_i \in \mathbb{R}^{32}$ 와의 내적으로 점수를 얻는다.

$$s_{p,i} = \frac{\langle \mathbf{W}_q \mathbf{q}_p + \mathbf{b}_q, \mathbf{f}_i \rangle}{\sqrt{d}}, \quad d = 32 \quad (16)$$

여기서 $\mathbf{W}_q \in \mathbb{R}^{d \times d}$, $\mathbf{b}_q \in \mathbb{R}^d$ 는 질의를 특징 공간에 맞추는 아핀 사영이다. 이는 어텐션 [20]의 점수 계산과 같은 형식이며, 포인터 방식 [19]으로 격자 위의 원소를 지목하는 구조에 해당한다. 특징 지도는 방어정마다 다르므로(15채널 중 3채널이 방어정별이다), 관측 텐서는 방어정을 배치 축으로 쌓아 **결정당 한 번의 배치 호출**로 U-Net을 통과한다. 합성곱 연산량은 방어정 수에 비례하지만, **가중치는 모든 방어정이 공유하므로 모델 크기는 방어정 수에 불변**이다. 방어정별로 달라지는 것은 질의 $\mathbf{q}_p$ 와 방어정별 3채널뿐이다.

합성곱 블록은 3×3 합성곱 — 그룹 정규화 [24] — SiLU로 구성한다.

$$\text{Block}(\mathbf{H}) = \text{SiLU}(\text{GN}_8(\text{Conv}_{3 \times 3}(\mathbf{H}))), \quad (17)$$

$$\text{SiLU}(z) = z / (1 + e^{-z})$$

그룹 정규화(GN₈, 8개 그룹)를 고른 이유는 성능이 아니라 배치 독립성이다. 표본 하나 안에서 채널을 묶어

정규화하므로 통계가 배치 구성에 의존하지 않으며, 이것이 §4.7에서 다루는 배치 크기 1의 실시간 추론이 학습과 같은 연산을 수행한다는 전제가 된다.

4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 다음 조건을 순차적으로 적용하여 유효 마스크를 구성하고, 그 밖은 $-\infty$ 로 차단한다.

1. 환상(annular) 요격 구역 — 모선에서 일정 반경 대역 — 안쪽
2. 육지가 아닌 곳
3. 배정된 요격점으로부터 반경 게이트 이내
4. 배정 무리의 방위 회랑 이내

픽셀 i 의 중심을 $\mathbf{x}_i$, 육지 픽셀 집합을 $\mathcal{L}_{\text{land}}$, 방어정 p 의 배정 요격점을 $\mathbf{I}_p$, 모선에서 본 요격점 방위를 ϑ_p , 픽셀 방위를 ϑ_i 라 하면 방어정 p 의 유효 픽셀 집합은 네 조건의 교집합이다.

$$\mathcal{V}_p = \{i : r_{\min} \leq \|\mathbf{x}_i - \mathbf{m}\| \leq r_{\max}, i \notin \mathcal{L}_{\text{land}}, \|\mathbf{x}_i - \mathbf{I}_p\| \leq r_g, |\vartheta_i - \vartheta_p| \leq \vartheta_g\} \quad (18)$$

여기서 $|\cdot|$ 는 $[0^\circ, 180^\circ]$ 로 접은 각도 차이이며 $r_{\min} = 400, r_{\max} = 4500, r_g = 3000 \text{ m}, \vartheta_g = 60^\circ$ 이다. 유효 픽셀이 하한 150개에 못 미치면 반경 게이트부터 툰다 — 방위 회랑은 “무엇을 막는 그물인가”를 정하므로 마지막까지 유지한다. 마스크는 점수에 곱해지는 것이 아니라 로짓 단계에서 적용된다.

$$\tilde{s}_{p,i} = \begin{cases} s_{p,i}, & i \in \mathcal{V}_p \\ -\infty, & i \notin \mathcal{V}_p \end{cases} \quad \pi_\theta(i | \mathbf{s}, p) = \frac{e^{\tilde{s}_{p,i}}}{\sum_{j \in \mathcal{V}_p} e^{\tilde{s}_{p,j}}} \quad (19)$$

유효 집합 밖 픽셀의 확률은 정확히 0이다. 이 마스크는 안전·임무 제약을 **행동 분포에 직접 부과**한다는 점에서 중요하다. 연속 좌표를 회귀시키는 방식에서는 이런 제약을 손실 항으로 넣어 “되도록 지키게” 유도할 수밖에 없지만, 지목 방식에서는 제약 위반이 애초에 표현 불가능하다.

이 제약이 실제로 얼마나 강한지 가능하기 위해 (Fig. 9) 학습된 체크포인트로 6,652회의 결정을 수집한 결과, $50 \times 50 = 2500$ 개 칸 가운데 평균 **10.5%**만이 선택 가능하였다. 대표 사례의 단계별 감소는 전체 2500칸 → 요격 구역 1000 → 육지 제외 979 → 반경 게이트 387 → 방위 회랑 299로, 격자의 **88%**가 애초에 갈 수 없는 자리이다. 연속 좌표 회귀에는 이 구조를 표현할 수단이 없다.

왜 연속 좌표가 아니라 이산 격자인가. 마스크 말고도 두 가지 이득이 있다. 첫째 **탐색의 유계성**이다. 범주형 표본은 정의상 유효 영역을 벗어나지 않으므로 좌표를 자르거나 squash 하는 장치가 필요 없고, 엔트로피가 유한하여 §4.5의 그룹 후보들이 서로 다른 칸을 실제로 밟는다 — 가우시안 정책은 표준편차가 줄면 후보가 한 점으로 뭉쳐 상대 이득(식 (26))이 사라진다. 둘째 구조의 **일치**이다. 합성곱의 평행이동 등변성은 픽셀




Figure 8: 점수맵 정책의 구조 — 방어정 상태 질의와 U-Net 특징맵의 내적으로 얻는 점수맵과 부화소 오프셋




Figure 9: 유효 마스크와 픽셀 지목(학습된 체크포인트의 실제 출력): (a) 유효 영역, (b) 점수맵과 선택된 픽셀 쌍, (c) 제약별 후보 수 감소

단위 출력에서 그대로 살아나므로, 관측 격자와 행동 격자를 같은 50×50 으로 두면 “이 칸이 좋다”는 판단이 국소 기하로부터 곧바로 나온다. 대가는 해상도이다. 한 칸이 252m 이므로 순수 격자 행동은 최대 ± 126 m 의 양자화 오차를 갖는데, 이를 위해 선택된 칸 안에서 $\pm$ 반픽셀의 연속 오프셋을 내는 회귀 머리를 함께 둔다 (Fig. 8). 즉 어느 칸인가는 이산으로, 칸 안 어디인가는 연속으로 결정하여 두 표현의 장점을 나누어 갖는다.

각 방어정은 유효 영역 안에서 점수 상위 픽셀 $K = 2$ 개를 순차적으로 고른다. k 번째 선택의 질의와 후보 집합을 $\mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}$ 라 하면 ($\mathbf{q}_p^{(0)} = \mathbf{q}_p, \mathcal{V}_p^{(0)} = \mathcal{V}_p$)

$$i_k \sim \pi_p^{(k)} \equiv \pi_\theta(\cdot | \mathbf{q}_p^{(k)}, \mathcal{V}_p^{(k)}), \quad \mathbf{q}_p^{(k+1)} = \mathbf{q}_p^{(k)} + \mathbf{f}_{i_k} \quad (20)$$

$$\mathcal{V}_p^{(k+1)} = \{i \in \mathcal{V}_p^{(k)} : r_{\text{dup}} \leq \|\mathbf{x}_i - \mathbf{x}_{i_k}\| \leq 1.5 L_{\text{net}}\} \quad (21)$$

이다. 먼저 고른 픽셀의 특징을 질의에 더해 두 번째를 고르므로 두 점이 서로를 알고 뽑힌다. 독립적으

로 뽑으면 두 점을 잇는 벽의 방향이 우연에 맡겨진다. 식 (21)는 두 점 *사이* 간격의 상·하한이다. $r_{\text{dup}} = 200$ m 안쪽은 두 점이 너무 가까워 벽이 서지 않고, 상한은 그 물벽 최대 길이의 1.5배인 675 m 로 두어 실제로 칠 수 없는 길이의 벽이 선택되지 않게 한다. 상한을 두지 않았을 때 휴리스틱 목표점을 유효 픽셀로 스냅한 간격의 중앙값이 504 m 로 그물 길이 450 m 를 초과했고 (초과율 66.7%), 정책의 표본은 88.6% 가 초과했다. 이 제약으로 후보가 모두 사라지면 제약을 완화하여 결정을 반환한다(최적정보다 결정 가능성을 우선한다).

선택된 칸 안의 위치는 연속 오프셋으로 정한다. 질의와 선택 픽셀의 특징으로부터 평균을 내고, 학습되는 로그표준편차 σ_o 를 가진 가우시안에서 표집한다.

$$\begin{aligned} \mu_k &= \text{MLP}_{2d \rightarrow d \rightarrow 2}([\mathbf{q}_p^{(0)}; \mathbf{f}_{i_k}]), \quad \mathbf{u}_k \sim \mathcal{N}(\mu_k, \sigma_o^2), \\ \mathbf{t}_k &= \mathbf{x}_{i_k} + \frac{\ell}{2} \text{clip}(\mathbf{u}_k, -1, 1) \end{aligned} \quad (22)$$

즉 어느 칸인가는 범주형으로, 칸 안 어디인가는 가우시

안으로 결정된다. 한 방어정의 행동 $a_p = \{(i_k, \mathbf{u}_k)\}_{k=0}^{K-1}$ 의 로그확률과 엔트로피는 두 분포의 합이다.

$$\log \pi_\theta(a_p) = \sum_{k=0}^{K-1} \left[\log \pi_p^{(k)}(i_k) + \log \mathcal{N}(\mathbf{u}_k; \boldsymbol{\mu}_k, \boldsymbol{\sigma}_o^2) \right] \quad (23)$$

$$\mathcal{H}(a_p) = \sum_{k=0}^{K-1} \left[\mathcal{H}(\pi_p^{(k)}) + \mathcal{H}(\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\sigma}_o^2)) \right] \quad (24)$$

식 (23)는 §4.5의 정책경사에, 식 (24)는 엔트로피 정칙화에 그대로 쓰인다. 특징 조회에서 두 번째 점까지의 흐름을 Fig. 10에 요약하였다.

선택된 두 좌표를 잇는 선분이 그물벽 경로가 된다. 방어정은 가까운 점까지 무전개로 이동한 뒤 다음 구간에서 그물을 전개한다. 운용 시에는 최대 점수를 취하고 (greedy), 학습 시에는 확률 분포에서 표본을 뽑는다.

정지 규칙. 그물이 없거나 배정되지 않은 방어정은 정지시킨다. 이런 방어정에는 학습 중 유의미한 보상 신호가 없어 점수맵이 거의 평평해지는데(최고 확률 0.02 수준, 배정된 방어정은 0.5 ~ 0.7), 이 무의미한 출력이 향해 명령으로 새어 나가는 것을 막기 위함이다. 정책의 출력은 좌표가 아니라 유효 마스크 위의 픽셀 두 개이므로, 휴리스틱과 같은 칸 집합에서 고른다는 점이 §6.1.1의 비교를 성립시키는 전제이다.

4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

4.5.1 그룹 상대 이득

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화 [14]를 다중 방어정 상황에 맞게 변형하여 수행한다. 결정 시점의 상태를 $\mathbf{s}$, 방어정 P 척의 결합 행동을 $\mathbf{a} = (a_1, \dots, a_P)$ 라 하자. 매 결정 시점에서 정책으로부터 G 개의 결합 행동 후보를 표집하되, 후보 가운데 하나($k=0$)는 휴리스틱 (§4.3)이 내는 행동으로 고정하여 기준선으로 삼는다.

$$\mathbf{a}^{(0)} = \mathbf{a}_{\text{heur}}(\mathbf{s}), \quad \mathbf{a}^{(k)} \sim \pi_\theta(\cdot | \mathbf{s}), \quad k = 1, \dots, G-1 \quad (25)$$

각 후보를 시뮬레이터에서 공통 구간 $H = 180 \text{ step}$ 만큼 실제로 진행시켜 창 보상 $R_k = R(\mathbf{s}, \mathbf{a}^{(k)}; H)$ 를 얻은 뒤 (§4.5.3), 후보들 사이의 상대 비교로 이득을 산정한다.

$$A_k = \frac{R_k - R_0}{\text{std}(\{R_j\}_{j=0}^{G-1}) + \epsilon}, \quad \epsilon = 10^{-6} \quad (26)$$

$R_0 = R_{\text{heur}}$ 이므로 휴리스틱과 같은 성과를 내는 후보의 이득은 0 이고, 휴리스틱을 넘어서는 후보만 양의 이득을 받는다. 그룹 표준편차로 나누므로 이득은 크기가 없는 양이며, 그룹 안의 순위 정보만 남는다. 어떤 선택이 더 나은지를 실제 결과로 직접 비교하므로 별도의 가치망이 필요하지 않다. 이는 가치 추정 편향과 비평가 학습의 불안정성을 원천적으로 제거한다.

한 갱신은 N 개의 병렬 전장(월드)에서 동시에 수행된다. 월드 n 의 후보 보상이 모두 같으면 이득이 정의되

지 않으므로, 유효 마스크 $w_n = \mathbb{1}[\text{std}(\{R_{n,k}\}_k) > \epsilon_{\text{var}}]$ ($\epsilon_{\text{var}} = 10^{-6}$)로 그런 월드를 갱신에서 제외한다. 정책경사 손실은 유효 월드의 모든 후보·모든 방어정에 대해 이득으로 가중한 로그확률 (식 (23))의 음수이다.

$$\mathcal{L}_{\text{PG}}(\theta) = - \frac{\sum_n w_n \sum_{k=0}^{G-1} A_{n,k} \sum_{p=1}^P \log \pi_\theta(a_{n,p}^{(k)} | \mathbf{s}_n)}{G \sum_n w_n} \quad (27)$$

여기에 엔트로피 정칙화(식 (24))를 더한 총손실을 Adam 으로 최소화한다.

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{PG}}(\theta) - \lambda_H(t) \frac{1}{NP} \sum_{k=0}^{G-1} \sum_{n=1}^N \sum_{p=1}^P \mathcal{H}(a_{n,p}^{(k)}) \quad (28)$$

엔트로피는 G 개 후보 모두에 대해 합하므로 유효 계수는 $G\lambda_H(t)$ 이며, $\lambda_H(t)$ 는 §4.5.4의 감쇠 계수이다. 기울기는 노름 $g_{\text{max}} = 1.0$ 에서 자른다.

$$\mathbf{g} = \nabla_\theta \mathcal{L}(\theta), \quad \theta \leftarrow \theta - \eta_t \cdot \text{Adam} \left(\mathbf{g} \cdot \min \left(1, \frac{g_{\text{max}}}{\|\mathbf{g}\|} \right) \right) \quad (29)$$

시뮬레이터를 직접 전진시켜 후보를 평가하는 착상은 탐색 기반 의사결정 [25]과 같은 계열이되, 본 연구는 탐색 트리를 전개하지 않고 한 결정 시점의 후보 집합만 비교한다. 이 절차와 다음 소절의 크레딧 배분을 Fig. 11에 한 장으로 정리하였다. 그림은 기전 전달을 위해 후보 수와 창을 $G = 4, H = 4$ 로 줄여 그렸으며, 실제 학습은 $G = 8$, 평가 구간 180 step이다.

4.5.2 반사실적 크레딧 배분: 비교 변형

식 (27)는 팀 보상의 이득 $A_{n,k}$ 를 모든 방어정의 로그 확률에 같은 값으로 곱한다. 팀 보상을 모든 방어정이 그대로 나누어 가지면 개별 기여가 가려진다. 잘한 방어정과 못한 방어정이 같은 신호를 받으면 학습이 진행되지 않는다. 따라서 한 척의 행동만 바꾸고 나머지는 고정한 채 재평가하여, 그 차이를 해당 방어정의 몫으로 돌린다. 기준 표본 $\mathbf{a}^{\text{base}} \sim \pi_\theta(\cdot | \mathbf{s})$ 를 하나 두고, 방어정 p 에 대해 p 의 행동만 바꾼 혼합 후보 G 개를 만든다.

$$\mathbf{a}^{(k,p)} = (\mathbf{a}_{-p}^{\text{base}}, \tilde{a}_p^{(k)}), \quad \tilde{a}_p^{(0)} = a_{\text{heur},p}(\mathbf{s}), \quad \tilde{a}_p^{(k)} \sim \pi_\theta(\cdot | \mathbf{s}, p) \quad (30)$$

여기서 $\mathbf{a}_{-p}$ 는 p 를 제외한 나머지 방어정의 행동이다. 각 혼합 후보를 같은 구간 H 만큼 재진행하여 얻은 창 보상 $R_k^{(p)} = R(\mathbf{s}, \mathbf{a}^{(k,p)}; H)$ 로 방어정 p 만의 이득을 산정한다.

$$A_k^{(p)} = \frac{R_k^{(p)} - R_0^{(p)}}{\text{std}(\{R_j^{(p)}\}_{j=0}^{G-1}) + \epsilon} \quad (31)$$

나머지 방어정의 행동이 고정되어 있으므로 $R_k^{(p)} - R_0^{(p)}$ 는 방어정 p 의 선택이 바뀐 데서만 온 차이이다. 이 이

득은 방어정 p 의 로그확률에만 곱해진다.

$$\mathcal{L}_{CF}(\theta) = -\frac{\sum_p \sum_n w_n^{(p)} \sum_k A_{n,k}^{(p)} \log \pi_\theta(\tilde{a}_{n,p}^{(k)} | \mathbf{s}_n)}{G \sum_p \sum_n w_n^{(p)}} \quad (32)$$

$w_n^{(p)}$ 은 유효 마스크 w_n 을 방어정 p 의 후보 집합에 적용한 것이며, 이 모드에서 식 (28)의 엔트로피는 기준 표본 $\mathbf{a}^{\text{base}}$ 에서만 계산한다. 식 (32)는 식 (28)에서 $\mathcal{L}_{PG}$ 자리에 들어간다. 이는 COMA [10]의 반사실적 기준선과 같은 착상이되, 학습된 비평가로 주변화하는 대신 시뮬레이터를 실제로 재진행하여 얻는다는 점이 다르다. 비평가 근사 오차가 개입하지 않는 대신, 결정당 시뮬레이터 호출이 G 회에서 GP 회로 늘어난다.

채택 여부. 두 손실을 같은 예산(800 업데이트)으로 비교한 스크리닝에서 반사실 모드는 600 업데이트 시점 greedy 포획률 0.801 로 팀 이득 모드의 0.800 과 동물이었고, 시뮬레이터 호출은 3배였다. 본 논문이 평가하는 체크포인트는 팀 이득 손실(식 (27)–(29))로 학습한 것이다.

4.5.3 보상 설계

한 후보의 창 보상 $R(\mathbf{s}, \mathbf{a}; H)$ 는 결정 시점부터 H step 동안 일어난 일을 하나의 스칼라로 합산한 팀 공유 보상이며, 이벤트 항·퍼텐셜 차분·조밀 항으로 구성된다.

$$R = R_{\text{event}} + [\gamma \Phi(\mathbf{s}_{t+H}) - \Phi(\mathbf{s}_t)] + R_{\text{dense}} \quad (33)$$

이벤트 항은 창 안의 사건 수에 고정 가중을 곱한 합이다.

$$R_{\text{event}} = r_{\text{cap}} N_{\text{cap}} + r_{\text{brc}} N_{\text{brc}} + r_{\text{col}} (N_{\text{col}} + N_{\text{land}}) + r_{\text{tng}} N_{\text{tng}} + \mathbb{K}_{\text{end}} (r_{\text{wipe}} \mathbb{K}[\mathcal{A} = \emptyset] + r_{\text{surv}} |\mathcal{A}|) \quad (34)$$

계수는 포획 $r_{\text{cap}} = +13.5$, 돌파 $r_{\text{brc}} = -8.0$, 아군·모선·육지 충돌 $r_{\text{col}} = -30$, 설치 그물 접촉 $r_{\text{tng}} = -13$, 창 안에서 에피소드가 끝날 때($\mathbb{K}_{\text{end}}$) 전멸 $r_{\text{wipe}} = +8$, 잔존 적 1척당 $r_{\text{surv}} = -5$ 이다. Φ 는 적의 모선 근접도에 대한 퍼텐셜로, 차분 형태로 주어지므로 최적 정책을 보존한다 [26].

$$\Phi(\mathbf{s}) = -w_{\text{threat}} \sum_{m \in \mathcal{A}} \text{clip}\left(1 - \frac{\|\mathbf{e}_m - \mathbf{m}\|}{R_w}, 0, 1\right) \quad (35)$$

여기서 $\mathcal{A}$ 는 생존 적선 집합, $R_w = 6300 \text{ m}$ 는 교전 해역 반폭, $w_{\text{threat}} = 3.0$, $\gamma = 0.99$ 이다. 적이 포획되어 $\mathcal{A}$ 에서 빠지거나 멀어지면 Φ 가 오른다.

조밀 항은 창 안의 기동 품질을 재는 비용·보너스의 합이다. 창 길이 H , 방어정 속력 v_a , 최대 선회율 $\dot{\psi}_{\text{max}}$, 창 안 총 이동거리 D , 소모 그물 수 N_{net} 에 대해

$$\begin{aligned} R_{\text{dense}} = & -w_{\text{path}} \frac{D}{H v_a P} - w_{\text{net}} N_{\text{net}} - \frac{w_{\text{turn}}}{P} \sum_{p=1}^P S_p \\ & - w_{\text{prox}} \sum_{p=1}^P (\rho_p^{\text{m}^2} + \rho_p^{\text{a}^2}) - \frac{w_{\text{cons}}}{P} \sum_{p=1}^P \Xi_p \\ & + w_{\text{cov}} \text{Cov} + w_{\text{ray}} \text{Ray} \end{aligned} \quad (36)$$

이다. $S_p = \sum_t |\Delta \psi_{p,t}| / (H \dot{\psi}_{\text{max}}) \in [0, 1]$ 은 창 안 누적 선회량을 최대 가능 선회량으로 나눈 값이고, $\Xi_p = \|\mathbf{t}_p - \mathbf{t}_p^{\text{prev}}\| / L_{\text{max}}$ 는 직전 결정 대비 목표점 이동을 최대 경로 길이 $L_{\text{max}} = L_{\text{net}}$ 로 나눈 값이다(구현은 경유점 6개와 생존 방어정에 대해 평균하며, 여기서는 목표점 단위로 단순화하여 적었다). 근접 페널티는 창 안에서 방어정 p 가 모선·타 방어정에 가장 가까웠던 거리 d_p^{m} , d_p^{a} 를 영향 반경으로 정규화한 뒤 제공하여, 불을수록 급격히 커지게 한다.

$$\rho_p^{\text{m}} = \text{clip}\left(\frac{R_m - d_p^{\text{m}}}{\varrho_m}, 0, 1\right), \quad \rho_p^{\text{a}} = \text{clip}\left(\frac{\varrho_a - d_p^{\text{a}}}{\varrho_a}, 0, 1\right) \quad (37)$$

($R_m = 800$, $\varrho_m = 500$, $\varrho_a = 600 \text{ m}$). 커버리지는 적에서 모선으로 향하는 직선(ray)이 설치된 그물에 막힌 생존 적의 비율이며, 포획의 선행 지표로서 창 안에 포획이 없을 때도 변별력을 준다.

$$\text{Cov} = \frac{1}{|\mathcal{A}|} \sum_{m \in \mathcal{A}} \mathbb{K}[\exists \lambda \in \Lambda : \mathbf{e}_m + \lambda(\mathbf{m} - \mathbf{e}_m) \in \mathcal{W}] \quad (38)$$

여기서 $\mathcal{W}$ 는 설치된 그물이 차지하는 영역이고, Λ 는 $[0.05, 0.95]$ 를 16등분한 표본점이다. Ray 는 같은 검사를 계획된 그물벽까지 포함하되, 두 방어정이 충돌 거리 안에서 같은 ray 를 겹쳐 막으면 무효로 치고, 차단된 적마다 배율 $b_{\text{net}} (1 + g_{\text{far}} (1 - \lambda_m))$ ($b_{\text{net}} = 1.3$, $g_{\text{far}} = 1.0$, λ_m 은 차단점의 ray 상 위치로 적에 가까울수록 0)을 곱해 적에 가까운 차단을 우대하는 단일 커버 판이다 (Ray $\in [0, 2.6]$). 가중은 $w_{\text{path}} = 0.5$, $w_{\text{net}} = 0.3$, $w_{\text{prox}} = 0.75$, $w_{\text{turn}} = w_{\text{cons}} = 0.3$, $w_{\text{cov}} = 0.1$, $w_{\text{ray}} = 1.6$ 이다.




Figure 10: 점수맵 위 픽셀 지목의 네 단계 — 픽셀 특징, 유효 마스크, 첫 점 선택, 간격 제약 아래 둘째 점 선택




Figure 11: 가치망 없는 그룹 상대 최적화의 한 갱신 — 후보 표집(위), 룰아웃 창 평가(가운데), 상대 비교와 반사실적 크레딧(아래)

레이 커버 항을 제외한 조밀 항은 이벤트 계수의 수십분의 일 규모이고, 레이 커버 항은 최대 4.2 로 포획 1건(13.5)의 3분의 1을 넘지 않게 두었다. 이 밖에 요격점 접근·예비 방어정 정지·인공 퍼텐셜 척력 등 가중 0.1 ~ 0.25 의 보조 항이 있으나 규모가 작아 생략한다.

퍼텐셜 항을 둔 이유는 이벤트 항만으로는 학습 신호가 지나치게 희소하기 때문이다. 216개 결정에 대한 실측에서 포획은 평가 창 의 46.8 %에서만 발생하였다. 나머지 절반의 창에서는 퍼텐셜 항이 유일한 큰 신호이며(비영 비율 100 %), 이것이 없으면 그룹 내 후보들의 순위가 갈리지 않아 식 (26)의 이득이 정의되지 않는다. 같은 측정에서 퍼텐셜 항의 평균은 +0.36 인 데 비해 절댓값 평균은 7.40 으로, 창마다 크게 변동하지만 전체적으로는 상쇄된다. 이는 퍼텐셜 기반 성형이 설계대로 정책은 바꾸지 않고 변별력만 제공한다는 설계 의도와 부합한다.

4.5.4 학습 프로토콜

학습은 실해역 6곳을 에피소드마다 돌려가며 진행하였다(Fig. 7; 각 패널은 12.6 km 박스이고 백분율은 박스 안 육지 비율과 요격 구역 잠식 비율, 거리는 최근접 육지까지의 여유다). 한 해역만으로 학습하면 정책이 그 해안선의 형상을 외워 “섬은 항상 저기 있다”를 전제로 굳는다. 여섯 곳은 육지 비율 0%(외해)에서 7.5 %까지, 요격 구역에 육지가 잠식하는 비율 0에서 6 %까지 분포 하도록 골랐고, 모션에서 가장 가까운 육지까지의 여유도 1.6km에서 무한대까지 걸쳐 있다. 육지 비율 0%인 외해는 포항 호미곶 동측으로, 지형이 없는 상황을 학습 분포에 넣기 위한 대조 해역이다. 평가(\$5)는 이 가운데 통영 매물도 서측 한 곳에서 수행한다. 총 800 업데이트 (50² 격자, 후보 $G = 8$, 후보 평가 구간 180 step)를 돌리고 200 업데이트마다 greedy 평가를 두어, 그 최고점 (600 업데이트, 포획률 0.805; 휴리스틱 기준선 0.744)의 가중치를 본 논문의 정책으로 채택하였다. 학습 중 포획률 곡선은 매 업데이트 새로 표집한 전장의 난이도

가 실려 진동하므로, 채택은 학습 곡선이 아니라 고정 프로토콜의 greedy 평가로 판정한다.

행동 복제 초기화 그룹 상대 이득은 후보들이 실제로 갈릴 때만 신호를 주므로, 무작위 초기화된 정책에서 곧바로 시작하면 초기 후보가 모두 무의미한 자리에 흩어져 갱신이 잡히지 않는다. 그래서 그룹 상대 최적화에 앞서 휴리스틱 행동(\$4.3)을 목표로 하는 행동 복제를 300 step 수행하여 정책을 부팅한다(Adam, 학습률 3×10^{-4}). 목표 분포에는 가우시안 라벨 스무딩을 적용한다. 휴리스틱이 지목한 픽셀 i_k^* 주변에 유효 픽셀로 제한한 가우시안 가중을 두고, 그 가중과 정책의 교차엔트로피를 최소화한다.

$$\omega_k(i) = \frac{\mathbb{I}[i \in \mathcal{V}_p^{(k)}] \exp(-\|\mathbf{x}_i - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{BC}^2)}{\sum_{j \in \mathcal{V}_p^{(k)}} \exp(-\|\mathbf{x}_j - \mathbf{x}_{i_k^*}\|^2 / 2\sigma_{BC}^2)} \quad (39)$$

$$\mathcal{L}_{BC}(\theta) = -\frac{1}{P} \sum_{p=1}^P \sum_{k=0}^{K-1} \sum_{i \in \mathcal{V}_p^{(k)}} \omega_k(i) \log \pi_p^{(k)}(i) \quad (40)$$

$\sigma_{BC} = 0.8\text{px}(\approx 202\text{m})$ 이며, 두 번째 픽셀의 질의는 휴리스틱의 첫 픽셀로 갱신한다(teacher forcing). 격자 위의 인접 픽셀은 사실상 같은 행동이므로 단일 픽셀 원-핫을 목표로 두면 불필요하게 뽀족한 분포를 강요하게 되고, 조밀한 점수맵에서 원-핫 교차엔트로피의 기울기는 지나치게 희소하여 초기 학습이 붙지 않기 때문이다. 그룹 상대 최적화 단계에서는 이 항을 쓰지 않으며, 대신 식 (26)의 휴리스틱 기준선이 정책을 휴리스틱 근방에 붙잡는 신뢰 영역 구실을 한다.

학습률·엔트로피 계수 스케줄 옵티마이저는 Adam이고 학습률은 재시작 없는 단일 주기 코사인 어닐링 [27]

으로 줄인다.

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})\left(1 + \cos \frac{\pi t}{T}\right), \quad (41)$$

$$\eta_0 = 10^{-4}, \quad \eta_{\min} = 0.05 \eta_0, \quad T = 800.$$

주기 T 를 총 업데이트 수에 묶었으므로 예산을 바꾸면 스케줄 전체가 함께 늘어난다 — 비교 실험은 같은 T 로만 한다. 같은 축 위에서 식 (28)의 엔트로피 계수는 선형으로 감쇠한다.

$$\lambda_H(t) = \lambda_0 \left(1 - (1 - \kappa) \frac{t}{T}\right), \quad \lambda_0 = 0.01, \quad \kappa = 0.1 \quad (42)$$

즉 0.01 에서 0.001 로 줄어든다. 기울기는 식 (29)대로 노름 $g_{\max} = 1.0$ 에서 자른다. 코사인을 고른 이유는 순위만 쓰는 그룹 상대 이득의 기울기 분산이 커서 후반 보폭을 줄여야 하고, 학습률과 엔트로피 계수를 같은 예산 축에서 함께 줄이면 분포가 뽕족해지는 시점과 보폭이 작아지는 시점이 맞물리기 때문이다. 상수 학습률과의 대조 실험은 수행하지 않았다.

수렴 진단 채택 런은 보상·포획률·손실만 20 업데이트마다 남겼으므로 *정책이 정지점에 닿았는가*를 직접 보이는 지표가 없다. 이를 보완하기 위해 같은 설정을 시드 3개로 다시 돌리며 수렴 진단을 매 업데이트마다 기록하였다(Fig. 12; 파란 실선은 시드 평균의 10업데이트 이동평균, (a)의 빨간 파선은 채택 런, 초록 파선은 휴리스틱 기준선). 재현 런의 가중치는 논문의 결과에 쓰지 않는다. 갱신 전후 정책을 θ_t, θ_{t+1} 라 하면 두 진단량은 다음과 같다.

$$\widehat{KL}_t = \frac{1}{NP(G-1)} \sum_{n,p} \sum_{k=1}^{G-1} (\zeta_{n,p,k} - 1 - \log \zeta_{n,p,k}),$$

$$\zeta_{n,p,k} = \frac{\pi_{\theta_{t+1}}(a_{n,p}^{(k)} | \mathbf{s}_n)}{\pi_{\theta_t}(a_{n,p}^{(k)} | \mathbf{s}_n)}, \quad \varsigma_t = \frac{\|\theta_t - \theta_{BC}\|}{\|\theta_{BC}\|} \quad (43)$$

$\widehat{KL}_t$ 는 같은 관측·같은 표본 후보(휴리스틱 후보 $k=0$ 은 정책의 표본이 아니므로 제외)에 대한 확률비 ζ 의 k_3 추정량으로, $KL(\pi_{\theta_t} \| \pi_{\theta_{t+1}})$ 의 비음(非陰)·저분산 몬테카를로 추정이다. ς_t 는 행동복제 초기점 θ_{BC} 로부터의 상대 파라미터 이동 거리이다.

세 시드에서 지표들이 같은 방향을 가리킨다. 업데이트 간 근사 KL 은 처음 100 업데이트 평균 1.4×10^{-2} 에서 마지막 100 업데이트 1.5×10^{-4} 로 두 자릿수 줄고, 파라미터 이동 거리는 400 업데이트 0.031 에서 800 업데이트 0.034 로 뒤 절반에서 포화하며, 정책 엔트로피는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하다(붕괴 없이 침체해진다). 유효 픽셀 중앙값 273개의 균일분포 상한 $\ln 273 \approx 5.6 \text{ nat}$ 에 비하면 크게 낮다. 표본 후보의 휴리스틱 대비 보상 이득은 -1.3 에서 $+5.1$ 로 부호가 바뀐다. greedy 평가 포획률은 세 시드 모두 800 업데이트에서 기준선 0.749 위에 있고 (0.817, 0.777, 0.801), 채택 런의 세 평가점은 이 범위 안에 든다 — 채택 런이 특별히 운 좋은 경과가 아니었다는 뜻이다. 그래디언트 노름은 800 업데이트 내내

클립 한계의 12배 이상이라 수렴 지표로 쓰지 않는다 — 식 (26)의 이득이 그룹 표준편차로 정규화되어 크기가 없는 양이기 때문이며, 이 구조에서 실제 보폭을 정하는 것은 학습률이다.

4.6 언어모델 기반 전략 계층

전략 계층의 위치는 Fig. 3에, 실제 동작 화면은 Fig. 13에 있다. 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고, 출력은 무리별 배정과 대기(HOLD)이며, 그 배정이 기동 계층으로 전달되어 각 방어정의 그물벽 위치 결정을 조건짓는다.

언어모델에는 좌표 원시 데이터 대신 *기하량이 미리 계산된* 전장 상태를 직렬화하여 전달한다. 각 적 무리의 요격점까지의 이동거리와 선회량, 모션 기준 방위, 설치된 그물에 의한 접근로 차단 여부 등이 포함된다. 언어모델이 삼각함수를 암산하게 하는 대신 판단에 필요한 양을 미리 제공하는 것이다.

4.6.1 구조적 출력에 의한 행동 규제

언어모델의 출력을 자유 문장으로 받으면 하위 계층이 파싱에 실패할 수 있고, 실패 시 그 주기의 배정이 통째로 사라진다. 본 연구는 출력을 *스키마로 강제*하여 이 실패 모드를 구조적으로 차단한다 [23]. 계획을 다음 자료형으로 선언하고, 그로부터 생성한 JSON 스키마를 모델 호출에 함께 넘긴다.

```
CommanderPlan {
  rationale: str
  deployments: List[{
    cluster_id: int,
    ally_ids: List[int] }]
  hold_ships: List[int]
}
```

이 스키마는 디코딩 단계에서 문법으로 작용하여, 형식에 맞지 않는 토큰이 애초에 생성되지 않게 한다. 지역 실행에서는 스키마를 `format` 인자로, 상용 API에서는 `response_schema` 로 전달하며, 두 경우 모두 응답을 같은 자료형으로 역직렬화하여 검증한다. 온도는 0으로 두어 같은 전장에서 같은 배정이 나오게 한다. 이는 §5.2의 시드 대응표본 설계가 성립하기 위한 전제이기도 하다.

필드 순서. 스키마는 *판단 근거* → *무리별 배정* → *대기 목록* 순으로 고정하여 배정이 근거를 조건으로 생성되게 하되, 근거 원문은 저장하지 않았으므로 그 인용 준수 여부는 검증하지 못한다 (§7.2).

빈 배정의 의미는 프롬프트가 규정한다. `ally_ids` 를 비우는 것은 “시스템이 대신 고르라”가 아니라 “이 무리에는 아무도 보내지 않는다”를 뜻한다. 앞에서 밝혔듯 코드 보완이 없으므로 빈 목록은 그대로 무방비를 낳으며, 프롬프트가 이 결과를 명시하여 지휘관이 그 대가를 알고 결정하게 한다.

조합 최적화 후처리를 두지 않는다. 언어모델이 지목한 배가 그대로 배정되며, 최소비용 매칭이나 2-opt 개선이 개입하지 않는다. 언어모델이 비워 둔 무리는 담당 없이 남고, 지목되지 않은 방어정은 대기한다. 후




Figure 12: 수렴 진단(회색 시드별, 파란 실선 시드 평균): (a) greedy 포획률, (b) 정책 엔트로피, (c) 근사 KL 발산, (d) 파라미터 이동



Figure 13: 실행 화면(양동 포메이션, Gemini 지휘관) — 전장(왼쪽)과 지휘관의 배정·근거(오른쪽)

처리를 두면 최종 배정이 사실상 비용 함수의 산물이 되어 언어모델의 기여를 측정할 수 없기 때문이다. 이 선택은 성능이 아니라 측정 가능성을 위한 것이며, 그 대가는 §6에서 정량적으로 드러난다.

후처리를 두지 않는다는 것이 기하 보정이 없다는 뜻은 아니다. 언어모델이 정할 수 있는 것은 출력 스키마가 정확히 제한한다 — 무리별 배정 항목의 필드는 `cluster_id` 와 `ally_ids` 둘뿐이고, 그 밖에 결정되는 것은 판단 근거와 대기 목록(`hold_ships`) 뿐이다. 즉 권한은 어느 배가 어느 무리를 맡는가와 이번 주기에 누가 멈추는가로 닫혀 있다. 그물 전개 여부도, 벽의 방위도, 교전 반경도 출력에 없다. 배정으로부터 요격

점을 만드는 기하는 전적으로 코드다.

그 기하는 두 경로에서 같은 규칙을 쓴다. 한 무리에 두 척 이상이 배정되면 §4.3의 잉여 배정과 같은 두 손잡이가 작동한다 — 모션 쪽으로 $\lambda_L = 0.18$ 씩 미는 반경 층 분리와 $\pm 40^\circ$ 씩 번갈아 뜨는 방위 분리다. 완전히 같지는 않아서, 언어모델 경로는 (i) 층 순서를 기본 요격점에 가까운 배부터 주고, (ii) 층을 깊게 넣다 요격점이 모션 코앞으로 들어오는 것을 막기 위해 반경을 요격 구역 안으로 자른다. 구역을 벗어난 요격점은 기동 계층의 유효 마스크를 붕괴시켜 폴백으로 떨어지기 때문이다.

권한이 배정과 대기로 닫혀 있다는 점이 중요하다.

전략 계층이 기하까지 건드릴 수 있으면 §6.1.1에서 관측되는 차이가 배정 판단에서 온 것인지 기하 조정에서 온 것인지 분리되지 않는다. 두 경로가 같은 기하 규칙을 공유하기 때문에, 조건 간 차이는 배정 그 자체의 차이로 읽을 수 있다.

배정이 확정되면 각 방어정의 요격점이 정해지고, 그 요격점을 중심으로 기동 계층이 그물벽을 놓을 수 있는 후보 영역(유효 마스크)이 함께 결정된다. 즉 배정은 기동 계층의 선행 조건이며, 배정이 바뀌면 후보 영역 자체가 바뀐다. 조합 최적화 후처리를 두지 않았으므로 §6.2.1 이하의 조건 간 차이는 지휘관의 배정 그 자체에 귀속된다.

4.7 온보드 배치 고려사항

제안 정책은 배치 크기 1의 온보드 추론을 전제로 설계되었다. 첫째, 정규화가 전부 그룹 정규화이고(§4.4) 관측은 격자 크기와 설정 상수로만 나누므로, running statistics 가 없어 학습과 추론의 연산이 같다. 둘째, 정책은 경유점만 지정하고 조타는 저수준 제여기가 담당하므로 선제 동역학 [28]과 분리되어, 선제 특성이 다른 플랫폼에 재학습 없이 이식할 여지가 있다. 셋째, 관측과 행동이 절대 길이가 아닌 격자 상대 좌표라 실해역 이식 시 격자 축척만 재설정하면 된다. 온보드 구성(단일 GPU에 시뮬레이터·정책 추론·언어모델 서빙이 함께 올라가는 것)에서 기동 정책의 순전파(244,389 파라미터)는 결정 주기 대비 무시할 만하며, 언어모델 지휘관의 지연 분포와 그것이 요구하는 비동기 분리는 §6.4에서 실측으로 다룬다. 세 성질 모두 시뮬레이션 안에서만 확인되었으며, 실증은 §7.2의 한계로 남긴다.

5 실험 설계

이 절의 장치 — 2×2 조건 행렬, 시드 대응표본, 지표 10개에 대한 다중비교 보정 — 는 모두 한 목적을 위한 것이다: 두 계층의 기여를 분리하여 계층별로 식별하여 앞 절의 설계가 실제로 무엇을 얼마나 사는지 — 기동 계층의 그물·신뢰량 절감과 지휘관 계층의 능력 임계 — 를 말할 수 있게 하는 것. 그중 기동 계층 단독 조건은 언어모델을 호출하지 않으므로 외부 API 없이 공개 시뮬레이터와 체크포인트만으로 재현된다.

5.1 실험 조건

두 계층의 기여를 분리하려면 각 계층을 독립적으로 켜고 끌 수 있어야 한다. 따라서 배정 축과 기동 축을 각각 이분하여 2×2 조건 행렬을 구성한다(Table 5).

휴리스틱 배정과 기동은 §4.3의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직접 비교 가능하다. `heur_unet` 조건은 언어모델을 호출하지 않아 외부 API 없이 재현된다. 전략 계층에는 능력 수준이 다른 세 모델 — Qwen2.5 7B, Qwen2.5 14B(로컬), Gemini 3.5 Flash-Lite(클라우드) — 을 두어, LLM 조건은 온보드 대 클라우드라는 배치 선택지까지 포함해 총 8조건이 된다.

5.2 수집 프로토콜

모든 조건이 동일한 시드 집합(0–29)을 사용한다. 시드 k 의 전장은 조건이 달라도 동일하므로 조건 간 차이를 취하면 시나리오 난이도의 변동이 상쇄되어 독립표본 설계보다 좁은 신뢰구간을 얻는다. 총 수집량은 8조건 $\times$ 3포메이션 $\times$ 30시드 = **720 에피소드**이며, 조건·포메이션별 칸이 모두 30개로 균형을 이룸을 확인하였다(불균형 시 공통 교집합만 집계한다). 지휘관 재계획은 배치 설정과 같이 매 결정(25 step)마다 수행한다 — 주기를 늘리면 매 결정 새로 계산되는 휴리스틱 배정과 낡은 LLM 계획을 비교하게 되어 LLM 조건에 불리한 편향이 생기기 때문이다.

5.3 통계 절차

신뢰구간. 조건별 평균의 95% 신뢰구간은 편향-가속 보정(BCa) 부트스트랩 [29, 30]으로 구한다. 포획률은 $[0, 1]$ 로 잘려 분포가 치우치므로 단순 백분위 부트스트랩은 편향된 구간을 주기 때문이다.

대응 차이. 기준선 대비 개선은 시드별 차이의 부트스트랩 분포로 평가한다. 조건 X 와 기준선 Y 의 시드 k 에서의 지표값을 x_k, y_k 라 하면

$$d_k = x_k - y_k, \quad \bar{d} = \frac{1}{n_s} \sum_{k=1}^{n_s} d_k, \quad (44)$$

$$s_d^2 = \frac{1}{n_s - 1} \sum_{k=1}^{n_s} (d_k - \bar{d})^2, \quad d_z = \frac{\bar{d}}{s_d}$$

이며 시드 수 $n_s = 30$ 이다. $\bar{d}$ 의 BCa 신뢰구간은 $\{d_k\}$ 를 $B = 9999$ 회 재표집하여 얻으며, 구간이 0을 포함하면 평균이 높아도 기준선과 다르다고 말하지 않는다.

효과크기. 지표마다 단위가 달라 개선 폭의 절대값으로는 지표 간 비교가 불가능하므로 식 (44)의 대응표본 효과크기 d_z 를 함께 보고한다(관례상 $|d_z|$ 0.2·0.5·0.8이 작음·중간·큼).

다중비교. 한 조건에 대해 지표 10개를 동시에 검정하므로, 보정하지 않은 95% 구간과 지표 $m = 10$ 개에 대한 Bonferroni 보정 구간($\alpha' = \alpha/m = 0.005$, 즉 99.5% 구간)을 함께 보고한다(Table 11). 조건 수까지 곱하지 않은 것은 조건별 비교가 각각 독립된 질문이기 때문이다. 어느 결론이 보정을 견디는지는 §6.3.2에서 보고한다.

상호작용 분해. 두 계층이 서로를 돕는지는 2×2 상호작용으로 판정한다.

$$\text{Int} = (\text{llm_unet} - \text{llm_heur}) - (\text{heur_unet} - \text{heur_heur}) \quad (45)$$

Int > 0 이면 상승, ≈ 0 이면 가산, < 0 이면 상쇄이며, 모든 지표에 대해 보고한다.

Table 5: 2 × 2 조건 행렬. 조건 사이에 달라지는 것은 두 스위치뿐이며, 체크포인트·환경 설정·난수 시드는 모두 동일하다.

조건	배정 × 기동	무엇을 측정하는가
heur_heur	휴리스틱 × 휴리스틱	기준선(baseline)
heur_unet	휴리스틱 × U-Net	기동 계층의 순수 기여 — LLM을 쓰지 않는다
llm_heur	LLM × 휴리스틱	전략 계층의 순수 기여
llm_unet	LLM × U-Net	제안 체계(상호작용 포함)

5.4 지휘관 계층 계층

포획률은 체계 전체의 지표이므로 언어모델 계층의 기여를 가린다. 따라서 계획이 산출된 시점에 확인 가능한 양을 시뮬레이션 결과와 독립적으로 계층한다: 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지, churn, 교차 배정. 재계획 t 에서 방어정 p 가 맡은 무리를 j_p^t (미배정이면 $\emptyset$), 활성 무리 집합을 $\mathcal{C}^t$, 직전 계획에도 있던 방어정 집합을 $\mathcal{P}^t$ 라 하면 커버리지와 churn 은 다음과 같다.

$$\text{Cover}^t = \frac{|\{j_p^t : j_p^t \neq \emptyset\}|}{|\mathcal{C}^t|},$$

$$\text{Churn}^t = \frac{1}{|\mathcal{P}^t|} \sum_{p \in \mathcal{P}^t} \mathbb{1}[j_p^t \neq j_p^{t-1}] \quad (46)$$

교차 배정은 방어정 위치와 배정 무리 중심을 잇는 선분 쌍 가운데 서로 교차하는 쌍의 수이다. 세 지표 모두 에피소드 안의 재계획에 걸쳐 평균한다.

폴백률이 0이 아니면 해당 LLM 조건의 일부는 휴리스틱 출력이다. 본 수집에서 폴백률은 Gemini 0.000, Qwen2.5 14B 0.001, Qwen2.5 7B 0.007로 무시할 수 있는 수준이었다.

6 결과

§5의 설계가 답하려는 질문은 하나다 — 두 계층의 기여를 분리했을 때 계층별로 무엇을 얼마나 사는가 — 기동 계층은 그물과 선회량을, 지휘관 계층은 능력 임계 위에서만 포획률을. 아래는 그 답을 세 묶음으로 보인다: 기동 계층이 사는 것 (§6.1), 지휘관 계층이 사는 것과 그 조건 (§6.2), 그리고 둘이 더해지는가 (§6.3). 마지막으로 배치 관점의 지연을 보고한다 (§6.4).

6.1 기동 계층이 사는 것: 같은 방어를 더 적은 자원으로

6.1.1 기동 계층: 휴리스틱 대 U-Net 점수맵 (LLM 미사용)

먼저 언어모델을 배제하고, §4.3의 기하 휴리스틱과 §4.4의 점수맵 정책만 비교한다. 두 조건 모두 배정은 휴리스틱이므로 차이는 오직 기동 방식이다 (Table 6). 3개 포메이션 통합 기준으로 포획률은 0.844 → 0.886 (+0.041, $d_z = 0.37$)로 개선되었고 95 % 신뢰구간이 0을 포함하지 않는다. **다만 이 개선은 아슬아슬하다** — 지표 10개에 대한 다중비교 보정을 걸면 구간이 $[-0.013, +0.100]$ 로 0을 포함한다 (§5.3). 이 절이 보

이려는 것은 포획률의 증가가 아니라, 뒤에서 보이듯 같은 정도로 막으면서 자원과 기동을 크게 줄인다는 쪽이다.

같은 비교를 10개 지표 전부에 걸쳐 한눈에 보인 것이 Fig. 14다. 각 축은 지표별 조건 평균을 평가한 8개 조건의 범위로 0–1 정규화한 값이며 (낮을수록 좋은 지표는 방향을 뒤집어 1 = 8개 조건 중 최선), 두 다각형이 겹치는 축은 기동 방식이 결과를 바꾸지 않는 지표다. 전체 (a)에서 U-Net 다각형은 포획률·돌파·포획 이격거리·포획 시간·포획당 그물·그물 걸림·총 선회량 축에서 바깥에 있고, 충돌률·전개 시 적 거리 축에서는 거의 겹치며, 포획당 이동거리 축에서만 안쪽이다 — 자리를 골라 그물벽을 놓는 대신 더 멀리 움직이는 셈이다.

포메이션별로 보면 기여가 고르지 않다. 파상 포메이션에서 +0.157($d_z = 0.48$)로 가장 크고, 집중 포메이션에서는 0.000, 양동 포메이션에서는 −0.033 으로 오히려 소폭 낮다(다만 후자의 신뢰구간은 0을 포함하므로 약화라고 말할 수 없다).

이 분포는 포메이션의 구조와 대응한다. 파상 공격은 이웃한 방위의 3개 단이 거리차를 두고 도달하므로, 앞단을 막은 그물벽의 위치가 뒤 단까지 막을 수 있는지를 좌우한다. 해면 전체를 평가하여 자리를 고르는 점수맵 방식이 여기서 직접적으로 값을 한다. 반면 양동 공격은 세 방위에서 동시에 도래하여 방어정 수와 무리 수가 같으므로, 결정적인 것은 어느 방어정을 어느 무리에 붙이는가라는 **배정** 판단이다. 배정이 어긋나면 기동 계층이 아무리 좋은 자리를 골라도 애초에 잘못된 무리를 막게 되므로 보정되지 않는다. 집중 포메이션은 뒤에서 보이듯 천장 구간이다.

운용 함의. 언어모델 없이 기동 계층만 교체해도 같은 방어 성과를 더 적은 그물과 기동으로 얻는다. 이 조건은 외부 API가 없는 온보드 구성에서 먼저 적용할 수 있는 부분이다.

6.2 지휘관 계층이 사는 것과 그 조건

6.2.1 전체 조건 비교

Table 7과 Fig. 15에 8개 조건의 포획률을 정리하였다. 그림의 무채색 두 막대가 언어모델 없는 기준선이고 그 오른쪽은 모델 규모 오름차순이며, 오차막대는 시드 부트스트랩 95 % 신뢰구간이다.

Gemini 지휘관을 쓴 두 조건이 기준선 대비 유의한 개선을 보인다(각각 +0.060, +0.062). 반면 Qwen2.5 7B 는 두 기동 조건 모두에서 기준선보다 **유의하게 나쁘다** (−0.192, −0.203). 이 음의 결과는 §6.2.2에서 다룬다.

Table 6: 기동 계층(U-Net 점수맵 + GRPO)의 단독 기여. 두 조건 모두 배정은 휴리스틱이며 **LLM** 을 전혀 사용하지 않는다 — 따라서 이 결과는 외부 API 에 의존하지 않고 재현 가능하다. 파상 포메이션에서 가장 크다.

포메이션	휴리스틱 기동	U-Net 기동	Δ [95 % CI]	d_z
집중	0.997	0.997	+0.000 [-0.010, +0.010]	+0.00
양동	0.787	0.753	-0.033 [-0.077, +0.000]	-0.31
파상	0.750	0.907	+0.157 [+0.043, +0.270]*	+0.48
전체	0.844	0.886	+0.041 [+0.003, +0.082]*	+0.37

* 신뢰구간이 0 을 포함하지 않음. 전체 행은 3개 포메이션 통합.




Figure 14: 휴리스틱 대 U-Net 기동의 지표 프로파일(바깥일수록 우수): (a) 전체, (b) 집중, (c) 양동, (d) 파상

Table 7: 조건별 포획률. 평균과 부트스트랩 95 % 신뢰구간, baseline 대비 대응표본 차이. 3개 포메이션 통합(각 조건 30시드).

지휘관(배정)	기동	포획률 [95 % CI]	Δ vs baseline	d_z
휴리스틱 (baseline)	휴리스틱	0.844 [0.808, 0.880]	—	—
휴리스틱	U-Net 점수맵	0.886 [0.847, 0.918]	+0.041 [+0.003, +0.082]*	+0.37
Qwen2.5 7B	휴리스틱	0.652 [0.571, 0.716]	-0.192 [-0.264, -0.129]*	-1.00
Qwen2.5 14B	휴리스틱	0.811 [0.766, 0.854]	-0.033 [-0.086, +0.017]	-0.23
Gemini 3.5 Flash-Lite	휴리스틱	0.904 [0.864, 0.937]	+0.060 [+0.024, +0.100]*	+0.56
Qwen2.5 7B	U-Net 점수맵	0.641 [0.582, 0.693]	-0.203 [-0.274, -0.138]*	-1.03
Qwen2.5 14B	U-Net 점수맵	0.754 [0.698, 0.806]	-0.090 [-0.153, -0.033]*	-0.54
Gemini 3.5 Flash-Lite	U-Net 점수맵	0.907 [0.869, 0.937]	+0.062 [+0.013, +0.113]*	+0.44

* 신뢰구간이 0 을 포함하지 않음. d_z 는 대응표본 효과크기. 첫 두 열이 2×2 설계의 두 축이다 — 같은 지휘관 행 두 개를 비교하면 기동 계층의 기여가, 같은 기동 열을 비교하면 지휘관의 기여가 나온다. Qwen2.5 는 로컬(단일 RTX 4070) 서빙, Gemini 는 클라우드 API 다.




Figure 15: 포메이션별·조건별 포획률(색: 지휘관, 빗금: 기동 계층, 오차막대: 시드 부트스트랩 신뢰구간)

포메이션별 분해 통합 수치는 포메이션에 따라 다르게 읽어야 한다(Table 8). 집중 포메이션은 휴리스틱만으로 포획률 0.997에 도달하므로 개선 방향으로는 어떤 방법도 변별되지 않고(기동 계층 단독 차이 +0.000, 95 % CI [-0.010, +0.010]), 통합값은 이 구간이 3분의 1을 차지하여 희석된다. 양동과 파상만 보면 제안 체계의 개선은 각각 +0.090, +0.103 으로 통합값 +0.062 보다 크다. 한편 이 구간은 악화 방향으로 여전히 변별력을 가진다 — Qwen2.5 7B 배정이 -0.157 ([-0.323, -0.057]), 같은 모델에 점수맵을 붙여도 -0.110 ([-0.247, -0.043]), 14B에 점수맵을 붙인 경우가 -0.040 ([-0.100, -0.010]) 으로, 약한 지휘관은 거의 완벽한 상황도 악화시킨다. 이는 §6.2.2의 능력 임계가 가장 쉬운 포메이션에서도 관측된다는 뜻이다.

Table 8: 포메이션별 천장 효과. 집중 포메이션은 baseline 이 이미 0.997 이라 개선 여지가 0.003 뿐이다 — 이 포메이션 단독으로 결론을 내면 안 된다.

포메이션	baseline	남은 여유	제안	Δ
집중	0.997	0.003	0.990	-0.007
양동	0.787	0.213	0.877	+0.090*
파상	0.750	0.250	0.853	+0.103

* 신뢰구간이 0 을 포함하지 않음.

6.2.2 지휘관 능력 임계

기동 계층을 휴리스틱으로 고정하여 지휘관 측만 분리하면, 모델 능력에 따른 단조 증가가 나타난다(Fig. 16; 오차막대는 시드 부트스트랩 95 % 신뢰구간).

3개 포메이션 통합 기준으로 Qwen2.5 7B는 0.652, Qwen2.5 14B는 0.811, Gemini는 0.904이며, 휴리스틱 기준선은 0.844이다. 즉 휴리스틱 선을 14B와 Gemini 사이에서 교차한다.

이 결과가 함의하는 바는 “LLM 지휘관을 쓰면 좋다”가 아니라 “일정 능력 수준에 못 미치는 지휘관은 코드 휴리스틱보다 못하다”이다. Qwen2.5 7B의 -0.192($d_z = -1.00$)는 유의한 악화이며, 이 음의 결과가 임계 주장을 신뢰할 수 있게 만든다.




Figure 16: 지휘관 능력 사다리(기동 계층 휴리스틱 고정, 점선: 휴리스틱 배정 기준선)

6.2.3 무엇이 지휘관 성능을 만드는가

능력 순위 자체는 모델이 바뀌면 남는다. 더 오래 남는 질문은 무엇이 성능을 만드는가이다. 계획 단위 계획 결과를 Table 9와 Fig. 17에 정리하였다(점 하나가 지휘관 모델 하나, 오차막대는 양방향 부트스트랩 95 % 신뢰구간). 그림에 회귀선이나 상관계수는 없지 않았다 — 모델이 3종이라 $n = 3$ 이며, 여기에 상관을 적으면 없는 통계적 근거를 주장하는 셈이 된다.

결정적인 관측은 다음과 같다. Qwen2.5 7B는 커버리지 가장 높은데(0.934) 포획률은 가장 낮다(0.652). 즉 막아야 할 무리를 배정하지 않아서 지는 것이 아니다. 오히려 7B는 거의 모든 무리에 배를 지목한다.

성능과 단조로 대응하는 것은 churn과 경로 교차이다. churn은 0.324 → 0.167 → 0.098, 경로 교차는 0.152 → 0.111 → 0.033 으로 능력축을 따라 감소하며, 같은 순서로 포획률은 0.652 → 0.811 → 0.904 로 증가한다(모두 기동 계층을 휴리스틱으로 고정한 조건). churn 0.324는 재계획마다 방어정의 약 3분의 1이 담당을 바꾼다는 뜻이며, 이는 반쯤 전개한 그물벽을 버리고 떠난다는 것을 의미한다. 경로 교차는 두 방어정이 서로의 진로를 가로지르는 배정으로, 충돌 위험으로 직결된다.

이 관찰은 순위표가 아니라 설계 원리를 제시한다.




Figure 17: 계획 품질 대 성능: (a) 배정 커버리지, (b) 재계획 간 churn, (c) 경로 교차

Table 9: 지휘관 계획 품질과 성능. 계획 품질은 시뮬레이션 결과와 독립적으로, 계획이 산출된 시점에 측정한다. 7B는 커버리지가 가장 높는데 포획률은 가장 낮다 — 실패 원인은 미배정이 아니다.

지휘관	지연 (s)	커버리지 ↑	churn ↓	교차 ↓	폴백 ↓	포획률 ↑
Qwen2.5 7B (로컬)	2.75	0.934	0.324	0.152	0.007	0.652
Qwen2.5 14B (로컬)	16.59	0.877	0.167	0.111	0.001	0.811
Gemini 3.5 Flash-Lite (클라우드)	1.56	0.881	0.098	0.033	0.000	0.904

커버리지 = 배정된 활성 클러스터 비율. churn = 재계획 간 당당이 바꾼 배의 비율. 교차 = 두 방어정의 요격 경로가 교차한 비율. 포획률은 기동 계층을 휴리스틱으로 고정한 조건(LLM 지휘관 + 휴리스틱 기동)의 값이다.

주기적으로 재계획하는 구조에서는 계획의 최적성보다 계획의 안정성이 중요하다. 매 재계획마다 국소적으로 더 나은 배정을 찾아 바꾸는 것은, 그 전환 비용(버려지는 그물, 교차하는 경로)을 고려하면 손해일 수 있다.

6.2.4 정성적 예시

Fig. 13은 제안 체계가 실제로 동작하는 한 장면이다. 지휘관이 세 무리에 세 방어정을 각각 배정하고(패널 우측의 배정과 근거; 근거 문장은 모델 출력을 영문으로 옮겨 실었다), 각 방어정이 배정된 회랑에 그물벽을 친 결과 이 시점까지 적 3척이 포획되고 돌파와 아군 충돌은 없다. 재계획 주기는 §5의 평가 설정과 같은 25 step 이다.

운용 함의. 지휘관 계층은 능력 임계 위의 모델에만 켜다 — 본 실험 기준 로컬 7B는 끄는 편이 낮고 14B는 이득이 없으며, 클라우드 모델만 이득이었다. 지휘관을 고르거나 프롬프트를 손볼 때의 기준은 배정 커버리지가 아니라 재계획 간 담당 유지율이다.

6.3 두 기여는 더해진다

6.3.1 두 계층의 기여는 가산적이다

식 (45)의 상호작용을 10개 지표 전부에 대해 계산하였다 (Table 10, Fig. 18). 그림의 (a)에서 두 선이 평행해 가파를수록 두 계층의 기여가 가산적이고, (b)의 속이 빈 표식은 95% 구간이 0을 포함하는 차이이다. (a)에 오차막대를 두지 않은 것은 의도적이다 — 셀별 구간은 대응이 풀린 구간이라 시나리오 난이도의 분산을 그대로 포함해 넓고, 그것을 겹쳐 그리면 유의한 대응차이가 유의하지 않은 것처럼 읽힌다. 불확실성은 전부 (b)에

있다.

10개 지표 중 9개에서 상호작용의 신뢰구간이 0을 포함한다. 즉 두 계층은 서로를 돕지도, 서로를 잠식하지도 않는다. 본 논문은 이를 상승효과로 포장하지 않고 가산적이라고 보고한다. 이는 약점이 아니라 설계 검증으로 읽어야 한다. 두 계층이 서로 다른 실패 모드를 다루므로 기여가 독립적으로 누적된다는 뜻이기 때문이다.

이 판정은 다중비교 보정에도 흔들리지 않는다. Bonferroni 보정 구간(99.5%)으로 바꾸어도 0을 포함하는 지표는 그대로 9개다 — 보정은 구간을 넓히므로 “차이 없음”을 더 쉽게 만드는 방향인데, 그 방향으로 옮겨도 판정이 바뀌지 않는다는 뜻이다.

한 가지 예외는 평균 포획 시각이다. 상호작용이 -11.98 이고 95% 신뢰구간이 $[-19.84, -5.93]$ 로 유의한 상쇄를 보인다. 이 예외는 보정 구간에서도 살아남는다 — 99.5% 구간이 $[-23.31, -3.54]$ 이다. 따라서 다중비교가 만들어 낸 우연이 아니다. 이는 해석이 된다. 두 계층 모두 제압을 앞당기는 방향으로 작용하는데, 같은 포획을 두 번 앞당길 수는 없다. 공유 메커니즘에 대한 수확체감이다.

포메이션별로 보면 두 계층의 분업이 드러난다. 양동 포메이션에서는 기동 계층 단독 (-0.033)도 전략 계층 단독 ($+0.070$)도 신뢰구간이 0을 포함하여 유의하지 않은데, 둘을 결합하면 $+0.090$ 으로 유의해진다. 각각으로는 부족한 두 기여가 합쳐져 임계를 넘는 것이며, 2계층 설계가 값을 하는 지점이 여기다. 이는 이 포메이션의 구조와 부합한다 — 세 무리가 동시에 도래하고 방어정도 세 척이라 여유가 전혀 없으므로, 배정과 기동 어느 한쪽만 좋아서는 부족하고 둘 다 맞아야 막힌다. 반대로 파상 포메이션에서는 단이 시간차를 두고 오므로 자원 재배분의 여지가 있고, 기동 계층 단독 ($+0.157$)

Table 10: 2×2 상호작용 분해 (Gemini 지휘관). 10개 지표 중 9개에서 상호작용 신뢰구간이 0 을 포함한다 — 두 계층의 기여는 가산적이다.

지표	총효과	상호작용 [95 % CI]	판정
포획률	+0.062	-0.039 [-0.083, +0.012]	가산
돌파 수	-0.62	+0.39 [-0.13, +0.83]	가산
총돌률(적당)	-0.052	-0.015 [-0.070, +0.022]	가산
그물 걸림	-0.60	+0.17 [-0.08, +0.41]	가산
포획당 그물	-0.328	+0.004 [-0.045, +0.059]	가산
포획당 이동거리 (m)	-182	-55 [-125, +30]	가산
총 선회량 (rad)	-757	-56 [-165, +59]	가산
포획 이격거리 (m)	+223	+38 [-2, +81]	가산
평균 포획 시각 (step)	-22	-12 [-20, -6]	상쇄
전개 시 적 거리 (m)	-371	+26 [-44, +109]	가산

상호작용 = (LLM+U-Net − LLM+휴리스틱) − (휴리스틱+U-Net − baseline). 신뢰구간이 0 을 포함하면 두 계층이 서로를 돕지도 잡아먹지도 않는다.




Figure 18: 2 × 2 상호작용(Gemini 지휘관): (a) 네 셀의 포획률 평균, (b) 시드 대응차이와 BCa 신뢰구간

이 이미 유의하며 결합이 그보다 낮지 않다.

6.3.2 요약: 무엇이 남는가 — 포획률은 가장 둔한 지표다

§3.2에서 정의한 10개 지표 전부에 대해 제안 체계와 기준선의 대응 차이를 계산하였다(Table 11, Fig. 19; llm_unet@Gemini 대 heur_heur, 굵은 선은 95 %, 열은 선은 Bonferroni 보정 99.5 % 구간, 속이 빈 표식은 보정 구간이 0을 포함). 그림의 d_z 구간은 평균차의 BCa 신뢰구간을 $sd(d)$ 로 나눈 것이므로, 그림이 0 을 배제하는 것과 표의 평균차 구간이 0 을 배제하는 것은 같은 사건이다.

결과는 명확하다. 포획률의 효과크기($d_z = 0.44$)는 측정한 10개 지표 중 최하위권이며, 총 선회량(−3.23)의 7분의 1 수준이다. 개선이 가장 큰 지표는 기동 비용과 자원 효율 쪽이다.

- 총 선회량 1625 → 868 (−47 %, $d_z = -3.23$)
- 포획당 그물 0.737 → 0.409 (−45 %, $d_z = -2.09$)
- 포획 이격거리 1511 → 1734 m ($d_z = +1.81$)
- 그물 걸림 0.82 → 0.22 (−73 %, $d_z = -1.19$)

이 대조는 다중비교 보정에서 더 선행해진다. 지표 10개에 대한 Bonferroni 보정 (99.5 % 구간)을 적용하면 10개 중 8개가 그대로 유의하지만, 포획률과 돌파 수는 유의성을 잃는다(Table 11의 단검 표시). 포획률의 보정




Figure 19: 제안 대 기준선의 전 지표 효과크기 d_z (굵은 선 신뢰구간, 열은 선 Bonferroni 보정 구간)

구간은 [−0.003, +0.132] 로 0 을 아슬아슬하게 포함한다. 기동 계층 단독 조건에서도 같은 두 지표가 탈락한다([−0.013, +0.100]).

이 결과를 감출 이유가 없다. 오히려 이 논문이 말하려는 바를 정확히 드러내기 때문이다 — 보정을 견디지 못하는 것은 “더 많이 막는다”는 주장이고, 견디는 것은 “같은 정도로 막으면서 자원과 기동과 위험을 크게 줄인다”는 주장이다. 따라서 본 논문은 포획률 개선을 주장의 중심에 두지 않는다.

즉 제안 체계의 이득은 “더 많이 잡는다”보다 “같은 정도로 막으면서 훨씬 적은 자원과 기동, 더 낮은 위험으로 해낸다”에 가깝다. 이는 자원이 제한된 실운용에

Table 11: 전 지표 효과크기 (제안 = LLM 지휘관 + U-Net 점수맵, Gemini). $|d_z|$ 내림차순. 포획률이 가장 둔한 지표이며, 다중비교 보정에서 유의성을 잃는 유일한 방어 성과 지표다.

지표	방향	baseline	제안	Δ	d_z
총 선회량 (rad)	↓	1625	868	-757* [†]	-3.23
포획당 그물	↓	0.737	0.409	-0.328* [†]	-2.09
포획 이격거리 (m)	↑	1511	1734	+223* [†]	+1.81
전개 시 적 거리 (m)	↓	1499	1128	-371* [†]	-1.60
그물 걸림	↓	0.82	0.22	-0.60* [†]	-1.19
평균 포획 시각 (step)	↓	430	408	-22* [†]	-1.04
포획당 이동거리 (m)	↓	825	643	-182* [†]	-0.65
충돌률(척당)	↓	0.130	0.078	-0.052* [†]	-0.52
돌파 수	↓	1.56	0.93	-0.62*	-0.44
포획률	↑	0.844	0.907	+0.062*	+0.44

방향 ↑ = 높을수록 좋음, ↓ = 낮을수록 좋음. * 95% 신뢰구간이 0 을 포함하지 않음. [†] 지표 10개에 대한 Bonferroni 보정(99.5% 구간)에서도 0 을 배제함 — 즉 단검이 없는 행은 보정을 견디지 못한다.




Figure 20: 지휘관 응답 지연의 경험 누적분포(파선은 결정 주기)

서 오히려 더 중요한 성질이다. 포획률의 효과크기가 작은 것은 방법의 한계가 아니라 지표의 천장 때문이며 (§6.2.1), 효율 지표에는 그러한 천장이 없다.

운용 함의. 두 계층이 서로 간섭하지 않으므로 각 계층을 독립적으로 개선·교체할 수 있다. 성과 관리 지표로는 천장이 있는 포획률보다 자원·기동 지표(포획당 그물, 총 선회량)가 변별력이 있다.

6.4 배치 관점: 지연

응답 지연은 모델 규모에 단조가 아니다(Table 9). 로컬 14B가 16.59초인 데 비해 클라우드 모델은 1.56초로, **로컬이 10.6배 느리다**. 한 결정 주기가 25초 ($25 \text{ step} \times \Delta t = 1 \text{ s}$)이므로 14B의 평균 지연은 주기의 **약 3분의 2**를 소모한다.

평균만 보면 주기 안에 들어오지만, 결정적인 것은 분포의 꼬리다 (Table 12, Fig. 20). 14B 호출 5,366건 가운데 **4.2%가 25초 주기를 초과**하였고, 99 백분위는 27.8초, 최댓값은 296.4초였다. 동기 구조라면 이 4.2%마다 제어 루프가 실제로 정지한다. 반면 클라우드 모델은 최댓값이 2.75초로 주기의 11%에 그쳐 동기 호출로도 여유가 있다.

단 이 수치의 측정 구성에는 교란 요인이 있다(§7.2 참조). 즉 §4.1의 비동기 설계는 클라우드 배치에서는

선택이지만 **로컬 배치에서는 지연 꼬리에 대한 안전장치**로서 실질적 의미를 갖는다.

운용 함의. 로컬 배치에서 비동기 분리는 선택이 아니라 전제이며, 배치 전에 확인할 값은 평균 지연이 아니라 주기를 넘기는 호출의 비율이다.

Table 12: 지휘관 응답 지연 분포. 결정 주기 25초와 비교한다. 로컬 14B만 주기를 초과하는 꼬리를 갖는다.

지휘관	n	평균	p_{99}	최대	> 25초
Qwen2.5 7B (로컬)	4,299	2.75	7.08	10.06	0.0 %
Qwen2.5 14B (로컬)	5,366	16.59	27.81	296.41	4.2 %
Gemini (클라우드)	3,882	1.56	2.30	2.75	0.0 %

단위는 초. 로컬 모델은 Ollama 서버(Qwen2.5 14B는 Q4_K_M 양자화, 문맥 16,384 토큰), NVIDIA RTX 4070(12GB) 단일 GPU에서 측정하였다. ★ **해석 시 주의:** 이 GPU에는 시뮬레이터와 정책 추론이 동시에 올라가 있었다. 14B는 Q4 가중치만 약 9GB이므로 KV 캐시를 더하면 12GB를 압박하며, 최대값 296초는 가중치 오프로드/재적재를 시사한다. 실제로 본 저장소의 설치 문서는 같은 GPU에서 2 ~ 4초를 예상하고 있어 실험과 4 ~ 8배 차이가 난다. 따라서 **14B의 꼬리가 로컬 중형 모델 서버의 본질적 성질인지, 이 구성에서 GPU를 공유한 결과인지는 본 실험으로 구분되지 않는다.** 여기서 읽어야 할 것은 개별 수치가 아니라 **자원이 제한된 온보드 환경에서는 로컬 중형 모델의 지연이 결정 주기를 넘길 수 있다**는 정성적 사실이며, 이는 전용 가속기를 갖추면 완화될 수 있다.

7 고찰 및 결론

7.1 결과가 말하는 것

§6의 결과를 실무 판단으로 옮기면 세 가지다. 기동 계층은 조건 없이 넣는다 — 언어모델 없이도 같은 방어 성과를 더 적은 자원으로 내며 외부 의존이 없다. 지휘관 계층은 능력 임계를 넘는 모델에만 켜다. 본 실험에서 그 경계는 로컬 14B와 클라우드 모델 사이였고 로컬 7B는 코드 휴리스틱보다 유의하게 나뉘었다(§6.2.2). 두 계층의 기여는 가산적이므로(§6.3) 지휘관 모델 교체와 기동 정책 재학습을 독립적으로 진행할 수 있다.

지휘관의 성능을 설명하는 것은 커버리지가 아니라 재계획 간 계획 안정성이라는 관찰(§6.2.3)은 본 문제에 국한되지 않는다. 주기적으로 재계획하는 계층 구조에서 상위 결정의 변경은 하위 계층에 전환 비용을 발생시킨다 — 그물벽을 절반쯤 전개한 방어정의 담당이 바뀌면 그때까지의 이동과 그물이 회수되지 않는다. 상위 계층이 매 재계획마다 순간 최적을 추구하면 이 비용이 누적되어 국소적으로 나온 배정이 전역적으로 손해가 된다. 언어모델은 매 호출이 독립적이라 이 일관성이 구조적으로 보장되지 않으므로, 직전 배정을 상태에 포함시키고 담당 무리를 방위로 식별하게 한 것이 그 대응이다. 따라서 언어모델을 계획 계층에 둘 때는 계획 품질을 국소 최적성이 아니라 **시간에 걸친 일관성**으로 평가해야 하며, 프롬프트와 상태 표현이 그 일관성을 지원해야 한다.

가장 큰 개선이 총 선회량($d_z = -3.23$, §6.3.2)에서 나타난 것은 점수맵 표현의 성질과 직결된다. 경유점이 격자에 고정되므로 연속 회귀의 미세 진동이 구조적으로 배제되어 궤적이 부드러워지며, 선회 감소는 실제 선박에서 연료·시간·기동 여유로 환산된다. 포획당 그물 소모의 감소(-45%) 역시 유효 마스크가 배정 회랑과 사거리 제약을 행동 분포에 직접 부과해 무의미한 위치의 그물벽이 애초에 표현되지 않기 때문이다.

배치 관점에서 로컬 14B는 클라우드 대비 10.6배 느리면서 성능도 낮았고(0.811 대 0.904) 호출의 4.2%가 결정 주기를 초과하였으므로(§6.4, Table 12), 비동기 설계는 로컬 배치의 전제 조건이다.

7.2 설계 선택의 대가와 한계

후처리를 제거한 대가. 배정 후처리를 두지 않은 것(§4.6)은 측정 가능성을 위한 선택이었고, 그 대가가

§6.2.2의 음의 결과다. 후처리가 있었다면 7B의 배정 오류는 상당 부분 코드가 교정됐겠지만, 그때 얻는 것은 “언어모델이 잘한다”가 아니라 “후처리가 잘한다”이다. 언어모델의 기여를 주장하려면 보정을 제거한 조건이 함께 보고되어야 한다.

시뮬레이션 한정. 모든 결과는 시뮬레이션에서 얻었고 §4.7의 이식 유리 조건은 전이 성공의 증거가 아니다. 그물의 유체 거동(선분 모형 대 곡면 전개·침강·조류 변형), 추진기 얽힘 판정(접촉 즉시 무력화 대 속도·각도 의존), 관측 완전성(무오차 위치 대 탐지 누락·식별 지연)이 단순화되어 있으며, 관측 불확실성은 배정이 의존하는 무리 구성을 흔들며 *churn* 을 직접 키우므로 점수맵 정책보다 지휘관 계층에 더 크게 작용할 것이다. 지연 측정이 GPU 공유 구성의 교란을 받는다는 점은 §6.4에서 다루었다.

폐쇄형 모델 의존. 가장 좋은 지휘관은 상용 API의 폐쇄형 모델이라 그 수치의 장기 재현은 보장되지 않으며, §6.2.2의 능력 임계 위치는 시점 의존적이라 절대 기준으로 인용되어서는 안 된다. 기동 계층 단독 조건(§6.1.1)은 언어모델을 쓰지 않으므로 이 위험과 무관하게 재현된다.

비교하지 않은 대안. 기준 방법을 기하 휴리스틱으로 둔 것은 같은 행동공간 위의 비교를 위해서이며(§4.3), MADDPG·QMIX·MAPPO 같은 표준 다중 에이전트 강화학습과는 비교하지 않았다. 이 계열을 관례대로 쓰면 행동이 연속 좌표나 에이전트별 이산 행동이라 관측되는 차이에 *표현*(연속 회귀 대 픽셀 지목)과 *알고리즘*(가치망 유무, 크레딧 배분)이 뒤섞이므로, 공정한 비교는 그 알고리즘들을 같은 픽셀 지목 행동공간으로 옮겨 학습시키는 별도 연구다. 구성요소 절제 실험도 수행하지 않았다 — §4의 설계별 측정 근거는 각 요소가 왜 필요한가의 근거이지 얼마나 기여하는가의 측정이 아니며, FiLM 조건화·좌표 채널·자기회귀 두 번째 선택의 기여를 분리하려면 각각을 **뺀** 재학습이 필요하다.

규모와 일반화. 실험은 적 10척 대 방어정 3척의 고정 규모에서 수행되었다. 표현의 개수 불변성이 성능 유지로 이어지는지, 방어정 수가 늘어 배정 조합이 급증할 때 능력 임계가 어디로 이동하는지는 측정되지 않았다. 세 공격 포메이션은 사전 정의된 규칙 기반 행동이며, 그물벽 배치 패턴을 학습해 회피하는 적응적 적은 범위 밖이다.

7.3 결론

조합 최적화 후처리 없이 시드 대응 2×2 설계로 두 계층의 기여를 분리 측정한 720 에피소드에서 세 가지가 얻어졌다. 첫째, 두 계층의 기여는 **가산적**이다 — 10개 지표 중 9개에서 상호작용의 신뢰구간이 0을 포함하였고, 본 논문은 이를 상승효과로 포장하지 않았다. 둘째, **포획률은 측정한 지표 중 가장 둔하다**. 효과크기로 총 선회량(-3.23)과 포획당 그물 소모(-2.09)의 개선이 포획률(+0.44)보다 훨씬 크고, 다중비교 보정을 걸면 10개 지표 중 8개가 견디는데 포획률과 돌파 수만 유의성을 잃는다. 제안 체계의 실질적 이득은 “더 많이 막는다”보다 “같은 정도로 막으면서 훨씬 적은 자원과 위험으로 해낸다”에 있다. 셋째, **언어모델 지휘관에는 능력 임계가 존재하며**, 그 성능을 설명하는 것은 배경 커버리지가 아니라 재계획 간 계획 안정성이다. 가장 낮은 성능의 모델이 오히려 커버리지는 가장 높았다는 관측은 주기적 재계획 구조에서 최적정보보다 일관성이 중요하다는 설계 원리를 시사한다.

검증은 시뮬레이션에 한정되며, 실해역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.

CRediT authorship contribution statement

[투고 전 저자 확인 필요] 아래는 CRediT 분류에 따른 초안이며, 각 저자의 실제 기여로 교체하여야 한다.

윤영준: 개념 설계, 방법론, 소프트웨어, 검증, 형식 분석, 조사, 자료 큐레이션, 초고 작성. **방현태**: 소프트웨어, 검증, 시각화. **전유라**: 방법론, 조사, 검토 및 편집. **김덕환**: 검토 및 편집, 감독. **윤원근**: 개념 설계, 감독, 연구 관리, 재원 획득.

Declaration of competing interest

[투고 전 저자 확인 필요] 저자들은 본 논문에 보고된 연구에 영향을 미칠 수 있는 경쟁적 재정적 이해관계나 개인적 관계가 없음을 선언한다.

Declaration of generative AI and AI-assisted technologies in the writing process

원고 작성 과정에서 저자들은 문헌 정리, 초고 문장 다듬기, $\LaTeX$ 조판 및 도판 생성 스크립트 작성에 생성형 인공지능 보조 도구를 사용하였다. 모든 실험 설계, 데이터 수집, 수치 산출과 해석은 저자들이 수행하였으며, 저자들은 원고 전체를 검토하고 그 내용에 대해 전적인 책임을 진다.

Data availability

본 연구의 결과를 재현하는 데 필요한 자료는 다음과 같이 구성된다.

- **원 자료**: 720 에피소드의 에피소드별 지표 (episodes.csv) 및 계획 호출 계층값 (llm_metrics.csv). 본문의 모든 표와 그림은 이 두 파일에서 기계적으로 생성되며 (tools/make_paper_tables.py, boatattack_sim/eval/paper_figs.py), 손으로 옮겨 적은 수치는 없다.
- **정책 체크포인트**: 기동 계층의 가중치와 그 학습 설정 (u-net_map.pt). 설정은 체크포인트 안에 함께 저장되어 있어 별도 설정 파일 없이 복원된다.
- **시뮬레이터**: 환경, 관측 래스터화, 평가 하네스 전체.

[투고 전 공개 URL 기입 필요] 위 자료는 논문 게재 시 공개 저장소를 통해 배포한다.

보존하지 않은 것. 언어모델이 생성한 판단 근거 (rationale)의 원문은 저장하지 않았고, 길이만 계층하였다. 따라서 근거 문장 자체에 대한 사후 분석은 본 자료로 재현할 수 없다 (§7.2). 또한 상용 API로 제공되는 폐쇄형 지휘관 모델은 버전이 갱신되거나 서비스가 종료될 수 있어, 그 조건의 수치가 시점에 따라 달라질 수 있다. 언어모델을 쓰지 않는 조건 (heur_heur, heur_unet)은 이 위험 없이 재현 가능하다.

References

- [1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., 2007. Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem. *Operations Research*, 55(6), pp.1136–1146.
- [2] Wang, J., Liu, Y. and Song, H., 2021. Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends. *IEEE Aerospace and Electronic Systems Magazine*, 36(3), pp.4–29.
- [3] Sutea, V., 2026. *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*. Atlantic Council UkraineAlert, 24 February 2026.
- [4] Rumbaugh, W., 2024. *Cost and Value in Air and Missile Defense Intercepts*. Washington, DC: Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024.
- [5] Kuhn, H.W., 1955. The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly*, 2(1–2), pp.83–97.
- [6] Liu, Z., Zhang, Y., Yu, X. and Yuan, C., 2016. Unmanned surface vehicles: An overview of developments and challenges. *Annual Reviews in Control*, 41, pp.71–93.
- [7] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., 2025. Multi-USV cooperative target encirclement through learning-based distributed transferable policy and experimental validation. *Ocean Engineering*, 318, 120124.
- [8] Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P. and Mordatch, I., 2017. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [9] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., 2018. QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning. *International Conference on Machine Learning (ICML)*, pp.4295–4304.

- [10] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., 2018. Counterfactual Multi-Agent Policy Gradients. *AAAI Conference on Artificial Intelligence*, pp.2974–2982.
- [11] Yu, C., Velu, A., Vinitzky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., 2022. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. *Advances in Neural Information Processing Systems 35 (NeurIPS)*.
- [12] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. and Klimov, O., 2017. Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*.
- [13] Haarnoja, T., Zhou, A., Abbeel, P. and Levine, S., 2018. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. *International Conference on Machine Learning (ICML)*, pp.1861–1870.
- [14] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. and Guo, D., 2024. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. *arXiv preprint arXiv:2402.03300*.
- [15] Long, J., Shelhamer, E. and Darrell, T., 2015. Fully Convolutional Networks for Semantic Segmentation. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp.3431–3440.
- [16] Ronneberger, O., Fischer, P. and Brox, T., 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp.234–241.
- [17] Liu, R., Lehman, J., Molino, P., Petroski Such, F., Frank, E., Sergeev, A. and Yosinski, J., 2018. An Intriguing Failing of Convolutional Neural Networks and the CoordConv Solution. *Advances in Neural Information Processing Systems 31 (NeurIPS)*.
- [18] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., 2018. FiLM: Visual Reasoning with a General Conditioning Layer. *AAAI Conference on Artificial Intelligence*, pp.3942–3951.
- [19] Vinyals, O., Fortunato, M. and Jaitly, N., 2015. Pointer Networks. *Advances in Neural Information Processing Systems 28 (NeurIPS)*.
- [20] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L. and Polosukhin, I., 2017. Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NeurIPS)*.
- [21] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., 2022. Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents. *International Conference on Machine Learning (ICML)*, pp.9118–9147.
- [22] Ahn, M., Brohan, A., Brown, N., et al., 2022. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances. *Conference on Robot Learning (CoRL)*.
- [23] OpenAI, 2026. *Function calling*. [Online] Available at: <https://developers.openai.com/api/docs/guides/function-calling> [Accessed 9 August 2026].
- [24] Wu, Y. and He, K., 2018. Group Normalization. *European Conference on Computer Vision (ECCV)*.
- [25] Silver, D., Huang, A., Maddison, C.J., et al., 2016. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), pp.484–489.
- [26] Ng, A.Y., Harada, D. and Russell, S., 1999. Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *International Conference on Machine Learning (ICML)*, pp.278–287.
- [27] Loshchilov, I. and Hutter, F., 2017. SGDR: Stochastic Gradient Descent with Warm Restarts. *International Conference on Learning Representations (ICLR)*.
- [28] Fossen, T.I., 2011. *Handbook of Marine Craft Hydrodynamics and Motion Control*. Chichester: John Wiley & Sons.
- [29] Efron, B. and Tibshirani, R.J., 1993. *An Introduction to the Bootstrap*. New York: Chapman & Hall.
- [30] DiCiccio, T.J. and Efron, B., 1996. Bootstrap Confidence Intervals. *Statistical Science*, 11(3), pp.189–228.
- [31] Sutton, R.S. and Barto, A.G., 2018. *Reinforcement Learning: An*

Introduction. 2nd ed. Cambridge, MA: MIT Press.