

자폭 무인수상정 군집 방어를 위한 LLM 기반 임무배정과 점수맵 기반 다중 에이전트 방어 체계 구축

윤영준(충남대학교), 방현태(충남대학교), 전유라(한국과학기술원), 김덕환(한국과학기술원), 윤원근(충남대학교)

LLM-Based Task Allocation and Score-Map Reinforcement Learning for a Multi-Agent Defense System against Suicide USV Swarms

Yeonjun Yoon(Chungnam National Univ.), Hyeontaek Bang(Chungnam National Univ.), Yura Jeon(Korea Advanced Institute of Science and Technology), Deokhwan Kim(Korea Advanced Institute of Science and Technology), Wonkeun Yoon(Chungnam National Univ.)

요약

Swarms of low-cost suicide unmanned surface vehicles (USVs) are difficult to counter by conventional means: soft-kill jamming is indiscriminate, leaves the warhead intact, and does not reach fiber-optic guided craft, while hard-kill interceptors cost far more than the targets they destroy and engage them one at a time. This paper therefore adopts physical capture, in which a small number of defending USVs, slower than the attackers, deploy capture nets across the approach corridors of a mothership. The defense is organized in two layers that run on different decision cycles. A large language model (LLM) commander receives a battlefield state whose geometry has already been computed, and decides which enemy each vessel engages and which vessel holds; no combinatorial optimizer revises that decision. The commander is called asynchronously, so its response latency does not stall the control loop. Between successive replans the battlefield is rasterized into a multi-channel image centred on the mothership, and a parameter-shared convolutional policy turns that image into a score map over the sea surface. Each vessel picks two high-scoring pixels within the region assigned to it, and lays a net along the segment joining them. Picking pixels on a score map, rather than regressing continuous waypoints, constrains the action space and fixes the selected waypoints, keeping the maneuver stable.

Keywords : Unmanned surface vehicle(무인수상정), Swarm defense(군집 방어), Multi-agent reinforcement learning(다중 에이전트 강화학습), Task allocation(임무배정), Large language model(대규모 언어모델), Convolutional neural network(합성곱 신경망)

1. 서론

다수의 저비용 무인수상정(Unmanned Surface Vehicle, USV)이 고 가치 함정 한 척에게 여러 방향에서 동시에 돌진하는 자폭 공격은 대표적인 비대칭 전력이다. 유한한 아군 자산을 다수 표적에 배분하는 문제는 무기-표적 할당(weapon-target assignment)으로 연구되어 왔으나(Ahuja et al., 2007), 표적 수가 요격 자산을

넘어서면 최적 할당으로도 처리되지 않는 표적이 남는다.

무인 위협에 대한 기존 대응은 두 갈래로 구분된다(Wang et al., 2021). 표적의 통신·항법·센서를 교란하는 연성 대응(soft-kill)은 위협 자체를 제거하지 못하고, 전파를 방사하지 않는 유선 조종 표적에는 작용하지 않는다(Sutea, 2006). 표적을 직접 타격하는 경성 대응(hard-kill)은 위협을 확실히 제거하지만, 수천 달러 규모의 표적에 발당 수십만에서 수백만 달러의 요격 유도탄을 소모하는 비용 구조를 지탱하기 어렵다

(Rurbaugh, 2024). 또한 한 번에 한 표적만 처리하므로 표적 수가 교전 용량을 넘어서면 포화가 발생한다.

본 연구는 대안으로 저비용 그물을 이용한 물리적 포획을 채택한다. 이는 무인기 대응 분야에서 독립된 대응 범주로 다루어져 왔으며(Wang et al., 2021), 표적의 통신 방식과 무관하게 작용하고 표적을 정지시킨다는 점에서 앞의 두 한계를 비껴간다. 소수의 방어정이 적선의 공격 경로를 예측하여 기동하며 투하한 그물이 적선의 추진기에 얽히며 무력화시킨다. 그물은 유도탄보다 단가가 낮고 하드웨어적으로 적선을 무력화하므로, 다수의 표적을 경제적이고, 확실하게 처리할 수 있다.




Fig. 1 Engagement concept. A suicide USV swarm converges on the mothership from several bearings, while a smaller number of slower defending USVs close the approach corridors in advance with capture nets

방어정은 적선보다 느리므로 추격으로 따라잡을 수 없고, 대신 적선이 지나갈 접근 회랑을 앞질러 그물벽으로 차단한다(Fig. 1).

다중 무인수상정의 협력 기동은 꾸준히 연구되어 왔고(Liu et al., 2016), 최근에는 다중 에이전트 강화학습으로 회피 표적을 협조 포위하는 정책을 학습한 사례도 보고되었다(Zhang et al., 2025). 다만 추격·포위는 방어측 속력 우세를 전제하는 경우가 많다. 본 연구는 방어정이 더 느린 상황에서 추격의 방식 대신 예상 접근로를 사전에 차단한다는 점에서 구분된다.

방어의 성패는 유한한 자원을 어느 적 무리에 배정할 것인가와, 배정된 적을 어떻게 처리할 것인가에 달린다. 전자는 적의 접근 양상을 예측할 수 없어 상황에 따른 유연한 판단을 요구하고, 후자는 여러 방어정이 서로의 경로를 고려하는 협조 기동을 요구한다. 이 때 대규모 언어모델(Large Language Model, LLM)을 통해 알고리즘의 배정 방식보다 유연한 판단을 구현하고자 한다. 하지만 대규모 언어모델은 응답주기의 지연과 산술적 능력으로는 한계가 존재하여 해당 모델을 표적 아군 할당의 문제에만 국한하여 적용하였다.

제안하는 체계는 이 두 요구를 각각 담당하는 두 계층으로 분리한다(Fig. 2). LLM 지휘관이 느린 주기로 적선별 담당 무리와 대기 방어정을 확정하면, 강화학습 정책이 전장을 담은 격자 지

도로부터 배정된 적선을 포획하기 위해 그물을 투하할 위치를 선택한다. LLM 재계획 주기 사이에 강화학습 루프를 배치하여 고수준 판단은 LLM이, 실시간성이 요구되는 저수준 경유점 결정은 학습된 정책이 담당한다.

2. 제안 방법

2.1 문제 설정

중앙에 고가치 모선이 위치, 가장자리에서 적선 $M = 10$ 척이 접근한다. 아군 방어정은 $P = 3$ 척이며 각각 최대 길이 150m의 그물벽 하나를 전개할 수 있다(Fig. 1). 성능 지표는 식 (1)의 포획률이다.

$$\text{Capture Rate} = \frac{N_{\text{cap}}}{N_{\text{cap}} + N_{\text{brc}}} \quad (1)$$

여기서 N_{cap} 과 N_{brc} 는 각각 포획된 적선 수와 돌파한 적선 수이다.

2.2 전략 계층: LLM 지휘관

LLM에게 들어가는 정보는 좌표 원시 데이터 대신 기하량이 미리 계산된 형태로 직렬화되어 상황 판단을 위하여 해야 할 계산을 미리 수행한 후 정보를 제공한다. 각 적 무리의 요격점까지의 이동거리와 선회량, 모선 기준 방위, 설치된 그물에 의한 접근로 차단 여부 등이 여기에 포함된다.

출력은 구조적 출력(structured output)으로 강제되며(OpenAI, 2026), 판단 근거·무리별 배정·대기 목록 형태의 출력을 갖는다. 판단 근거를 사전에 먼저 출력하게 함으로 배정을 위한 판단을 할 때 사용자의 기준으로 설명 가능한 판단을 하게 한다. 해당 모델의 호출은 비동기로 이루어지며 그동안 경유점 생성 및 추종은 이어서 진행이 되어 대규모 언어모델의 응답 지연이 제어 주기를 막지 않는다.




Fig. 2 Two-layer defense system and its asynchronous decision cycles. The LLM commander turns the preprocessed battlefield state into a per-vessel assignment and hold decisions on a slow cycle; between successive replans the maneuver layer turns the rasterized battlefield image into a score map, picks waypoints on it, and lays nets along the segments joining them. The commander is called asynchronously, so its response latency does not stall the control loop




Fig. 3 Commander layer. Precomputed geometric quantities are serialized into a table, the response is constrained to a fixed field order in which the rationale precedes the assignment, and the resulting assignment fixes each vessel's intercept point and the corridor of candidate cells around it

배정이 확정되면 각 방어정의 요격점이 정해지고, 그 요격점을 중심으로 하위 계층이 그물을 놓을 수 있는 후보 영역이 함께 결정된다(Fig. 3). 즉 배정은 기동 계층의 선행 조건이며, 배정이 바뀌면 후보 영역 자체가 바뀐다.

2.3 기동 계층: 점수맵 기반 좌표 선택 정책

기동 계층의 입력은 좌표 목록이 아니라 모선을 중앙에 두고 전장을 일정 간격의 격자로 나눈 다채널 격자 지도이다. 적선과 아군의 위치·진행 방향, 위협도, 이미 설치된 그물, 모선과 요격 환경, 그리고 자기 자신과 배정된 요격점이 각각 하나의 채널로 그려진다. 목록 대신 격자 지도를 입력으로 쓰면 교전 중 적선의 수가 늘거나 줄어도 입력의 형태가 달라지지 않고, 적선

을 어떤 순서로 넣었는지에 따라 결과가 바뀌지도 않는다. 다만 합성곱만으로는 물체가 지도의 어디에 있는지가 흐려지므로, 각각의 좌표를 담은 채널을 함께 넣어 절대 위치를 보존한다(Liu et al., 2018). 이렇게 구성된 관측은 전역 공통 채널과 방어정별 채널, 좌표 채널의 세 묶음으로 이루어진 하나의 다채널 영상이 된다 (Fig. 4).




Fig. 4 Rasterized multi-channel observation. The battlefield is quantized onto a fixed grid centred on the mothership and drawn into global, per-vessel, and coordinate channels, so that the input shape stays fixed as the number of targets changes

이 격자 지도는 U-Net 구조의 합성곱 신경망을 지나 입력과 같은 해상도의 점수맵으로 변환된다(Ronneberger et al., 2015). 점수맵의 각 칸은 그 지점에 그물을 놓는 것이 얼마나 좋은지를 나타내며, 방어정은 자기 상태로부터 만든 질의 벡터와 칸 특징의 내적으로 이 점수를 얻는다. 각 방어정은 배정된 적군 주변으로 제한된 유효 영역 안에서 점수가 높은 칸 2개를 순차적으

로 선택하되, 먼저 고른 칸의 특징을 질의에 반영하여 두 점이 서로를 알고 뵙히도록 한다. 선택된 두 좌표를 잇는 구간이 그물을 설치할 하나의 경로가 되고, 방어정은 그 경로를 이동하며 그물을 투하한다(Fig. 5). 연속 경유점을 회귀시키는 대신 점수맵 위의 칸을 지목함으로써 행동공간을 규제하고 결정된 경유점의 위치를 고정하여 안정적인 기동을 할 수 있도록 한다.

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화(GFPO)를 다중 방어정 상황에 맞게 변형하여 수행하였다(Shao et al., 2024)(Fig. 6). 매 결정 시점에서 정책으로부터 여러 개의 후보 행동을 뽑고, 각 후보를 시뮬레이터에서 일정 구간 진행시켜 팀 보상을 얻은 뒤, 이 후보들끼리의 상대 비교로 이득을 산정한다. 어떤 선택이 더 나았는지를 실제 결과로 직접 비교하므로 별도의 가치망이 필요하지 않다. 다만 팀 보상을 모든 방어정이 그대로 나누어 가지면 개별 기여를 가릴 수 없으므로, 한 척의 행동만 바꾸고 나머지는 고정한 채 평가하여 그 차이를 해당 방어정의 몫으로 돌린다. 후보 가운데 하나는 휴리스틱이 내는 행동으로 채워 초기 학습의 출발점을 확보하였다. 보상은 포획, 돌파, 아군의 그물 접촉을 지배 향으로 하고, 위협 근접도에 대한 퍼텐셜 향을 두어 최적 정책을 보존하는 형태로 구현하였다(Ng et al., 1999).




Fig. 6 Group-relative training with per-vessel counterfactual credit. Candidate actions sampled at one decision point are advanced through the simulator over a common window; the resulting team rewards are compared against the group mean, and perturbing a single vessel while holding the others fixed isolates that vessel's contribution

3. 결론

본 연구는 자폭 무인수상정 군집에 대한 대응으로 저비용 그물을 이용한 물리적 포획을 채택하고, 이를 판단 주기가 서로 다른 계층으로 분리하여 구성하였다. 상위에서는 LLM 지휘관이 기하량이 미리 계산된 전장 상태를 받아 아군별 담당 무리와 대기 방어정을 결정하고, 하위에서는 강화학습 정책이 그 배정 아래서 전장 격자 지도로부터 그물벽을 놓을 좌표를 선택한다.

LLM 재계획 주기 사이에 강화학습 결정 루프를 배치함으로써, 응답 지연을 수반하는 고수준 판단과 매 스텝 갱신되는 저수준 기동이 서로를 막지 않도록 하였다.

배정은 조합 최적화의 보정 없이 언어모델의 판단만으로 확정된다. 최소비용 매칭과 같은 후처리를 덧붙이면 최종 배정이 결국 비용 함수의 산물이 되어 지휘관의 전술적 의도가 가려지므로, 언어모델이 내린 결정을 하위 계층이 그대로 소비하는 구조를 택하였다. 이를 가능하게 한 것은 출력 형식을 미리 선언하는 구조적 출력과, 판단 근거를 결정보다 먼저 생성시키는 항목 배치이다.

기동 계층에서는 전장을 다채널 격자 지도로 인코딩하고, 합성곱 신경망이 낸 점수맵 위에서 경유점을 지목하게 하여 행동공간을 규제하였다. 목록 대신 지도를 입력으로 삼으므로 교전 중 적선의 수가 달라져도 입력의 형태가 유지되며, 선택된 경유점의 위치가 고정되므로 기동이 안정적으로 유지된다. 여기에 후보 행동을 실제로 진행시켜 서로 비교하는 학습 방식을 결합하여 별도의 가치망 없이도 방어정별 기여를 구분한 학습이 성립한다.

이로써 응답 지연을 감수하는 언어모델의 전술 판단과 매 스텝의 강화학습 기동이 서로를 기다리지 않고 병렬로 추론을 진행하며, 담당 무리의 배정에서 그물 투하까지 이어지는 방어체계를 구성하였다.

참고 문헌

- Ahuja, R.K. Kumar, A. Jha, K.C. & Orlin, J.B., 2007. Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem. *Operations Research*, 55(6), pp.1136-1146.
- Liu, R. Lehman, J. Molino, P. Petroski Such, F. Frank, E. Sergeev, A. & Yosinski, J., 2018. An Intriguing Failing of Convolutional Neural Networks and the CoordConv Solution. *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, Montreal, Canada, 2-8 December 2018.
- Liu, Z. Zhang, Y. Yu, X. & Yuan, C., 2016. Unmanned surface vehicles: An overview of developments and challenges. *Annual Reviews in Control*, 41, pp.71-93.
- Ng, A.Y. Harada, D. & Russell, S., 1999. Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping. *Proceedings of the 16th International Conference on Machine Learning (ICML)*, Bled, Slovenia, 27-30 June 1999, pp.278-287.
- OpenAI, 2026. *Function calling*. [Online] Available at: <https://developers.openai.com/api/docs/guides/function-calling> [Accessed 9 August 2026].
- Ronneberger, O. Fischer, P. & Brox, T., 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015)*, Munich, Germany, 5-9 October 2015, pp.234-241.




Fig. 5 Score-map maneuver policy. The multi-channel observation passes through a U-Net that preserves the input resolution; the inner product between a query built from the vessel's own state and the per-cell features yields a score over the sea surface. Outside the valid region the score is masked away, two cells are picked in sequence with the first pick fed back into the query, and the segment joining them is laid as a net wall

- Runbaugh, W., 2024. *Cost and Value in Air and Missile Defense Intercepts*. Washington, DC: Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024. [Online] Available at: <https://www.csis.org/analysis/cost-and-value-air-and-missile-defense-intercepts> [Accessed 9 August 2026].
- Shao, Z. Wang, P. Zhu, Q. Xu, R. Song, J. Bi, X. Zhang, H. Zhang, M. Li, Y.K. Wu, Y. & Guo, D., 2024. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. *arXiv preprint arXiv:2402.03300*.
- Sutea, V., 2026. *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*. Atlantic Council UkraineAlert, 24 February 2026. [Online] Available at: <https://www.atlanticcouncil.org/blogs/ukrainealert/fiber-optics-drones-have-emerged-as-critical-kit-for-both-russia-and-ukraine/> [Accessed 12 August 2026].
- Wang, J. Liu, Y. & Song, H., 2021. Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends. *IEEE Aerospace and Electronic Systems Magazine*, 36(3), pp.4-29.
- Zhang, C. Zeng, R. Lin, B. Zhang, Y. Xie, W. & Zhang, W., 2025. Multi-USV cooperative target encirclement through learning-based distributed transferable policy and experimental validation. *Ocean Engineering*, 318, 120124.