자폭 무인수상정 군집 방어를 위한 LLM 지휘관과 U-Net 점수맵 기동 정책의 2계층 결합

Coupling an LLM Commander and a U-Net Score-Map Policy for Two-Layer Defense against Suicide USV Swarms

윤 영 준[*1], 방 현 태[*1], 전 유 라[*2], 김 덕 환[*2], 윤 원 근[*1]

([이메일 주소 기입 필요])

Swarms of low-cost suicide unmanned surface vehicles (USVs) evade conventional counters: electronic warfare cannot reach wire-guided targets, and interceptors cost more than their targets and saturate. We propose a two-layer defence architecture in which a few defenders, slower than the attackers, pre-emptively block the mothership's approach corridors with net walls. In the strategic layer a large language model (LLM) commander assigns each defender an enemy cluster; in the maneuver layer each defender points at a pixel of a score map that a U-Net produces over a rasterized battlefield grid to place its net wall. Both layers decide on the same period but differ sharply in response latency, so only the slow strategic layer is decoupled asynchronously. Pixel pointing confines the action space to the grid, imposes safety and mission constraints by masking and is invariant to swarm size, and training extends critic-free group-relative policy optimization to multiple agents. From 720 seed-paired episodes (8 conditions, 3 formations, 30 seeds) we separated the contributions of the two layers in a 2x2 design. The maneuver layer alone raised the capture rate from 0.844 to 0.886, and the full system cut nets per capture by 45 % and total turning by 47 % at the same defense level; the two contributions were additive rather than synergistic. The commander paid off only for models above a capability threshold, and its performance was explained not by assignment coverage but by plan stability across replans. In periodically replanning architectures, consistency over time matters more than local optimality.

Key Words: 무인수상정(Unmanned Surface Vehicle), 군집 방어(Swarm Defense), 다중 에이전트 강화학습(Multi-Agent Reinforcement Learning), 임무배정(Task Assignment), 대규모 언어모델(Large Language Model), 의미론적 분할(Semantic Segmentation), 그룹 상대 정책 최적화(Group Relative Policy Optimization)

1. 서 론

다수의 저비용 무인수상정(USV)이 고가치 함정을 향해 여러 방향에서 동시에 돌진하는 자폭 공격은 비대칭 위협의 전형이다. 표적 수가 요격 자산을 넘어서면 최적 할당으로도 남는 표적이 생기고 [1], 연

*1 충남대학교
*2 한국과학기술원

성 대응(soft-kill)은 유선 조종 표적에 무력하며 [2, 3], 경성 대응(hard-kill)은 값싼 표적에 고가 유도탄을 쓰는 비용 구조와 포화를 피하지 못한다 [4].

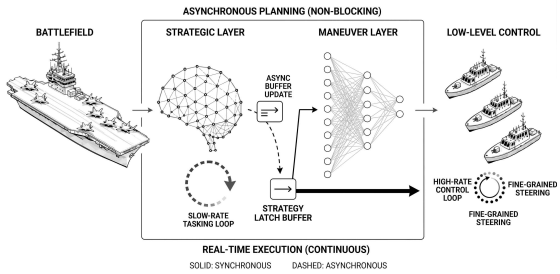


Fig. 1 Two-layer architecture of the proposed system

본 연구는 저비용 그물에 의한 물리적 포획을 택한다 [2]. 이 방식은 통신 방식과 무관하게 표적을 정지시킨다. 방어정은 적선보다 느려 추격할 수 없으므로, 적선이 지나갈 접근 회랑을 앞질러 그물벽으로 차단한다.

이 문제는 성격이 다른 두 판단을 요구한다. 하나는 어느 방어정이 어느 적 무리를 맡는가라는 이산적 배정이고, 다른 하나는 맡은 무리를 해면 어디에서 막는가라는 연속적 기동이다. 둘은 같은 주기로 갱신되지만 산출에 걸리는 시간이 크게 다르다. 본 연구는 느린 배정을 언어모델 지휘관에게, 빠른 기동을 학습된 정책에 맡기고 느린 계층만 비동기로 분리한다(Fig. 1).

학습과 평가는 OpenStreetMap 해안선을 래스터화한 실해역 지형에서 수행한다. 관측은 모선 중심 격자의 다채널 영상이고, 행동은 그 격자의 유효 픽셀 하나를 고르는 것이라 불가능한 자리가 애초에 뽑히지 않는다. 출력은 제어 신호가 아니라 경유점이라 저수준 추종과 분리된다(4절). 각 계층이 무엇을 얼마나 개선하는지는 시드 대응 2×2 설계로 분리해 측정한다 (5절).

2. 관련 연구

방어 자산을 표적에 배분하는 문제는 무기-표적 할당(WTA)으로 정식화되어 왔으나 [1], 이전 결정이 이미 막은 회랑과 남은 자산에 따라 달라지는 판단은 고정된 거리·각도 비용으로 표현되지 않으므로 본 연구는 배정 계층에 조합 최적화 대신 언어모델의 판단을 둔다. 무인 위협의 무력화 수단 가운데 연성 대응은 유선 조종 표적에, 경성 대응은 요격 비용의 비대칭에 막혀 포획이 남는다 [2, 3, 4]. 해상의 강화학습 협조 포위 [5]는 방어정이 표적보다 빠르거나 대등함을 전제하므로, 더 느린 조건에서는 추격 대신 접근 경로의 선제 차단이 남는다.

다중 에이전트 강화학습의 중앙 집중 학습·분산 실행 계열은 팀 보상에서 개체별 기여를 분리하려고 가치망을 학습한다 [6, 7, 8]. 그룹 상대 정책 최적화(GRPO) [9]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 가치망 자체를 없앤다. 본 연구는 GRPO를 다중 에이전트 제어로 옮기되, 후보 하나를 기하 휴리스틱으로 고정해 기준선으로 삼고 후보의 팀 보상을 시뮬레이터 재진행으로 얻으며, 같은 픽셀 행동공간 위의 MAPPO를 갱신 규칙의 비교 기준으로 둔다(6.1.2절).

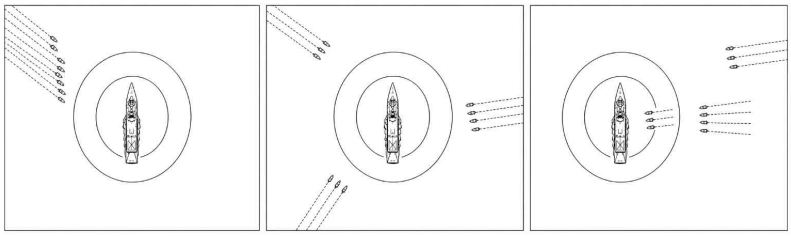


Fig. 2 Three attack formations: concentrated, diversionary and wave (left to right)

모든 픽셀에 값을 매기는 조밀 예측과 조건 변조 [10, 11]는 주로 상황 지각에, 후보마다 점수를 매겨 하나를 지목하는 출력 [12, 13]은 조합 최적화에 쓰였다. 본 연구는 점수맵을 정책의 행동 분포로 삼아 둘을 잇고, 안전 제약을 마스크로 행동 분포에 직접 부과한다(4.4절). 언어모델을 계획 주체로 쓰는 연구는 지시를 실행 가능한 단계로 분해하고 실행 가능성으로 계획을 거르며 [14, 15], 구조적 출력 [16]으로 파싱 가능한 형태를 보장한다. 본 연구는 언어모델에 배정만 맡기고 실행 가능성은 기동 계층의 유효 마스크가 픽셀 수준에서 강제한다(4.4.3절).

3. 문제 정의와 평가 지표

3.1 교전 시나리오

Table 1 Engagement scenario and observation settings

Item	Value
Number of attacking USVs M	10
Number of defenders P	3
Maximum number of clusters C	4
Side length of the engagement area	12.6 km
Attacker speed v_e	9.0 m/s
Defender speed v_a (speed ratio $v_e/v_a = 1.5$)	6.0 m/s
Decision period	25 s
Observation grid $n_g \times n_g$ (centred on mothership)	50×50
Observation pixel size ℓ	252 m
Nets per defender (training / evaluation)	1 / 3
Number of policy parameters	244,389

교전 해역 중앙에 고가치 모선 한 척이 있고, 가장자리에서 적 USV M척이 모선을 향해 돌진한다. 적은 집중·양동·파상의 세 공격 포메이션 가운데 하나를 취한다(Fig. 2). 방어정 P척은 각각 한정된 수의 그물벽을 전개할 수 있다. 체계는 스케일 불변이며, 기준 인스턴스에서 적은 방어정보다 1.5배 빠르고 두 계층 모두 25 s 마다 결정한다(Table 1). 관측·행동·보상은 모두 관측 픽셀 한 변 ℓ 로 정규화한다.

그물벽은 두 좌표를 잇는 선분이고, 방어정이 그 선분을 따라 이동하며 후미의 전개 장치로 부유식 그물을 풀어 놓으면 그 위를 지나는 적 USV가 추진을 잃는다(Fig. 3). 그물은 시간이 지날수록 차단 효과가 줄고 일찍 펴면 회피의 여지를 주므로, 적의 도달 직전에 적에 가까운 위치에 두는 것이 유리하다.

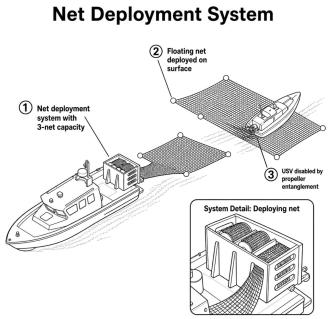


Fig. 3 Capture concept of the stern-launched floating net

집중(concentrated)은 전 병력이 한 방위에서 접근해 차단할 접근로가 하나이고, 양동(diversionary)은 세 방위로 나뉘어 동시에 접근하므로 어느 배가 어느 무리를 맡는 배정이 결과를 좌우하며, 파상(wave)은 3개 단(rank)이 방위를 조금씩 달리해 순차 도달하므로 보유량이 한정된 그물벽을 어디에 놓아 여러 단을 겸해 막을지가 관건이다.

3.2 평가 지표

방어 성과는 다섯 관점의 10개 지표로 에피소드마다 잰다(Table 2). 자원 효율은 교전하지 않은 조건이 가장 효율적으로 보이는 것을 막기 위해 총량이 아니라 포획당 비율로 두었고, 교전 품질은 거리축과 시간축으로 나누어 모선에서 먼 포획과 이른 포획을 함께 본다.

Table 2 Ten evaluation metrics

Aspect	Metric	Definition	Meaning
Defense outcome	Capture rate	$\mathrm{CR} = \mathrm{N}_{\mathrm{cap}}/(\mathrm{N}_{\mathrm{cap}} + \mathrm{N}_{\mathrm{brc}})$	Captured / resolved
	Breaches	N_{brc}	Reached the mothership
Safety	Collision rate	$N_{\mathrm{col}}/\mathrm{P}$	Collisions per defender
	Net entanglements	N_{tng}	Own-net entanglements
Resource efficiency	Nets per capture	$N_{\mathrm{net}}/\mathrm{N}_{\mathrm{cap}}$	Nets used per capture
	Distance per capture	$\sum_{p=1}^{P} D_p / N_{\mathrm{cap}}$	Travel per capture
Maneuver cost	Total turning	$\sum_{p=1}^{P} \sum_{t} \lvert \Delta\psi_{p,t} \rvert$	Total heading change
Engagement quality	Capture distance	$\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \lVert \mathbf{z}_{\mathbf{k}} - \mathbf{m} \rVert$	Range from mothership
	Capture time	$\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \mathrm{t}_{\mathrm{k}}$	Time of capture
	Enemy distance at deploy	$\frac{1}{N_{\mathrm{net}}} \sum_{\mathrm{d}} \min_{m \in A} \lVert \boldsymbol{a}_{\boldsymbol{d}} - \boldsymbol{e}_{\boldsymbol{m}} \rVert$	Nearest-attacker range

4. 제안 방법

4.1 2계층 비동기 구조

전략 계층은 어느 방어정이 어느 적 무리를 맡는가를, 기동 계층은 해면 어디에 그물벽을 놓는가를

정한다(Fig. 1). 두 계층은 같은 주기로 결정하지만 언어모델 호출에는 지연이 있으므로(6.2절) 전략 계층만 비동기로 분리하여, 응답을 기다리는 동안 기동 계층은 직전 배정으로 결정을 계속하고 응답이 도착하면 다음 결정부터 새 배정을 반영한다.

4.2 적 무리 군집화

두 판단 계층은 개별 적선이 아니라 무리를 단위로 배정하므로, 매 결정마다 생존 적선을 모선 기준 방위 ϑ_m 으로 묶어 최대 C 개의 무리로 요약한다(Fig. 4). 방위 구간을 고정해 나누면 무리가 경계에 걸려 쪼개지므로, 정렬한 방위의 이웃 간격 $g_{(q)}$ 로 무리 수를 데이터에 맞춘다. 방위는 순환값이라 간격도 순환으로 센다. 임계 δ_{gap} 을 넘는 간격의 개수가 활성 무리 수 $\hat{C}$ 이며, 1 이상 $\min(C,n)$ 이하로 자른다.

$$\hat{C} = \text{clip}(|\{\, q : g_{(q)} > \delta_{\text{gap}} \}|,\ 1,\ \min(C,n)) \tag{1}$$

가장 큰 간격 $\hat{C}$ 개를 경계로 삼아 방위 순으로 라벨을 붙여 무리별 구성원을 정하고, 각 무리를 척수 n_j, 중심 $\boldsymbol{c_j}$, 각도 퍼짐 $\Delta\vartheta_j$, 모선 방향 접근 속도 v_j^{app} 의 네 양으로 요약한다.

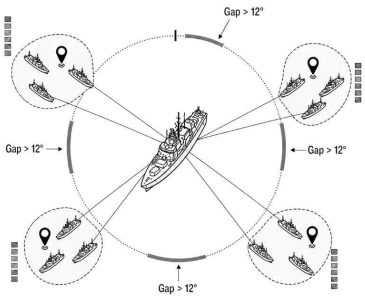


Fig. 4 Bearing sorting, clustering and cluster assignment

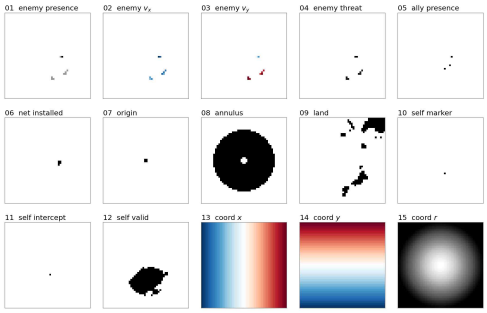


Fig. 5 Example of the rasterized 15-channel observation (wave formation, north of Maemuldo, Tongyeong)

이 규칙에서 집중은 무리 하나, 양동은 셋, 파상은 대개 단마다 하나로 요약된다.

4.3 기하 휴리스틱 기준 방법

무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법으로, 6절의 비교 기준이자 4.5.1절의 행동 복제 목표다. 무리 j 의 위협도 τ_j 는 척수 n_j 에 모선 근접도를 곱한 양이고, 요격점 $\boldsymbol{I_j}$ 는 무리

중심에서 모선을 향해 선분의 λ_{I} 비율만큼 옮긴 점이다.

$$\tau_j = n_j \cdot \mathrm{clip}\left(1 - \frac{\|\mathbf{c_j} - \mathbf{m}\|}{\mathrm{R_w}}, 0.05, 1\right), \qquad (2)$$
$$\boldsymbol{I_j} = \boldsymbol{c_j} + \lambda_{\mathrm{I}}(\mathbf{m} - \mathbf{c_j}), \quad \lambda_{\mathrm{I}} = 0.55$$

방어정이 적보다 느리므로 요격점은 모선 쪽으로 치우쳐 둔다.

위협 상위 P 개 무리에 대해 탐욕적 1:1 배정을 한다. 비용은 방어정 위치 $\boldsymbol{a_p}$ 에서 요격점까지의 거리 d_{pj} 에서, 직전 결정의 담당 j_p^{prev} 를 유지하는 쌍에만 보너스 β 를 감한 값으로, 거리 차이가 크게 벌어지기 전에는 직전 배정이 유지된다.

$$\widetilde{d_{pj}} = \begin{cases} d_{pj} - \beta, & j = j_p^{\mathrm{prev}} \\ \mathrm{d_{pj}}, & \text{그 밖} \end{cases} \qquad (3)$$

활성 무리가 P 보다 적으면 남는 방어정은 부하가 가장 큰 무리에 안쪽 층으로 덧붙인다. 그물벽은 요격점을 가운데 둔 접근 방향에 수직인 길이 L_{net} 의 선분이므로 경유점은 양 끝 $K=2$ 개이며, 학습 정책과 같은 격자·유효 마스크 위의 최근접 픽셀로 스냅한다. 따라서 두 방법의 행동공간은 같고 다른 것은 결정 규칙뿐이다.

4.4 점수맵 기반 기동 정책

4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모선을 중앙에 두고 관측 반폭 E 의 전장을 $n_{\mathrm{g}} \times \mathrm{n_g}$ 격자로 나눈 다채널 지도이다. 총 15개 채널은 모든 방어정이 공유하는 전역 9채널, 방어정마다 다른 3채널, 좌표 3채널로 구성된다(Fig. 5).

픽셀 크기는 $\ell = 2E/n_{\mathrm{g}}$ 이고, 각 개체의 연속 위치를 격자에 사상해 같은 픽셀의 개체를 집계한다. 방어정 p 의 자체 상태 $\boldsymbol{o_p} \in R^8$ 는 격자 밖에서 따로 입력한다. 모든 입력이 무차원 양이고 격자 지도는 개체 수와 순서에 불변이므로 해역 크기·격자 해상도·선박 수가 바뀌어도 입출력의 형태가 같다.

4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net 구조 [10]를 지나 입력과 같은 해상도의 특징 지도로 변환된다(Fig. 6). 전역 평균 풀링으로 압축한 전황 벡터는 FiLM [11] 변조로 특징에 실려, 국소 합성곱이 옮기지 못하는 전황을 모든 위치에 전달한다.

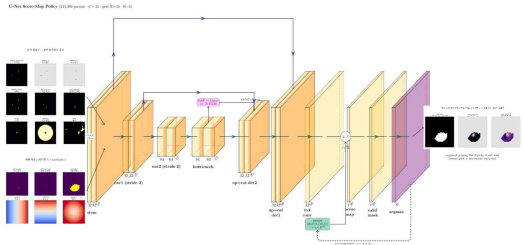


Fig. 6 Structure of the score map policy: query–feature inner product and sub-pixel offset

각 방어정 p 는 자신의 상태 벡터 $\boldsymbol{o_p}$ 로부터 MLP 로 질의 $\boldsymbol{q_p}$ 를 만들고, 아핀 사영 $\boldsymbol{W_q}$, $\boldsymbol{b_q}$ 를 거쳐

픽셀 i 의 특징 $\boldsymbol{f_i}$ 와 내적하여 점수 $s_{p,i}$ 를 얻는다.

$$s_{p,i} = \frac{\langle \boldsymbol{W_q q_p} + \boldsymbol{b_q}, \boldsymbol{f_i} \rangle}{\sqrt{d}}, \qquad d = 32 \tag{4}$$

어텐션 [13]과 같은 형식의 점수로 격자 위의 원소를 지목하는 포인터 구조다 [12]. 가중치는 모든 방어정이 공유하므로 모델 크기는 방어정 수에 불변이다.

4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 육지 픽셀 집합을 L_{land}, 모선에서 본 요격점 방위와 픽셀 방위의 차이를 $[0^\circ, 180^\circ]$ 로 접은 값을 $|\vartheta_i - \vartheta_p|_\circ$ 라 하면, 방어정 p 의 유효 픽셀 집합 V_p 는 환상 요격 구역($r_{\min} = 1.6\ell$, $r_{\max} = 18\ell$), 육지 밖, 요격점 반경 ($r_g = 12\ell$), 무리 방위($\vartheta_g = 60^\circ$)라는 네 조건의 교집합이다.

$$\begin{aligned} V_p = \{ i :\ & r_{\min} \le \|\boldsymbol{x_i} - \boldsymbol{m}\| \le r_{\max},\ i \notin L_{\text{land}}, \\ & \|\boldsymbol{x_i} - \boldsymbol{I_p}\| \le r_g,\ |\vartheta_i - \vartheta_p|_\circ \le \vartheta_g \} \end{aligned} \tag{5}$$

마스크는 로짓 단계에서 적용한다. 유효 집합 밖의 점수를 $-\infty$ 로 바꾼 마스크 점수 $\widetilde{s_{p,i}}$ 를 소프트맥스에 넣어 픽셀 선택 확률을 얻는다.

$$\widetilde{s_{p,i}} = \begin{cases} s_{p,i}, & i \in V_p \\ -\infty, & i \notin V_p, \end{cases} \qquad \pi_\theta(i \mid \boldsymbol{s}, p) = \frac{e^{\widetilde{s_{p,i}}}}{\sum_{j \in V_p} e^{\widetilde{s_{p,j}}}} \tag{6}$$

제약이 손실 항이 아니라 행동 분포에 직접 부과되므로 위반은 애초에 표현 불가능하며, 학습된 체크포인트에서 격자 대부분은 갈 수 없는 자리로 남는다(Fig. 7).

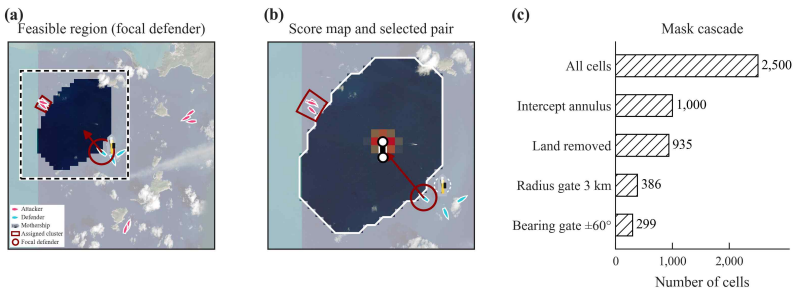


Fig. 7 Validity mask and pixel pointing (actual output of the trained checkpoint)

각 방어정은 유효 영역 안에서 픽셀 K 개를 순차적으로 고르며, 먼저 고른 픽셀의 특징을 질의에 더해 두 번째를 고르므로 두 점이 서로를 알고 뽑힌다. 칸 안 위치는 가우시안 오프셋으로 정하고, 두 점을 잇는 선분이 그물벽 경로가 된다.

4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

4.5.1 그룹 상대 이득

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화 [9]를 다중 방어정 상황에 맞게 변형하여 수행한다. 매 결정 시점에서 정책으로부터 G개의 결합 행동 후보를 표집하되, 후보 가운데 하나($k=0$)는 휴리스틱(4.3절)이 내는 행동으로 고정하여 기준선으로 삼는다. 각 후보를 시뮬레이터에서 공통 구간 $H=180\,\mathrm{step}$ 만큼 실제로 진행시켜 창 보상 R_k 를 얻은 뒤(4.5.2절), 휴리스틱 후보의 보상 R_0 를 기준으로 상대 비교하여 이득 A_k 를 산정한다. 그룹 표준편차로 나누되 ϵ 을 더해 0 나눗셈을 막는다.

$$A_k = \frac{\mathrm{R_k} - \mathrm{R_0}}{\mathrm{std}(\{\mathrm{R_j}\}_{\mathrm{j=0}}^{\mathrm{G-1}}) + \epsilon} \tag{7}$$

휴리스틱을 넘어서는 후보만 양의 이득을 받으며, 실제 결과를 직접 비교하므로 가치망과 그 추정 편향이 없다. 한 갱신은 N개의 병렬 전장(월드)에서 수행되고, 후보 보상이 모두 같은 월드는 유효 월드 마스크 w_n 으로 제외한다. 월드 n 의 상태를 $\boldsymbol{s_n}$, 후보 k 의 이득을 $A_{n,k}$, 그 후보에서 방어정 p 의 행동을 $a_{n,p}^{(k)}$ 라 하면 정책경사 손실은 다음과 같다.

$$L_{\mathrm{PG}}(\theta) = -\frac{\sum_{\mathrm{n}} \mathrm{w_n} \sum_{\mathrm{k=0}}^{\mathrm{G-1}} \mathrm{A_{n,k}} \sum_{\mathrm{p=1}}^{\mathrm{P}} \log \pi_\theta(a_{n,p}^{(k)} | \boldsymbol{s_n})}{\mathrm{G} \sum_{\mathrm{n}} \mathrm{w_n}} \tag{8}$$

여기에 엔트로피 정칙화를 더한 총손실을 최소화하며, 기울기 노름을 클립한 뒤 갱신한다.

그룹 상대 이득은 후보들이 갈릴 때만 신호를 주므로, 학습에 앞서 휴리스틱 픽셀 중심의 폭 좁은 가우시안을 목표로 한 행동 복제로 정책을 부팅한다. 옵티마이저는 Adam 이며, 학습률은 10^{-4} 에서 그 5% 까지 단일 주기 코사인 어닐링으로, 엔트로피 계수는 0.01 에서 그 10% 까지 선형으로, 총 800 업데이트의 같은 예산 축 위에서 함께 줄인다. 병렬 전장은 24개, 그룹 크기는 휴리스틱 후보를 포함해 $G=8$, 행동 복제는 300 갱신이다.

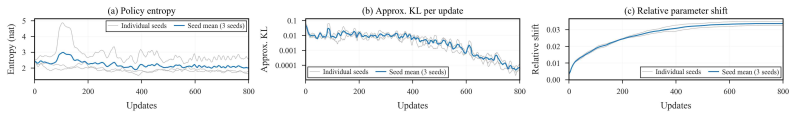


Fig. 8 Training progress (grey: individual seeds, blue: seed mean): (a) policy entropy, (b) approximate KL divergence, (c) parameter shift from the behaviour-cloning initialization

같은 설정을 시드 3개로 반복해 학습 경과를 기록하였다(Fig. 8). 갱신 전후 정책 사이의 근사 KL은 처음 100 업데이트 평균 1.4×10^{-2} 에서 마지막 100 업데이트 1.5×10^{-4} 로 두 자릿수 줄고, 파라미터 이동은 후반에 포화하며, 정책 엔트로피는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하다. 학습이 끝난 800 업데이트에서 세 시드의 greedy 포획률은 모두 휴리스틱 기준선 0.749 를 넘는다.

4.5.2 보상 설계

한 후보의 창 보상은 결정 시점부터 H step 동안의 팀 공유 보상으로, 이벤트 항 R_{event}, 창의 시작·끝 상태에서 잰 퍼텐셜 Φ 의 할인($\gamma=0.99$) 차분, 조밀 항 R_{dense} 로 구성된다.

$$R = R_{\mathrm{event}} + [\gamma \Phi(\mathbf{s_{t+H}}) - \Phi(\mathbf{s_t})] + \mathrm{R_{dense}} \tag{9}$$

이벤트 항은 포획(+13.5)·돌파(−8)·충돌(−30)·그물 접촉(−13) 건수의 가중합이고, 퍼텐셜은 생존 적선의 모선 근접도 합의 음수라 할인 차분 형태로 최적 정책을 보존한다 [17]. 조밀 항은 이동거리·그물 소모·선회량·목표점 변경·근접도를 벌하고 그물의 접근로 차단 비율을 보상한다. 포획은 평가 창의 46.8%에서만 일어나므로 나머지 창에서는 퍼텐셜·차단 비율 항이 후보 순위를 가르는 주된 신호다.

4.6 언어모델 기반 전략 계층

전략 계층의 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고 출력은 무리별 배정과 대기(HOLD)다. 언어모델에는 좌표 대신 무리별 요격점까지의 이동거리·선회량, 모선 기준 방위, 설치된 그물에 의한 차단 여부처럼 기하량을 미리 계산한 상태를 텍스트로 주고, 출력은 판단 근거·무리별 담당 방어정·대기 방어정의 세 필드로 된 JSON 형식으로 강제한다 [16]. 이 형식은 디코딩 단계에서 문법으로 작용해 파싱 실패로 그 주기의 배정을 잃는 일을 막는다. 언어모델이 정하는 것은 배정뿐이고 그물 전개·벽의 방위·요격점 기하는 기동 계층이 정하며, 배정이 바뀌면 요격점과 유효 마스크도 함께 바뀌므로 배정은 기동의 선행 조건이다.

5. 실험 설계

두 계층의 기여를 분리하기 위해 배정 축과 기동 축을 각각 이분한 2×2 조건 행렬을 두고, 시드 대응 차이로 판정한다.

5.1 환경과 학습 실행

지휘관으로는 능력 수준이 다른 소형 Qwen2.5 7B, 중형 Qwen2.5 14B, 상위 Gemini 3.5 Flash-Lite를 온도 0, 같은 프롬프트와 구조적 출력으로 매 결정마다 호출한다. 시뮬레이터는 $\Delta t = 1\,\mathrm{s}$ 의 질점 운동학, 규칙 기반의 적, 잡음 없는 완전 관측이라 포획률은 상한이며 조건 간 상대 비교로만 판정한다. 학습과 통계 비교는 이 시뮬레이터에서 하고, 학습된 정책은 선체 거동과 충돌을 물리 엔진으로 다루는 언리얼 엔진 환경(Fig. 9)에서 검증한다.



Fig. 9 Qualitative verification in the Unreal Engine–based simulator

학습은 한 해안선 형상에 과적합하지 않도록 실해역 6곳(Fig. 10)을 에피소드마다 돌려가며 진행하고, 평가는 그중 통영 매물도 서측에서 한다. 총 800 업데이트 동안 주기적 greedy 평가의 최고점 가중치(600 업데이트)를 채택하였다.

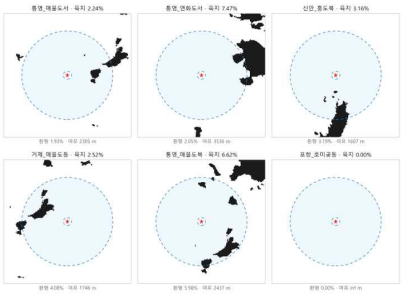


Fig. 10 Six training sites (star: mothership, dashed circle: intercept annulus)

5.2 조건, 판정 기준, 계측

Table 3 2×2 condition matrix (only two switches differ between conditions)

Condition	Assignment × maneuver	What it measures
heur_heur	Heuristic × heuristic	Baseline
heur_unet	Heuristic × U-Net	Pure contribution of the maneuver layer (no LLM)
llm_heur	LLM × heuristic	Pure contribution of the strategic layer
llm_unet	LLM × U-Net	Proposed system (incl. interaction)

휴리스틱 배정과 기동은 4.3절의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직접 비교 가능하다(Table 3). 전략 계층에 세 모델을 두고 모든 조건이 같은 시드 집합과 세 포메이션을 공유하도록 하여 720 에피소드를 수집하였다.

조건과 기준선의 시드 k 지표값을 x_k, y_k, 시드 수를 n_{s}, 대응 차이 d_k 의 표준편차를 s_d 라 하면 차이의 평균과 효과크기는

$$d_k = x_k - y_k, \qquad \bar{d} = \frac{1}{n_{\mathrm{s}}} \sum_{\mathrm{k}} \mathrm{d_k}, \qquad \mathrm{d_z} = \frac{\bar{\mathrm{d}}}{\mathrm{s_d}} \tag{10}$$

이며, 95 % 신뢰구간은 BCa 부트스트랩 [18]($B = 9999$)으로 구하고 지표 10개의 다중비교에는 Bonferroni 보정 구간(99.5 %)을 병기한다. 상호작용은 배정 축(H 휴리스틱, L 언어모델)과 기동 축(H 휴리스틱, U U-Net)의 조건별 지표값 x_k^{am} 에서

$$\mathrm{Int_k} = (\mathrm{x_k^{LU}} - \mathrm{x_k^{LH}}) - (\mathrm{x_k^{HU}} - \mathrm{x_k^{HH}}) \tag{11}$$

로 같은 절차를 거쳐 판정한다(>0 상승, ≈ 0 가산, <0 상쇄).

지휘관 계층은 포획률만으로 기여가 가려지므로 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지(활성 무리 중 배정된 비율), churn(재계획 간 담당을 바꾼 방어정 비율), 교차 배정을 따로 계측한다.

6. 결 과

6.1 기동 계층의 기여

6.1.1 휴리스틱 대 점수맵 정책

배정을 휴리스틱으로 고정하고 기동 방식만 비교하면(Table 4) 포획률은 0.844→0.886($d_z = 0.37$)으로 95% 수준에서 유의하나 다중비교 보정에서는 유의성을 잃는다. 기동 계층이 바꾸는 것은 포획률이 아니라 자원과 기동이다.

Table 4 Stand-alone contribution of the maneuver layer (U-Net score map + GRPO)

Formation	Heuristic maneuver	U-Net maneuver	Δ [95 % CI]	d_z
Concentrated	0.997	0.997	+0.000 [−0.010, +0.010]	+0.00
Diversionary	0.787	0.753	−0.033 [−0.077, +0.000]	−0.31
Wave	0.750	0.907	+0.157 [+0.043, +0.270]*	+0.48
Overall	0.844	0.886	+0.041 [+0.003, +0.082]*	+0.37

* The confidence interval excludes 0. The overall row pools the three formations.

10개 지표 전부로 넓혀도 U-Net 이 휴리스틱보다 불리한 축은 포획당 이동거리 하나로, 자리를 골라 그물벽을 놓는 대신 더 멀리 움직이기 때문이다.

포메이션별로 보면 기여가 고르지 않다. 파상에서 +0.157($d_z = 0.48$)로 가장 크고, 집중에서는 0.000, 양동에서는 −0.033 으로 오히려 소폭 낮다(유의하지 않아 악화로 읽지는 않는다). 파상에서는 앞 단을 막은 그물벽의 위치가 뒤 단의 차단을 좌우해 해면 전체를 평가하는 점수맵이 직접 효과를 내고, 양동에서는 결정적인 것이 배정이며, 집중은 휴리스틱만으로 포획률 0.997에 도달해 개선 여지가 없다.

6.1.2 갱신 규칙: 그룹 상대 최적화 대 MAPPO

같은 액터·행동공간·보상·예산 위에서 갱신 규칙만 MAPPO [8]로 바꾼 정책(시드 3개)은 포획률에서 GRPO 와 유의하게 갈리지 않았다(0.859 대 0.886). 갈린 것은 자원과 조기 제압으로, GRPO 는 포획당 그물을 MAPPO 의 0.733 에서 0.568 로 줄이고($d_z = -1.19$) 포획 이격거리를 154 m 늘렸으며($d_z = +1.21$), 두 차이 모두 다중비교 보정에서도 유의하였다.

6.2 지휘관 계층의 기여

기동 계층을 휴리스틱으로 고정해 지휘관 축만 분리하면 포획률은 모델 능력을 따라 단조로 오르되, 능력이 낮은 쪽은 휴리스틱 배정 기준선에 미치지 못하며, 개선은 양동과 파상에서 크다(Table 5, Fig. 11). 성능을 가르는 것은 배정 커버리지가 아니다(Table 6). 가장 낮은 성능의 모델이 커버리지는 가장 높았으므로 막아야 할 무리를 빠뜨려서 지는 것이 아니며, 성능과 맞물린 양은 재계획 간 담당 변경(churn)과 경로 교차였다. 재계획마다 방어정의 약 3분의 1이 담당을 바꾸면 전개하던 그물벽과 이동이 회수되지 않는다. 중형 모델은 응답이 간헐적으로 결정 주기를 넘기므로 전략 계층만 비동기로 떼어 둔 구조(4.1절)가 필요하다.

Table 5 Capture rate by condition (mean, 95 % CI, difference from baseline)

Commander (assignment)	Maneuver	Capture rate [95 % CI]	Δ vs baseline	d_z
Heuristic (baseline)	Heuristic	0.844 [0.808, 0.880]	-	-
Heuristic	U-Net score map	0.886 [0.847, 0.918]	+0.041 [+0.003, +0.082]*	+0.37
Qwen2.5 7B	Heuristic	0.652 [0.571, 0.716]	−0.192 [−0.264, −0.129]*	−1.00
Qwen2.5 14B	Heuristic	0.811 [0.766, 0.854]	−0.033 [−0.086, +0.017]	−0.23
Gemini 3.5 Flash-Lite	Heuristic	0.904 [0.864, 0.937]	+0.060 [+0.024, +0.100]*	+0.56
Qwen2.5 7B	U-Net score map	0.641 [0.582, 0.693]	−0.203 [−0.274, −0.138]*	−1.03
Qwen2.5 14B	U-Net score map	0.754 [0.698, 0.806]	−0.090 [−0.153, −0.033]*	−0.54
Gemini 3.5 Flash-Lite	U-Net score map	0.907 [0.869, 0.937]	+0.062 [+0.013, +0.113]*	+0.44

* The confidence interval excludes 0. d_z: paired effect size. Rows sharing a commander give the maneuver-layer contribution; rows sharing a maneuver give the commander contribution. Qwen2.5: local (RTX 4070); Gemini: cloud API.

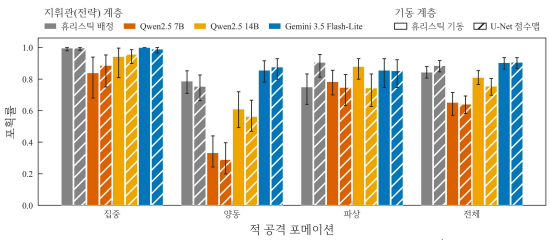


Fig. 11 Capture rate by formation and condition (error bars: 95 % CI)

Table 6 Commander plan quality and performance

Commander	Coverage ↑	churn ↓	Crossing ↓	Capture rate ↑
Qwen2.5 7B	0.934	0.324	0.152	0.652
Qwen2.5 14B	0.877	0.167	0.111	0.811
Gemini 3.5 Flash-Lite	0.881	0.098	0.033	0.904

Coverage: fraction of active clusters assigned. Churn: fraction of defenders changing assignment between replans. Crossing: fraction of crossing intercept paths. Capture rate with heuristic maneuver; fallback rate at most 0.007 for all models.

6.3 제안 체계 전체

6.3.1 두 계층의 상호작용

식 (11)의 상호작용을 10개 지표 전부에 대해 계산하였다(Table 7).

Table 7 2×2 interaction decomposition (Gemini commander)

Metric	Total effect	Interaction [95 % CI]
Capture rate	+0.062	−0.039 [−0.083, +0.012]
Breaches	−0.62	+0.39 [−0.13, +0.83]
Collision rate (per defender)	−0.052	−0.015 [−0.070, +0.022]
Net entanglements	−0.60	+0.17 [−0.08, +0.41]
Nets per capture	−0.328	+0.004 [−0.045, +0.059]
Distance per capture (m)	−182	−55 [−125, +30]
Total turning (rad)	−757	−56 [−165, +59]
Capture distance (m)	+223	+38 [−2, +81]
Capture time (step)	−22	−12 [−20, −6]*
Enemy distance at deploy (m)	−371	+26 [−44, +109]

Interaction = (LLM+U-Net − LLM+heuristic) − (heuristic+U-Net − baseline). * significant interaction.

10개 지표 중 9개에서 상호작용이 유의하지 않고, 다중비교 보정 후에도 그대로 9개다. 두 계층의 기여는 상승이 아니라 가산적이다. 예외인 평균 포획 시각은 두 계층이 모두 제압을 앞당겨 생기는 수확 체감이다. 가산성이 두 계층을 따로 써도 된다는 뜻은 아니다. 양동에서는 기동 계층 단독(−0.033)도 전략 계층 단독(+0.070)도 유의하지 않은데 결합은 +0.090 으로 유의해진다. 무리 수와 방어정 수가 같아 배정과 기동이 둘 다 맞아야 막히기 때문이다.

6.3.2 전 지표 효과크기

제안 체계와 기준선의 차이를 10개 지표에 걸쳐 효과크기로 잰다(Table 8).

Table 8 Effect sizes for all metrics (descending $|d_z|$)

Metric	Dir.	baseline	Proposed	Δ	d_z
Total turning (rad)	↓	1625	868	−757*†	−3.23
Nets per capture	↓	0.737	0.409	−0.328*†	−2.09
Capture distance (m)	↑	1511	1734	+223*†	+1.81
Enemy distance at deploy (m)	↓	1499	1128	−371*†	−1.60
Net entanglements	↓	0.82	0.22	−0.60*†	−1.19
Capture time (step)	↓	430	408	−22*†	−1.04
Distance per capture (m)	↓	825	643	−182*†	−0.65
Collision rate (per defender)	↓	0.130	0.078	−0.052*†	−0.52
Breaches	↓	1.56	0.93	−0.62*	−0.44
Capture rate	↑	0.844	0.907	+0.062*	+0.44

↑ higher is better, ↓ lower is better. * 95 % CI excludes 0. † Also excludes 0 under Bonferroni correction for 10 metrics.

개선은 기동 비용과 자원 효율에 몰려 있다. 총 선회량은 47 % 줄어 $d_z = -3.23$, 포획당 그물은 45 % 줄어 −2.09, 포획 이격거리는 223m 늘어 +1.81 인 반면 포획률은 $d_z = 0.44$ 로 최하위권이며, 다중비교 보정에서는 포획률과 돌파 수만 유의성을 잃는다.

7. 고찰 및 결론

7.1 결과의 해석

두 계층의 기여가 가산적이라는 것(6.3절)은 지휘관 모델 교체와 기동 정책 재학습을 서로 기다리지

않고 진행할 수 있다는 운용상의 자유를 뜻한다. 지휘관의 성능을 설명한 것이 커버리지가 아니라 계획 안정성이라는 관찰(6.2절)은 주기적으로 재계획하는 계층 구조 일반에 해당한다. 상위 결정의 변경은 하위 계층에 회수되지 않는 이동과 그물을 남기므로, 매 호출이 독립적인 언어모델을 계획 계층에 둘 때는 계획 품질을 시간에 걸친 일관성으로 평가하고 상태 표현이 그 일관성을 지원해야 한다. 가장 큰 개선이 총 선회량에서 나타난 것은 경유점이 격자에 고정되고 유효 마스크가 무의미한 위치를 배제하기 때문이며, 유효 셀 안에서 점수맵은 거의 단봉이므로 이득은 분포의 다봉성이 아니라 마스크와 격자 양자화에서 온다.

7.2 한계와 향후 과제

검증은 시뮬레이션에 한정되며 그물 거동·얽힘 판정·관측이 단순화되어 있다. 관측 불확실성은 배정이 딛고 선 무리 구성을 흔들므로 지휘관 계층에 더 크게 작용할 것이다. 규모가 적 10척 대 방어정 3척으로 고정이고 적이 규칙 기반이라, 배정 조합이 급증하는 규모와 그물벽 배치를 학습해 회피하는 적응적 적은 범위 밖이며, 연속 행동공간 기준선과 구성요소별 절제도 과제로 남는다.

7.3 결론

적보다 느린 방어정으로 자폭 군집을 막는 2계층 체계를 제안하고, 시드 대응 2×2 설계의 720 에피소드로 두 계층의 기여를 분리 측정하였다. 제안 체계는 같은 방어 수준에서 자원과 기동 비용을 크게 줄였으며, 두 계층의 기여는 가산적이었고, 언어모델 지휘관의 이득은 능력 임계 위에서만 나타났다. 실해역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.

사 사

[발표 전 확인 필요] 본 연구는 [지원 기관·과제명·과제번호]의 지원을 받아 수행되었다.

자료 공개

재현에 필요한 자료는 720 에피소드의 에피소드별 지표(episodes.csv), 계획 호출 계측값(llm_metrics.csv), 기동 계층 체크포인트(u-net_map.pt)와 시뮬레이터 전체이며, 본문의 모든 표와 그림은 앞의 두 파일에서 기계적으로 생성된다. [공개 URL 기입 필요] 상용 API 지휘관 모델의 수치는 버전 갱신에 따라 달라질 수 있으나, 언어모델을 쓰지 않는 조건(heur_heur, heur_unet)은 이 위험 없이 재현된다.

참고문헌

[1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., “Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem”, *Operations Research*, Vol.55-6, (2007), p.1136-1146.

[2] Wang, J., Liu, Y. and Song, H., “Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends”, *IEEE Aerospace and Electronic Systems Magazine*, Vol.36-3, (2021), p.4-29.

[3] Sutea, V., *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*, Atlantic Council UkraineAlert, 24 February 2026 (2026).

[4] Rumbaugh, W., *Cost and Value in Air and Missile Defense Intercepts*, Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024, Washington, DC (2024).

[5] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., “Multi-USV cooperative target encircl ement through learning-based distributed transferable policy and experimental validation”, *Ocean Engineering*, Vol.318, (2025), No.120124.

[6] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., “QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning”, *International Conference on Machine Learning (ICML)*, (2018), p.4295-4304.

[7] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., “Counterfactual Multi-Agent Policy Gradients”, *AAAI Conference on Artificial Intelligence*, (2018), p.2974-2982.

[8] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., “The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games”, *Advances in Neural Information Processing Systems 35 (NeurIPS)*, (2022).

[9] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. and Guo, D., “DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models”, *arXiv preprint arXiv:2402.03300*, (2024).

[10] Ronneberger, O., Fischer, P. and Brox, T., “U-Net: Convolutional Networks for Biomedical Image Segmentation”, *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, (2015), p.234-241.

[11] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., “FiLM: Visual Reasoning with a General Conditioning Layer”, *AAAI Conference on Artificial Intelligence*, (2018), p.3942-3951.

[12] Vinyals, O., Fortunato, M. and Jaitly, N., “Pointer Networks”, *Advances in Neural Information Processing Systems 28 (NeurIPS)*, (2015).

[13] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł. and Polosukhin, I., “Attention Is All You Need”, *Advances in Neural Information Processing Systems 30 (NeurIPS)*, (2017).

[14] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., “Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents”, *International Conference on Machine Learning (ICML)*, (2022), p.9118-9147.

[15] Ahn, M., Brohan, A., Brown, N., et al., “Do As I Can, Not As I Say: Grounding Language in Robotic Affordances”, *Conference on Robot Learning (CoRL)*, (2022).

[16] OpenAI, *Function calling*, [Online] Available at: https://developers.openai.com/api/docs/guides/function-calling [Accessed 9 August 2026] (2026).

[17] Ng, A.Y., Harada, D. and Russell, S., “Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping”, *International Conference on Machine Learning (ICML)*, (1999), p.278-287.

[18] Efron, B. and Tibshirani, R.J., *An Introduction to the Bootstrap*, Chapman & Hall, New York (1993).