자폭 무인수상정 군집 방어를 위한 LLM 지휘관과 U-Net 점수맵 기동 정책의 2계층 결합

Coupling an LLM Commander and a U-Net Score-Map Policy for Two-Layer Defense against Suicide USV Swarms

윤 영 준[*1], 방 현 태[*1], 전 유 라[*2], 김 덕 환[*2], 윤 원 근[*1]

(0204jun@o.cnu.ac.kr, htbang@g.cnu.ac.kr, youraj@kaist.ac.kr, dnb06116@kaist.ac.kr, wkyoun@cnu.ac.kr)

Swarms of low-cost suicide unmanned surface vehicles (USVs) evade conventional counters: electronic warfare cannot reach wire-guided targets, and interceptors cost more than their targets and saturate. We propose a two-layer defence architecture in which a few defenders, slower than the attackers, pre-emptively block the mothership's approach routes with nets. In the strategic layer a large language model (LLM) commander assigns each defender an enemy cluster; in the maneuver layer each defender points at a pixel of a score map that a U-Net produces over a rasterized battlefield grid to place its net. Both layers decide on the same period but differ sharply in response latency, so only the slow strategic layer is decoupled asynchronously. Pixel pointing confines the action space to the grid, imposes safety and mission constraints by masking and is invariant to swarm size, and training extends critic-free group-relative policy optimization to multiple agents. From 720 seed-paired episodes (8 conditions, 3 formations, 30 seeds) we separated the contributions of the two layers in a 2x2 design. The maneuver layer alone raised the capture rate from 0.844 to 0.886, and the full system cut nets per capture by 45 % and total turning by 47 % at the same defense level; the two contributions were additive rather than synergistic. The commander paid off only for models above a capability threshold, and its performance was explained not by assignment coverage but by plan stability across replans. In periodically replanning architectures, consistency over time matters more than local optimality.

Key Words: 무인수상정(Unmanned Surface Vehicle), 군집 방어(Swarm Defense), 다중 에이전트 강화학습(Multi-Agent Reinforcement Learning), 임무배정(Task Assignment), 대규모 언어모델(Large Language Model), 의미론적 분할(Semantic Segmentation), 그룹 상대 정책 최적화(Group Relative Policy Optimization)

1. 서 론

최근 분쟁에서는 폭약을 실은 값싼 무인수상정(USV) 여러 척이 여러 방향에서 동시에 고가치 함정으

*1 충남대학교
*2 한국과학기술원

로 돌진하는 자폭 USV 공격이 새로운 비대칭 위협으로 떠오르고 있다. 기존 방어 수단으로는 이 공격을 막기 어렵다. 첫째, 함정이 한 번에 상대할 수 있는 요격 수단보다 자폭 USV가 많으면, 아무리 효율적으로 배정해도 표적이 남는다 [1]. 둘째, 전파 교란이나 기만처럼 표적을 파괴하지 않고 무력화하는 연성 대응(soft-kill)은 광섬유 같은 유선으로 조종되는 표적에는 통하지 않는다 [2, 3]. 셋째, 함포나 유도탄으로 표적을 직접 파괴하는 경성 대응(hard-kill)은 값싼 표적 하나에 비싼 유도탄을 써야 해서 비용이 맞지 않는다. 표적이 한꺼번에 몰려와 대응 능력을 넘어서는 포화 상황 또한 문제이다 [4].

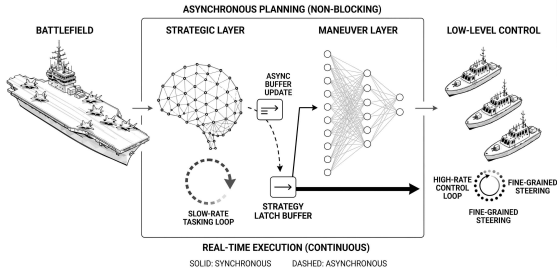


Fig. 1 Two-layer architecture of the proposed system

본 연구는 값싼 그물로 표적을 물리적으로 붙잡는 방식을 택한다 [2]. 그물은 표적이 무선으로 조종되든 유선으로 조종되든 똑같이 무력화한다. 다만 방어정은 자폭 USV보다 느려서 뒤쫓을 수 없다. 그래서 적이 지나갈 접근 경로에 먼저 가서 그물로 가로막는다.

이를 위해서는 두 가지를 판단해야 한다. 하나는 어느 방어정이 어느 자폭 USV를 맡을지 정하는 배정이고, 다른 하나는 그 표적을 어디에서 막을지 정하는 기동이다. 본 연구는 배정을 언어모델 지휘관에게, 기동을 강화학습으로 학습한 정책에 맡긴다. 언어모델은 답을 내는 데 오래 걸리지만, 학습된 정책은 신경망을 한 번 계산하는 것만으로도 행동을 산출해낸다. 두 판단은 걸리는 시간이 크게 다르므로, 기동이 언어모델의 응답을 기다리느라 늦어지지 않도록 느린 배정 계층만 비동기로 분리하여 기동 정책은 매 주기 지체 없이 행동하도록 구현한다(Fig. 1).

학습과 평가는 OpenStreetMap 해안선으로 만든 실해역 지형에서 수행한다. 기동 정책은 모선 중심 격자 지도를 영상으로 입력받아 그 지도에서 목표 격자 하나를 고르며, 갈 수 없는 격자는 후보에서 미리 제외한다. 고른 격자는 제어 명령이 아니라 경유점으로 디코딩되며, 정책은 그 지점까지 배를 모는 저수준 추종과 분리된다(4절). 배정과 기동의 기여는 각 계층을 휴리스틱과 제안 방법 중 하나로 두는 네 조합을 같은 시나리오에서 비교해 측정한다(5절).

2. 관련 연구

방어 자산을 표적에 배분하는 문제는 주로 무기-표적 할당(WTA)으로 정식화되어 왔다 [1]. 그러나 실제 배정은 앞선 결정으로 어느 경로가 이미 막혔는지, 자산이 얼마나 남았는지에 따라 달라지므로, 고정된 거리·각도 비용만으로는 이를 표현하기 어렵다. 이에 본 연구는 배정 계층에 조합 최적화 대신 언어모델의 판단을 둔다. 무인 위협을 무력화하는 수단 가운데 연성 대응은 유선으로 조종되는 표적에 통하지 않고, 경성 대응은 값싼 표적에도 고비용의 자원을 써야 하는 부담이 있다. 이러한 한계 때문에 본 연구는 저비용의 그물을 이용한 물리적 포획을 택한다 [2, 3, 4]. 해상에서 강화학습으로 표적을 포위하는 기존 연구 [5]는 방어정이 표적보다 빠르거나 비슷한 속도라고 가정한다. 그러나 실제 방어정은 고속으로 돌진하는 자폭 USV보다 느린 경우가 많기 때문에 본 연구에서는 방어정이 표적보다 느린 조건에서도 방어할 수 있도록, 표적의 경로에 먼저 가서 그물로 막는 선제 차단 방식을 제안한다.

기존 다중 에이전트 강화학습은 주로 중앙에서 학습하고 각자 실행하는 구조를 따르며, 팀 보상에서

개체별 기여를 분리하기 위해 가치망 학습에 의존한다 [6, 7, 8]. 그룹 상대 정책 최적화(GRPO) [9]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 가치망 자체를 없앤다. 본 연구는 GRPO를 다중 에이전트 제어로 확장하여, 후보 하나는 기하 휴리스틱으로 고정해 기준선으로 삼고 각 후보의 팀 보상은 시뮬레이터를 다시 진행해 얻는다. 이로써 정책은 부정확한 가치 추정에 흔들리지 않고, 휴리스틱보다 나은 행동을 후보 행동 간 직접 비교로 찾아가며 학습한다.

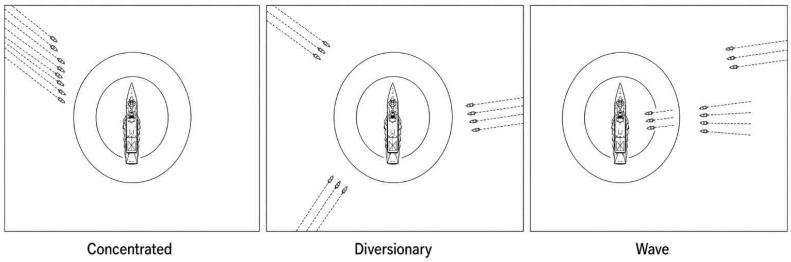


Fig. 2 Three attack formations: concentrated, diversionary and wave (left to right)

U-Net [10]처럼 영상의 픽셀마다 값을 매기는 신경망과, 여기에 영상 전체의 정보를 덧입히는 조건 변조 기법 [11]은 주로 영상 속 영역을 구분하는 데 쓰였다. 한편 Pointer Network [12]나 어텐션 [13]처럼 여러 후보에 점수를 매겨 하나를 고르는 출력은 주로 조합 최적화에 쓰였다. 본 연구는 두 방식을 결합하여 픽셀마다 매긴 점수, 즉 점수맵을 이동할 지점의 선택 확률로 삼는다(4.4절). 따라서 행동이 지도 위의 한 지점이 되어 공간 구조가 보존된다. 또한 특정 격자를 미리 선택 후보에서 배제하는 방식으로 안전 제약을 지키며, USV 정보를 지도 위 격자에 담으므로 USV 수와 무관하게 입력 차원이 고정되어, 그 수가 달라져도 유연하게 대응할 수 있다.

언어모델에게 계획을 맡기는 기존 연구는 지시를 실행 가능한 단계로 나누고 실행할 수 없는 계획을 차단하며 [14, 15], 출력을 정해진 형식으로 받아 기존 시스템이 읽을 수 있게 한다 [16]. 언어모델은 전장 상태와 임무 목표, 교전 규칙 등을 함께 읽으므로 비용 함수를 재설계하지 않고도 배정 기준을 유동적으로 바꿀 수 있다. 본 연구는 언어모델에게 배정만을 맡기고, 기동 계층에서는 격자 단위로 판단하는 모델과의 결합으로 언어모델이 배정에만 집중하고 그 출력이 불확실하더라도 위험한 기동으로는 이어지지 않게 한다(4.4.3절).

3. 문제 정의와 평가 지표

3.1 교전 시나리오

Table 1 Engagement scenario and observation settings

Item	Value
Number of attacking USVs M	10
Number of defenders P	3
Maximum number of clusters C	4
Side length of the engagement area	50ℓ
Speed ratio v_e/v_a (attacker / defender)	1.5
Observation grid $n_g \times n_g$ (centred on mothership)	50×50
Nets per defender (training / evaluation)	1 / 3
Number of policy parameters	244,389

교전 해역 중앙에 고가치 모선 한 척이 있고, 가장자리에서 적 USV M척이 모선을 향해 돌진한다.

적은 방어정보다 빠르다고 가정하며, 세 공격 포메이션 가운데 하나를 취한다(Fig. 2). 집중(concentrated)은 모든 적이 한 방향에서 몰려오는 형태이고, 양동(diversionary)은 적이 세 방향으로 나뉘어 동시에 접근하는 형태이며, 파상(wave)은 적이 다수의 무리로 나뉘어 같은 방향에서 조금씩 어긋난 경로로 시간차를 두고 차례로 밀려오는 형태이다.

방어정 P척은 각각 한정된 수의 그물을 전개할 수 있다. 방어정이 두 경유점 사이를 이동하며 후미의 전개 장치로 부유식 그물을 풀어 놓으면, 그 위를 지나는 적 USV의 추진기관이 무력화된다(Fig. 3). 외란에 의한 그물의 위치 변동과 적의 회피 기동을 최대한 줄이기 위해, 방어정은 적이 자신에게 최대한 근접하였을 때 그물을 펼치는 것을 목표로 한다. 세부 설정은 Table 1에 정리하였으며, 모든 거리는 관측 지도의 한 칸 크기 ℓ 을 기준으로 나타내므로 해역의 실제 크기가 달라져도 같은 체계를 그대로 적용할 수 있다.

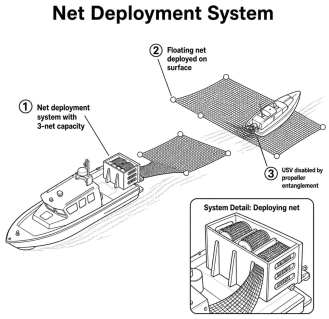


Fig. 3 Capture concept of the stern-launched floating net

3.2 평가 지표

방어 성과는 다섯 관점의 9개 지표로 에피소드마다 잰다(Table 2). 모든 에피소드에서 적 USV는 포획되거나 모선에 도달(돌파 수 N_{brc})하는 것으로 결판나 돌파 수는 포획률과 같은 정보이므로 따로 두지 않는다. 자원 효율은 교전하지 않은 조건이 가장 효율적으로 보이는 것을 막기 위해 총량이 아니라 포획당 비율로 두었고, 교전 품질은 거리축과 시간축으로 나누어 모선에서 먼 포획과 이른 포획을 함께 본다.

Table 2 Nine evaluation metrics

Aspect	Metric	Definition	Meaning
Defense outcome	Capture rate	$\mathrm{CR} = \mathrm{N_{cap}}/(\mathrm{N_{cap}} + \mathrm{N_{brc}})$	Captured / resolved
Safety	Collision rate	$N_{\mathrm{col}}/\mathrm{P}$	Collisions per defender
	Net entanglements	N_{tng}	Own-net entanglements
Resource efficiency	Nets per capture	$N_{\mathrm{net}}/\mathrm{N_{cap}}$	Nets used per capture
	Distance per capture	$\sum_{p=1}^{P} D_p / N_{\mathrm{cap}}$	Travel per capture
Maneuver cost	Total turning	$\sum_{p=1}^{P} \sum_{t} \lvert \Delta\psi_{p,t} \rvert$	Total heading change
Engagement quality	Capture distance	$\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \lVert \mathbf{z_k} - \mathbf{m} \rVert$	Range from mothership
	Capture time	$\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \mathrm{t_k}$	Time of capture
	Enemy distance at deploy	$\frac{1}{N_{\mathrm{net}}} \sum_{\mathrm{d}} \min_{m \in A} \lVert \boldsymbol{a_d} - \boldsymbol{e_m} \rVert$	Nearest-attacker range

4. 제안 방법

4.1 2계층 비동기 구조

전략 계층은 어느 방어정이 어느 적 무리를 맡는가를, 기동 계층은 어느 위치에 그물을 놓는가를 정한다(Fig. 1). 언어모델 호출에는 지연이 있으므로(6.2절), 기동 계층이 그 응답을 기다리느라 늦어지지 않도록 전략 계층만 비동기로 분리한다. 기동 계층은 배정 응답을 기다리는 동안 직전 배정으로 결정을 계속하고, 응답이 도착하면 다음 결정부터 새 배정을 반영한다.

4.2 적 무리 군집화

두 계층 모두 개별 적 USV가 아니라 무리를 단위로 다루므로, 매 결정마다 생존 적 USV n척을 모선에서 본 방위 ϑ_m 순으로 정렬해 최대 C 개의 무리로 묶는다(Fig. 4). 방위 구간을 고정해 나누면 한 무리가 경계에 걸려 쪼개질 수 있으므로, 원을 따라 이웃한 방위 사이의 간격 $g_{(q)}$ 가운데 크게 벌어진 곳을 무리의 경계로 삼아 무리 수를 적의 분포에 따라 정한다. 임계 δ_{gap} 을 넘는 간격의 개수가 활성 무리 수 $\hat{C}$ 이며, 이를 1 이상 $\min(C,n)$ 이하로 제한한다.

$$\hat{C} = \mathrm{clip}\left(\left|\{\, q : g_{(q)} > \delta_{\text{gap}} \,\}\right|,\ 1,\ \min(C,n)\right) \tag{1}$$

가장 큰 간격 $\hat{C}$ 개를 경계로 삼아 방위 순으로 무리를 나누고, 각 무리를 척수 n_j, 중심 $\boldsymbol{c_j}$, 각도 퍼짐 $\Delta\vartheta_j$, 모선 방향 접근 속도 v_j^{app} 의 네 양으로 요약한다. 이 규칙에 따르면 집중은 무리 하나, 양동은 셋으로 요약되며, 파상은 대개 차례로 밀려오는 무리마다 하나씩으로 요약된다.

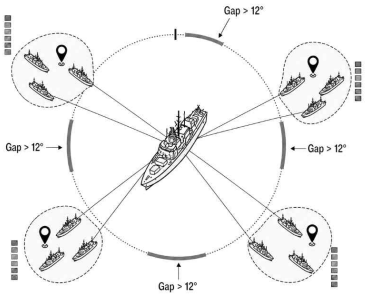


Fig. 4 Bearing sorting, clustering and cluster assignment

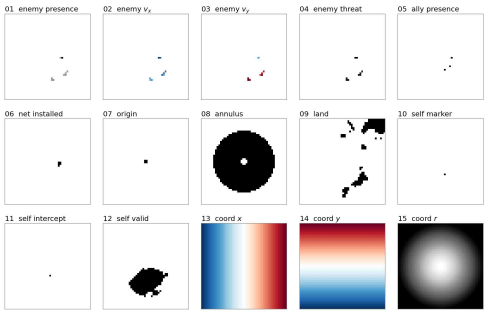


Fig. 5 Example of the rasterized 15-channel observation (wave formation, north of Maemuldo, Tongyeong)

4.3 기하 휴리스틱 기준 방법

무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법으로, 6절의 비교 기준이자 4.5.1절의 행동 복제 목표다. 무리 j 의 위협도 τ_j 는 척수 n_j 에 모선 근접도를 곱한 양이고, 요격점 $\boldsymbol{I_j}$ 는 무리 중심에서 모선을 향해 선분의 λ_{I} 비율만큼 옮긴 점이다.

$$\tau_j = n_j \cdot \mathrm{clip}\left(1 - \frac{\|\mathbf{c_j} - \mathbf{m}\|}{\mathrm{R_w}}, 0.05, 1\right), \qquad \boldsymbol{I_j} = \boldsymbol{c_j} + \lambda_{\mathrm{I}}(\mathbf{m} - \mathbf{c_j}), \quad \lambda_{\mathrm{I}} = 0.55 \tag{2}$$

방어정이 적보다 느리므로 요격점은 모선 쪽으로 치우쳐 둔다.

위협 상위 P 개 무리에 대해 Greedy 1:1 배정을 한다. 비용은 방어정 위치 $\boldsymbol{a_p}$ 에서 요격점까지의 거리 d_{pj} 에서, 직전 결정의 담당 j_p^{prev} 를 유지하는 쌍에만 보너스 β 를 감한 값으로, 거리 차이가 크게 벌어지기 전에는 직전 배정이 유지된다.

$$\widetilde{d_{pj}} = \begin{cases} d_{pj} - \beta, & \mathrm{if\ j} = \mathrm{j_p^{prev}}, \\ \mathrm{d_{pj}}, & \mathrm{otherwise}. \end{cases} \tag{3}$$

활성 무리가 P 보다 적으면 남는 방어정은 한 척당 맡는 적이 가장 많은 무리에 추가로 배정되어 기존 요격점보다 모선에 가까운 곳에서 그 무리를 한 번 더 막는다. 그물은 요격점을 가운데 두고 접근 방향에 수직으로 길이 L_{net} 만큼 펼치므로 경유점은 양 끝 $K = 2$ 개이며, 학습 정책과 같은 격자 위에서 갈 수 있는 가장 가까운 칸으로 맞춘다. 따라서 휴리스틱과 학습 정책은 같은 행동공간을 쓰며, 다른 것은 결정 규칙뿐이다.

4.4 점수맵 기반 기동 정책

4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모선을 중앙에 두고 사방으로 E 까지의 전장을 $n_g \times \mathrm{n_g}$ 격자로 나눈 다채널 지도이다. 15개 채널은 모든 방어정이 공유하는 전역 9채널, 방어정마다 다른 3채널, 좌표 3채널로 구성된다(Fig. 5). 한 칸의 크기는 $\ell = 2E/n_g$ 이며, 각 선박의 위치를 해당 칸에 표시하고 한 칸에 여러 척이 있으면 합산한다. 방어정 p 의 자체 상태 $\boldsymbol{o_p} \in R^8$ 는 지도와 별도로 입력한다. 모든 입력

은 ℓ 단위의 무차원 값이고, 지도는 선박이 몇 척이든 어떤 순서로 나열되든 같은 크기로 만들어지므로, 해역 크기나 선박 수가 바뀌어도 입출력의 형태가 같다.

4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net 구조 [10]를 지나 입력과 같은 해상도의 특징 지도로 변환된다(Fig. 6). 전역 평균 풀링으로 압축한 전황 벡터는 FiLM [11] 변조로 특징에 실려, 국소 합성곱이 옮기지 못하는 전황을 모든 위치에 전달한다.

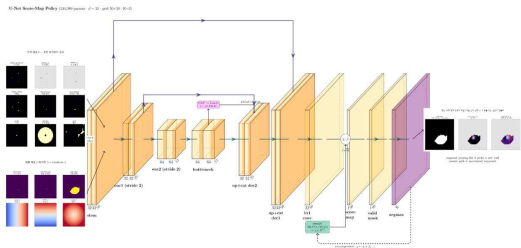


Fig. 6 Structure of the score map policy: query–feature inner product and sub-pixel offset

각 방어정 p 는 자신의 상태 벡터 $\boldsymbol{o}_p$ 로부터 MLP 로 질의 $\boldsymbol{q}_p$ 를 만들고, 아핀 사영 $\boldsymbol{W}_q$, $\boldsymbol{b}_q$ 를 거쳐 픽셀 i 의 특징 $\boldsymbol{f}_i$ 와 내적하여 점수 $s_{p,i}$ 를 얻는다.

$$s_{p,i} = \frac{\langle \boldsymbol{W}_q \boldsymbol{q}_p + \boldsymbol{b}_q, \boldsymbol{f}_i \rangle}{\sqrt{d}}, \qquad d = 32 \tag{4}$$

어텐션 [13]과 같은 형식의 점수로 격자 위의 원소를 지목하는 포인터 구조다 [12]. 가중치는 모든 방어정이 공유하므로 모델 크기는 방어정 수에 불변이다.

4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 육지 픽셀 집합을 L_{land}, 모선에서 본 요격점 방위와 픽셀 방위의 차이를 $[0^\circ, 180^\circ]$ 로 접은 값을 $|\vartheta_i - \vartheta_p|_\circ$ 라 하면, 방어정 p 의 유효 픽셀 집합 V_p 는 환상 요격 구역($r_{\min} = 1.6\ell$, $r_{\max} = 18\ell$), 육지 밖, 요격점 반경 ($r_g = 12\ell$), 무리 방위($\vartheta_g = 60^\circ$)라는 네 조건의 교집합이다.

$$V_p = \{\, i : \; r_{\min} \le \|\boldsymbol{x}_i - \boldsymbol{m}\| \le r_{\max},\; i \notin L_{\text{land}},\; \|\boldsymbol{x}_i - \boldsymbol{I}_p\| \le r_g,\; |\vartheta_i - \vartheta_p|_\circ \le \vartheta_g \,\} \tag{5}$$

마스크는 로짓 단계에서 적용한다. 유효 집합 밖의 점수를 $-\infty$ 로 바꾼 마스크 점수 $\widetilde{s}_{p,i}$ 를 소프트맥스에 넣어 픽셀 선택 확률을 얻는다.

$$\widetilde{s}_{p,i} = \begin{cases} s_{p,i}, & i \in V_p \\ -\infty, & i \notin V_p, \end{cases} \qquad \pi_\theta(i \mid \boldsymbol{s}, p) = \frac{e^{\widetilde{s}_{p,i}}}{\sum_{j \in V_p} e^{\widetilde{s}_{p,j}}} \tag{6}$$

제약이 손실 항이 아니라 행동 분포에 직접 부과되므로 위반은 애초에 표현 불가능하며, 학습된 체크포인트에서 격자 대부분은 갈 수 없는 자리로 남는다(Fig. 7).

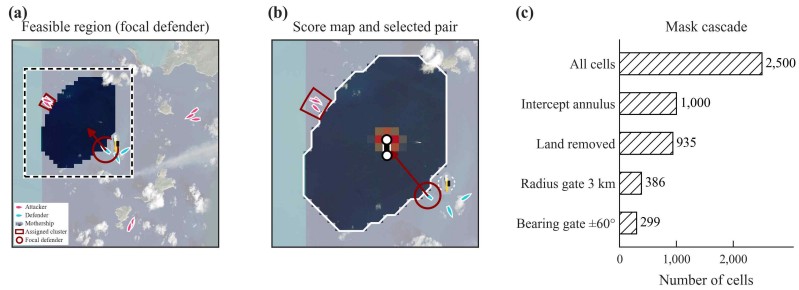


Fig. 7 Validity mask and pixel pointing (actual output of the trained checkpoint)

각 방어정은 유효 영역 안에서 픽셀 K 개를 순차적으로 고르며, 먼저 고른 픽셀의 특징을 질의에 더해 두 번째를 고르므로 두 점이 서로를 알고 뽑힌다. 칸 안 위치는 가우시안 오프셋으로 정하고, 두 점을 잇는 선분이 그물 경로가 된다.

4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

4.5.1 그룹 상대 이득

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화 [9]를 다중 방어정 상황에 맞게 변형하여 수행한다. 매 결정 시점에서 정책으로부터 G개의 결합 행동 후보를 표집하되, 후보 가운데 하나($k=0$)는 휴리스틱(4.3절)이 내는 행동으로 고정하여 기준선으로 삼는다. 각 후보를 시뮬레이터에서 공통 구간 $H=180\,\text{step}$ 만큼 실제로 진행시켜 창 보상 R_k 를 얻은 뒤(4.5.2절), 휴리스틱 후보의 보상 R_0 를 기준으로 상대 비교하여 이득 A_k 를 산정한다. 그룹 표준편차로 나누되 ϵ 을 더해 0 나눗셈을 막는다.

$$A_k = \frac{\mathrm{R_k} - \mathrm{R_0}}{\mathrm{std}(\{\mathrm{R_j}\}_{\mathrm{j}=0}^{\mathrm{G}-1}) + \epsilon} \tag{7}$$

휴리스틱을 넘어서는 후보만 양의 이득을 받으며, 실제 결과를 직접 비교하므로 가치망과 그 추정 편향이 없다. 한 갱신은 N개의 병렬 전장(월드)에서 수행되고, 후보 보상이 모두 같은 월드는 유효 월드 마스크 w_n 으로 제외한다. 월드 n 의 상태를 $\boldsymbol{s_n}$, 후보 k 의 이득을 $A_{n,k}$, 그 후보에서 방어정 p 의 행동을 $a_{n,p}^{(k)}$ 라 하면 정책경사 손실은 다음과 같다.

$$L_{\mathrm{PG}}(\theta) = -\frac{\sum_{\mathrm{n}} \mathrm{w_n} \sum_{\mathrm{k}=0}^{\mathrm{G}-1} \mathrm{A_{n,k}} \sum_{\mathrm{p}=1}^{\mathrm{P}} \log \pi_\theta(a_{n,p}^{(k)} | \boldsymbol{s_n})}{\mathrm{G} \sum_{\mathrm{n}} \mathrm{w_n}} \tag{8}$$

여기에 엔트로피 정칙화를 더한 총손실을 최소화하며, 기울기 노름을 클립한 뒤 갱신한다.

그룹 상대 이득은 후보들이 갈릴 때만 신호를 주므로, 학습에 앞서 휴리스틱 픽셀 중심의 폭 좁은 가우시안을 목표로 한 행동 복제로 정책을 부팅한다. 옵티마이저는 Adam 이며, 학습률은 10^{-4} 에서 그 5% 까지 단일 주기 코사인 어닐링으로, 엔트로피 계수는 0.01 에서 그 10% 까지 선형으로, 총 800 업데이트의 같은 예산 축 위에서 함께 줄인다. 병렬 전장은 24개, 그룹 크기는 휴리스틱 후보를 포함해 $G=8$, 행동 복제는 300 갱신이다.

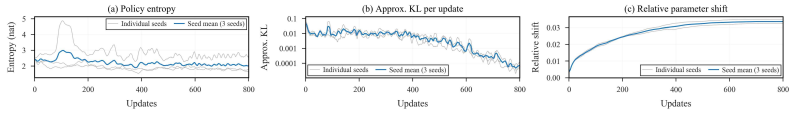


Fig. 8 Training progress (grey: individual seeds, blue: seed mean): (a) policy entropy, (b) approximate KL divergence, (c) parameter shift from the behaviour-cloning initialization

같은 설정을 시드 3개로 반복해 학습 경과를 기록하였다(Fig. 8). 갱신 전후 정책 사이의 근사 KL은 처음 100 업데이트 평균 1.4×10^{-2} 에서 마지막 100 업데이트 1.5×10^{-4} 로 두 자릿수 줄고, 파라미터 이동은 후반에 포화하며, 정책 엔트로피는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하다. 학습이 끝난 800 업데이트에서 세 시드의 greedy 포획률은 모두 휴리스틱 기준선 0.749 를 넘는다.

4.5.2 보상 설계

한 후보의 창 보상은 결정 시점부터 H step 동안의 팀 공유 보상으로, 이벤트 항 R_{event}, 창의 시작·끝 상태에서 잰 퍼텐셜 Φ 의 할인($\gamma=0.99$) 차분, 조밀 항 R_{dense} 로 구성된다.

$$R = R_{\text{event}} + [\gamma\Phi(\mathbf{s_{t+H}}) - \Phi(\mathbf{s_t})] + \mathrm{R}_{\text{dense}} \tag{9}$$

이벤트 항은 포획(+13.5)·돌파(−8)·충돌(−30)·그물 접촉(−13) 건수의 가중합이고, 퍼텐셜은 생존 적선의 모선 근접도 합의 음수라 할인 차분 형태로 최적 정책을 보존한다 [17]. 조밀 항은 이동거리·그물 소모·선회량·목표점 변경·근접도를 벌하고 그물의 접근로 차단 비율을 보상한다. 포획은 평가 창의 46.8%에서만 일어나므로 나머지 창에서는 퍼텐셜·차단 비율 항이 후보 순위를 가르는 주된 신호다.

4.6 언어모델 기반 전략 계층

전략 계층의 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고 출력은 무리별 배정과 대기(HOLD)다. 언어모델에는 좌표 대신 무리별 요격점까지의 이동거리·선회량, 모선 기준 방위, 설치된 그물에 의한 차단 여부처럼 기하량을 미리 계산한 상태를 텍스트로 주고, 출력은 판단 근거·무리별 담당 방어정·대기 방어정의 세 필드로 된 JSON 형식으로 강제한다 [16]. 이 형식은 디코딩 단계에서 문법으로 작용해 파싱 실패로 그 주기의 배정을 잃는 일을 막는다. 언어모델이 정하는 것은 배정뿐이고 그물 전개·벽의 방위·요격점 기하는 기동 계층이 정하며, 배정이 바뀌면 요격점과 유효 마스크도 함께 바뀌므로 배정은 기동의 선행 조건이다.

5. 실험 설계

두 계층의 기여를 분리하기 위해 배정 축과 기동 축을 각각 이분한 2×2 조건 행렬을 두고, 시드 대응 차이로 판정한다.

5.1 환경과 학습 실행

지휘관으로는 능력 수준이 다른 소형 Qwen2.5 7B, 중형 Qwen2.5 14B, 상위 Gemini 3.5 Flash-Lite 를 온도 0, 같은 프롬프트와 구조적 출력으로 매 결정마다 호출한다. 시뮬레이터는 질점 운동학, 규칙 기반의 적, 잡음 없는 완전 관측이라 포획률은 상한이며 조건 간 상대 비교로만 판정한다. 학습과 통계 비교는 이 시뮬레이터에서 하고, 학습된 정책은 선체 거동과 충돌을 물리 엔진으로 다루는 언리얼 엔진 환경(Fig. 9)에서 검증한다.



Fig. 9 Qualitative verification in the Unreal Engine–based simulator

학습은 한 해안선 형상에 과적합하지 않도록 실해역 6곳(Fig. 10)을 에피소드마다 돌려가며 진행하고, 평가는 그중 통영 매물도 서측에서 한다. 총 800 업데이트 동안 주기적 greedy 평가의 최고점 가중치(600 업데이트)를 채택하였다.

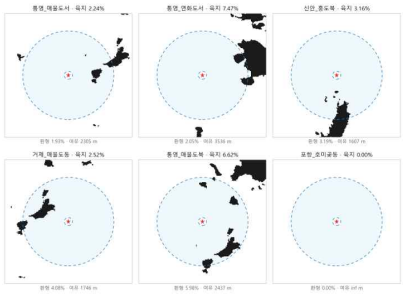


Fig. 10 Six training sites (star: mothership, dashed circle: intercept annulus)

5.2 조건, 판정 기준, 계측

Table 3 2×2 condition matrix (only two switches differ between conditions)

Condition	Assignment × maneuver	What it measures
heur_heur	Heuristic × heuristic	Baseline
heur_unet	Heuristic × U-Net	Pure contribution of the maneuver layer (no LLM)
llm_heur	LLM × heuristic	Pure contribution of the strategic layer
llm_unet	LLM × U-Net	Proposed system (incl. interaction)

휴리스틱 배정과 기동은 4.3절의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직접 비교 가능하다(Table 3). 전략 계층에 세 모델을 두고 모든 조건이 같은 시드 집합과 세 포메이션을 공유하도록 하여 720 에피소드를 수집하였다.

조건과 기준선의 시드 k 지표값을 x_k, y_k, 시드 수를 n_s, 대응 차이 d_k 의 표준편차를 s_d 라 하면 차이의 평균과 효과크기는

$$d_k = x_k - y_k, \qquad \bar{d} = \frac{1}{n_s}\sum_k d_k, \qquad d_z = \frac{\bar{d}}{s_d} \tag{10}$$

이며, 95 % 신뢰구간은 BCa 부트스트랩 [18]($B = 9999$)으로 구하고 지표 9개의 다중비교에는 Bonferroni 보정 구간(99.4 %)을 병기한다. 상호작용은 배정 축(H 휴리스틱, L 언어모델)과 기동 축(H

휴리스틱, U U-Net)의 조건별 지표값 x_k^{am} 에서

$$\mathrm{Int_k} = (\mathrm{x_k^{LU}} - \mathrm{x_k^{LH}}) - (\mathrm{x_k^{HU}} - \mathrm{x_k^{HH}}) \tag{11}$$

로 같은 절차를 거쳐 판정한다(>0 상승, ≈ 0 가산, <0 상쇄).

지휘관 계층은 포획률만으로 기여가 가려지므로 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지(활성 무리 중 배정된 비율), churn(재계획 간 담당을 바꾼 방어정 비율), 교차 배정을 따로 계측한다.

6. 결 과

6.1 기동 계층의 기여

6.1.1 휴리스틱 대 점수맵 정책

배정을 휴리스틱으로 고정하고 기동 방식만 비교하면(Table 4) 포획률은 0.844→0.886($d_z = 0.37$)으로 95% 수준에서 유의하나 다중비교 보정에서는 유의성을 잃는다. 기동 계층이 바꾸는 것은 포획률이 아니라 자원과 기동이다.

Table 4 Stand-alone contribution of the maneuver layer (U-Net score map + GRPO)

Formation	Heuristic maneuver	U-Net maneuver	Δ [95 % CI]	d_z
Concentrated	0.997	0.997	+0.000 [−0.010, +0.010]	+0.00
Diversionary	0.787	0.753	−0.033 [−0.077, +0.000]	−0.31
Wave	0.750	0.907	+0.157 [+0.043, +0.270]*	+0.48
Overall	0.844	0.886	+0.041 [+0.003, +0.082]*	+0.37

* The confidence interval excludes 0. The overall row pools the three formations.

9개 지표 전부로 넓혀도 U-Net 이 휴리스틱보다 불리한 축은 포획당 이동거리 하나로, 자리를 골라 그물을 놓는 대신 더 멀리 움직이기 때문이다.

포메이션별로 보면 기여가 고르지 않다. 파상에서 $+0.157$($d_z = 0.48$)로 가장 크고, 집중에서는 0.000, 양동에서는 -0.033 으로 오히려 소폭 낮다(유의하지 않아 악화로 읽지는 않는다). 파상에서는 앞 단을 막은 그물의 위치가 뒤 단의 차단을 좌우해 해면 전체를 평가하는 점수맵이 직접 효과를 내고, 양동에서는 결정적인 것이 배정이며, 집중은 휴리스틱만으로 포획률 0.997에 도달해 개선 여지가 없다.

6.1.2 갱신 규칙: 그룹 상대 최적화 대 MAPPO

같은 액터·행동공간·보상·예산 위에서 갱신 규칙만 MAPPO [8]로 바꾼 정책(시드 3개)은 포획률에서 GRPO 와 유의하게 갈리지 않았다(0.859 대 0.886). 갈린 것은 자원과 조기 제압으로, GRPO 는 포획당 그물을 MAPPO 의 0.733 에서 0.568 로 줄이고($d_z = -1.19$) 포획 이격거리를 0.61ℓ 늘렸으며 ($d_z = +1.21$), 두 차이 모두 다중비교 보정에서도 유의하였다.

6.2 지휘관 계층의 기여

기동 계층을 휴리스틱으로 고정해 지휘관 축만 분리하면 포획률은 모델 능력을 따라 단조로 오르되, 능력이 낮은 쪽은 휴리스틱 배정 기준선에 미치지 못하며, 개선은 양동과 파상에서 크다(Table 5, Fig.

11). 성능을 가르는 것은 배정 커버리지가 아니다(Table 6). 가장 낮은 성능의 모델이 커버리지는 가장 높았으므로 막아야 할 무리를 빠뜨려서 지는 것이 아니며, 성능과 맞물린 양은 재계획 간 담당 변경(churn)과 경로 교차였다. 재계획마다 방어정의 약 3분의 1이 담당을 바꾸면 전개하던 그물과 이동이 회수되지 않는다. 중형 모델은 응답이 간헐적으로 결정 주기를 넘기므로 전략 계층만 비동기로 떼어 둔 구조(4.1절)가 필요하다.

Table 5 Capture rate by condition (mean, 95 % CI, difference from baseline)

Commander (assignment)	Maneuver	Capture rate [95 % CI]	Δ vs baseline	d_z
Heuristic (baseline)	Heuristic	0.844 [0.808, 0.880]	-	-
Heuristic	U-Net score map	0.886 [0.847, 0.918]	+0.041 [+0.003, +0.082]*	+0.37
Qwen2.5 7B	Heuristic	0.652 [0.571, 0.716]	−0.192 [−0.264, −0.129]*	−1.00
Qwen2.5 14B	Heuristic	0.811 [0.766, 0.854]	−0.033 [−0.086, +0.017]	−0.23
Gemini 3.5 Flash-Lite	Heuristic	0.904 [0.864, 0.937]	+0.060 [+0.024, +0.100]*	+0.56
Qwen2.5 7B	U-Net score map	0.641 [0.582, 0.693]	−0.203 [−0.274, −0.138]*	−1.03
Qwen2.5 14B	U-Net score map	0.754 [0.698, 0.806]	−0.090 [−0.153, −0.033]*	−0.54
Gemini 3.5 Flash-Lite	U-Net score map	0.907 [0.869, 0.937]	+0.062 [+0.013, +0.113]*	+0.44

* The confidence interval excludes 0. d_z: paired effect size. Rows sharing a commander give the maneuver-layer contribution; rows sharing a maneuver give the commander contribution. Qwen2.5: local (RTX 4070); Gemini: cloud API.

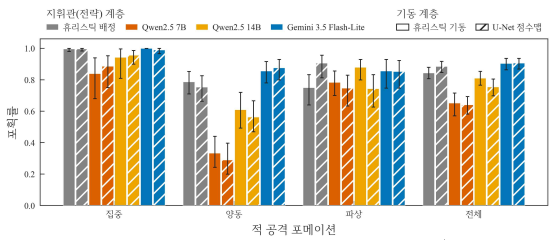


Fig. 11 Capture rate by formation and condition (error bars: 95 % CI)

Table 6 Commander plan quality and performance

Commander	Coverage ↑	churn ↓	Crossing ↓	Capture rate ↑
Qwen2.5 7B	0.934	0.324	0.152	0.652
Qwen2.5 14B	0.877	0.167	0.111	0.811
Gemini 3.5 Flash-Lite	0.881	0.098	0.033	0.904

Coverage: fraction of active clusters assigned. Churn: fraction of defenders changing assignment between replans. Crossing: fraction of crossing intercept paths. Capture rate with heuristic maneuver; fallback rate at most 0.007 for all models.

6.3 제안 체계 전체

6.3.1 두 계층의 상호작용

식 (11)의 상호작용을 9개 지표 전부에 대해 계산하였다(Table 7).

Table 7 2×2 interaction decomposition (Gemini commander)

Metric	Total effect	Interaction [95 % CI]
Capture rate	+0.062	−0.039 [−0.083, +0.012]
Collision rate (per defender)	−0.052	−0.015 [−0.070, +0.022]
Net entanglements	−0.60	+0.17 [−0.08, +0.41]
Nets per capture	−0.328	+0.004 [−0.045, +0.059]
Distance per capture (ℓ)	−0.72	−0.22 [−0.50, +0.12]
Total turning (rad)	−757	−56 [−165, +59]
Capture distance (ℓ)	+0.88	+0.15 [−0.01, +0.32]
Capture time (step)	−22	−12 [−20, −6]*
Enemy distance at deploy (ℓ)	−1.47	+0.10 [−0.17, +0.43]

Interaction = (LLM+U-Net − LLM+heuristic) − (heuristic+U-Net − baseline). * significant interaction.

9개 지표 중 8개에서 상호작용이 유의하지 않고, 다중비교 보정 후에도 그대로 8개다. 두 계층의 기여는 상승이 아니라 가산적이다. 예외인 평균 포획 시각은 두 계층이 모두 제압을 앞당겨 생기는 수확체감이다. 가산성이 두 계층을 따로 써도 된다는 뜻은 아니다. 양동에서는 기동 계층 단독(−0.033)도 전략 계층 단독(+0.070)도 유의하지 않은데 결합은 +0.090 으로 유의해진다. 무리 수와 방어정 수가 같아 배정과 기동이 둘 다 맞아야 막히기 때문이다.

6.3.2 전 지표 효과크기

제안 체계와 기준선의 차이를 9개 지표에 걸쳐 효과크기로 잰다(Table 8).

Table 8 Effect sizes for all metrics (descending $|d_z|$)

Metric	Dir.	baseline	Proposed	Δ	d_z
Total turning (rad)	↓	1625	868	−757*†	−3.23
Nets per capture	↓	0.737	0.409	−0.328*†	−2.09
Capture distance (ℓ)	↑	6.00	6.88	+0.88*†	+1.81
Enemy distance at deploy (ℓ)	↓	5.95	4.48	−1.47*†	−1.60
Net entanglements	↓	0.82	0.22	−0.60*†	−1.19
Capture time (step)	↓	430	408	−22*†	−1.04
Distance per capture (ℓ)	↓	3.27	2.55	−0.72*†	−0.65
Collision rate (per defender)	↓	0.130	0.078	−0.052*†	−0.52
Capture rate	↑	0.844	0.907	+0.062*	+0.44

↑ higher is better, ↓ lower is better. * 95 % CI excludes 0. † Also excludes 0 under Bonferroni correction for 9 metrics.

개선은 기동 비용과 자원 효율에 몰려 있다. 총 선회량은 47 % 줄어 $d_z = -3.23$, 포획당 그물은 45 % 줄어 −2.09, 포획 이격거리는 0.88ℓ 늘어 +1.81 인 반면 포획률은 $d_z = 0.44$ 로 최하위권이며, 다중비교 보정에서는 포획률만 유의성을 잃는다.

7. 고찰 및 결론

7.1 결과의 해석

두 계층의 기여가 가산적이라는 것(6.3절)은 지휘관 모델 교체와 기동 정책 재학습을 서로 기다리지 않고 진행할 수 있다는 운용상의 자유를 뜻한다. 지휘관의 성능을 설명한 것이 커버리지가 아니라 계획

안정성이라는 관찰(6.2절)은 주기적으로 재계획하는 계층 구조 일반에 해당한다. 상위 결정의 변경은 하위 계층에 회수되지 않는 이동과 그물을 남기므로, 매 호출이 독립적인 언어모델을 계획 계층에 둘 때는 계획 품질을 시간에 걸친 일관성으로 평가하고 상태 표현이 그 일관성을 지원해야 한다. 가장 큰 개선이 총 선회량에서 나타난 것은 경유점이 격자에 고정되고 유효 마스크가 무의미한 위치를 배제하기 때문이며, 유효 셀 안에서 점수맵은 거의 단봉이므로 이득은 분포의 다봉성이 아니라 마스크와 격자 양자화에서 온다.

7.2 한계와 향후 과제

검증은 시뮬레이션에 한정되며 그물 거동·얽힘 판정·관측이 단순화되어 있다. 관측 불확실성은 배정이 딛고 선 무리 구성을 흔들므로 지휘관 계층에 더 크게 작용할 것이다. 규모가 적 10척 대 방어정 3척으로 고정이고 적이 규칙 기반이라, 배정 조합이 급증하는 규모와 그물 배치를 학습해 회피하는 적응적 적은 범위 밖이며, 연속 행동공간 기준선과 구성요소별 절제도 과제로 남는다.

7.3 결론

적보다 느린 방어정으로 자폭 군집을 막는 2계층 체계를 제안하고, 시드 대응 2×2 설계의 720 에피소드로 두 계층의 기여를 분리 측정하였다. 제안 체계는 같은 방어 수준에서 자원과 기동 비용을 크게 줄였으며, 두 계층의 기여는 가산적이었고, 언어모델 지휘관의 이득은 능력 임계 위에서만 나타났다. 실해역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.

사 사

본 연구는 2025년 정부(방위사업청)의 재원으로 국방과학연구소의 지원을 받아 수행된 미래도전국방기술 연구개발사업임 (No.915141301)

참고문헌

[1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., “Exact and Heuristic Algorithms for the Weapon-Target Assignment Problem”, *Operations Research*, Vol.55-6, (2007), p.1136-1146.

[2] Wang, J., Liu, Y. and Song, H., “Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends”, *IEEE Aerospace and Electronic Systems Magazine*, Vol.36-3, (2021), p.4-29.

[3] Sutea, V., *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*, Atlantic Council UkraineAlert, 24 February 2026 (2026).

[4] Rumbaugh, W., *Cost and Value in Air and Missile Defense Intercepts*, Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024, Washington, DC (2024).

[5] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., “Multi-USV cooperative target encirclement through learning-based distributed transferable policy and experimental validation”, *Ocean Engineering*, Vol.318, (2025), No.120124.

[6] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., “QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning”, *International Conference on Machine Learning (ICML)*, (2018), p.4295-4304.

[7] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., “Counterfactual Multi-Agent Policy Gradients”, *AAAI Conference on Artificial Intelligence*, (2018), p.2974-2982.

[8] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., “The Surprising Effecti veness of PPO in Cooperative Multi-Agent Games”, *Advances in Neural Information Processin g Systems 35 (NeurIPS)*, (2022).

[9] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. and Guo, D., “DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Mo dels”, *arXiv preprint arXiv:2402.03300*, (2024).

[10] Ronneberger, O., Fischer, P. and Brox, T., “U-Net: Convolutional Networks for Biomedical Imag e Segmentation”, *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, (2 015), p.234-241.

[11] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., “FiLM: Visual Reasoning with a General Conditioning Layer”, *AAAI Conference on Artificial Intelligence*, (2018), p.3942-3951.

[12] Vinyals, O., Fortunato, M. and Jaitly, N., “Pointer Networks”, *Advances in Neural Information Processing Systems 28 (NeurIPS)*, (2015).

[13] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł. and Polos ukhin, I., “Attention Is All You Need”, *Advances in Neural Information Processing Systems 30 (NeurIPS)*, (2017).

[14] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., “Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents”, *International Conference on Machine L earning (ICML)*, (2022), p.9118-9147.

[15] Ahn, M., Brohan, A., Brown, N., et al., “Do As I Can, Not As I Say: Grounding Language in R obotic Affordances”, *Conference on Robot Learning (CoRL)*, (2022).

[16] OpenAI, *Function calling*, [Online] Available at: https://developers.openai.com/api/docs/guides/fun ction-calling [Accessed 9 August 2026] (2026).

[17] Ng, A.Y., Harada, D. and Russell, S., “Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping”, *International Conference on Machine Learning (ICML)*, (1 999), p.278-287.

[18] Efron, B. and Tibshirani, R.J., *An Introduction to the Bootstrap*, Chapman & Hall, New York (1 993).