# 군집 자폭 수상 드론 방어를 위한 LLM 기반 지휘체계와 U-Net 점수맵 기반 다중 에이전트 협력 강화학습

# LLM-Based Command Architecture and U-Net Score-Map Multi-Agent Cooperative Reinforcement Learning for Defense Against Suicide USV Swarms

윤 영 준[*1], 방 현 태[*1], 전 유 라[*2], 김 덕 환[*2], 윤 원 근[*1]

([이메일 주소 기입 필요])

Swarms of low-cost suicide unmanned surface vehicles (USVs) evade conventional counters: electronic warfare cannot reach wire-guided targets, and interceptors cost more than their targets and saturate. We propose a two-layer defence architecture in which a few defenders, slower than the attackers, pre-emptively block the mothership's approach corridors with net walls. In the strategic layer a large language model (LLM) commander assigns each defender an enemy cluster; in the maneuver layer each defender points at a pixel of a score map that a U-Net produces over a rasterized battlefield grid to place its net wall. Both layers decide on the same period but differ sharply in response latency, so only the slow strategic layer is decoupled asynchronously. Pixel pointing confines the action space to the grid, imposes safety and mission constraints by masking and is invariant to swarm size, and training extends critic-free group-relative policy optimization to multiple agents. From 720 seed-paired episodes (8 conditions, 3 formations, 30 seeds) we separated the contributions of the two layers in a 2x2 design. The maneuver layer alone raised the capture rate from 0.844 to 0.886, and the full system cut nets per capture by 45 % and total turning by 47 % at the same defense level; the two contributions were additive rather than synergistic. The commander paid off only for models above a capability threshold, and its performance was explained not by assignment coverage but by plan stability across replans. In periodically replanning architectures, consistency over time matters more than local optimality.

**Key Words**: 무인수상정(Unmanned Surface Vehicle), 군집 방어(Swarm Defense), 다중 에이전트 강화학습(Multi-Agent Reinforcement Learning), 임무배정(Task Assignment), 대규모 언어모델(Large Language Model), 의미론적 분할(Semantic Segmentation), 그룹 상대 정책 최적화(Group Relative Policy Optimization)

## 1. 서 론

*1 충남대학교
*2 한국과학기술원

다수의 저비용 무인수상정(USV)이 고가치 함정을 향해 여러 방향에서 동시에 돌진하는 자폭 공격은 비대칭 위협의 전형이다. 유한한 방어 자산의 배분은 무기-표적 할당 문제로 오래 연구되었으나 [1], 표적 수가 요격 자산을 넘어서면 최적 할당으로도 남는 표적이 생긴다. 교란에 의한 연성 대응(soft-kill)은 위협을 제거하지 못하고 유선 조종 표적에 무력하며 [2, 3], 직접 타격하는 경성 대응(hard-kill)은 값싼 표적에 고가 유도탄을 쓰는 비용 구조 [4]와 표적 수에 따른 포화를 피하지 못한다.

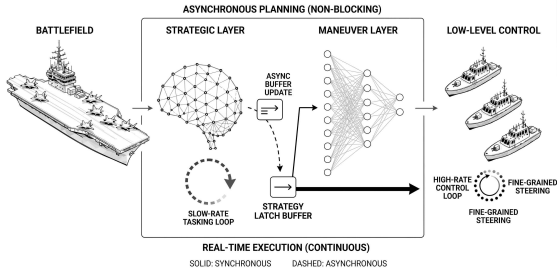



**Fig. 1** Two-layer architecture of the proposed system

본 연구는 저비용 그물에 의한 물리적 포획을 택한다 [2]. 이 방식은 통신 방식과 무관하게 표적을 정지시킨다. 방어정은 적선보다 느려 추격할 수 없으므로, 적선이 지나갈 접근 회랑을 앞질러 그물벽으로 차단한다.

이 문제는 성격이 다른 두 판단을 요구한다. 하나는 어느 방어정이 어느 적 무리를 맡는가라는 이산적 배정이고, 다른 하나는 맡은 무리를 해면 어디에서 막는가라는 연속적 기동이다. 둘은 같은 주기로 갱신되지만 산출에 걸리는 시간이 크게 다르다. 본 연구는 느린 배정을 언어모델 지휘관에게, 빠른 기동을 학습된 정책에 맡기고 느린 계층만 비동기로 분리한다(Fig. 1).

학습과 평가는 OpenStreetMap 해안선을 래스터화한 실해역 지형에서 수행한다. 관측은 모선 중심 격자의 다채널 영상이고, 행동은 그 격자의 유효 픽셀 하나를 고르는 것이라 불가능한 자리가 애초에 뽑히지 않는다. 출력은 제어 신호가 아니라 경유점이라 저수준 추종과 분리된다(4절). 각 계층이 무엇을 얼마나 개선하는지는 시드 대응 2×2 설계로 분리해 측정한다 (5절).

## 2. 관련 연구

### 2.1 자산 배분과 무인 위협 대응

방어 자산을 표적에 배분하는 문제는 무기-표적 할당(WTA)으로 정식화되어 정확해법과 휴리스틱이 모두 연구되었고 [1], 1:1 배정으로 축소하면 헝가리안 알고리즘 [5]으로 최소비용 매칭을 얻는다. 다만 이전 결정이 이미 막은 회랑과 남은 자산에 따라 달라지는 판단은 고정된 거리·각도 비용으로 표현되지 않는다. 본 연구는 배정 계층에 조합 최적화 대신 언어모델의 판단을 둔다.

무인 위협의 무력화 수단은 연성(전자전)·경성(물리 타격)·포획으로 구분되는데 [2], 유선 조종 표적의 확산 [3]이 연성의 범위를, 요격 비용의 비대칭 [4]이 경성의 지속성을 제약하면서 포획이 남는다. 해상에서는 다중 USV 협력 기동 [6]과 강화학습 협조 포위 [7]가 보고되었으나 포위는 방어정이 표적보다 빠르거나 대등함을 전제하므로, 더 느린 조건에서는 추격 대신 접근 경로의 선제 차단이 남는다.

### 2.2 다중 에이전트 강화학습과 크레딧 배분

중앙 집중 학습·분산 실행(CTDE) 계열은 팀 보상에서 개체별 기여를 분리하려고 가치망을 학습하며,

중앙 비평가 [8], 단조 가치 분해 [9], 반사실적 기준선 [10], PPO [12]의 다중 에이전트 확장 [11]이 그 예다. 그러나 공유 가치망의 추정 편향과 학습 불안정 [13]은 여러 에이전트가 함께 학습하는 비정상 환경에서 더 커진다. 그룹 상대 정책 최적화(GRPO) [14]는 같은 상태에서 뽑은 여러 후보의 보상을 서로 비교해 이득을 산정함으로써 가치망 자체를 없앤다. 본 연구는 GRPO를 다중 에이전트 제어로 옮기되, 후보 하나를 기하 휴리스틱으로 고정해 기준선으로 삼고 후보의 팀 보상을 비평가가 아니라 시뮬레이터 재진행으로 얻는다. 다중 에이전트 근위 정책 최적화(MAPPO)는 같은 픽셀 행동공간 위의 기준선으로 두어 표현과 갱신 규칙의 기여를 분리한다(6.1.2절).

### 2.3 격자 표현·픽셀 지목과 언어모델 계획

모든 픽셀에 값을 매기는 조밀 예측 계열 [15, 16]과 그 확장인 좌표 채널 [17]·조건 변조 [18]는 모두 상황 지각에 쓰였고, 후보마다 점수를 매겨 하나를 지목하는 출력 [19, 20]은 주로 조합 최적화에 머물렀다. 본 연구는 둘을 잇는다. U-Net 특징 지도의 각 픽셀에 방어정별 질의로 점수를 매기고(4.4절), 그 점수맵을 정책의 행동 분포로 삼아 픽셀 하나를 지목하는 것이 곧 행동이므로, 안전 제약을 마스크로 행동 분포에 직접 부과할 수 있다.

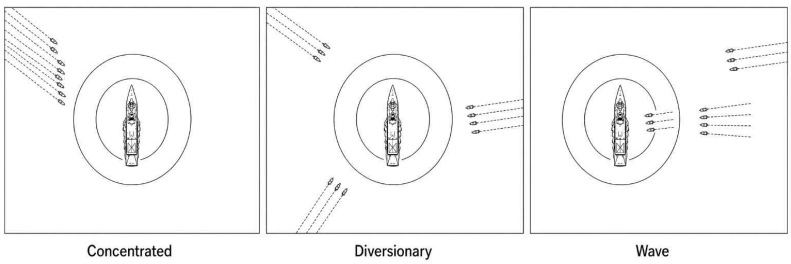



**Fig. 2** Three attack formations: concentrated, diversionary and wave (left to right)

언어모델을 계획 주체로 쓰는 연구는 고수준 지시를 실행 가능한 단계로 분해하고 [21], 실행 가능성 추정을 결합해 불가능한 계획을 걸러내며 [22], 구조적 출력 [23]으로 하위 시스템이 파싱 가능한 형태를 보장한다. 본 연구도 판단을 실행 가능성으로 거르되, 언어모델에는 배정만 맡기고 실행 가능성은 기동 계층의 유효 마스크가 픽셀 수준에서 강제한다(4.4.3절).

## 3. 문제 정의와 평가 지표

### 3.1 교전 시나리오

**Table 1** Engagement scenario and observation settings

| Item | Value |
|---|---|
| Number of attacking USVs $M$ | 10 |
| Number of defenders $P$ | 3 |
| Maximum number of clusters $C$ | 4 |
| Side length of the engagement area | 12.6 km |
| Attacker speed $v_e$ | 9.0 m/s |
| Defender speed $v_a$ (speed ratio $v_e/v_a = 1.5$) | 6.0 m/s |
| Decision period | 25 s |
| Observation grid $n_g \times n_g$ (centred on mothership) | $50 \times 50$ |
| Observation pixel size $\ell$ | 252 m |
| Nets per defender (training / evaluation) | 1 / 3 |
| Number of policy parameters | 244,389 |

**Table 2** Ten evaluation metrics

| Aspect | Metric | Dir. | Definition | Meaning |
|---|---|---|---|---|
| Defense outcome | Capture rate | ↑ | $\mathrm{CR} = \mathrm{N}_{\mathrm{cap}}/(\mathrm{N}_{\mathrm{cap}} + \mathrm{N}_{\mathrm{br}}$ | Fraction of resolved attackers that were captured |
| | Breaches | ↓ | $N_{\mathrm{brc}}$ | Number of attackers that reached the mothership |
| Safety | Collision rate | ↓ | $N_{\mathrm{col}}/\mathrm{P}$ | Defender–defender and defender–mothership collisions per defender |
| | Net entanglements | ↓ | $N_{\mathrm{tng}}$ | Times a defender was caught in a deployed net |
| Resource efficiency | Nets per capture | ↓ | $N_{\mathrm{net}}/\mathrm{N}_{\mathrm{cap}}$ | Nets consumed per captured attacker |
| | Distance per capture | ↓ | $\sum_{p=1}^{P} D_p / N_{\mathrm{cap}}$ | Total team travel per captured attacker |
| Maneuver cost | Total turning | ↓ | $\sum_{p=1}^{P} \sum_{t} \lvert \Delta\psi_{p,t} \rvert$ | Accumulated heading change (trajectory smoothness) |
| Engagement quality | Capture distance | ↑ | $\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \lVert \mathbf{z_k} - \mathbf{m} \rVert$ | Distance of capture points from the mothership (early defeat in space) |
| | Capture time | ↓ | $\frac{1}{N_{\mathrm{cap}}} \sum_{\mathrm{k}} \mathrm{t_k}$ | Time at which captures occur (early defeat in time) |
| | Enemy distance at deploy | ↓ | $\frac{1}{N_{\mathrm{net}}} \sum_{\mathrm{d}} \min_{m \in A} \lVert \boldsymbol{a_d} -$ | Distance to the nearest attacker when net deployment starts |

교전 해역 중앙에 고가치 모선 한 척이 있고, 가장자리에서 적 USV $M$척이 모선을 향해 돌진한다. 적은 집중·양동·파상의 세 공격 포메이션 가운데 하나를 취한다(Fig. 2). 방어정 $P$척은 각각 한정된 수의 그물벽을 전개할 수 있다. 체계는 스케일 불변이므로 아래는 한 기준 인스턴스다. 교전 해역은 한 변 12.6 km 의 정사각 해역이고, 적선은 9.0 m/s, 방어정은 6.0 m/s 로 적이 1.5배 빠르며, 두 계층 모두 25 s 마다 결정한다 (Table 1). 관측·행동·보상은 모두 관측 픽셀 한 변 $\ell = 252$ m 로 정규화한다(4.4.1절).

방어정은 적이 지나갈 자리를 미리 선점해야 한다. 그물벽은 두 좌표를 잇는 선분이고, 방어정이 그 선분을 따라 이동하면서 후미의 전개 장치로 부유식 그물을 해면에 풀어 놓는다. 그 위를 지나는 적 USV가 추진을 잃는 것을 포획으로 본다(Fig. 3). 전개된 그물은 해면에 고정되지 않아 시간이 지날수록 차단 효과가 줄고, 미리 전개하면 적에게 노출되어 회피의 여지를 준다. 그물벽을 적의 도달 직전, 적에

가까운 위치에 두는 것이 유리하다고 가정한다.

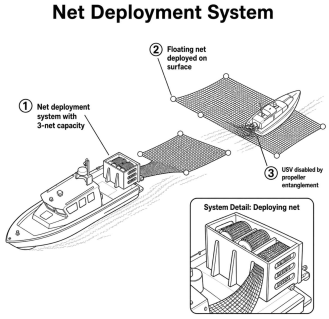



**Fig. 3** Capture concept of the stern-launched floating net

○ 집중(concentrated): 적 전 병력이 한 방위에서 동시에 접근한다. 차단할 접근로가 하나라 소수의 방어정으로도 대응된다.

○ 양동(diversionary): 적이 세 방위로 나뉘어 동시에 접근한다. 가용 방어정을 모두 투입해야 하므로 어느 배가 어느 무리를 맡는 배정이 결과를 좌우한다.

○ 파상(wave): 적이 3개 단(rank)으로 나뉘어 방위를 조금씩 달리하며 거리차를 두고 순차 도달한다. 앞 단에 쓴 그물벽은 그 자리에 남고 보유량은 한정되므로, 그물벽을 어느 자리에 놓아 여러 단을 겸해 막을지가 관건이다.

### 3.2 평가 지표

방어 성과는 다섯 관점의 10개 지표로 에피소드마다 잰다(Table 2). 자원 효율은 교전하지 않은 조건이 가장 효율적으로 보이는 것을 막기 위해 총량이 아니라 포획당 비율로 두었고, 교전 품질은 거리축과 시간축으로 나누어 모선에서 먼 포획과 이른 포획을 함께 본다.

## 4. 제안 방법

### 4.1 2계층 비동기 구조

제안 체계는 방어 판단을 전략 계층과 기동 계층으로 분리한다(Fig. 1). 전략 계층은 어느 방어정이 어느 적 무리를 맡는가를 정하고, 기동 계층은 배정된 무리를 막기 위해 해면 어디에 그물벽을 놓는가를 정한다. 두 계층은 같은 주기로 결정을 내리지만 응답 속도가 다르다. 기동 계층의 순전파는 순간에 끝나는 반면, 전략 계층의 언어모델 호출은 응답에 지연이 발생한다(6.2절). 느린 전략 계층 호출만 비동기로 분리하여, 호출이 진행되는 동안 기동 계층은 직전 배정으로 결정을 계속하고 응답이 도착하면 다음 결정부터 새 배정을 반영한다.

### 4.2 적 무리 군집화

두 판단 계층은 개별 적선이 아니라 무리를 단위로 배정하므로, 매 결정마다 생존 적선을 모선 기준 방위 $\vartheta_m$ 으로 묶어 최대 $C$ 개의 무리로 요약한다(Fig. 4). 방위 구간을 고정해 나누면 무리가 경계에 걸려 쪼개지므로, 정렬한 방위의 이웃 간격 $g_{(q)}$ 로 무리 수를 데이터에 맞춘다. 방위는 순환값이라 간격도 순환으로 센다. 임계 $\delta_{\mathrm{gap}}$ 을 넘는 간격의 개수가 활성 무리 수 $\hat{C}$ 이며, 1 이상 $\min(C,n)$ 이하로 자른다.

$$\hat{C} = \mathrm{clip}(|\{\, q : g_{(q)} > \delta_{\mathrm{gap}} \}|,\ 1,\ \min(C, n)) \tag{1}$$

가장 큰 간격 $\hat{C}$ 개를 경계로 삼아 방위 순으로 라벨을 붙여 무리별 구성원을 정하고, 각 무리를 척수 $n_j$, 중심 $\boldsymbol{c_j}$, 각도 퍼짐 $\Delta\vartheta_j$, 모선 방향 접근 속도 $v_j^{\mathrm{app}}$ 의 네 양으로 요약한다.

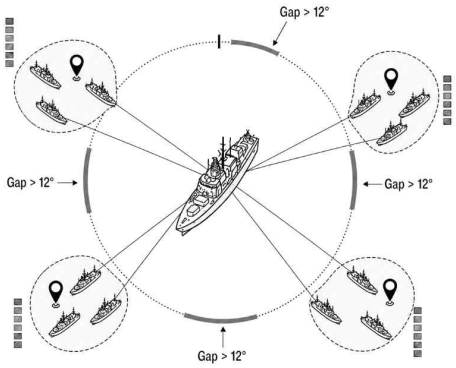



**Fig. 4** Bearing sorting, clustering and cluster assignment

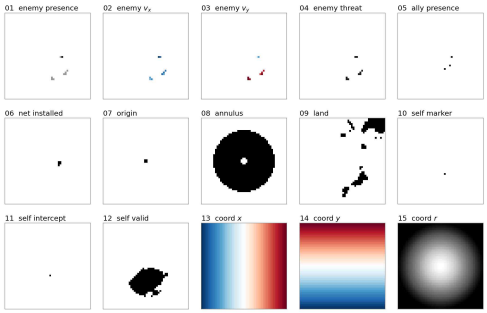



**Fig. 5** Example of the rasterized 15-channel observation (wave formation, north of Maemuldo, Tongyeong)

이 규칙에서 집중은 무리 하나, 양동은 셋, 파상은 대개 단마다 하나로 요약된다. 척수와 중심은 4.3절의 위협도와 요격점을, 네 요약량 전부는 4.6절의 지휘관 입력을 구성한다.

### 4.3 기하 휴리스틱 기준 방법

무리 요약 위에서 같은 문제를 기하 규칙만으로 푸는 기준 방법으로, 6절의 비교 기준이자 4.5.1절의 행동 복제 목표다. 무리 $j$ 의 위협도 $\tau_j$ 는 척수 $n_j$ 에 모선 근접도를 곱한 양이고, 요격점 $\boldsymbol{I_j}$ 는 무리 중심에서 모선을 향해 선분의 $\lambda_{\mathrm{I}}$ 비율만큼 옮긴 점이다.

$$\tau_j = n_j \cdot \mathrm{clip}\left(1 - \frac{\|\mathbf{c_j} - \mathbf{m}\|}{\mathrm{R_w}}, 0.05, 1\right), \tag{2}$$
$$\boldsymbol{I_j} = \boldsymbol{c_j} + \lambda_{\mathrm{I}}(\mathbf{m} - \mathbf{c_j}), \qquad \lambda_{\mathrm{I}} = 0.55$$

하한은 먼 무리도 척수에 비례하는 최소 위협을 갖게 한다. 방어정이 적보다 느려 무리 중심 가까이 잡은 요격점에는 적보다 늦게 도달하므로, 요격점은 모선 쪽으로 치우쳐 둔다.

위협 상위 $P$ 개 무리에 대해 탐욕적 1:1 배정을 한다. 비용은 방어정 위치 $\boldsymbol{a_p}$ 에서 요격점까지의 거리 $d_{pj}$ 에서, 직전 결정의 담당 $j_p^{\text{prev}}$ 를 유지하는 쌍에만 보너스 $\beta$ 를 감한 값이다. $\beta$ 는 해역 규모에 맞먹는 크기로 두어, 거리 차이가 그만큼 벌어지기 전에는 직전 배정이 유지되게 한다.

$$\widetilde{d_{pj}} = \begin{cases} d_{pj} - \beta, & j = j_p^{\text{prev}} \\ \mathrm{d_{pj}}, & \text{그 밖} \end{cases} \tag{3}$$

활성 무리가 $P$ 보다 적으면 남는 방어정은 부하가 가장 큰 무리에 안쪽 층으로 덧붙인다. 층은 반경 증분 $\lambda_{\mathrm{L}}$ 과 방위차만큼 어긋나게 둔다. 그물벽은 요격점을 가운데 둔, 접근 방향에 수직인 길이 $L_{\text{net}}$ 의 선분이므로 경유점은 그 양 끝 $K=2$ 개이며, 학습 정책과 같은 격자·유효 마스크(4.4.3절) 위의 최근접 픽셀로 스냅한다.

따라서 두 방법의 행동공간은 같고 다른 것은 결정 규칙뿐이다.

## 4.4 점수맵 기반 기동 정책

### 4.4.1 다채널 격자 관측

기동 계층의 입력은 좌표 목록이 아니라, 모선을 중앙에 두고 관측 반폭 $E$ 의 전장을 $n_{\mathrm{g}} \times \mathrm{n_g}$ 격자로 나눈 다채널 지도이다. 총 15개 채널은 모든 방어정이 공유하는 전역 9채널, 방어정마다 다른 3채널, CoordConv [17] 좌표 3채널로 구성되며(Fig. 5), 각 채널의 정의와 값 범위를 Table 3에 정리하였다.

**Table 3** Composition of the 15-channel grid observation

| # | Group | Channel | Definition | Range |
|---|---|---|---|---|
| 1 | Global | Enemy density | Surviving attackers in the pixel $/M$ | $[0,1]$ |
| 2 | | Enemy heading $x$ | Mean heading unit vector of attackers in the pixel | $[-1,1]$ |
| 3 | | Enemy heading $y$ | Same as above | $[-1,1]$ |
| 4 | | Enemy threat | Maximum imminence of reaching the mothership in the pixel | $[0,1]$ |
| 5 | | Defender positions | Surviving defenders in the pixel $/P$ | $[0,1]$ |
| 6 | | Deployed nets | Max-pooled net occupancy of the physics grid | $\{0,1\}$ |
| 7 | | Origin | Pixels within the mothership radius | $\{0,1\}$ |
| 8 | | Intercept annulus | Pixels with $r_{\min} \leq \lVert \boldsymbol{x_i} - \boldsymbol{m} \rVert \leq r_{\max}$ | $\{0,1\}$ |
| 9 | | Land | Area fraction of the high-resolution land mask | $[0,1]$ |
| 10 | Per defender | Own position | Pixel containing defender $p$ | $\{0,1\}$ |
| 11 | | Assigned intercept point | Pixel containing $\boldsymbol{I_p}$ (all 0 if unassigned) | $\{0,1\}$ |
| 12 | | Valid region | Validity mask $V_p$, Eq. (6) | $\{0,1\}$ |
| 13 | Coordinate | $x$ | $(x_i - m_x)/E$ | $[-1,1]$ |
| 14 | | $y$ | $(y_i - m_y)/E$ | $[-1,1]$ |
| 15 | | $r$ | $\mathrm{clip}(\lVert \mathbf{x_i} - \mathbf{m} \rVert / \mathrm{E}, 0, 1)$ | $[0,1]$ |

픽셀 크기는 $\ell = 2E/n_{\mathrm{g}}$ 이고, 월드 좌표 $\boldsymbol{x}=(x,y)$ 는 모선 위치 $\boldsymbol{m}=(m_x,m_y)$ 를 중심으로 다음 픽셀 인덱스 $i=(\iota_x,\iota_y)$ 로 사상된다.

$$\iota_x = \mathrm{clip}\left( \left\lfloor \frac{\mathrm{x} - \mathrm{m_x} + \mathrm{E}}{\ell} \right\rfloor, 0, \mathrm{n_g} - 1 \right), \qquad (4)$$
$$\iota_y = \mathrm{clip}\left( \left\lfloor \frac{\mathrm{y} - \mathrm{m_y} + \mathrm{E}}{\ell} \right\rfloor, 0, \mathrm{n_g} - 1 \right)$$

적 관련 채널은 각 개체의 연속 위치를 식 (4)로 픽셀에 사상한 뒤 같은 픽셀에 속한 개체를 집계하여 값을 만든다. 밀도는 픽셀 내 적선 수를 전체 수 $M$ 으로, 진행 방향은 헤딩 단위벡터의 픽셀 내 평균으로, 위협도는 적선이 에피소드 상한 안에 달릴 수 있는 최대 거리로 모선까지 거리를 정규화해 1에서 뺀 값의 픽셀 내 최대로 둔다. 아군 위치 채널은 같은 방식으로 $P$ 로 나누고, 설치된 그물 채널은 고해상도 물리 격자의 최대값 풀링, 육지 채널은 OpenStreetMap 해안선·섬 폴리곤을 래스터화한 실해역 마스크의 면적비 다운샘플이고, 충돌 판정은 다운샘플 전 물리 격자에서 한다. 좌표 채널은 픽셀 중심의 모선 상대 위치와 거리를 반폭 $E$ 로 나눈 값이다. 격자에 담지 않는 방어정 $p$ 의 자체 상태 벡터 $\boldsymbol{o_p} \in R^8$ 는 같은 반폭으로 정규화한 자기 위치와 배정 요격점, 헤딩 단위벡터, 잔여 그물 비율, 전개 중 여부로 구성된다. 합성곱은 평행이동 등변이라 절대 위치가 흐려지므로 좌표 채널을 함께 넣어 위치를 보존한다. 모든 입력은 길이·개수·시간으로 나뉜 무차원 양이고 격자 지도는 개체 수와 순서에 불변이므로, 해역 크기·격자 해상도·선박 수가 바뀌어도 입출력의 형태가 같다.

#### 4.4.2 FiLM 조건화 U-Net과 점수맵

관측은 U-Net 구조 [16]를 지나 입력과 같은 해상도의 특징 지도로 변환된다(Fig. 6). 전역 평균 풀링으로 압축한 전황 벡터는 FiLM [18] 변조로 특징에 실려, 국소 합성곱이 옮기지 못하는 전황을 모든 위치에 전달한다.

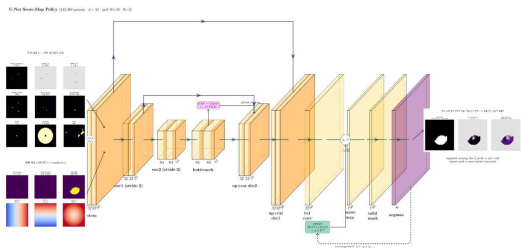


**Fig. 6** Structure of the score map policy: query–feature inner product and sub-pixel offset

각 방어정 $p$ 는 자신의 상태 벡터 $\boldsymbol{o_p}$ 로부터 MLP 로 질의 $\boldsymbol{q_p}$ 를 만들고, 아핀 사영 $\boldsymbol{W_q}$, $\boldsymbol{b_q}$ 를 거쳐 픽셀 $i$ 의 특징 $\boldsymbol{f_i}$ 와 내적하여 점수 $s_{p,i}$ 를 얻는다.

$$s_{p,i} = \frac{\langle \boldsymbol{W_q} \boldsymbol{q_p} + \boldsymbol{b_q}, \boldsymbol{f_i} \rangle}{\sqrt{d}}, \qquad d = 32 \qquad (5)$$

어텐션 [20]과 같은 형식의 점수로 격자 위의 원소를 지목하는 포인터 구조다 [19]. 관측 텐서는 방어정을 묶어 결정마다 한 번의 순전파로 통과하며, 가중치는 모두가 공유하므로 모델 크기는 방어정 수에 불변이다. 합성곱 블록의 그룹 정규화 [24]는 배치 통계를 쓰지 않아 묶음 크기와 무관하게 같은 연산이다.

#### 4.4.3 유효 마스크와 픽셀 지목

점수맵 전체가 후보가 되는 것은 아니다. 육지 픽셀 집합을 $L_{\mathrm{land}}$, 모선에서 본 요격점 방위와 픽셀 방위의 차이를 $[0^\circ, 180^\circ]$ 로 접은 값을 $|\vartheta_i - \vartheta_p|$。라 하면, 방어정 $p$ 의 유효 픽셀 집합 $V_p$ 는 환상 요격

구역, 육지 밖, 요격점 반경, 무리 방위라는 네 조건의 교집합이다(설정값은 Table 4).

$$V_p = \{\, i :\ r_{\min} \le \|\boldsymbol{x}_i - \boldsymbol{m}\| \le r_{\max},\ i \notin L_{\text{land}},\ \|\boldsymbol{x}_i - \boldsymbol{I}_p\| \le r_g,\ |\vartheta_i - \vartheta_p|_\circ \le \vartheta_g \} \tag{6}$$

마스크는 로짓 단계에서 적용한다. 유효 집합 밖의 점수를 $-\infty$ 로 바꾼 마스크 점수 $\widetilde{s}_{p,i}$ 를 소프트맥스에 넣어 픽셀 선택 확률을 얻는다.

$$\widetilde{s}_{p,i} = \begin{cases} s_{p,i}, & i \in V_p \\ -\infty, & i \notin V_p, \end{cases} \qquad \pi_\theta(i|\boldsymbol{s}, p) = \frac{e^{\widetilde{s}_{p,i}}}{\sum_{j \in V_p} e^{\widetilde{s}_{p,j}}} \tag{7}$$

안전·임무 제약이 손실 항이 아니라 행동 분포에 직접 부과되므로 위반은 애초에 표현 불가능하다. 학습된 체크포인트에서 격자 대부분은 갈 수 없는 자리로 남으며(Fig. 7), 연속 좌표 회귀에는 이 구조를 표현할 수단이 없다. 범주형 표본은 유효 영역을 벗어나지 않고 엔트로피가 유한하므로 4.5절의 그룹 후보들이 실제로 서로 다른 칸을 밟는다.

**Table 4** Settings of the validity mask and pixel pointing

| Category | Symbol / item | Value |
|---|---|---|
| Valid pixel conditions | Inner and outer radii of the intercept annulus $r_{\min}$, $r_{\max}$ | $1.6\ell$ / $18\ell$ |
| | Range gate around the intercept point $r_g$ | $12\ell$ |
| | Bearing gate of the cluster $\vartheta_g$ | $60^\circ$ |
| | Minimum number of valid pixels | 150 cells |
| Pixel pointing | Waypoints per defender $K$ | 2 |
| | Minimum spacing of the two points $r_{\text{dup}}$ | $0.8\ell$ |
| | Maximum spacing of the two points | $1.5L_{\text{net}}$ |
| Measured | Mean valid fraction per decision | 10.5% |

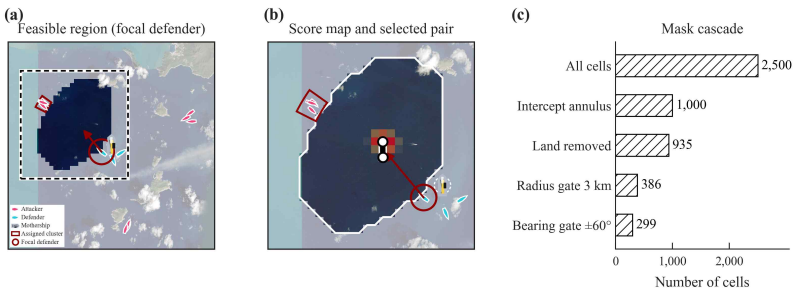



**Fig. 7** Validity mask and pixel pointing (actual output of the trained checkpoint)

각 방어정은 유효 영역 안에서 점수 상위 픽셀 $K$ 개를 순차적으로 고른다. 먼저 고른 픽셀의 특징을 질의에 더해 두 번째를 고르므로 두 점이 서로를 알고 뽑히며, 간격의 상·하한이 벽이 서지 않을 만큼 가까운 쌍과 그물 길이를 넘는 벽을 함께 배제한다. 칸 안 위치는 선택 픽셀의 특징으로부터 MLP 가 내는 평균과 학습되는 표준편차의 가우시안에서 표집해 칸의 절반 폭 $\ell/2$ 안에서 정하므로, 목표점 $\boldsymbol{t}_k$ 의 로그확률과 엔트로피는 범주형과 가우시안 두 분포의 합이다.

선택된 두 좌표를 잇는 선분이 그물벽 경로가 되며, 방어정은 가까운 점까지 이동한 뒤 다음 구간에서 그물을 전개한다. 그물이 없거나 배정되지 않은 방어정은 정지시킨다.

### 4.5 가치망 없는 다중 에이전트 그룹 상대 최적화

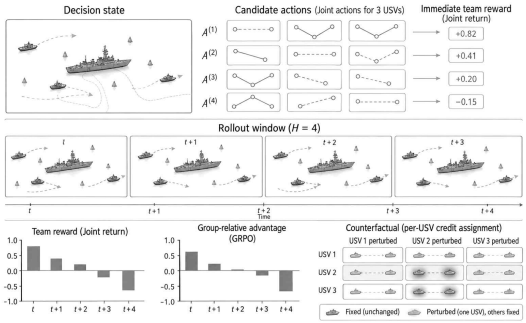



**Fig. 8** One update of group-relative optimization (illustrated with $G=4$, $H=4$)

#### 4.5.1 그룹 상대 이득

학습은 가치함수를 따로 두지 않는 그룹 상대 정책 최적화 [14]를 다중 방어정 상황에 맞게 변형하여 수행한다(Fig. 8). 매 결정 시점에서 정책으로부터 $G$개의 결합 행동 후보를 표집하되, 후보 가운데 하나($k=0$)는 휴리스틱(4.3절)이 내는 행동으로 고정하여 기준선으로 삼는다. 각 후보를 시뮬레이터에서 공통 구간 $H=180\,\mathrm{step}$ 만큼 실제로 진행시켜 창 보상 $R_k$ 를 얻은 뒤(4.5.2절), 휴리스틱 후보의 보상 $R_0$ 를 기준으로 상대 비교하여 이득 $A_k$ 를 산정한다. 그룹 표준편차로 나누되 $\epsilon$ 을 더해 0 나눗셈을 막는다.

$$A_k = \frac{\mathrm{R_k} - \mathrm{R_0}}{\mathrm{std}(\{\mathrm{R_j}\}_{\mathrm{j}=0}^{\mathrm{G}-1}) + \epsilon} \tag{8}$$

휴리스틱을 넘어서는 후보만 양의 이득을 받고, 그룹 표준편차로 나누므로 이득은 크기가 없는 순위 정보만 남는다. 어떤 선택이 더 나았는지를 실제 결과로 직접 비교하므로 가치망과 그 추정 편향·학습 불안정이 없다.

한 갱신은 $N$개의 병렬 전장(월드)에서 동시에 수행된다. 후보 보상이 모두 같은 월드는 이득이 정의되지 않으므로 유효 월드 마스크 $w_n$ 으로 갱신에서 제외한다. 월드 $n$ 의 상태를 $\boldsymbol{s_n}$, 후보 $k$ 의 이득을 $A_{n,k}$, 그 후보에서 방어정 $p$ 의 행동을 $a_{n,p}^{(k)}$ 라 하면, 정책경사 손실은 유효 월드의 모든 후보·모든 방어정에 대해 이득으로 가중한 로그확률의 음수이다.

$$L_{\mathrm{PG}}(\theta) = -\frac{\sum_{\mathrm{n}} \mathrm{w_n} \sum_{\mathrm{k}=0}^{\mathrm{G}-1} \mathrm{A_{n,k}} \sum_{\mathrm{p}=1}^{\mathrm{P}} \log \pi_\theta(a_{n,p}^{(k)} | \boldsymbol{s_n})}{\mathrm{G} \sum_{\mathrm{n}} \mathrm{w_n}} \tag{9}$$

여기에 엔트로피 정칙화를 더한 총손실을 최소화하며, 기울기 노름을 클립한 뒤 갱신한다.

그룹 상대 이득은 후보들이 갈릴 때만 신호를 주므로, 학습에 앞서 휴리스틱 행동(4.3절)을 목표로 짧은 행동 복제로 정책을 부팅한다. 목표는 원-핫이 아니라 휴리스틱 픽셀을 중심으로 한 폭 좁은 가우시안을 유효 픽셀 위에서 정규화한 가중이다. 옵티마이저는 Adam 이며, 학습률은 $10^{-4}$ 에서 그 5% 까지 단일 주기 코사인 어닐링 [26]으로, 엔트로피 계수는 0.01 에서 그 10% 까지 선형으로, 총 800 업데

이트의 같은 예산 축 위에서 함께 줄인다. 나머지 상수는 Table 7에 모았다.

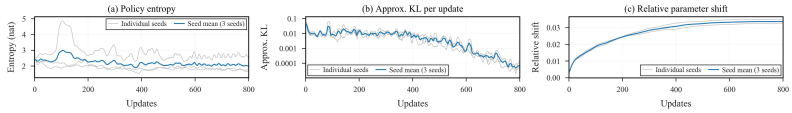



**Fig. ??** Training progress (grey: individual seeds, blue: seed mean): (a) policy entropy, (b) approximate KL divergence, (c) parameter shift from the behaviour-cloning initialization

같은 설정을 시드 3개로 반복해 학습 경과를 기록하였다(Fig. ??). 갱신 전후 정책 사이의 근사 KL은 처음 100 업데이트 평균 $1.4\times10^{-2}$ 에서 마지막 100 업데이트 $1.5\times10^{-4}$ 로 두 자릿수 줄고, 파라미터 이동은 후반에 포화하며, 정책 엔트로피는 2.42 에서 2.06 nat 로 내려가 400 업데이트 이후 평탄하다. 학습이 끝난 800 업데이트에서 세 시드의 greedy 포획률은 모두 휴리스틱 기준선 0.749 를 넘는다.

### 4.5.2 보상 설계

한 후보의 창 보상은 결정 시점부터 $H$ step 동안 일어난 일을 하나의 스칼라로 합산한 팀 공유 보상이며, 이벤트 항 $R_{\text{event}}$, 창의 시작·끝 상태에서 잰 퍼텐셜 $\Phi$ 의 할인($\gamma$) 차분, 조밀 항 $R_{\text{dense}}$ 로 구성된다. 세 항의 계수는 Table 5에 모았다.

$$R = R_{\text{event}} + [\gamma\Phi(\mathbf{s_{t+H}}) - \Phi(\mathbf{s_t})] + \mathrm{R}_{\text{dense}} \tag{10}$$

**Table 5** Reward coefficients

| Term | Symbol | Value | Meaning |
|---|---|---|---|
| Event | $r_{\text{cap}}$ | +13.5 | Per capture |
| | $r_{\text{brc}}$ | −8.0 | Per breach |
| | $r_{\text{col}}$ | −30 | Per collision or grounding |
| | $r_{\text{tng}}$ | −13 | Per net contact |
| | $r_{\text{wipe}}$ | +8 | Annihilation when the episode ends in the window |
| | $r_{\text{surv}}$ | −5 | Per surviving attacker when the episode ends in the window |
| Potential | $w_{\text{threat}}$ | 3.0 | Weight of the summed proximity to the mothership |
| | $R_w$ | 25 ℓ | Proximity normalization (half-width of the engagement area) |
| | $\gamma$ | 0.99 | Discount |
| Dense | $w_{\text{path}}$ | 0.5 | Travel cost |
| | $w_{\text{net}}$ | 0.3 | Net consumption cost |
| | $w_{\text{turn}}$ | 0.3 | Turning cost |
| | $w_{\text{cons}}$ | 0.3 | Target consistency cost |
| | $w_{\text{prox}}$ | 0.75 | Proximity cost to mothership and other defenders |
| | $w_{\text{cov}}$ | 0.1 | Coverage bonus |
| | $w_{\text{ray}}$ | 1.6 | Ray-blocking bonus |
| | $R_{\text{m}}$ | 3.2 ℓ | Mothership safety radius |
| | $\varrho_{\text{m}}$ | 2.0 ℓ | Influence radius of mothership proximity |
| | $\varrho_{\text{a}}$ | 2.4 ℓ | Influence radius of proximity to other defenders |

이벤트 항은 창 안의 포획·돌파·충돌·그물 접촉 건수에 고정 가중을 곱한 합이며, 창 안에서 에피소드가 끝나면 전멸 보너스와 잔존 적 1척당 벌점을 더한다. 퍼텐셜 $\Phi$ 는 생존 적선의 모선 근접도 합에 가중을 곱해 부호를 바꾼 것이라 적이 포획되거나 멀어지면 오르며, 할인 차분 형태로 주어지므로 최적 정책을 보존한다 [25]. 조밀 항은 기동 품질에 대한 비용·보너스의 합으로, 이동거리·소모 그물 수·선회

량·직전 결정 대비 목표점 이동과 모선·타 방어정 근접도를 벌하고, 설치된 그물이 적의 접근로를 막는 비율(커버리지)을 보상한다. 포획은 평가 창의 46.8% 에서만 일어나므로, 나머지 창에서는 퍼텐셜·커버리지 항이 후보 순위를 가르는 주된 신호다.

### 4.6 언어모델 기반 전략 계층

전략 계층의 입력은 전장 상태·임무 목표·교전 규칙·자산 상태이고, 출력은 무리별 배정과 대기(HOLD)이며, 그 배정이 기동 계층으로 전달되어 각 방어정의 그물벽 위치 결정을 조건짓는다.

언어모델에는 좌표 원시 데이터 대신 기하량이 미리 계산된 전장 상태를 텍스트로 전달한다. 각 적 무리의 요격점까지의 이동거리와 선회량, 모선 기준 방위, 설치된 그물에 의한 접근로 차단 여부가 포함된다. 출력은 자유 문장이 아니라 다음 자료형이 정하는 JSON 형식으로 강제한다 [23]. 자유 문장은 파싱에 실패하면 그 주기의 배정을 통째로 잃지만, 이 형식은 디코딩 단계에서 문법으로 작용해 어긋난 토큰 자체를 막는다.

CommanderPlan {
rationale: str
deployments: List[{
cluster_id: int,
ally_ids: List[int] }]
hold_ships: List[int]
}

언어모델이 정하는 것은 어느 배가 어느 무리를 맡는가뿐이고 나머지는 대기다. 그물 전개 여부·벽의 방위·교전 반경과 요격점 기하는 기동 계층이 정하며, 배정은 코드가 보정하지 않고 그대로 쓰인다.

한 무리에 두 척 이상이 배정되면 4.3절의 잉여 배정과 같은 반경·방위 분리가 작동하되, 요격점이 요격 구역을 벗어나 유효 마스크가 붕괴하지 않도록 반경을 구역 안으로 자른다. 배정이 바뀌면 요격점과 함께 기동 계층의 유효 마스크(4.4.3절)도 바뀌므로, 배정은 기동의 선행 조건이다.

## 5. 실험 설계

두 계층의 기여를 분리하기 위해 배정 축과 기동 축을 각각 이분한 2×2 조건 행렬을 두고, 시드 대응 차이로 판정한다.

### 5.1 환경과 학습 실행

교전 설정값은 Table 1, 지표는 Table 2를 따르고, 지휘관 재계획은 매 결정마다 수행한다. 지휘관으로는 능력 수준이 다른 소형 Qwen2.5 7B, 중형 Qwen2.5 14B, 상위 Gemini 3.5 Flash-Lite 를 온도 0, 같은 프롬프트, 같은 구조적 출력(4.6절)으로 쓰며, 이하 본문은 이들을 능력 수준으로 지칭한다.

시뮬레이터의 물리·판정 모델과 단순화는 Table 6에 모았다. 실선 동역학 [27] 대신 쓴 질점 운동학, 규칙 기반의 적, 잡음 없는 완전 관측은 모두 방어에 유리하므로 포획률은 상한이며, 네 조건이 같은 가정을 공유하므로 조건 간 상대 비교로만 판정한다.

**Table 6** Physical and adjudication models of the simulator and their simplifications

| Element | Model and settings | Simplification |
|---|---|---|
| Time | $\Delta t = 1$s; episode limit 2,000 steps | Fixed decision period |
| Defender motion | Constant 6.0 m/s; max. turn 8°/step; waypoint arrival radius 200 m | Point-mass kinematics without inertia, current or waves |
| Attacker motion | Constant 9.0 m/s; mothership bearing tracking + sinusoidal weaving; max. turn 5°/step | Rule-based, no learning or communication |
| Attacker avoidance | ±32° lateral steering for deployed nets or land within 500 m ahead | Local reaction that does not learn deployment patterns |
| Spawn | Concentrated / diversionary at 5,450 m; wave in 3 ranks from 4,000 m at 1,000 m spacing; bearing random per seed | Fixed structure without domain randomization |
| Net wall | Segment joining two pixels, max. 450 m; deployed while moving | Fixed after deployment, no drift or loss |
| Capture / breach | Capture = entering a net cell; breach = entering 260 m of the mothership | No entanglement delay or partial damage |
| Collision | Defenders within 115 m, mothership within 300 m, land, or entering a deployed net; the defender is disabled | Total loss on contact |
| Spatial grid | Physics, collision and net grid 200×200, 63 m/cell | Observation and action grids are 4 times coarser |
| Observation | Full observation of position, heading and remaining nets of all vessels | No sensor noise, latency or missed detection |
| Land | OpenStreetMap coastline raster; 6 training sites (Fig. 10), evaluation west of Maemuldo, Tongyeong | No bathymetry or tides |

학습은 질점 운동학 시뮬레이터에서 수행하고, 학습된 정책의 성능은 선체 거동과 충돌을 물리 엔진으로 다루는 언리얼 엔진 환경(Fig. 9)에서 검증한다. 6절의 통계 비교는 같은 시드 집합을 조건마다 되풀이 수집해야 하므로 질점 시뮬레이터에서 수행하였다.




**Fig. 9** Qualitative verification in the Unreal Engine-based simulator

학습은 한 해안선 형상에 과적합하지 않도록 실해역 6곳(Fig. 10)을 에피소드마다 돌려가며 진행하고, 평가는 그중 통영 매물도 서측에서 한다. 학습 설정은 Table 7에 모았으며, 주기적 greedy 평가의 최고점 가중치를 채택하였다.

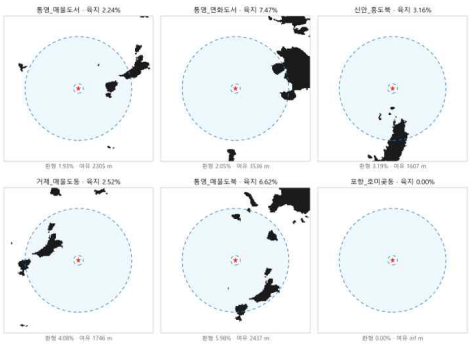


**Fig. 10** Six training sites (star: mothership, dashed circle: intercept annulus)

**Table 7** Training settings of the maneuver policy

| Category | Item | Value |
|---|---|---|
| Environment | Parallel worlds $N$ | 24 |
| | Training formations | Cycling concentrated, diversionary, wave |
| | Nets per defender (training / evaluation) | 1 / 3 |
| | Training sites | Cycling 6 real coastal sites |
| GRPO | Group size $G$ (incl. heuristic) | 8 |
| | Rollout window $H$ | 180 step |
| | Advantage normalization | Heuristic-anchored, group standard deviation |
| | Variance threshold $\epsilon_{\text{var}}$ | $10^{-6}$ |
| | Credit assignment | Joint |
| Optimization | Optimizer | Adam |
| | Total updates $T$ | 800 |
| | Learning rate $\eta_0 \rightarrow \eta_{\min}$, cosine | $10^{-4} \rightarrow 5\times10^{-6}$ |
| | Entropy coefficient $\lambda_0 \rightarrow \varkappa\lambda_0$, linear | 0.01→0.001 |
| | Gradient norm clip $g_{\max}$ | 1.0 |
| BC warm-up | Updates / learning rate | 300 / $3\times10^{-4}$ |
| | Label Gaussian $\sigma_{\text{BC}}$ | 0.8 px (202 m) |
| | Target | Geometric heuristic (Sec. 4.3) |
| Evaluation / adoption | Greedy evaluation interval (adopted / replication runs) | 200 / 100 updates |
| | Adoption criterion | Best evaluation (600, 0.805) |
| | Replication run seeds | 0, 1, 2 |

## 5.2 조건, 판정 기준, 계측

**Table 8** 2×2 condition matrix (only two switches differ between conditions)

| Condition | Assignment × maneuver | What it measures |
|---|---|---|
| heur_heur | Heuristic × heuristic | Baseline |
| heur_unet | Heuristic × U-Net | Pure contribution of the maneuver layer (no LLM) |
| llm_heur | LLM × heuristic | Pure contribution of the strategic layer |
| llm_unet | LLM × U-Net | Proposed system (incl. interaction) |

휴리스틱 배정과 기동은 4.3절의 기준 방법이며 학습 정책과 같은 행동공간을 거치므로 네 조건은 직

접 비교 가능하다(Table 8). 전략 계층에 세 모델을 두고 모든 조건이 같은 시드 집합과 세 포메이션을 공유하도록 하여 720 에피소드를 수집하였다.

갱신 규칙 자체를 가르기 위해, 같은 액터·관측·행동공간·보상·행동복제 초기화 위에서 갱신 규칙만 MAPPO [11]로 바꾼 정책을 시드 3개로 학습하고, 같은 step 예산과 같은 프로토콜로 평가한다(6.1.2절).

조건과 기준선의 시드 $k$ 지표값을 $x_k$, $y_k$, 시드 수를 $n_{\mathrm{s}}$, 대응 차이 $d_k$ 의 표준편차를 $s_d$ 라 하면 차이의 평균과 효과크기는

$$d_k = x_k - y_k, \qquad \bar{d} = \frac{1}{n_{\mathrm{s}}} \sum_{\mathrm{k}} \mathrm{d_k}, \qquad \mathrm{d_z} = \frac{\bar{\mathrm{d}}}{\mathrm{s_d}} \tag{11}$$

이며, $\bar{d}$ 의 95 % 신뢰구간은 편향 보정·가속(bias-corrected and accelerated, BCa) 부트스트랩 [28, 29]($B = 9999$)으로 구한다. 구간이 0을 포함하면 기준선과 다르다고 말하지 않으며, 지표 10개의 다중비교에는 Bonferroni 보정 구간(99.5 %)을 병기한다. 두 계층의 상호작용은 배정 축(H 휴리스틱, L 언어모델)과 기동 축(H 휴리스틱, U U-Net)으로 쓴 조건 $(a,m)$ 의 지표값 $x_k^{am}$ 에서

$$\mathrm{Int_k} = (\mathrm{x_k^{LU}} - \mathrm{x_k^{LH}}) - (\mathrm{x_k^{HU}} - \mathrm{x_k^{HH}}) \tag{12}$$

의 평균과 신뢰구간을 식 (11)와 같은 절차로 구해 판정한다($>0$ 상승, $\approx 0$ 가산, $<0$ 상쇄).

포획률은 체계 전체의 지표라 지휘관 계층의 기여를 가리므로, 계획 산출 시점에 확인 가능한 양을 따로 계측한다: 응답 지연, 폴백률(언어모델 실패로 휴리스틱이 대체한 비율), 커버리지(활성 무리 중 배정된 비율), churn(재계획 간 담당을 바꾼 방어정 비율), 교차 배정(방어정 - 담당 무리 선분이 서로 교차하는 쌍의 수). 뒤의 세 양은 재계획에 걸쳐 평균한다.

# 6. 결 과

## 6.1 기동 계층의 기여

### 6.1.1 휴리스틱 대 점수맵 정책

언어모델 없이 4.3절의 기하 휴리스틱과 4.4절의 점수맵 정책만 비교한다. 배정은 둘 다 휴리스틱이므로 차이는 기동 방식뿐이다(Table 9). 3개 포메이션 통합 기준으로 포획률은 0.844→0.886($d_z = 0.37$)으로 95% 수준에서 유의하나, 다중비교 보정을 걸면 구간이 0을 포함한다(5.2절). 기동 계층이 바꾸는 것은 포획률이 아니라 자원과 기동이다.

**Table 9** Stand-alone contribution of the maneuver layer (U-Net score map + GRPO)

| Formation | Heuristic maneuver | U-Net maneuver | $\Delta$ [95 % CI] | $d_z$ |
|---|---|---|---|---|
| Concentrated | 0.997 | 0.997 | +0.000 [−0.010, +0.010] | +0.00 |
| Diversionary | 0.787 | 0.753 | −0.033 [−0.077, +0.000] | −0.31 |
| Wave | 0.750 | 0.907 | +0.157 [+0.043, +0.270]* | +0.48 |
| Overall | 0.844 | 0.886 | +0.041 [+0.003, +0.082]* | +0.37 |

* The confidence interval excludes 0. The overall row pools the three formations.

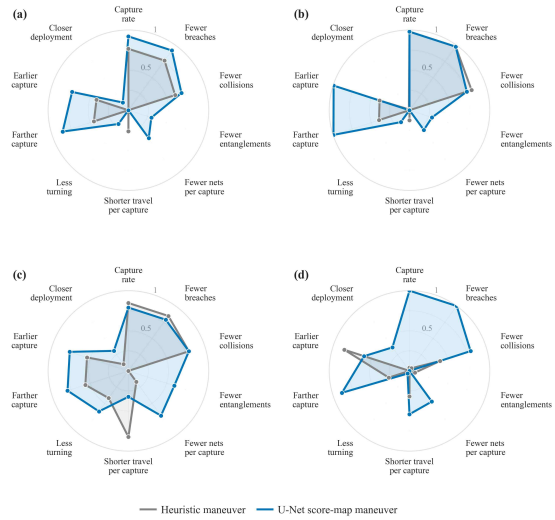



**Fig. 11** Metric profiles: (a) overall, (b) concentrated, (c) diversionary, (d) wave

같은 비교를 10개 지표 전부로 넓히면(Fig. 11, 각 축은 8개 조건의 범위로 0 - 1 정규화) U-Net 은 포획당 이동거리 축에서만 안쪽이다. 자리를 골라 그물벽을 놓는 대신 더 멀리 움직이기 때문이다. 충돌률·전개 시 적 거리 축은 겹치고, 나머지 일곱 축에서 바깥에 있다.

포메이션별로 보면 기여가 고르지 않다. 파상에서 $+0.157$($d_z = 0.48$)로 가장 크고, 집중에서는 0.000, 양동에서는 $-0.033$ 으로 오히려 소폭 낮다(유의하지 않아 악화로 읽지는 않는다). 3.1절의 포메이션 구조가 이 대비를 설명한다. 파상에서는 앞 단을 막은 그물벽의 위치가 뒤 단의 차단을 좌우하므로 해면 전체를 평가하는 점수맵이 직접 효과를 내고, 양동에서는 무리 수와 방어정 수가 같아 결정적인 것이 배정이라 배정이 어긋나면 기동이 보정하지 못한다. 집중은 휴리스틱만으로 포획률 0.997에 도달해 개선 여지가 남지 않는 구간이다(6.2절).

### 6.1.2 갱신 규칙: 그룹 상대 최적화 대 MAPPO

점수맵 정책의 이득이 픽셀 지목이라는 표현에서 오는지 가치망 없는 갱신 규칙에서 오는지를 가르기 위해, 같은 액터·행동공간·보상·예산 위에서 갱신 규칙만 MAPPO 로 바꾼 정책 세 개를 같은 프로토콜로 평가하였다(Table 10).

**Table 10** Comparison of learning algorithms on the same pixel action space

| Metric | Heuristic | MAPPO | GRPO (adopted) | $\Delta$ [95 % CI] | $d_z$ |
|---|---|---|---|---|---|
| Capture rate ↑ | 0.844 | 0.859 | 0.886 | +0.026 [−0.003, +0.056] | +0.31 |
| Breaches ↓ | 1.56 | 1.41 | 1.14 | −0.26 [−0.57, +0.03] | −0.31 |
| Collision rate (per defender) ↓ | 0.130 | 0.138 | 0.119 | −0.020 [−0.047, +0.004] | −0.27 |
| Net entanglements ↓ | 0.82 | 0.70 | 0.62 | −0.08 [−0.23, +0.05] | −0.20 |
| Nets per capture ↓ | 0.737 | 0.733 | 0.568 | −0.165 [−0.213, −0.116]*† | −1.19 |
| Distance per capture (m) ↓ | 825 | 813 | 896 | +82 [+40, +139]*† | +0.59 |
| Total turning (rad) ↓ | 1625 | 1541 | 1464 | −77 [−158, +17] | −0.31 |
| Capture distance (m) ↑ | 1511 | 1523 | 1678 | +154 [+112, +202]*† | +1.21 |
| Capture time (step) ↓ | 430 | 430 | 418 | −12 [−19, −5]*† | −0.58 |
| Enemy distance at deploy (m) ↓ | 1499 | 1525 | 1425 | −100 [−154, −51]*† | −0.68 |

* The 95 % interval excludes 0. † Still excluded under Bonferroni correction (99.5 %). Capture rates of the

individual MAPPO runs: 0.876, 0.838, 0.864. Three formations pooled (30 seeds per condition).

포획률은 갈리지 않는다. MAPPO 0.859 와 GRPO 0.886 의 차이는 유의하지 않고, 포메이션별 방향도 파상 개선·양동 저하로 같다. 갈리는 것은 자원과 조기 제압이다. MAPPO 의 프로파일은 포획률·돌파 축을 빼면 휴리스틱 위에 그대로 겹치는 반면, GRPO 는 포획당 그물을 0.737→0.568 로 줄이고 ($d_z$=−1.19), 포획 이격거리를 154 m 늘리며($d_z$=+1.21), 평균 포획 시각과 전개 시 적 거리도 앞당긴다. 네 지표 모두 다중비교 보정에서도 유의하다. MAPPO 가 이기는 축은 포획당 이동거리 하나다.

같은 표현을 공유하는 한 갱신 규칙은 포획률을 가르지 못하고 그물 절약과 조기 제압만 좌우한다. 휴리스틱 후보를 기준으로 삼는 그룹 상대 이득(4.5절)은 휴리스틱을 넘어서는 선택에만 양의 이득을 주어 그 자원 사용 패턴에서 벗어나게 하는 반면, 팀 가치로 학습하는 MAPPO 는 어느 배가 그물을 아꼈는지를 개별 배에 귀속시킬 신호가 약하다.

### 6.2 지휘관 계층의 기여

지휘관 계층은 가져다 쓴 구성요소이므로 모델 사이의 순위가 아니라 배치에 필요한 것만 본다. 기동 계층을 휴리스틱으로 고정해 지휘관 축만 분리하면 포획률은 모델 능력을 따라 단조로 오르되, 능력이 낮은 쪽은 휴리스틱 배정 기준선에 미치지 못한다(Table 11, Fig. 12). 개선 폭은 포메이션에 따라 갈려, 휴리스틱만으로 이미 포화한 집중에는 남는 여지가 없고 여유가 없는 양동과 파상에서 크다. 성능을 가르는 것은 배정 커버리지가 아니다(Table 12). 가장 낮은 성능의 모델이 커버리지는 가장 높았으므로 막아야 할 무리를 빠뜨려서 지는 것이 아니며, 성능과 맞물린 양은 재계획 간 담당 변경(churn)과 경로 교차였다. 재계획마다 방어정의 약 3분의 1이 담당을 바꾸면 그때까지 전개하던 그물벽과 이동이 회수되지 않고, 두 방어정의 진로가 서로를 가로지르는 배정은 충돌 위험을 높인다. 지연도 배치 조건을 가른다. 중형 모델은 응답이 간헐적으로 결정 주기를 넘겨 동기 구조라면 그동안 제어 루프가 멈추므로, 4.1절은 전략 계층만 비동기로 떼어 둔다.

**Table 11** Capture rate by condition (mean, 95 % CI, difference from baseline)

| Commander (assignment) | Maneuver | Capture rate [95 % CI] | $\Delta$ vs baseline | $d_z$ |
|---|---|---|---|---|
| Heuristic (baseline) | Heuristic | 0.844 [0.808, 0.880] | - | - |
| Heuristic | U-Net score map | 0.886 [0.847, 0.918] | +0.041 [+0.003, +0.082]* | +0.37 |
| Qwen2.5 7B | Heuristic | 0.652 [0.571, 0.716] | −0.192 [−0.264, −0.129]* | −1.00 |
| Qwen2.5 14B | Heuristic | 0.811 [0.766, 0.854] | −0.033 [−0.086, +0.017] | −0.23 |
| Gemini 3.5 Flash-Lite | Heuristic | 0.904 [0.864, 0.937] | +0.060 [+0.024, +0.100]* | +0.56 |
| Qwen2.5 7B | U-Net score map | 0.641 [0.582, 0.693] | −0.203 [−0.274, −0.138]* | −1.03 |
| Qwen2.5 14B | U-Net score map | 0.754 [0.698, 0.806] | −0.090 [−0.153, −0.033]* | −0.54 |
| Gemini 3.5 Flash-Lite | U-Net score map | 0.907 [0.869, 0.937] | +0.062 [+0.013, +0.113]* | +0.44 |

* The confidence interval excludes 0. $d_z$: paired effect size. Rows sharing a commander give the maneuver-layer contribution; rows sharing a maneuver give the commander contribution. Qwen2.5: local (RTX 4070); Gemini: cloud API.

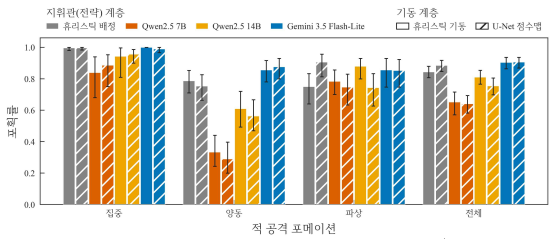



**Fig. 12** Capture rate by formation and condition (error bars: 95 % CI)

**Table 12** Commander plan quality and performance

| Commander | Coverage ↑ | churn ↓ | Crossing ↓ | Capture rate ↑ |
|---|---|---|---|---|
| Qwen2.5 7B | 0.934 | 0.324 | 0.152 | 0.652 |
| Qwen2.5 14B | 0.877 | 0.167 | 0.111 | 0.811 |
| Gemini 3.5 Flash-Lite | 0.881 | 0.098 | 0.033 | 0.904 |

Coverage: fraction of active clusters assigned. Churn: fraction of defenders changing assignment between replans. Crossing: fraction of crossing intercept paths. Capture rate with heuristic maneuver; fallback rate at most 0.007 for all models.

## 6.3 제안 체계 전체

### 6.3.1 두 계층의 상호작용

식 (12)의 상호작용을 10개 지표 전부에 대해 계산하였다(Table 13).

**Table 13** 2×2 interaction decomposition (Gemini commander)

| Metric | Total effect | Interaction [95 % CI] |
|---|---|---|
| Capture rate | +0.062 | −0.039 [−0.083, +0.012] |
| Breaches | −0.62 | +0.39 [−0.13, +0.83] |
| Collision rate (per defender) | −0.052 | −0.015 [−0.070, +0.022] |
| Net entanglements | −0.60 | +0.17 [−0.08, +0.41] |
| Nets per capture | −0.328 | +0.004 [−0.045, +0.059] |
| Distance per capture (m) | −182 | −55 [−125, +30] |
| Total turning (rad) | −757 | −56 [−165, +59] |
| Capture distance (m) | +223 | +38 [−2, +81] |
| Capture time (step) | −22 | −12 [−20, −6]* |
| Enemy distance at deploy (m) | −371 | +26 [−44, +109] |

Interaction = (LLM+U-Net − LLM+heuristic) − (heuristic+U-Net − baseline). * significant interaction.

10개 지표 중 9개에서 상호작용이 유의하지 않고, 다중비교 보정 후에도 그대로 9개다. 두 계층의 기여는 상승이 아니라 가산적이다. 예외인 평균 포획 시각은 유의한 상쇄인데, 두 계층 모두 제압을 앞당기는 쪽으로 작용하므로 같은 포획을 두 번 앞당길 수는 없는 수확체감이다. 가산성이 두 계층을 따로 써도 된다는 뜻은 아니다. 양동에서는 기동 계층 단독(−0.033)도 전략 계층 단독(+0.070)도 유의하지 않은데 결합은 +0.090 으로 유의해진다. 무리 수와 방어정 수가 같아 배정과 기동이 둘 다 맞아야 막히기 때문이다.

### 6.3.2 전 지표 효과크기

제안 체계와 기준선의 차이를 10개 지표에 걸쳐 효과크기로 잰다(Table 14, Fig. 13).

**Table 14** Effect sizes for all metrics (descending $|d_z|$)

| Metric | Dir. | baseline | Proposed | $\Delta$ | $d_z$ |
|---|---|---|---|---|---|
| Total turning (rad) | ↓ | 1625 | 868 | −757*† | −3.23 |
| Nets per capture | ↓ | 0.737 | 0.409 | −0.328*† | −2.09 |
| Capture distance (m) | ↑ | 1511 | 1734 | +223*† | +1.81 |
| Enemy distance at deploy (m) | ↓ | 1499 | 1128 | −371*† | −1.60 |
| Net entanglements | ↓ | 0.82 | 0.22 | −0.60*† | −1.19 |
| Capture time (step) | ↓ | 430 | 408 | −22*† | −1.04 |
| Distance per capture (m) | ↓ | 825 | 643 | −182*† | −0.65 |
| Collision rate (per defender) | ↓ | 0.130 | 0.078 | −0.052*† | −0.52 |
| Breaches | ↓ | 1.56 | 0.93 | −0.62* | −0.44 |
| Capture rate | ↑ | 0.844 | 0.907 | +0.062* | +0.44 |

↑ higher is better, ↓ lower is better. * 95 % CI excludes 0. † Also excludes 0 under Bonferroni correction for 10 metrics.

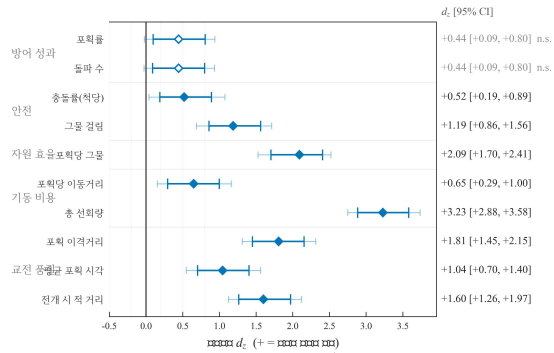



**Fig. 13** Effect sizes $d_z$ for all metrics (light lines: corrected intervals)

개선은 포획률이 아니라 기동 비용과 자원 효율에 몰려 있다. 총 선회량은 1625 에서 868 로 47 % 줄어 $d_z = -3.23$, 포획당 그물은 45 % 줄어 −2.09, 그물 걸림은 73 % 줄어 −1.19, 포획 이격거리는 223m 늘어 +1.81 이다. 반면 포획률은 $d_z = 0.44$ 로 10개 지표 중 최하위권이며 총 선회량의 7분의 1 수준이다.

다중비교 보정에서는 10개 중 8개가 그대로 유의하고, 포획률과 돌파 수만 유의성을 잃는다.

## 7. 고찰 및 결론

### 7.1 결과의 해석

두 계층의 기여가 가산적이라는 것(6.3절)은 운용상의 자유를 뜻한다. 지휘관 모델 교체와 기동 정책 재학습을 서로 기다리지 않고 독립적으로 진행할 수 있다.

지휘관의 성능을 설명하는 것은 커버리지가 아니라 재계획 간 계획 안정성이라는 관찰(6.2절)은 본 문제에 국한되지 않는다. 주기적으로 재계획하는 계층 구조에서 상위 결정의 변경은 하위 계층에 전환 비용(회수되지 않는 이동과 그물)을 발생시킨다. 상위 계층이 매 재계획마다 순간 최적을 추구하면 이 비용이 누적되어, 한 번의 재계획에서 나은 배정이 에피소드 전체로는 불리해진다. 언어모델은 매 호출이 독립적이라 이 일관성이 구조적으로 보장되지 않으므로, 직전 배정을 상태에 포함시키고 담당 무리를 방위로 식별하게 한 것이 그 대응이다. 따라서 언어모델을 계획 계층에 둘 때는 계획 품질을 국소 최적

성이 아니라 시간에 걸친 일관성으로 평가해야 하며, 프롬프트와 상태 표현이 그 일관성을 지원해야 한다.

가장 큰 개선이 총 선회량(6.3.2절)에서 나타난 것은 점수맵 표현의 성질에서 온다. 경유점이 격자에 고정되므로 연속 회귀의 미세 진동이 배제되어 궤적이 부드러워지고, 선회 감소는 실제 선박에서 연료·시간·기동 여유로 환산된다. 포획당 그물 소모의 감소 역시 유효 마스크가 방위 조건과 사거리 제약을 행동 분포에 직접 부과해 무의미한 위치의 그물벽을 애초에 배제한 결과다. 다만 이 이득은 점수맵의 다봉 표현력에서 오는 것이 아니다. 유효 마스크가 남기는 셀 안에서 점수맵은 거의 단봉이며, 이득은 분포의 모양이 아니라 마스크와 격자 양자화에서 온다.

### 7.2 한계와 향후 과제

검증은 시뮬레이션에 한정되며 그물 거동·얽힘 판정·관측이 단순화되어 있다(Table 6). 특히 관측 불확실성은 배정이 딛고 선 무리 구성을 흔들므로, 점수맵 정책보다 지휘관 계층에 더 크게 작용할 것이다.

가장 좋은 지휘관이 상용 폐쇄형 모델이라는 데서 오는 제약 — 수치의 장기 재현, 능력 임계의 시점 의존성, 판단 근거 원문의 미저장 — 은 재현성 선언에 함께 적었다.

규모는 적 10척 대 방어정 3척으로 고정이어서 방어정이 늘어 배정 조합이 급증할 때 능력 임계가 어디로 옮겨 가는지는 측정하지 않았고, 적이 규칙 기반이라 그물벽 배치를 학습해 회피하는 적응적 적은 범위 밖이다. 학습 알고리즘 비교도 같은 픽셀 행동공간 위의 MAPPO 한 종에 그치며(6.1.2절), 연속 행동공간 기준선과 구성요소별 절제는 과제로 남는다.

### 7.3 결론

적보다 느린 방어정으로 자폭 군집을 막는 2계층 체계를 제안하고, 시드 대응 2×2 설계의 720 에피소드로 두 계층의 기여를 분리 측정하였다. 제안 체계는 같은 방어 수준에서 자원과 기동 비용을 크게 줄였으며, 두 계층의 기여는 가산적이었고, 언어모델 지휘관의 이득은 능력 임계 위에서만 나타났다. 실해역 이식과 관측 불확실성 하에서의 계획 안정성은 향후 과제로 남는다.

## 사 사

**[발표 전 확인 필요]** 본 연구는 [지원 기관·과제명·과제번호]의 지원을 받아 수행되었다.

## 자료 공개

본 연구의 결과를 재현하는 데 필요한 자료는 720 에피소드의 에피소드별 지표(episodes.csv)와 계획 호출 계측값(llm_metrics.csv), 기동 계층의 정책 체크포인트(u-net_map.pt; 학습 설정이 체크포인트 안에 함께 저장되어 별도 설정 파일 없이 복원된다), 그리고 환경·관측 래스터화·평가 하네스를 포함한 시뮬레이터 전체다. 본문의 모든 표와 그림은 앞의 두 파일에서 기계적으로 생성되며 손으로 옮겨 적은 수치는 없다. [공개 URL 기입 필요]

언어모델이 생성한 판단 근거(rationale)의 원문은 저장하지 않았고 길이만 계측하였으므로, 근거 문장 자체에 대한 사후 분석은 재현할 수 없다(7.2절). 또한 상용 API로 제공되는 폐쇄형 지휘관 모델은 버전 갱신이나 서비스 종료로 그 조건의 수치가 시점에 따라 달라질 수 있다. 언어모델을 쓰지 않는 조건(heur_heur, heur_unet)은 이 위험 없이 재현 가능하다.

## 참고문헌

[1] Ahuja, R.K., Kumar, A., Jha, K.C. and Orlin, J.B., "Exact and Heuristic Algorithms for the Weap on-Target Assignment Problem", *Operations Research*, Vol.55-6, (2007), p.1136-1146.
[2] Wang, J., Liu, Y. and Song, H., "Counter-Unmanned Aircraft System(s) (C-UAS): State of the Art, Challenges, and Future Trends", *IEEE Aerospace and Electronic Systems Magazine*, Vol.3 6-3, (2021), p.4-29.
[3] Sutea, V., *Fiber-optic drones have emerged as critical kit for both Russia and Ukraine*, Atlantic Council UkraineAlert, 24 February 2026 (2026).
[4] Rumbaugh, W., *Cost and Value in Air and Missile Defense Intercepts*, Center for Strategic and International Studies (CSIS) Commentary, 13 February 2024, Washington, DC (2024).
[5] Kuhn, H.W., "The Hungarian Method for the Assignment Problem", *Naval Research Logistics Q uarterly*, Vol.2-1-2, (1955), p.83-97.
[6] Liu, Z., Zhang, Y., Yu, X. and Yuan, C., "Unmanned surface vehicles: An overview of developme nts and challenges", *Annual Reviews in Control*, Vol.41, (2016), p.71-93.
[7] Zhang, C., Zeng, R., Lin, B., Zhang, Y., Xie, W. and Zhang, W., "Multi-USV cooperative target e ncirclement through learning-based distributed transferable policy and experimental validation", *Ocean Engineering*, Vol.318, (2025), No.120124.
[8] Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P. and Mordatch, I., "Multi-Agent Actor-Critic fo r Mixed Cooperative-Competitive Environments", *Advances in Neural Information Processing S ystems 30 (NeurIPS)*, (2017).
[9] Rashid, T., Samvelyan, M., Schroeder de Witt, C., Farquhar, G., Foerster, J. and Whiteson, S., "Q MIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning", *I nternational Conference on Machine Learning (ICML)*, (2018), p.4295-4304.
[10] Foerster, J., Farquhar, G., Afouras, T., Nardelli, N. and Whiteson, S., "Counterfactual Multi-Age nt Policy Gradients", *AAAI Conference on Artificial Intelligence*, (2018), p.2974-2982.
[11] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A. and Wu, Y., "The Surprising Effecti veness of PPO in Cooperative Multi-Agent Games", *Advances in Neural Information Processin g Systems 35 (NeurIPS)*, (2022).
[12] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. and Klimov, O., "Proximal Policy Optimizatio n Algorithms", *arXiv preprint arXiv:1707.06347*, (2017).
[13] Haarnoja, T., Zhou, A., Abbeel, P. and Levine, S., "Soft Actor-Critic: Off-Policy Maximum Entr opy Deep Reinforcement Learning with a Stochastic Actor", *International Conference on Machin e Learning (ICML)*, (2018), p.1861-1870.
[14] Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y.K., Wu, Y. an d Guo, D., "DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models", *arXiv preprint arXiv:2402.03300*, (2024).
[15] Long, J., Shelhamer, E. and Darrell, T., "Fully Convolutional Networks for Semantic Segmentati on", *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, (2015), p.3431-34 40.
[16] Ronneberger, O., Fischer, P. and Brox, T., "U-Net: Convolutional Networks for Biomedical Imag e Segmentation", *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, (2 015), p.234-241.
[17] Liu, R., Lehman, J., Molino, P., Petroski Such, F., Frank, E., Sergeev, A. and Yosinski, J., "An I ntriguing Failing of Convolutional Neural Networks and the CoordConv Solution", *Advances in*

*Neural Information Processing Systems 31 (NeurIPS)*, (2018).

[18] Perez, E., Strub, F., de Vries, H., Dumoulin, V. and Courville, A., "FiLM: Visual Reasoning with a General Conditioning Layer", *AAAI Conference on Artificial Intelligence*, (2018), p.3942-3951.

[19] Vinyals, O., Fortunato, M. and Jaitly, N., "Pointer Networks", *Advances in Neural Information Processing Systems 28 (NeurIPS)*, (2015).

[20] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł. and Polos ukhin, I., "Attention Is All You Need", *Advances in Neural Information Processing Systems 30 (NeurIPS)*, (2017).

[21] Huang, W., Abbeel, P., Pathak, D. and Mordatch, I., "Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents", *International Conference on Machine L earning (ICML)*, (2022), p.9118-9147.

[22] Ahn, M., Brohan, A., Brown, N., et al., "Do As I Can, Not As I Say: Grounding Language in R obotic Affordances", *Conference on Robot Learning (CoRL)*, (2022).

[23] OpenAI, *Function calling*, [Online] Available at: https://developers.openai.com/api/docs/guides/fun ction-calling [Accessed 9 August 2026] (2026).

[24] Wu, Y. and He, K., "Group Normalization", *European Conference on Computer Vision (ECCV)*, (2018).

[25] Ng, A.Y., Harada, D. and Russell, S., "Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping", *International Conference on Machine Learning (ICML)*, (1 999), p.278-287.

[26] Loshchilov, I. and Hutter, F., "SGDR: Stochastic Gradient Descent with Warm Restarts", *Interna tional Conference on Learning Representations (ICLR)*, (2017).

[27] Fossen, T.I., *Handbook of Marine Craft Hydrodynamics and Motion Control*, John Wiley & Son s, Chichester (2011).

[28] Efron, B. and Tibshirani, R.J., *An Introduction to the Bootstrap*, Chapman & Hall, New York (1 993).

[29] DiCiccio, T.J. and Efron, B., "Bootstrap Confidence Intervals", *Statistical Science*, Vol.11-3, (199 6), p.189-228.